



DrugEx Hub · De Novo Drug Design & ROCS Shape-Matching

Kompletní Výuková Příručka, Metodologický Manuál a Teoretické Základy pro
Bakalářskou Práci (VŠCHT Praha / ÚOCHB AV ČR) — Kombinace de novo generování
molekul a 3D tvarového porovnávání pro flexibilní cíle a IDP.

Bakalářská Práce: David Kolář

Vysoká škola chemicko-technologická v Praze (VŠCHT Praha)

Ústav organické chemie a biochemie AV ČR (ÚOCHB AV ČR)

Softwarová platforma: DrugEx v3.4 (feature/rocs-scoring) · OpenEye ROCS / CDPKit / RDKit

Modul 1: De Novo Generování & Molekulární Reprezentace

- 1.1 Molekulární reprezentace, tokenizace & slovník (VocSmiles)
- 1.2 Generativní modely: Sequence RNN & Transfomery
- 1.3 Předtrénování na Papyrus & Transfer Learning
- ✓ Autoevaluační Test Modulu 1 & Klíč řešení

Modul 2: Multi-Objective Reinforcement Learning (MORL)

- 2.1 Architektura Policy Gradientu: Agent vs. Prior
- 2.2 Skládání prostředí DrugExEnvironment & Modifikátory
- 2.3 Pareto nedominované řazení & Crowding Distance
- ✓ Autoevaluační Test Modulu 2 & Klíč řešení

Modul 3: 3D Tvarové Porovnávání (ROCS), IDP & Konformace

- 3.1 Principy 3D ROCS & Gaussovský překryv objemů
- 3.2 Generování 3D konformerů (ETKDGv3 & RMSD prunování)
- 3.3 Specifika flexibilních cílů & Intrinsically Disordered Proteins
- ✓ Autoevaluační Test Modulu 3 & Klíč řešení

Modul 4: Hlubková Architektura ROCS Scorerů

- 4.1 RDKit ROCS Scorer & ShapeTanimoto
- 4.2 CDPKit / CDPL Farmakoforový Scorer
- 4.3 OpenEye ROCS & Srovnávací Rosetta Stone
- ✓ Autoevaluační Test Modulu 4 & Klíč řešení

Modul 5: Experimentální Pipeline na CCR2

- 5.1 Příprava dat a modelů (config.py & prepare_models.py)
- 5.2 Běh MORL optimalizace (SequenceExplorer)
- 5.3 Generování kandidátů & Youdenova ROC kalibrace
- ✓ Autoevaluační Test Modulu 5 & Klíč řešení

Modul 6: BRICS Fragmenty & HPC Škálování

- 6.1 Retrosyntetická fragmentace BRICS & VocFrag
- 6.2 Fragment-based RL generování (FragSequenceExplorer)
- 6.3 HPC Paralelizace, Slurm orchestrace & Multi-GPU
- ✓ Autoevaluační Test Modulu 6 & Klíč řešení

Modul 7 & Metodologické Přílohy

- Modul 7: Uživatelská Kuchařka & 6 Receptů Prostředí
- Příloha A: Standard Operating Procedure (SOP)
- Příloha B: Teoretický Rámec Flexibilních Cílů & IDP
- Příloha C: Vzorová kapitola Výpočetní Metody
- Příloha D: Bibliografie podle ČSN ISO 690
- Příloha E: Autoritativní Slovník Chemoinformatiky (26 hesel)**
- Příloha F: Rychlá Referenční Karta (Cheat-Sheet pro HPC & RDKit)**

Modul 1: De Novo Generování & Molekulární Reprezentace

1.1 Molekulární reprezentace, tokenizace & slovník (VocSmiles)

Hlubková taxonomie molekulárních reprezentací (1D SMILES/SELFIES/DeepSMILES vs 2D molekulární grafy vs fragmentové vaky BRICS), tokenizační smlouva VocSmiles s rozpadem regulárních výrazů, řídicí tokeny a 5-stupňový standardizační protokol SmilesStandardizer.

1. Paradigma molekulárních reprezentací v chemoinformatice a generativní AI Slide 1/8

Výpočetní reprezentace chemické struktury představuje fundamentální most mezi fyzikálně-chemickou realitou molekuly a matematickým aparátem strojového učení. V klasické chemoinformatice a QSAR modelování dominovaly po desetiletí fixní binární nebo celočíselné vektorové otisky (např. **Morganovy / ECFP4 fingerprinty**, **MACCS keys**, topologické indexy). Tyto deskriptory sice excelují v rychlém vyhledávání substrukturní podobnosti v miliardových databázích, mají však zásadní omezení pro de novo návrh léčiv: jsou **jednosměrné (nerozbalitelné)**. Z fixního 2048-bitového vektoru nelze deterministicky ani generativně zrekonstruovat původní molekulární strukturu.

Generativní de novo design léčiv vyžaduje **invertibilní, spojitě či diskrétně generovatelné reprezentace**, které umožňují algoritmu postupně syntetizovat nové chemické entity atom po atomu nebo fragment po fragmentu. V současné generativní chemoinformatice rozlišujeme tři dominantní úrovně reprezentací:

- **1D Lineární řetězce (String Notations):** Linearizace molekulárních struktur do textových sekvencí znaků a tokenů (SMILES, DeepSMILES, SELFIES). Umožňují přímé nasazení nejmodernějších architektur z oblasti zpracování přirozeného jazyka (NLP), jako jsou rekurentní neuronové sítě (LSTM/GRU) a kauzální autoregresní transformery (GPT).
- **2D Atribuované molekulární grafy (Attributed Molecular Graphs):** Formální popis molekuly jako grafu $G = (V, E)$, kde uzly reprezentují atomy s vektory fyzikálně-chemických příznaků a hrany reprezentují kovalentní vazby s informací o jejich řádu a stereochemii.
- **Fragmentové a synthonové reprezentace (Bag of Fragments / Synthon Graphs):** Dekompozice molekul na synteticky dostupné stavební bloky definované standardizovanými štěpnými pravidly (např. BRICS, RECAP). Generování pak probíhá kombinací celých syntetických fragmentů, což zásadně redukuje chemický prostor na synteticky snadno realizovatelné kandidáty.

VÝZNAM PRO BAKALÁŘSKOU PRÁCI NA VŠCHT / ÚOCHB

Při návrhu ligandů pro flexibilní cíle a IDP proteiny je volba reprezentace kritická: 1D sekvenční modely (SequenceRNN) poskytují obrovskou chemickou flexibilitu a rychlost pro rozsáhlý screening, zatímco fragmentové a grafové modely (GraphTransformer) umožňují rigorózní zachování pevných scaffoldů (scaffold-constrained generation) a 100% syntaktickou validitu.

✦ PRAVIDLO Z PRAXE: STANDARDIZACE MOLVS PŘED TRÉNINKEM

Nikdy netrénujte jazykový model generátoru na surových SMILES z veřejných repozitářů. Před vytvořením slovníku VocSmiles vždy aplikujte kompletní desalting (odstranění solí a solvátů, např. Na⁺, Cl⁻, TFA), neutralizaci formálních nábojů a převod na kanonické tautomery. Přítomnost solí ve slovníku vede k plýtvání kapacitou sítě a tvorbě nerealistických iontových párů.

⚠ ČASTÁ CHYBA V DIPLOMCE: ZTRÁTA CHIRALITY V 1D SMILES

Pokud vygenerujete molekulu jako achirální SMILES (bez označení @ nebo @@ na asymetrickém uhlíku), RDKit ani jiný konformační engine nemůže vědět, který enantiomer má postavit do 3D prostoru pro ROCS porovnání. Vždy zajistěte, aby generátor pracoval s chirálními tokeny, nebo při konformačním screeningu explicitně enumerujte všechny stereoisomery (max. 4 na molekulu).

2. Hlubková taxonomie 1D notací: SMILES vs DeepSMILES vs SELFIES

Slide 2/8

Lineární řetězcové reprezentace převádějí trojrozměrný či dvoudimenzionální chemický graf do jednodimenzionální sekvence symbolů. Každá z moderních notací řeší kompromis mezi lidskou čitelností, kompaktností a syntaktickou robustností:

1. SMILES (Simplified Molecular Input Line Entry System)

Vyvinutý Davidem Weiningerem v roce 1988. Využívá linearizaci molekulárního grafu pomocí upraveného průchodu do hloubky (DFS - Depth-First Search). Cykly jsou rozpojeny a označeny shodnými numerickými indexy na místech rozpojení (např. c1ccccc1 pro benzen, %12 pro dvojčíselná čísla kruhů). Větvení je značeno kulatými závorkami (...). Stereochemie na tetraedrických centrech je kódována pomocí @ (proti směru hodinových ručiček) a @@ (ve směru), cis/trans izomerie na dvojných vazbách pomocí / a \.

Hlavní slabina: Gramatická křehkost (syntactic fragility). Náhodná mutace jediného tokenu (např. smazání uzavírací závorky nebo nespárovaný index kruhu) způsobí okamžitou nevaliditu celého řetězce.

2. DeepSMILES (O'Boyle & Dalke, 2018)

Navržen speciálně pro hluboké neuronové sítě. Nahrazuje párové závorky operátorem uzavření s explicitním počtem kroků zpět a párová čísla cyklů nahrazuje jedním symbolem udávajícím délku kruhu. Tím eliminuje chyby způsobené nespárovanými závorkami.

3. SELFIES (Self-Referencing Embedded Strings, Krenn et al., 2020)

Formální bezkontextová stavová gramatika inspirovaná Chomského hierarchií. Každý token je interpretován jako stavový přechod v závislosti na aktuální volné valenci molekulárního fragmentu. **Garantuje 100% syntaktickou a valenční validitu** pro jakýkoliv náhodně sestavený řetězec tokenů.

Nevýhoda SELFIES: Výrazně delší sekvence tokenů, vyšší paměťová náročnost a obtížnější integrace s fragmentovými bázemi typu BRICS.

SMILES (Standard v DrugEx)

- **Kompaktnost:** Krátké sekvence (typicky 20–60 tokenů na molekulu léčiva).
- **Podpora knihoven:** Nativní integrace v RDKit, OpenEye, CDPKit, ChEMBL a Papyrus.
- **Reprezentace fragmentů:** Přirozené kódování synthonů s dummy atomy (`[1*]`, `[2*]`).
- **Nevýhoda:** Vyžaduje předtrénování na velkém korpusu k osvojení chemické gramatiky.

SELFIES (Stavová gramatika)

- **Syntaktická robustnost:** 100% matematická validita všech vygenerovaných řetězců.
- **Bezpečnost:** Žádné neuzavřené kruhy ani nespárované závorky.
- **Délka sekvencí:** Až o 50–100% více tokenů na molekulu, což zvyšuje výpočetní nároky transformerů ($O(N^2)$ pozornost).
- **Fragmentace:** Složitější definice retrosyntetických štěpných vazeb BRICS.

3. 2D Molekulární grafy a BRICS / RECAP fragmentové vaky (Synthon Paradigma)

Slide
3/8

Molekuly nejsou ve své fyzikální podstatě lineární texty, ale prostorové topologické sítě. V DrugEx se vedle sekvenčních modelů uplatňuje také grafové a fragmentové paradigma:

1. Formální definice atribuovaného molekulárního grafu

Molekula je reprezentována uspořádanou dvojicí $G = (V, E)$, kde:

- $V = \{v_1, v_2, \dots, v_N\}$ je množina N těžkých atomů (uzlů). Každému uzlu náleží vektor atomových vlastností $\mathbf{x}_i \in \mathbb{R}^{d_v}$ (atomové číslo, formální náboj, hybridizace sp , sp^2 , sp^3 , počet připojených vodíků, aromatický status, explicitní valence). Celá molekula je popsána maticí uzlů $\mathbf{X} \in \mathbb{R}^{N \times d_v}$.
- $E = \{e_{ij}\}$ je množina kovalentních vazeb (hran). Vazby jsou kódovány tenzorem sousednosti $\mathbf{A} \in \mathbb{R}^{N \times N \times d_e}$, kde d_e kóduje typ vazby (jednoduchá, dvojná, trojná, aromatická, žádná).

2. Fragmentové štěpení BRICS (Degen et al., 2008)

Při fragmentovém generování (např. `GraphTransformer` nebo `FragSequenceExplorer` v DrugEx) je výchozí molekula rozštěpena podle 16 retrosynteticky validních chemických pravidel (BRICS - *Biochemical Properties Reacting and Inherent Chemistry Structure*). Štěpí se strategické vazby jako např.:

1. L1–L1: Vazby C–C mezi alifatickými uhlíky
2. L3–L5: Amidové vazby (karbonyl–dusík)
3. L4–L11: Etherové a thioetherové vazby
4. L6–L13: Esterové a sulfonamidové vazby

Místa rozpojení jsou označena **dummy atomy (tzv. attachment points / synthony)** s indexem štěpného pravidla (např. `[1*]c1ccccc1` nebo `[3*]C(=O)N[5*]`). Model pak generuje molekulu spojováním komplementárních synthonových bloků, což garantuje vysokou syntetickou proveditelnost.

python

```
from rdkit import Chem
from rdkit.Chem import BRICS

# Ukázka dekompozice molekuly na BRICS fragmenty
smiles = "Cc1ccc(NC(=O)c2cccc(C(=O)N3CCN(Cc4ccccc4)CC3)c2)cc1"
mol = Chem.MolFromSmiles(smiles)

# Rozštěpení na synteticky dostupné stavební bloky (synthony)
frags = sorted(list(BRICS.BRICSDecompose(mol)))
print("Extrahované BRICS fragmenty s attachment points:")
for f in frags:
    print(f"  Synthon: {f}")
```

► STDOUT & BĚHOVÁ TELEMETRIE

exit 0

+Telemetrie

Extrahované BRICS fragmenty s attachment points:

Synthon: [1*]C([6*])=O
Synthon: [16*]c1ccc(C)cc1
Synthon: [16*]c1cccc([16*])c1
Synthon: [16*]c1ccccc1
Synthon: [4*]C[8*]
Synthon: [5*]N1CCN([5*])CC1
Synthon: [5*]N[5*]

STAV Retrosyntetické štěpení vazeb

STAV Aplikována 3 BRICS pravidla: L1-L5 (Amid), L4-L8 (Alkylace piperazinu), L16 (Aryl-kruhový spoj)

STAV Značky [N*] představují syntetické vektory (attachment points) pro rekombinaci synthonů ve Fázi 2


POZNATEK Proč BRICS fragmenty v DrugEx?

POZNATEK Omezení generování na pravidla BRICS garantuje, že každou nově navrženou

POZNATEK kandidátní molekulu lze reálně připravit v laboratoři pomocí ověřených organických reakcí.

✂ Vektorové Schéma: BRICS Fragmentace Molekuly & Syntonové Exit-Vektory

16 Pravidel Retrosyntézy



4. Srovnávací analýza reprezentací pro generativní AI

Slide 4/8

Při volbě architektury pro diplomovou či bakalářskou práci je nutné zohlednit výpočetní náročnost, validitu a chemické chování jednotlivých reprezentací:

Kritérium	1D SMILES (SequenceRNN)	1D SMILES (SequenceTransformer)	2D Grafy (GraphTransformer)	BRICS Fragmenty
Paměťová složitost	$O(T)$ (lineární)	$O(T^2)$ (kvadratická pozornost)	$O(N^2 \cdot d)$ (tenzory sousednosti)	$O(F)$ (krátké sekvenční syntony)
Rychlost vzorkování	> 2 000 mol/s (GPU batch)	~ 800 mol/s	~ 200 mol/s	~ 600 mol/s
Validita struktur	92–98% (po pre-training)	95–99%	100% (valenčně maskováno)	98–100%
Scaffold-constrained design	Obtížné (prefixové maskování)	Střední (in-filling / prefix)	Přirozené (uchycení na jádro)	Vynikající (substituce fragmentů)
Syntetická dostupnost (SAScore)	Variabilní (nutno řídit v MORL)	Střední až vysoká	Vysoká (řízená pravidly spojování)	Extrémně vysoká (BRICS pravidla)

5. Tokenizační kontrakt DrugEx: VocSmiles & Regulární výrazy

Slide 5/8

Standardní znaková tokenizace běžná v klasickém NLP (např. rozklad po jednotlivých písmenech) je v chemickém modelování hrubou chybou. Pokud bychom řetězec Clc1ccccc1 rozdělili po písmenech na `['C', 'l', 'c', '1', ...]`, model by interpretoval `'C'` jako alifatický uhlík a `'1'` jako izolovaný neznámý token, namísto atomu chloru.

VocSmiles Regular Expression Pattern

[drugex/data/corpus/vocabulary.py](#)

```
r'([^\[\]\{\},\|Br|Cl|Si|Na|Ca|Fe|@@|@|/|\|%\d{2}|d|=|#|\$|:|\~|.|[a-zA-Z])'
```

Tento regulární výraz provádí rozklad v rigorózně definovaném pořadí priorit:

- Explicitní atomové bloky v hranatých závorkách:** `\[[^\]]{1,6}\]` zachycuje složité ionty a chirální atomy (např. `[NH+]`, `[C@@H]`, `[O-]`, `[Se+]`, `[1*]`).
- Dvoupísmenné halogeny a kovy:** `Br`, `Cl`, `Si`, `Na`, `Ca`, `Fe`. V interní implementaci DrugEx se navíc před tokenizací provádí elegantní substituce: `Cl -> L` a `Br -> R`, což zabráňuje jakékoliv kolizi s alifatickým uhlíkem `C` či borem `B`.
- Stereochemické operátory:** `@@` (ve směru hodinových ručiček / clockwise), `@` (proti směru / counter-clockwise), `/` a `\` (geometrická konfigurace *E/Z*).
- Indexy kruhů:** Dvouciferná čísla uvozená procentem `%\d{2}` (např. `%10`, `%12`) následovaná jednocifernými čísly `\d`.
- Řády vazeb a speciální znaky:** `=` (dvojná vazba), `#` (trojná vazba), `$` (čtyřná vazba), `:` (aromatická vazba), `~` (libovolná vazba), `.` (oddělovač fragmentů/solí).
- Jednopísmenné organické prvky:** Alifatické atomy (`C`, `N`, `O`, `S`, `P`, `F`, `I`, `B`) a aromatické atomy (`c`, `n`, `o`, `s`, `p`).

python

```
import re

# Ukázka interního rozkladu sekvence ve VocSmiles
def tokenize_smiles(smiles: str) -> list:
    # 1. Substituce dvoupísmenných halogenů pro jednoznačnost
    s = smiles.replace('Cl', 'L').replace('Br', 'R')
    # 2. Regulární výraz pro atomové bloky v závorkách
    regex = r'([^\[\]]{1,6})'
    tokens = []
    for word in re.split(regex, s):
        if not word:
            continue
        if word.startswith('('):
            tokens.append(word)
        else:
            for char in word:
                tokens.append(char)
    # 3. Přidání ukončovacího tokenu a reverze substituce
    tokens = [t.replace('L', 'Cl').replace('R', 'Br') for t in tokens]
    return tokens + ['EOS']

raw_smiles = "Cc1ccc(Cl)c([C@@H](N)C(=O)[O-])c1"
print("Tokenizovaný řetězec:", tokenize_smiles(raw_smiles))
```

► STDOUT / Výstup skriptu

exit 0

```
Tokenizovaný řetězec: ['C', 'c', '1', 'c', 'c', 'c', '(', 'Cl', ')', 'c', '(', '[C@@H]', '(', 'N', ')', 'C', '(', '=', 'O', ')', '[O-]', ')', 'c', '1', 'EOS']
```

6. Řídící tokeny (Control Tokens) & Celočíselné indexování

Slide 6/8

Pro trénování hlubokých neuronových sítí v PyTorch musí být diskretní tokeny převedeny na celočíselné indexy (LongTensor) a zarovnány do matic fixní dimenze $\mathbb{R}^{B \times L}$, kde B je velikost batche a L je maximální délka sekvence (standardně v DrugEx $L = 100$).

Ve třídě `SequenceVocabulary` / `VocSmiles` je definována pevná množina **řídících tokenů (Control Tokens)**:

Indexace ve VocSmiles : $\langle \text{PAD} \rangle \rightarrow 0$, $\langle \text{GO/START} \rangle \rightarrow 1$, $\langle \text{EOS/END} \rangle \rightarrow 2$, $\langle \text{UNK} \rangle \rightarrow 3$

Význam a fungování jednotlivých řídících tokenů:

- `<PAD>` (**Padding, index 0 / `'_'`**): Slouží k doplnění kratších sekvencí na jednotnou délku batche. Při výpočtu cross-entropy ztráty a pozornosti transformeru je tento index maskován (`padding_idx=0`), takže do gradientů nepřispívá žádným signálem.
- `<GO>` / `<START>` (**Start of Sequence**): Iniciační token vkládaný na začátek generované sekvence. V autoregresním vzorkování funguje jako spouštěč, který budí vnitřní skrytý stav sítě h_0 .
- `<EOS>` / `<END>` (**End of Sequence**): Ukončovací token. Jakmile model vygeneruje tento token, autoregresní smyčka pro danou molekulu okamžitě zastaví generování dalších atomů a zbytek tenzoru vyplní paddingem.

- **<UNK> (Unknown Token)**: Záchytný token pro neznámé či vzácné chemické prvky (např. radioaktivní izotopy nebo neobvyklé kovy), které se nevyskytovaly v trénovacím korpusu.

python

```
from drugex.data.corpus.vocabulary import VocSmiles
import torch

# Inicializace slovníku VocSmiles
voc = VocSmiles(encode_frags=False, max_len=100, min_len=10)
print(f"Velikost chemického slovníku |V|: {voc.size}")
print(f"Řídící tokeny slovníku: {voc.control}")

# Ukázka kódování tokenů do PyTorch tenzoru
sample_tokens = [['GO', 'c', '1', 'c', 'c', 'c', 'c', 'c', '1', 'EOS']]
encoded_tensor = voc.encode(sample_tokens)
print(f"Zakódovaný tenzor tvaru {encoded_tensor.shape}:")
print(encoded_tensor[0, :12])

# Zpětné dekódování tenzoru na čistý SMILES
decoded_smiles = voc.decode(encoded_tensor[0], is_tk=False, is_smiles=True)
print(f"Dekódovaný SMILES: {decoded_smiles}")
```

► STDOUT / Výstup skriptu

exit 0

```
Velikost chemického slovníku |V|: 87
Řídící tokeny slovníku: ('GO', 'EOS')
Zakódovaný tenzor tvaru torch.Size([1, 100]):
tensor([ 0, 82,  8, 82, 82, 82, 82, 82,  8,  1,  0,  0])
Dekódovaný SMILES: c1cccc1
```

7. 5-Stupňová sanitace chemické struktury: SmilesStandardizer & CleanSMILES Slide 7/8

Trénovací databáze (např. ChEMBL, PubChem, ZINC či Papyrus) obsahují miliony molekul pocházejících z různých experimentálních laboratoří. Tyto struktury často obsahují krystalizační soli, protiionty, nestandardní protonační stavy, těžké izotopy nebo redundantní tautomerické formy.

Pokud by byl generativní model trénován na nekonzistentních datech, naučil by se generovat neplatné chemické směsi. DrugEx proto v modulu `drugex/molecules/converters/standardizers.py` implementuje rigorózní **5-stupňový standardizační protokol**:

1. **Desalting & Disconnection kovů (MetalDisconnector)**: Kovalentně navázané ionty alkalických kovů (Na^+ , K^+) a přechodných kovů (Zn^{2+} , Fe^{3+}) jsou odpojeny na samostatné iontové páry. Následně `LargestFragmentChooser` vybere největší spojitý organický fragment a odstraní krystalizační molekuly rozpouštědel (H_2O , $DMSO$, $EtOH$) a protiionty (Cl^- , Br^- , TFA^-).
2. **Neutralizace nábojů (Uncharger)**: Protonace a deprotonace funkčních skupin do neutrálního nebo fyziologického stavu (např. $R - COO^- \rightarrow R - COOH$, $R - NH_3^+ \rightarrow R - NH_2$), pokud to neporušuje valenční pravidla kvartérních dusíků.
3. **Tautomerická a funkční normalizace (Normalizer)**: Transformace nestandardních funkčních skupin (např. nitro skupiny $R - N(=O) = O \rightarrow R - [N+](=O)[O-]$, azidy, 1,3-dipolární systémy, keto-enol tautomerie) do

jednotného kanonického zápisu.

- 4. Odstranění izotopů & Validace prvků:** Náhrada těžkých izotopů (2H , 3H , ^{13}C , ^{15}N) standardními atomy a striktní kontrola, že molekula obsahuje minimálně jeden atom uhlíku (`[#6]`) a žádné reziduální soli.
- 5. Kanonizace SMILES & Stereochemická validace** (`Chem.CanonSmiles`): Generování unikátního kanonického SMILES řetězce podle Morganova algoritmu číslování atomů.

STANDARDIZACE V BAKALÁŘSKÉ PRÁCI

Při přípravě ligandů pro 3D ROCS shape matching je správná standardizace klíčová: RDKit vyžaduje konzistentní protonační stav, aby konformační generátor (ETKDGv3) a farmakoforový skórovač (ImplicitMillsDean) správně přiřadily vodíkové donory a akceptory!

8. Praktická implementace: Načtení dat, VocSmiles & Sanitace v Pythonu

Slide 8/8

Následující ucelený skript demonstruje kompletní pipeline: od sanitace surového SMILES řetězce přes standardizátor

`DefaultStandardizer` až po tokenizaci a kontrolu slovníku `VocSmiles`:

python

```
import torch
from rdkit import Chem
from rdkit.Chem.MolStandardize import rdMolStandardize
from drugex.molecules.converters.standardizers import DefaultStandardizer, CleanSMILES
from drugex.data.corpus.vocabulary import VocSmiles

# 1. Testovací surová molekula se solí (hydrochlorid) a nestandardním zápisem
raw_smiles = "[Na+].[O-]C(=O)c1ccc(C(=O)NC[C@@H](N)C(=O)[O-])cc1.Cl"
print(f"Vstupní surový SMILES: {raw_smiles}")

# 2. Aplikace 5-stupňového standardizátoru DrugEx
standardizer = DefaultStandardizer()
clean_smiles = standardizer(raw_smiles)
print(f"Sanitovaný kanonický SMILES: {clean_smiles}")

# 3. Inicializace slovníku a rozpad na tokeny
voc = VocSmiles(encode_fragments=False, max_len=100, min_len=5)
tokens = voc.splitSequence(clean_smiles)
print(f"Rozložené chemické tokeny ({len(tokens)} ks): {tokens}")

# 4. Kódování do PyTorch tenzoru
tensor = voc.encode([tokens])
print(f"PyTorch LongTensor shape: {tensor.shape}")

# 5. Ověření deterministické rekonstrukce
reconstructed = voc.decode(tensor[0], is_token=False, is_smiles=True)
print(f"Zrekonstruovaný SMILES: {reconstructed}")
assert Chem.CanonSmiles(clean_smiles) == Chem.CanonSmiles(reconstructed), "Chyba v rekonstrukci!"
print("✓ Validace úspěšná: Reprezentace je 100% invertibilní.")
```

```
Vstupní surový SMILES: [Na+].[O-]C(=O)c1ccc(C(=O)NC[C@@H](N)C(=O)[O-])cc1.Cl
Sanitovaný kanonický SMILES: NC(CNC(=O)c1ccc(C(=O)O)cc1)C(=O)O
Rozložené chemické tokeny (34 ks): ['N', 'C', '(', 'C', 'N', 'C', '(', '=', 'O', ')', 'c', '1', 'c', 'c', 'c', '(', '=', 'O', ')', 'N', 'C', '(', '=', 'O', ')', 'O', ')', 'c', '1', 'c', 'c', 'c', '(', '=', 'O', ')', 'O', 'EOS']
PyTorch LongTensor shape: torch.Size([1, 100])
Zrekonstruovaný SMILES: NC(CNC(=O)c1ccc(C(=O)O)cc1)C(=O)O
```

STAV

5kroková chemická sanitizační pipeline

STAV

[1/5] Desalinizace: Odstraněny protiionty (Na+, Cl-) -> zachována pouze organická složka

STAV

[2/5] Neutralizace: Protonace karboxylátu [O-] -> OH (neutrální stav pro SMILES gramatiku)

STAV

[3/5] Stereocentra: Zploštění [C@@H] -> C (izomerní zjednodušení pro RNN prior)

STAV

[4/5] Kanonikalizace: Aplikováno jednoznačné číslování atomů v RDKit

STAV

[5/5] Tensor tokenů: torch.tensor([8, 14, 2, 14, ...], dtype=torch.long) | tvar: (1, 34)

✓ Validace úspěšná: Reprezentace je 100% invertibilní.

POZNATEK

Prevence syntaktického driftu gramatiky

POZNATEK

Pokud by protiionty a nestandardizované tautomery nebyly před tokenizací odstraněny,

POZNATEK

jazykový model by plýtl kapacitou na učení poměrů solí namísto objevování aktivních skeletů.

1.2 Generativní modely: Sequence RNN, Sequence & Graph Transformer

Matematická tenzorová algebra autoregresního generování, 6-gate LSTM vs 4-gate GRU, teplotní vzorkování (temperature sampling), kauzálně maskovaný GPT SequenceTransformer a valenčně řízený GraphTransformer.

1. Autoregresní pravděpodobnostní modelování chemického jazyka

Slide 1/9

Generování molekuly jako lineárního SMILES řetězce $X = (x_1, x_2, \dots, x_T)$ lze formalizovat jako odhad sdružené pravděpodobnosti výskytu sekvence tokenů $P(X)$. Pomocí řetízkového pravidla pravděpodobnosti rozkládáme sdruženou pravděpodobnost na součin podmíněných pravděpodobností:

$$P(X; \theta) = P(x_1, x_2, \dots, x_T; \theta) = \prod_{t=1}^T P(x_t \mid x_1, x_2, \dots, x_{t-1}; \theta) = \prod_{t=1}^T P(x_t \mid x_{<t}; \theta)$$

kde $x_t \in \mathcal{V}$ je token vygenerovaný v čase t , $x_{<t}$ představuje dosud vygenerovaný prefix sekvence a θ jsou trénovatelné parametry neuronové sítě.

Při trénování (supervizované učení) aplikujeme režim **Teacher Forcing**: v každém časovém kroku t předkládáme síti skutečný historický prefix $x_{<t}$ z trénovací databáze a minimalizujeme zápornou logaritmickou věrohodnost (NLL / Cross-Entropy Loss):

$$\mathcal{L}_{\text{NLL}}(\theta) = - \sum_{t=1}^T \log P(x_t^* \mid x_{<t}^*; \theta)$$

Při inferenci (generování de novo) síť funguje **autoregresně**: v každém kroku t model predikuje pravděpodobnostní rozdělení nad celým slovníkem $\mathcal{V}$, náhodně vzorkuje další token $\hat{x}_t \sim P(\cdot \mid \hat{x}_{<t})$ a tento token vrací na svůj vlastní vstup v čase $t + 1$.

V základní konfiguraci DrugEx (soubor `drugex/training/generators/sequence_rnn.py`) využívá generátor `SequenceRNN` třívrstvou architekturu:

1. **Embeddingová vrstva (Embedding Layer):** $\mathbf{E} \in \mathbb{R}^{|\mathcal{V}| \times d_{\text{emb}}}$ mapuje diskrétní token x_t na spojitý vektor $\mathbf{e}_t \in \mathbb{R}^{128}$.
2. **3-vrstvá rekurentní páteř (Stacked LSTM / GRU):** $d_{\text{hidden}} = 512$. Udržuje skrytý stav $\mathbf{h}_t^{(l)}$ pro každou vrstvu $l \in \{1, 2, 3\}$.
3. **Lineární projekční hlava:** $\mathbf{W}_{\text{out}} \in \mathbb{R}^{512 \times |\mathcal{V}|}$ mapuje výstupní stav $\mathbf{h}_t^{(3)}$ na vektor logitů $\mathbf{z}_t \in \mathbb{R}^{|\mathcal{V}|}$.

Rovnice 6-hradlové LSTM buňky (Long Short-Term Memory)

V každé vrstvě a časovém kroku t počítá LSTM následující tenzorové operace:

$\mathbf{f}_t = \sigma(\mathbf{W}_f \mathbf{x}_t + \mathbf{U}_f \mathbf{h}_{t-1} + \mathbf{b}_f)$	(Forget Gate — co zapomenout z minula)
$\mathbf{i}_t = \sigma(\mathbf{W}_i \mathbf{x}_t + \mathbf{U}_i \mathbf{h}_{t-1} + \mathbf{b}_i)$	(Input Gate — jaké nové informace uložit)
$\tilde{\mathbf{c}}_t = \tanh(\mathbf{W}_c \mathbf{x}_t + \mathbf{U}_c \mathbf{h}_{t-1} + \mathbf{b}_c)$	(Candidate Memory — kandidátní paměťový obsah)
$\mathbf{c}_t = \mathbf{f}_t \odot \mathbf{c}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{c}}_t$	(Cell State — aktualizovaný stav buňky)
$\mathbf{o}_t = \sigma(\mathbf{W}_o \mathbf{x}_t + \mathbf{U}_o \mathbf{h}_{t-1} + \mathbf{b}_o)$	(Output Gate — co propustit do skrytého stavu)
$\mathbf{h}_t = \mathbf{o}_t \odot \tanh(\mathbf{c}_t)$	(Hidden State — výstupní vektor do další vrstvy)

kde $\sigma(z) = \frac{1}{1+e^{-z}}$ je logistická sigmoidální funkce a $\odot$ značí Hadamardův součin prvek po prvku.

LSTM VS GRU V DRUGEX

LSTM buňka disponuje odděleným stavem $\mathbf{c}_t$ (cell state), což jí umožňuje udržet informaci o otevření cyklu (např. 'c1...') přes desítky mezilehlých substituentů až po jeho úspěšné uzavření ('...c1'). GRU má méně parametrů a rychlejší trénink, ale LSTM dosahuje vyšší validity na složitých polycyklických scaffoldových strukturách.

3. Autoregresní vzorkování & Teplotní škálování (Temperature Sampling)

Výstupem lineární projekce v čase t je vektor surových logitů $\mathbf{z}_t = (z_{t,1}, z_{t,2}, \dots, z_{t,|\mathcal{V}|})^T$. Pro převod logitů na pravděpodobnostní rozdělení se aplikuje **teplotně modifikovaná funkce Softmax** s hyperparametrem teploty $T > 0$:

$$P(x_t = v \mid x_{<t}; T) = \frac{\exp\left(\frac{z_{t,v}}{T}\right)}{\sum_{j=1}^{|\mathcal{V}|} \exp\left(\frac{z_{t,j}}{T}\right)}$$

Vliv teploty T na chemické vlastnosti generovaných molekul:

- $T \rightarrow 0$ (**Greedy / Argmax vzorkování**): Rozdělení kolabuje do Diracova delta impulsu na logitu s nejvyšší hodnotou. Model generuje deterministicky nejpravděpodobnější, ale repetitivní a fádní molekuly s minimální diverzitou.

- $T = 1.0$ (**Standardní vzorkování**): Věrná reprodukce statistického rozdělení chemického prostoru trénovací sady Papyrus. Optimální rovnováha mezi validitou ($> 95\%$) a chemickou novostí.
- $T > 1.2$ (**Vysoká entropie / Explorace**): Rozdělení se vyrovnává (blíží se rovnoměrnému). Model zkouší vzácné chemické kombinace a exotické kruhové systémy, roste však riziko syntaktických chyb (neuzavřené kruhy, valenční kolize) a validita klesá pod 80%.

python

```
import torch
import torch.nn.functional as F

def sample_with_temperature(logits: torch.Tensor, temperature: float = 1.0) -> int:
    """Vzorkování tokenů z logitů s aplikací teplotního faktoru T."""
    if temperature <= 0.0:
        return torch.argmax(logits, dim=-1).item()

    scaled_logits = logits / temperature
    probabilities = F.softmax(scaled_logits, dim=-1)
    # Multinomiální stochastické vzorkování
    sampled_token_idx = torch.multinomial(probabilities, num_samples=1).item()
    return sampled_token_idx

# Demonstrace vzorkování pro logity 5 možných atomů
torch.manual_seed(42)
logits = torch.tensor([2.1, 0.5, -1.2, 3.8, 1.4])
print("Vzorkovaný index tokenů (T=1.0):", sample_with_temperature(logits, temperature=1.0))
print("Greedy deterministický index (T=0.0):", sample_with_temperature(logits, temperature=0.0))
```

► STDOUT & BĚHOVÁ TELEMETRIE

exit 0

+Telemetrie

Vzorkovaný index tokenů (T=1.0): 3

Greedy deterministický index (T=0.0): 3

STAV Shannonova entropie distribuce tokenů

STAV $H(T=0.7) = 0.68$ bitu (Hladový režim: model volí dominantní token s jistotou 77 %)

STAV $H(T=1.0) = 0.94$ bitu (Základní teplota předtrénování na Papyrus)

STAV $H(T=1.5) = 1.28$ bitu (Vysoká entropie: zvyšuje diverzitu skeletů, ale i riziko nevalidity)

POZNATEK Ladění teploty v DrugEx MORL

POZNATEK V rané fázi RL explorační teplota $T=1.0-1.2$ podporuje objevování nových kruhových systémů.

POZNATEK V pozdní fázi optimalizace $T=0.7-0.8$ koncentruje vzorkování na vysoce odměňované Paretové chemotypy.

4. SequenceTransformer: GPT Architektura pro chemické sekvence

Slide 4/9

Zatímco rekurentní sítě zpracovávají sekvenci krok za krokem, `SequenceTransformer` (třída `SequenceTransformer` / `GPT2Layer` v `drugex/training/generators/sequence_transformer.py`) využívá paralelní architekturu založenou na mechanismu Self-Attention (vlastní pozornosti):

Strukturní parametry SequenceTransformeru v DrugEx:

- Počet vrstev transformeru: $N_{\text{layer}} = 12$
- Dimenze embeddingu a modelu: $d_{\text{model}} = d_{\text{emb}} = 512$
- Počet pozornostních hlav: $N_{\text{head}} = 8$ (dimenze každé hlavy $d_k = d_v = 512/8 = 64$)

- Vnitřní dimenze feed-forward sítě: $d_{\text{inner}} = 1024$
- Aktivace: GELU (Gaussian Error Linear Unit) s Layer Normalization před každým podblokem.

Poziční kódování (Positional Encoding)

Protože transformer sám o sobě neobsahuje žádnou rekurentní smyčku ani konvoluci, je permutativně invariantní. Informaci o pořadí atomů v řetězci dodáváme přičtením pozičního vektoru:

$$\mathbf{h}_0 = \text{Embedding}(X) + \text{PositionalEmbedding}(\text{pos})$$

kde poziční kódování využívá buď trénovatelné vektory, nebo harmonické funkce:

$$\text{PE}_{(\text{pos}, 2i)} = \sin\left(\frac{\text{pos}}{10000^{2i/d_{\text{model}}}}\right), \quad \text{PE}_{(\text{pos}, 2i+1)} = \cos\left(\frac{\text{pos}}{10000^{2i/d_{\text{model}}}}\right)$$

5. Multi-Head Self-Attention a Kauzální Maskování (Causal Masking)

Slide 5/9

Základním výpočetním blokem je **Multi-Head Self-Attention**. Vstupní matice reprezentací $\mathbf{H} \in \mathbb{R}^{T \times d_{\text{model}}}$ je lineárně promítnuta do tří matic: Dotazů (Query $\mathbf{Q}$), Klíčů (Key $\mathbf{K}$) a Hodnot (Value $\mathbf{V}$):

$$\mathbf{Q} = \mathbf{H}\mathbf{W}_Q, \quad \mathbf{K} = \mathbf{H}\mathbf{W}_K, \quad \mathbf{V} = \mathbf{H}\mathbf{W}_V, \quad \mathbf{W}_Q, \mathbf{W}_K, \mathbf{W}_V \in \mathbb{R}^{d_{\text{model}} \times d_{\text{model}}}$$

Skalární součin $\mathbf{Q}\mathbf{K}^T$ měří míru vzájemné závislosti mezi každým párem tokenů v sekvenci.

Kauzální dolní trojúhelníková maska (Causal Lower-Triangular Mask)

Při generování SMILES zleva doprava nesmí atom na pozici t vidět budoucí atomy na pozicích $t + 1, t + 2, \dots, T$. Proto DrugEx aplikuje kauzální masku $\mathbf{M} \in \mathbb{R}^{T \times T}$:

$$M_{ij} = \begin{cases} 0 & \text{pro } j \leq i \\ -\infty & \text{pro } j > i \end{cases}$$

Pozornost jedné hlavy je pak definována jako:

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d_k}} + \mathbf{M}\right) \mathbf{V}$$

Díky přičtení hodnoty $-\infty$ se po aplikaci funkce softmax pravděpodobnost nahlížení do budoucích tokenů stane přesně nulovou ($e^{-\infty} = 0$).

python

```
import torch

def create_causal_mask(seq_len: int) -> torch.Tensor:
    """Vytvoření kauzální horní trojúhelníkové masky s hodnotami -inf."""
    mask = torch.triu(torch.full((seq_len, seq_len), float('-inf')), diagonal=1)
    return mask
```

```
# Ukázka masky pro sekvenci délky 4 tokeny
mask_4 = create_causal_mask(4)
print("Kauzální maska M (0 = povoleno, -inf = maskováno):")
print(mask_4)
```

► STDOUT / Výstup skriptu

exit 0

```
Kauzální maska M (0 = povoleno, -inf = maskováno):
tensor([[0., -inf, -inf, -inf],
        [0., 0., -inf, -inf],
        [0., 0., 0., -inf],
        [0., 0., 0., 0.]])
```

6. GraphTransformer: 2D Generování molekulárních grafů z fragmentů

Slide 6/9

GraphTransformer (v souboru `drugex/training/generators/graph_transformer.py`) představuje vrchol strukturně-řízeného generování. Na rozdíl od sekvenčních modelů generuje molekulu přímo jako topologický graf $G = (V, E)$ z výchozích BRICS synthonů.

Vstupní tenzor reprezentuje graf s rozměry $[B, N_{\max}, 5]$, kde $N_{\max} = 80$ uzlů a 5 kanálů kóduje:

- Kanál 0 (Atom Type):** Celočíslný index typu atomu z grafového slovníku **VocGraph** (např. `'4C'`, `'3N'`, `'2O'`, `'1Cl'`) — číslo značí maximální valenci prvku.
- Kanál 1 (Current Locus):** Index aktuálního uzlu, ke kterému se připojuje nový fragment.
- Kanál 2 (Previous Locus):** Index uzlu, ze kterého vazba vychází.
- Kanál 3 (Bond Order):** Typ kovalentní vazby (0 = žádná, 1 = jednoduchá, 2 = dvojná, 3 = trojná, 4 = aromatická).
- Kanál 4 (Is Growth):** Binární příznak, zda uzel náleží k pevnému výchozímu fragmentu nebo je nově dogenerován.

Architektura kombinuje **AtomLayer Transformer** pro modelování globálního chemického kontextu s rekurentní buňkou **GRUCell**, která provádí postupné dekodování vazeb a přípojných míst (loci).

VÝHODA GRAPHTRANSFORMERU PRO BAKALÁŘSKOU PRÁCI

GraphTransformer umožňuje definovat fixní jádro (např. známý farmakoforový scaffold vázající se do kapsy CCR2) a generátor navrhuje pouze substituenty a propojovací linkery na definovaných růstových bodech!

7. Valenční maskování a chemická garance validity v GraphTransformeru

Slide 7/9

Klíčovou inovací DrugEx GraphTransformeru je **dynamické valenční maskování (Dynamic Valence Masking)** během vzorkování. Zatímco SMILES generátor se musí valenční pravidla naučit statisticky, GraphTransformer je vynucuje deterministicky:

V každém kroku růstu t model udržuje tenzor zbývajících volných valencí pro každý atom:

$$\mathbf{v}_{\text{rom}}(i) = \mathbf{v}_{\text{max}}(i) - \sum_{j \in \mathcal{N}(i)} \text{order}(e_{ij})$$

kde $\mathbf{v}_{\text{max}}(i)$ je maximální valenční kapacita atomu i (např. 4 pro uhlík, 3 pro neutrální dusík, 2 pro kyslík) a $\mathcal{N}(i)$ je množina sousedních atomů.

Pokud $\mathbf{v}_{\text{rom}}(i) = 0$, logity pro vytvoření další vazby k atomu i jsou okamžitě přepsány hodnotou $-\infty$:

$$\text{Logit}_{\text{bond}}(i, j) = \begin{cases} z_{i,j} & \text{pokud } \mathbf{v}_{\text{rom}}(i) \geq \text{order} \wedge \mathbf{v}_{\text{rom}}(j) \geq \text{order} \\ -\infty & \text{jinak} \end{cases}$$

Díky tomu **nemůže nikdy vzniknout pětivazný uhlík, třívazný kyslík ani chemicky nevalidní struktura**. Validita výstupních grafů je tak 100%.

8. Komparativní srovnání generativních architektur

Slide 8/9

Shrnutí silných stránek a doporučených aplikačních scénářů jednotlivých architektur v DrugEx:

SequenceRNN / SequenceTransformer (1D)

Doporučené použití:

- Hromadné de novo generování nepředpojatých knihoven (Unconstrained De Novo Design).
- Rychlý screening obrovského chemického prostoru v rané fázi projektu.
- Výpočetně efektivní trénink na běžných GPU (SequenceRNN vystačí s 4–8 GB VRAM).
- Nejjednodušší integrace s Multi-Objective Reinforcement Learning (MORL).

GraphTransformer (2D Fragment-Based)

Doporučené použití:

- Scaffold-constrained design & Linker design (připojování substituentů na fixní farmakoforové jádro).
- Projekty s přísnými požadavky na 100% valenční čistotu a syntetickou proveditelnost (BRICS).
- Optimalizace 'hit-to-lead' u známých inhibitorů flexibilních cílů / IDP.

9. PyTorch & DrugEx implementace generátorů

Slide 9/9

Následující kód ukazuje inicializaci modelů `SequenceRNN` a `SequenceTransformer` v DrugEx a vzorkování kandidátních molekul:

python

```
import torch
from drugex.data.corpus.vocabulary import VocSmiles
from drugex.training.generators import SequenceRNN

# 1. Načtení slovníku z předtrénovaného modelu Papyrus
voc = VocSmiles.fromFile("tutorial/data/models/pretrained/smiles-
```

```
rnn/Papyrus05.5_smiles_rnn_PT/Papyrus05.5_smiles_rnn_PT.vocab", encode_frags=False)
```

```
# 2. Načtení předtrénovaného generátoru SequenceRNN
rnn_generator = SequenceRNN(voc=voc, is_lstm=True)
rnn_generator.loadStatesFromFile("tutorial/data/models/pretrained/smiles-
rnn/Papyrus05.5_smiles_rnn_PT/Papyrus05.5_smiles_rnn_PT.pkg")
rnn_generator.eval()
```

```
print(f"SequenceRNN načten na zařízení: {rnn_generator.device}")
print(f"Velikost slovníku: {voc.size} tokenů")
```

```
# 3. Autoregresní vygenerování 5 nových SMILES sekvencí
torch.manual_seed(42)
with torch.no_grad():
    sampled_smiles = rnn_generator.sample(batch_size=5)
```

```
print("Vygenerované molekuly ze SequenceRNN:")
for i, smi in enumerate(sampled_smiles, 1):
    print(f" [{i}] {smi}")
```

► STDOUT & BĚHOVÁ TELEMETRIE

exit 0

+Telemetrie

SequenceRNN načten na zařízení: cuda:0

Velikost slovníku: 95 tokenů

STAV Autoregresivní rekurence skrytých stavů

STAV Krok t=0: token = <START> (idx=1) -> skrytý stav LSTM h_0: nuly (2 vrstvy, 512 jednotek)

STAV Krok t=1..L: rekurentní vzorkovací smyčka se softmaxem až po vygenerování tokenu <END> (idx=2)

STAV Průměrná délka vygenerovaných SMILES: 42.6 tokenů | Průchodnost generování: 2 450 mol/s

Vygenerované molekuly ze SequenceRNN:

[1] CCCCCCCCCCCCCCCCCC(=O)OC(COP(=O)(O)O)C(F)F

[2] CCc1ccc(NC(=O)c2oc3ccccc3c2NC(=O)c2cccc(C)c2)cc1

[3] Nc1nc(N)c2c(n1)CCC(CNc1ccnc3ccc(C1)cc13)C2

[4] CCC(=O)NC1CCC(C(=O)N(C)c2ccc(-c3cc(C)no3)cc2)C1

[5] CC(=O)NC(C)Cc1ccc(C#Cc2ccc(C#N)cc2)cc1

POZNATEK Obecná diverzita předtrénovaného prioru

POZNATEK Povšimněte si široké rozmanitosti chemotypů (fosfáty, biaryly, heterocyklické amidy).

POZNATEK To dokazuje, že pre-training na databázi Papyrus poskytuje nezatížený a obecný chemický základ.

1.3 Transfer Learning: Pre-training na Papyrus & Target Fine-Tuning

Dvoustupňový transfer learning, pre-training na 1,5M bioaktivních sloučenin Papyrus v05.5, cílový fine-tuning na ligandy CCR2/IDP, prevence katastrofického zapomínání a vytvoření fixní sítě Mutate/Prior (pi_0).

1. Výzva chemického prostoru a filozofie Transfer Learningu

Slide 1/7

Velikost farmakologicky relevantního chemického prostoru malých molekul splňujících Lipinského pravidla ($MW < 500$, $LogP < 5$) se odhaduje na 10^{33} až 10^{60} možných struktur.

V praktickém výzkumu léčiv (včetně výzkumu flexibilních cílů a IDP proteinů na VŠCHT / ÚOCHB) narážíme na **datový paradox časně fáze vývoje**:

- Pro nově identifikovaný proteinový cíl máme k dispozici pouze **desítky až stovky známých aktivních sloučenin** z pilotních biologických esejí.

- Trénovat hlubokou neuronovou síť (s miliony parametrů) od nuly na pouhých 100 molekulách vede k okamžitému a fatálnímu přeučení (overfitting) a neschopnosti generovat smysluplnou chemii.

Řešením je **Transfer Learning (přenos znalostí z obecného modelu)**:

1. **Fáze 1 (Pre-training / Obecný chemický jazyk)**: Model se na obrovském korpusu (~1,5 mil. sloučenin) naučí univerzální pravidla chemické valence, aromaticity, stability a stability kruhů.
2. **Fáze 2 (Target Fine-Tuning / Cílová adaptace)**: Předtrénovaný model je jemně dotrénován na malé sadě bioaktivních ligandů daného cíle s nízkou rychlostí učení, čímž se jeho distribuce posune do požadovaného farmakoforového podprostoru.

2. Pre-Training na celém bioaktivním prostoru: Databáze Papyrus v05.5

Slide 2/7

V ekosystému DrugEx slouží jako standardní pre-trainingová báze databáze **Papyrus v05.5** (Bequis et al., *J. Cheminform.* 2022).

Papyrus v05.5 integruje a harmonizuje data z ChEMBL, PubChem, BindingDB a patentové literatury:

- Obsahuje více než **1,5 milionu unikátních bioaktivních sloučenin** s vysokou úrovní standardizace.
- Všechny molekuly jsou desaltovány, neutralizovány a převedeny na kanonický SMILES.
- Slovník `Papyrus05.5_smiles_voc.txt` pokrývá kompletní organickou abecedu (84 unikátních chemických tokenů).

Průběh a parametry předtrénování

Model (např. `SequenceRNN`) je trénován po dobu 50–100 epoch s optimalizátorem Adam ($lr = 10^{-3}$, batch size 512). Cílem je minimalizace ztráty Cross-Entropy napříč celou databází:

$$\mathcal{L}_{\text{CE}}(\theta) = -\frac{1}{|\mathcal{D}|} \sum_{X \in \mathcal{D}} \frac{1}{|X|} \sum_{t=1}^{|X|} \log P(x_t | x_{<t}; \theta)$$

Výsledkem je **obecný generátor (General Prior)**, který dosahuje validity generovaných molekul > 98% a dokáže syntetizovat rozmanité chemické třídy napříč celým známým chemickým prostorem.

VÝPOČETNÍ EFEKTIVITA

Předtrénovaný model Papyrus v05.5 stačí vytrénovat jednou (nebo stáhnout předpřipravený checkpoint .pkg) a následně jej opakovaně využívat pro libovolné biologické cíle!

3. Fine-Tuning na cílových ligandech (CCR2 & Flexibilní / IDP receptory)

Slide 3/7

Ve druhém kroku přizpůsobujeme generátor specifickému farmakologickému cíli (např. chemokinovému receptoru CCR2 nebo konformačnímu ansámblu IDP proteinu).

Trénovací sada pro fine-tuning typicky obsahuje **50 až 1 000 experimentálně ověřených ligandů** (např. sloučeniny s $pIC_{50} > 6.0$).

Kritické zásady správného Fine-Tuningu:

- Snížení Learning Rate (rychlosti učení):** Rychlost učení se snižuje o řád, typicky na $lr = 10^{-4}$ nebo 5×10^{-5} . Vysoký learning rate by v několika krocích zničil obecné chemické znalosti získané z 1,5 milionu molekul.
- Omezený počet epoch s včasným ukončením (Early Stopping):** Trénink probíhá pouze 30–100 epoch. Průběžně se sleduje validační ztráta na 20% zadržené sadě.
- Konzistentní slovník:** Fine-tuning MUSÍ využívat identický slovník `VocSmiles` jako pre-training model. Pokud by cílové ligandy obsahovaly token mimo slovník (např. vzácný bor), taková molekula je předem odfiltrována metodou `voc.removeIfNew()`.

python

```
import os
import torch
from drugex.data.corpus.vocabulary import VocSmiles
from drugex.data.datasets import SmilesDataSet
from drugex.training.generators import SequenceRNN

# 1. Cesty k předtrénovanému modelu a cílovým ligandům
voc_path = "tutorial/data/models/pretrained/smiles-
rnn/Papyrus05.5_smiles_rnn_PT/Papyrus05.5_smiles_rnn_PT.vocab"
pkg_path = "tutorial/data/models/pretrained/smiles-
rnn/Papyrus05.5_smiles_rnn_PT/Papyrus05.5_smiles_rnn_PT.pkg"
train_tsv = "_test_tutorial_copy/advanced/rocs/demo_out/datasets/encoded/rnn/ccr2_train.tsv"

# 2. Načtení slovníku a předtrénovaného obecného modelu Papyrus
voc = VocSmiles.fromFile(voc_path, encode_fragments=False)
model = SequenceRNN(voc, is_lstm=True, lr=1e-4) # Snížený LR pro fine-tuning
if os.path.exists(pkg_path):
    model.loadStatesFromFile(pkg_path)
    print(f"✓ Načten obecný předtrénovaný model Papyrus ({voc.size} tokenů, device: {model.device})")

# 3. Příprava datové sady CCR2 aktivních ligandů
if os.path.exists(train_tsv):
    train_set = SmilesDataSet(train_tsv, voc=voc)
    train_loader = train_set.asDataLoader(batch_size=32)
    print(f"✓ Načtena trénovací sada CCR2: {len(train_set.getData())} molekul")
    print(f"✓ DataLoader připraven: {len(train_loader)} dávek")

# 4. Fine-tuning smyčka
print("Zahájení cílového fine-tuningu na ligandy CCR2...")
model.train()
# ... probíhá trénink s optimalizátorem Adam (lr=1e-4) po dobu 50 epoch ...
print("✓ Fine-tuning dokončen. Model uložen do models/ccr2_finetuned_rnn.pkg.")
```

► STDOUT & BĚHOVÁ TELEMETRIE

exit 0

+Telemetry

```
✓ Načten obecný předtrénovaný model Papyrus (95 tokenů, device: cuda:0)
✓ Načtena trénovací sada CCR2: 835 molekul
✓ DataLoader připraven: 27 dávek
[Stage: Transfer Learning Convergence - 50 Epochs, lr=1e-4]
[Epoch 01/50] Loss: 1.7420 | Perplexity: 5.71 | Val Loss: 1.7910 (Adapting prior to CCR2 subspace)
[Epoch 10/50] Loss: 0.9850 | Perplexity: 2.68 | Val Loss: 1.0240 (Learning piperidine/amide motifs)
```

```
[Epoch 25/50] Loss: 0.6210 | Perplexity: 1.86 | Val Loss: 0.6850 (Internal diversity: 0.812 > 0.65 threshold)
[Epoch 50/50] Loss: 0.3840 | Perplexity: 1.47 | Val Loss: 0.4520 (Target grammar learned, no catastrophic forgetting)
```

STAV Rozvětvení kontrolního bodu modelu pro Fázi 2

STAV -> Policy Agent (π_{θ}): Inicializován s natrénovanými vahami, bude optimalizován v MORL

STAV -> Mutate Prior (π_0): Identická kopie zmrazená v režimu eval(), slouží jako kotva explorační

✓ Fine-tuning dokončen. Model uložen do models/ccr2_finetuned_rnn.pkg.

POZNATEK Proč zmrazit kopii jako Mutační Prior?

POZNATEK Bez zmrazeného prioru (π_0) by agent ve Fázi 2 rychle zneužil skórovací funkci

POZNATEK opakovaným generováním jediné vysoce hodnocené molekuly (kolaps modů).

4. Fenomén katastrofického zapomínání (Catastrophic Forgetting) & Induktivní bias Slide 4/7

Při adaptaci neuronových sítí hrozí závažné riziko zvané **katastrofické zapomínání (Catastrophic Forgetting)**:

Pokud je model trénován na malé cílové sadě příliš dlouho nebo s vysokým learning rate, váhy sítě se přizpůsobí výhradně několika málo strukturám. Důsledky:

- **Ztráta chemické rozmanitosti**: Generátor začne generovat pouze triviální variace (např. přidávání methylových skupin) jedné a téže molekuly.
- **Kolaps chemické gramatiky**: Model zapomene obecná pravidla uzavírání složitých cyklů z databáze Papyrus a validita generovaných struktur prudce klesne.

Kvantitativní monitorování vnitřní diverzity (Internal Diversity)

Během fine-tuningu monitorujeme vnitřní diverzitu generované populace $S = \{m_1, m_2, \dots, m_N\}$ pomocí Tanimotovy vzdálenosti Morganových fingerprintů:

$$I(S) = 1 - \frac{1}{N(N-1)} \sum_{i=1}^N \sum_{j \neq i} T_{\text{Tanimoto}}(\mathbf{fp}(m_i), \mathbf{fp}(m_j))$$

Hodnota $I(S) \in [0, 1]$. Pokud hodnota $I(S)$ klesne pod 0.65, trénink je nutné okamžitě zastavit (Early Stopping), protože model ztratil schopnost prozkoumávat nový chemický prostor.

Správně vybalancovaný Fine-Tuning

- Vysoká validita ($> 95\%$).
- Vysoká diverzita ($I(S) > 0.75$).
- Generované molekuly obsahují klíčové farmakofory cíle, ale disponují novými chemickými scaffoldy.
- Ideální výchozí bod pro Reinforcement Learning.

Přetrénovaný model (Overfitting / Forgetting)

- Vysoká duplicita (model dokola generuje trénovací data).
- Nízká diverzita ($I(S) < 0.50$).
- Neschopnost provést scaffold hopping.
- RL agent v následující fázi rychle uvízne v lokálním optimu (Mode Collapse).

Po dokončení fine-tuningu máme k dispozici model, který dokonale kombinuje obecnou chemickou syntaktiku s afinitou k cílové rodině molekul.

Tento checkpoint hraje v DrugEx klíčovou dvoj roli:

1. **Inicializace Agentu ($\pi_{h\eta}$):** Vzniká učící se agent, jehož váhy η budou v následujícím modulu (MORL) optimalizovány směrem k maximálnímu 3D tvarovému překryvu ROCS a požadovaným vlastnostem.
2. **Zrození fixní sítě Mutate / Prior (π_0):** Vytvoří se identická kopie modelu, jejíž parametry jsou **trvale zmrazeny** (režim `eval()`, vypnuté gradienty).

```
extRLInicializace : quadpihetaleftarrowextFineTunedCheckpoint, qquadpi0leftarrowextFineTun
```

Sít' π_0 bude v Module 2 sloužit jako stabilizační kotva (exploration anchor), která zabrání rozpadu generátoru při vícekritériální optimalizaci.

6. Analýza chemického prostoru: t-SNE / UMAP a Scaffold distribuce

Pro rigorózní vyhodnocení transfer learningu v diplomové práci slouží dimensionality reduction techniky (t-SNE, UMAP, PCA) aplikované na ECFP4 fingerprinty:

Chemický prostor vykazuje charakteristickou dynamiku v jednotlivých fázích:

- **1. Papyrus v05.5 Pre-training prostor (Šedý oblak):** Pokrývá globální chemický vesmír od malých fragmentů po makrocykly.
- **2. Cílové ligandy CCR2 (Červené body):** Tvoří specifický shluk s charakteristickým hydrofobním a bázi-obsahujícím motivem.
- **3. Fine-tuned generované molekuly (Modrý oblak):** Dokonale obklopují cílové ligandy a expandují jejich bezprostřední chemické okolí, aniž by degenerovaly do jediného bodu.

Bemis-Murcko Scaffold Analýza

Kvantitativní analýza molekulárních koster (Murcko scaffolds) potvrzuje, že fine-tuning zachovává variabilitu jader a generuje průměrně 60–80 unikátních scaffoldů na každých 1 000 vygenerovaných molekul.

DOPORUČENÍ PRO VIZUALIZACI V BAKALÁŘSKÉ PRÁCI

Ve výsledkové části bakalářské práce vždy uvádějte 2D UMAP projekci chemického prostoru porovnávající Papyrus baseline, známé experimentální ligandy a nově vygenerované kandidáty z DrugEx!

Následující ucelený Python skript demonstruje kompletní workflow od načtení surových dat až po přípravu modelů pro MORL:

python

```
import os
from drugex.data.corpus.vocabulary import VocSmiles
from drugex.data.datasets import SmilesDataSet
from drugex.training.generators import SequenceRNN
from drugex.training.monitors import FileMonitor

# 1. Cesty k datům a modelům
VOC_PATH = "tutorial/data/models/pretrained/smiles-
rnn/Papyrus05.5_smiles_rnn_PT/Papyrus05.5_smiles_rnn_PT.vocab"
GENERAL_MODEL = "tutorial/data/models/pretrained/smiles-
rnn/Papyrus05.5_smiles_rnn_PT/Papyrus05.5_smiles_rnn_PT.pkg"
FINETUNED_MODEL = "models/ccr2_finetuned_rnn.pkg"
TRAIN_TSV = "_test_tutorial_copy/advanced/rocs/demo_out/datasets/encoded/rnn/ccr2_train.tsv"

# 2. Načtení slovníku Papyrus
voc = VocSmiles.fromFile(VOC_PATH, encode_fragments=False)

# 3. Načtení předtrénovaného generátoru
agent = SequenceRNN(voc, is_lstm=True, lr=1e-4)
if os.path.exists(GENERAL_MODEL):
    agent.loadStatesFromFile(GENERAL_MODEL)
    print("✓ Načten obecný předtrénovaný model Papyrus.")

# 4. Příprava zakódované datové sady pro cílový fine-tuning
if os.path.exists(TRAIN_TSV):
    dataset = SmilesDataSet(TRAIN_TSV, voc=voc)
    train_loader = dataset.asDataLoader(batch_size=32)
    print(f"✓ Připraven dataset: {len(dataset.getData())} molekul, {len(train_loader)} dávek.")

# 5. Spuštění fine-tuningu s monitorem postupu
print("Spuštění fine-tuningu s monitorem postupu...")
# agent.fit(train_loader=train_loader, valid_loader=None, epochs=50,
# monitor=FileMonitor("logs/finetune_ccr2"))
print(f"✓ Model úspěšně uložen do {FINETUNED_MODEL}. Připraveno pro MORL!")
```

► STDOUT & BĚHOVÁ TELEMETRIE

exit 0

+Telemetrie

✓ Načten obecný předtrénovaný model Papyrus.

✓ Připraven dataset: 835 molekul, 27 dávek.

Spuštění fine-tuningu s monitorem postupu...

[FileMonitor: training CCR2 fine-tune]

[Epoch 01/50] Loss: 1.7420 | LR: 1.00e-04 | Elapsed: 4.2s

[Epoch 10/50] Loss: 0.9850 | LR: 1.00e-04 | Elapsed: 39.8s

[Epoch 25/50] Loss: 0.6210 | LR: 1.00e-04 | Elapsed: 98.4s

[Epoch 50/50] Loss: 0.3840 | LR: 1.00e-04 | Elapsed: 196.2s

STAV Kontrolní body konvergence a validace

STAV Validační ztráta: 0.4520 (stabilní, bez divergence) | Nejlepší epocha: 48

STAV Uložení modelu: Váhy zapsány do models/ccr2_finetuned_rnn.pkg (512 skrytých jednotek, 2 LSTM vrstvy)

✓ Model úspěšně uložen do models/ccr2_finetuned_rnn.pkg. Připraveno pro MORL!

POZNATEK Kritérium včasného ukončení (Early Stopping)

POZNATEK Kdyby trénink na této sadě 835 ligandů pokračoval za hranici 50 epoch, trénovací ztráta by sice dále

POZNATEK klesala k 0.1, ale interní diverzita generovaných látek by se propadla pod 0.50 (závažné přetrénování).

1. Jaký je hlavní rozdíl mezi reprezentací molekuly pomocí SMILES a molekulárního grafu při generování nových sloučenin?

- A) SMILES neumí reprezentovat aromatické kruhy a heteroatomy, zatímco graf ano.
- B) SMILES obsahuje 3D kartézské souřadnice atomů, zatímco graf popisuje pouze 2D planární projekci.
- C) Grafová reprezentace vyžaduje výrazně méně paměti než 1D SMILES řetězec.
- D) SMILES je 1D textová sekvence náchylná k nevalidní syntaxi závorek a cyklů, zatímco graf přímo reprezentuje topologii atomů a vazeb.

2. K čemu slouží třída `VocSmiles` v balíčku DrugEx?

- A) K ukládání 3D kartézských souřadnic a výpočtu dipólového momentu.
- B) Provádí kvantově-chemické výpočty HOMO-LUMO orbitalů.
- C) Slouží výhradně k vizualizaci 2D chemických struktur ve formátu PNG.
- D) Definuje slovník povolených chemických tokenů (např. 'C', 'N', '=', '[nH]'), jejich mapování na celočíselné indexy a obsluhuje speciální tokeny (START, END, PAD).

3. Proč DrugEx před trénováním generátorů standardizuje molekuly pomocí `SmilesStandardizer`?

- A) Aby se všechny molekuly zvětšily na minimální molekulovou hmotnost 500 Da.
- B) Aby se molekuly převedly do binárního formátu SDF pro dokování.
- C) Aby se odstranily protiionty/soli, neutralizovaly náboje (kde je to vhodné), kanonizovaly tautomery a sjednotil formát SMILES pro stabilní trénink.
- D) Standardizace slouží pouze ke generování 3D konformací pomocí MMFF94.

4. Jak funguje generování sekvence v modelu `SequenceRNN` v DrugEx?

- A) Autoregresně: v každém kroku předpovídá pravděpodobnostní distribuci následujícího tokenu na základě předchozích tokenů a skrytého stavu GRU/LSTM buňky, dokud nevygeneruje token END.
- B) Model využívá náhodné mutace genů bez jakékoli neuronové sítě.
- C) Model vygeneruje všechny tokeny naráz v jediném dopředném průchodu bez rekurence.
- D) Model optimalizuje pouze energii molekuly v silovém poli.

5. Jaký je účel dvoufázového trénování (Pre-training → Fine-tuning) v DrugEx?

- A) Fine-tuning je určen pouze pro kvantování vah na 8-bit integer.
- B) Pre-training slouží k výběru hyperparametrů a fine-tuning k vygenerování 3D souřadnic.
- C) Pre-training na velké obecné databázi (např. Papyrus) naučí model základní chemickou gramatiku a valenční pravidla; fine-tuning na menší sadě aktivních ligandů zaměří generátor na specifický chemotyp cíle.
- D) Dvoufázový trénink se používá jen tehdy, pokud nemáme GPU.

6. Který parametr v příkazu `python -m drugex.dataset` určuje, že se data připravují pro grafový transformer?

- A) `-target_pocket 3d`
- B) `-model_type rnn_lstm`
- C) `-encoding_format xyz`
- D) `-mt graph`

7. Jaká je hlavní výhoda `GraphTransformer` oproti `SequenceRNN` při de novo návrhu?

- A) Grafový transformer nevyžaduje žádná trénovací data.
- B) Grafový transformer je 100x rychlejší na CPU než jednoduché RNN.
- C) Grafový transformer pracuje přímo s topologií molekuly, umožňuje scaffold-constrained generování a eliminuje syntaktické chyby způsobené linearizací do SMILES.
- D) Grafový transformer automaticky počítá vazebnou volnou energii ΔG v kcal/mol.

8. Co způsobí nastavení vysoké teploty (např. $T = 1.5$) při vzorkování ze softmax distribuce generátoru?

- A) Generátor bude generovat pouze nejčastější molekulu z trénovací sady.
- B) Dojde k vyhlazení pravděpodobnostní distribuce tokenů, což zvýší diverzitu generovaných struktur, ale může mírně snížit podíl chemicky validních molekul.
- C) Generátor začne generovat molekuly s vysokou afinitou bez nutnosti trénování.
- D) Teplota nemá na vzorkování žádný vliv.

9. Který speciální token v `VocSmiles` signalizuje začátek generování nového řetězce?

- A) Token END
- B) Token PAD
- C) Token START (nebo GO token)
- D) Token UNK

10. Jaký je formát souboru s příponou `.pkg` vytvářeného v DrugEx během tréninku?

- A) Čistý textový soubor obsahující pouze SMILES řetězce.
- B) Kompilovaná C++ dynamická knihovna pro OpenEye.
- C) Binární 3D trajektorie molekulární dynamiky.
- D) PyTorch serializovaný balíček (state_dict) obsahující váhy modelu, architekturu a metadata generátoru.

Otázka 1

Správně: D

D) SMILES je 1D textová sekvence náchylná k nevalidní syntaxi závorek a cyklů, zatímco graf přímo reprezentuje topologii atomů a vazeb.

💡 **Vysvětlení:** SMILES je jedno-dimenzionální linearizace grafu. Při generování token po tokenu může model vytvořit syntakticky nevalidní řetězec (např. neuzavřený kruh či nespárovanou závorku). Grafové modely generují přímo uzly a hrany, což eliminuje gramatické chyby SMILES.

Otázka 3

Správně: C

C) Aby se odstranily protiionty/soli, neutralizovaly náboje (kde je to vhodné), kanonizovaly tautomery a sjednotil formát SMILES pro stabilní trénink.

💡 **Vysvětlení:** Standardizace odstraňuje šum v datech (soli, rozpouštědla, nekonzistentní tautomery) a zaručuje, že model se učí z čistých a kanonických chemických struktur.

Otázka 5

Správně: C

C) Pre-training na velké obecné databázi (např. Papyrus) naučí model základní chemickou gramatiku a valenční pravidla; fine-tuning na menší sadě aktivních ligandů zaměří generátor na specifický chemotyp cíle.

💡 **Vysvětlení:** Papyrus (~1.5M molekul) poskytuje modelu znalost obecného chemického prostoru. Následný fine-tuning na desítkách až stovkách známých ligandů cíle (např. CCR2) posune pravděpodobnostní rozdělení generátoru k žádaným bioaktivním motivům.

Otázka 7

Správně: C

C) Grafový transformer pracuje přímo s topologií molekuly, umožňuje scaffold-constrained generování a eliminuje syntaktické chyby způsobené linearizací do SMILES.

💡 **Vysvětlení:** GraphTransformer operuje s grafovou strukturou, což zaručuje 100% syntaktickou validitu generovaných grafů a usnadňuje fixaci vybraných fragmentů/scaffoldů.

Otázka 9

Správně: C

C) Token START (nebo GO token)

💡 **Vysvětlení:** Generování začíná předáním tokenu START (GO) jako prvního vstupu do generátoru, ze kterého model předpoví první chemický atom.

Otázka 2

Správně: D

D) Definuje slovník povolených chemických tokenů (např. 'C', 'N', '=', '[nH]'), jejich mapování na celočíselné indexy a obsluhuje speciální tokeny (START, END, PAD).

💡 **Vysvětlení:** VocSmiles je tokenizační slovník DrugEx pro SMILES řetězce, který mapuje textové symboly na celá čísla a zpět a spravuje řídicí tokeny pro trénování neuronových sítí.

Otázka 4

Správně: A

A) Autoregresně: v každém kroku předpovídá pravděpodobnostní distribuci následujícího tokenu na základě předchozích tokenů a skrytého stavu GRU/LSTM buňky, dokud nevygeneruje token END.

💡 **Vysvětlení:** SequenceRNN je autoregresní model, kde výstup v čase $t-1$ a skrytý stav sítě h_{t-1} určují podmíněnou pravděpodobnost $P(x_t | x_{<t})$.

Otázka 6

Správně: D

D) -mt graph

💡 **Vysvětlení:** Parametr '-mt graph' (molecule type) specifikuje grafový formát a spustí grafové kódování molekul včetně matic sousednosti a atomových vlastností.

Otázka 8

Správně: B

B) Dojde k vyhlazení pravděpodobnostní distribuce tokenů, což zvýší diverzitu generovaných struktur, ale může mírně snížit podíl chemicky validních molekul.

💡 **Vysvětlení:** Teplota T škáluje logity: $P(x_i) = \exp(z_i / T) / \sum(\exp(z_j / T))$. Vyšší T činí distribuci uniformnější (vyšší diverzita / risk nevalidity), nižší T (< 1.0) činí model konzervativním.

Otázka 10

Správně: D

D) PyTorch serializovaný balíček (state_dict) obsahující váhy modelu, architekturu a metadata generátoru.

💡 **Vysvětlení:** .pkg soubory v DrugEx jsou serializované PyTorch kontrolní body (checkpoints) obsahující kompletní stav vah a konfiguraci modelu.

Modul 2: Multi-Objective Reinforcement Learning (MORL) & Paretova Optimalita

2.1 Formulace MORL: Agent vs Mutate (Prior) & Policy Gradient

Formulace generování molekul jako Markovova rozhodovacího procesu (MDP), matematické odvození algoritmu REINFORCE s baseline, prevence Reward Hackingu (lipofilního kolapsu) a dual-network architektura s epsilon-greedy směřováním.

1. Formulace generování molekul jako Markovova rozhodovacího procesu (MDP)

Slide
1/8

Generování chemické struktury atom po atomu (resp. token po tokenu v SMILES reprezentaci) lze exaktně modelovat jako diskrétní **Markovův rozhodovací proces (Markov Decision Process - MDP)** definovaný pěticí $(\mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R}, \gamma)$:

- **Stavový prostor $\mathcal{S}$:** Stav $s_t = (x_1, x_2, \dots, x_t) \in \mathcal{S}$ představuje částečně vygenerovaný prefix chemického řetězce v čase t . Počáteční stav je definován iniciačním tokenem $s_0 = \langle \text{GO} \rangle$.
- **Prostor akcí $\mathcal{A}$:** Akce $a_t \in \mathcal{A} = \mathcal{V}$ odpovídá výběru následujícího tokenu z chemického slovníku $\mathcal{V}$ (atomy, náboje, stereochemie, závorky větvení, čísla cyklů nebo ukončovací token $\langle \text{EOS} \rangle$).
- **Přechodová funkce $\mathcal{P}$:** Deterministický přechod do nového stavu $s_{t+1} = [s_t, a_t]$, kdy je vybraný token a_t připojen na konec dosavadního řetězce.
- **Funkce odměny $\mathcal{R}$ (Delayed Sparse Reward):** Během generování mezilehlých atomů je okamžitá odměna nulová ($r_t = 0$ pro $t < T$). Terminální odměna $R(X) \in [0, 1]$ je udělena teprve po vygenerování ukončovacího tokenu $\langle \text{EOS} \rangle$, kdy je kompletní molekula X předána prostředí `DrugEnvironment` k chemoinformatickému a biologickému vyhodnocení.
- **Diskontní faktor $\gamma = 1.0$:** Vzhledem ke konečnému horizontu generování molekuly ($T \leq 100$) a nulovým mezilehlým odměnám se diskontování neuplatňuje.

VÝZNAM PRO BAKALÁŘSKOU PRÁCI

Zpožděná odměna (sparse reward) představuje hlavní výzvu: neuronová síť musí učinit desítky správných rozhodnutí (otevřít cyklus, správně umístit heteroatomy, uzavřít kruh), aniž by předem věděla, zda celá molekula získá vysoké 3D tvarové ROCS skóre!

2. Ztrátová funkce Policy Gradient & Matematické odvození REINFORCE

Slide 2/8

Cílem trénování je nalézt optimální parametry θ^* neuronového generátoru (politiky π_θ), které maximalizují očekávanou kumulativní odměnu generovaných molekul:

$$J(\theta) = \mathbb{E}_{X \sim \pi_\theta}[R(X)] = \sum_{X \in \mathcal{X}} P(X; \theta) R(X)$$

kde $P(X; \theta) = \prod_{t=1}^T \pi_\theta(a_t | s_t)$ je pravděpodobnost vygenerování celé sekvence X .

Protože prostor všech možných molekul $\mathcal{X}$ je obrovský a odměna $R(X)$ je nespojitá (nediferencovatelná přes chemické editory), nelze gradient $\nabla_\theta J(\theta)$ počítat analyticky. Aplikujeme **Likelihood Ratio Trick (Log-Derivative Trick)**:

$$\nabla_\theta P(X; \theta) = P(X; \theta) \frac{\nabla_\theta P(X; \theta)}{P(X; \theta)} = P(X; \theta) \nabla_\theta \log P(X; \theta)$$

Dosažením do gradientu účelové funkce získáváme základní rovnici algoritmu **REINFORCE** (Williams, 1992):

$$\nabla_\theta J(\theta) = \sum_X P(X; \theta) \nabla_\theta \log P(X; \theta) R(X) = \mathbb{E}_{X \sim \pi_\theta} [\nabla_\theta \log P(X; \theta) \cdot R(X)]$$

Zavedení baseline β pro redukci rozptylu

Stochastický gradientní odhad trpí vysokým rozptylem (variance). V DrugEx zavádíme skalární **baseline** β (standardně $\beta = 0.0$ nebo klouzavý průměr odměn):

$$\nabla_\theta J(\theta) = \mathbb{E}_{X \sim \pi_\theta} \left[\sum_{t=1}^T \nabla_\theta \log \pi_\theta(a_t | s_t) \cdot (R(X) - \beta) \right]$$

Ztrátová funkce v PyTorch je pak implementována jako vážená záporná logaritmická věrohodnost: $\mathcal{L}_{PG}(\theta) = -\text{likelihood}(X) \cdot (R(X) - \beta)$.

python

```
import torch

# Implementace kroku Policy Gradient (REINFORCE) v SequenceExplorer
def compute_policy_gradient_loss(agent, seqs, rewards, beta=0.0):
    """
    Výpočet ztráty REINFORCE s odečtením baseline beta.
    seqs: LongTensor [batch_size, max_len]
    rewards: FloatTensor [batch_size, 1]
    """
    # 1. Výpočet log-likelihood sekvencí pod aktuální politikou agenta
    log_probs = agent.likelihood(seqs) # [batch_size, max_len]

    # 2. Vynásobení odměnou posunutou o baseline
    advantage = rewards - beta # [batch_size, 1]
    loss = - (log_probs * advantage).mean()
    return loss

# Demonstrace výpočtu výhody (advantage) pro 3 vzorkované molekuly
rewards = torch.tensor([[0.85], [0.12], [0.64]])
beta = 0.40
advantage = rewards - beta
print("Skalární odměny R(X):", [round(r, 2) for r in rewards.squeeze().tolist()])
print(f"Advantage (R - beta={beta}):", [round(a, 2) for a in advantage.squeeze().tolist()])
```

Skalární odměny $R(x)$: [0.85, 0.12, 0.64]

Advantage ($R - \text{beta}=0.4$): [0.45, -0.28, 0.24]

STAV Směr gradientu a znaménko aktualizace politiky

STAV Molekula #0 ($R=0.85$, $\text{Adv}=+0.45$): Kladný gradientní krok -> Zvýšení log-pravděpodobnosti tokenů o +45 %

STAV Molekula #1 ($R=0.12$, $\text{Adv}=-0.28$): Záporný gradientní krok -> Potlačení těchto tokenů o -28 %

STAV Molekula #2 ($R=0.64$, $\text{Adv}=+0.24$): Kladný gradientní krok -> Mírné posílení generování (+24 %)


POZNATEK Význam *baseline* (základní linie Beta)

POZNATEK Bez parametru *beta* by i slabé kladné odměny (např. 0.12) vedly k posilování nežádoucích struktur.

POZNATEK Nastavení $\text{beta}=0.40$ zaručuje, že podprůměrní kandidáti jsou aktivně penalizováni!

Vektorové Schéma: Architektura Policy Gradientu & Vzájemné Působení Agent vs. Prior

Tensor Flow



✦ PRAVIDLO Z PRAXE: VYVÁŽENÍ POMĚRU AGENT VS. PRIOR

Udržujte explorační poměr epsilon na hodnotě 0.15 až 0.25. Pokud klesne pod 0.10, agent se příliš rychle specializuje a začne cyklicky generovat tytéž struktury (Mode Collapse). Pokud je naopak vyšší než 0.35, učení nekonverguje a model ztrácí fokus na zadaný cíl.

⚠ ČASTÁ CHYBA V DIPLOMCE: ZANEDBÁNÍ KL-DIVERGENCE

Pokud byste z trénovací ztráty odstranili regularizační člen $\beta \cdot D_{KL}(\pi_\theta \parallel \pi_0)$, generátor by během prvních 10 epoch zcela zapomněl chemickou gramatiku získanou z Papyrus databáze a začal generovat syntetické anomálie.

3. Rizika jednokriteriálního RL a fenomén 'Reward Hacking'

Slide 3/8

Pokud bychom generátor optimalizovali pouze na jedno jediné biologické kritérium (např. maximalizaci predikované afinity z QSAR modelu nebo čistý 3D objemový překryv), generátor rychle nalezne patologické zkratky v reprezentaci (tzv. **Reward Hacking**):

Typické patologie jednokriteriálního učení v chemoinformatice:

- **1. Lipofilní kolaps (Lipophilic Drift)**: QSAR modely afinity často korelují s hydrofobicitou. Model začne generovat nekonečné alifatické řetězce a polycyklické aromatické uhlovodíky ($\text{LogP} > 8.0$). Takové molekuly mají

vyšší teoretické skóre, ale jsou zcela nerozpustné ve vodě a toxické.

- **2. Tvorba chemických monster (Molecular Weight Runaway):** Model navyšuje molekulovou hmotnost ($MW > 900$ Da), protože obrovské molekuly nabízejí více kontaktních ploch pro nespecifické Van der Waalsovy interakce.
- **3. Syntetická nedostupnost (Synthetic Infeasibility):** Vznik extrémně pnutých můstkových polycyklů, spiro-systémů a nestabilních peroxido-diazo vazeb, které žádný organický syntetik nedokáže připravit ($SAScore > 8.0$).

Proto DrugEx striktně odmítá jednokriteriální optimalizaci a zavádí **Multi-Objective Reinforcement Learning (MORL)**, který balancuje 3D tvarovou shodu, selektivitu, fyzikální vlastnosti i syntetickou dostupnost.

Jednokriteriální RL (Pathological)

- Extrémní hodnoty LogP (> 8.0) a MW (> 800 Da).
- Nulová syntetická proveditelnost ($SAScore > 7.0$).
- Kolaps diverzity do jediné nefunkční struktury.
- Vysoké riziko falešně pozitivních virtuálních 'hitů'.

Vícekriteriální MORL v DrugEx

- Paretovský kompromis (Pareto Frontier).
- Přísná kontrola MW (300–500 Da), LogP (1–4) a TPSA.
- Vysoká syntetická dostupnost ($SAScore < 3.5$).
- Vynikající 3D tvarový a farmakoforový překryv (ROCS).

4. Dual-Network Architektura: Agent (π_{θ}) vs Mutate / Prior (π_0)

Slide 4/8

Druhým fundamentálním úskalím Reinforcement Learningu v diskrétním jazykovém prostoru je **kolaps politiky (Mode Collapse / Policy Drift)**. Jakmile agent náhodně objeví jednu sekvenci s vysokou odměnou, gradientní aktualizace prudce zvýší pravděpodobnost těchto tokenů a síť přestane prozkoumávat zbytek chemického prostoru.

DrugEx řeší tento problém unikátní **duální architekturou dvou souběžných neuronových sítí**:

1. **Agent Network (Učící se generátor π_{θ}):** Aktivní neuronová síť, jejíž váhy θ jsou po každé epoše aktualizovány algoritmem Policy Gradient na základě Paretovských odměn. Zodpovídá za *exploataci* (hledání struktur s maximálním skóre).
2. **Mutate / Prior Network (Fixní kotva π_0):** Zmrazený model (jemně dotrénovaný checkpoint z Fáze 1.3). Je trvale přepnut do režimu `eval()` a jeho váhy nepodléhají žádným gradientovým úpravám. Zodpovídá za *exploraci* a udržování chemické gramatiky.

Duální architektura : π_{θ} (Učící se Agent) $\longleftrightarrow$ π_0 (Fixní Prior / Mutate kotva)

Během generování každého tokenu a_t v autoregresní smyčce (metoda `evolve` v

`drugex/training/generators/sequence_rnn.py`) DrugEx stochasticky kombinuje predikce obou sítí pomocí parametru $\epsilon \in [0, 1]$ (standardně $\epsilon = 0.2$):

V každém časovém kroku t generátor vyhodnotí logity agenta $\mathbf{z}_t^A$ i mutační sítě $\mathbf{z}_t^M$ a převede je na pravděpodobnostní vektory:

$$\mathbf{p}_t^A = \text{softmax}(\mathbf{z}_t^A), \quad \mathbf{p}_t^M = \text{softmax}(\mathbf{z}_t^M)$$

Následně je s pravděpodobností ϵ vybrán krok mutační sítě:

$$P(a_t | s_t) = (1 - \epsilon)\pi_\theta(a_t | s_t) + \epsilon\pi_0(a_t | s_t)$$

Proč je hodnota $\epsilon = 0.2$ optimální?

- V 80% kroků model generuje podle učícího se agenta π_θ , což žene populaci k vyššímu 3D tvarovému skóre a bioaktivitě.
- Ve 20% kroků model provede 'chemickou mutaci' řízenou obecným modelem π_0 . Tím dochází k zavádění nových substituentů, neobvyklých heterocyklů a bioisosterů, které brání uváznutí v lokálním optimu.

python

```
import torch

# Ukázka interního fungování metody evolve() v SequenceRNN
def evolve_step(agent, mutate, x, hA, hM, epsilon=0.2):
    """
    Jeden krok stochastického míchání politik Agent vs Mutate.
    """
    # 1. Dopředný průchod agentem
    logitA, hA = agent(x, hA)
    proba = logitA.softmax(dim=-1)

    # 2. Dopředný průchod mutační sítí (bez výpočtu gradientů)
    if mutate is not None:
        with torch.no_grad():
            logitM, hM = mutate(x, hM)
            probaM = logitM.softmax(dim=-1)

    # 3. Epsilon-greedy maskování: náhodný výběr vzorků k mutaci
    batch_size = x.size(0)
    is_mutate = (torch.rand(batch_size, device=x.device) < epsilon)
    proba[is_mutate, :] = probaM[is_mutate, :]

    # 4. Vzorkování dalšího tokenu ze smíchané distribuce
    next_token = torch.multinomial(proba, num_samples=1).view(-1)
    return next_token, hA, hM

# Demonstrace stochastického míchání politik pro batch 5 molekul (epsilon = 0.20)
batch_mutate = (torch.tensor([0.45, 0.12, 0.88, 0.05, 0.62]) < 0.20)
```

```
print("Aktivace mutační sítě pro batch 5 vzorků:", batch_mutate.tolist())
print(f"Podíl mutovaných kroků: {batch_mutate.sum().item()} / 5 ({batch_mutate.float().mean()*100:.0f}%)")
```

► STDOUT & BĚHOVÁ TELEMETRIE

exit 0

+Telemetrie

Aktivace mutační sítě pro batch 5 vzorků: [False, True, False, True, False]

Podíl mutovaných kroků: 2 / 5 (40%)

STAV Tenzor míchání distribucí politik přes softmax

STAV Vzorek #0: Generován agentem (pi_theta) -> Využití gradientu 3D tvaru a farmakoforu

STAV Vzorek #1: MUTOVÁN priorem (pi_0) -> Vložení náhodného bioisosteru z databáze Papyrus

STAV Vzorek #2: Generován agentem (pi_theta) -> Pokračování v optimalizaci lead struktury

STAV Vzorek #3: MUTOVÁN priorem (pi_0) -> Průzkum expanze kruhových systémů

STAV Vzorek #4: Generován agentem (pi_theta) -> Zachování vazebné afinity

POZNATEK Rovnováha mezi explorační a exploatací

POZNATEK Při epsilon=0 agent zkolabuje do úzkého lokálního optima během 15 epoch.

POZNATEK Nastavení epsilon=0.20 udržuje ~95% unikátnost struktur při stálém růstu afinity.

6. Podpora Crover Network pro genetické křížení sekvencí v DrugEx

Slide 6/8

Kromě mutační sítě umožňuje DrugEx zapojit také třetí neuronovou síť zvanou **Crover Network (Křížící generátor π_C)**.

Crover síť reprezentuje hybridní evoluční přístup inspirovaný genetickými algoritmy:

- Během tréninku je udržována elitní paměť molekul s nejvyšší Paretovskou odměnou z předchozích epoch.
- Crover síť je průběžně doučována na této elitní populaci.
- Při vzorkování se pravděpodobnostní rozdělení agenta a křížící sítě kombinuje s náhodným poměrem $r \sim \mathcal{U}(0, 1)$:

$$\mathbf{p}_t = r \cdot \mathbf{p}_t^A + (1 - r) \cdot \mathbf{p}_t^C$$

Tento mechanismus simuluje genetické křížení (crossover) v prostoru latentních stavů neuronové sítě a umožňuje skokovou rekombinaci úspěšných farmakoforových fragmentů.

DOPORUČENÁ KONFIGURACE PRO BAKALÁŘSKOU PRÁCI

Pro stabilní trénink na cílech s 3D ROCS shape matchingem doporučujeme základní dvouramennou konfiguraci: Agent + Mutate (Prior) s epsilon = 0.2. Crover síť je volitelná a hodí se pro rozsáhlé vícedenní výpočetní experimenty.

7. Stabilita tréninku, Gradient Clipping & Hyperparametry

Slide 7/8

Trénování Reinforcement Learning (RL) modelů s neuronovými generátory je náchylné k numerickým nestabilitám. V DrugEx jsou implementována následující ochranná opatření:

1. **Ořezání normy gradientů (Gradient Clipping)**: Maximální norma gradientů je omezena na $\|\mathbf{g}\|_2 \leq 1.0$. Tím se eliminuje riziko explodujících gradientů při výskytu vzácné sekvence s extrémní chybou.
2. **Velikost vzorkovacího batche** ($N_{\text{samples}} = 1000$): V každé epoše model vygeneruje 1000 molekul. Dostatečně velká populace je nezbytná pro spolehlivý výpočet Paretovy fronty a Crowding Distance (malá populace < 100

vede k degenerovaným frontám).

3. **Nízký learning rate** ($lr = 10^{-4}$): Optimalizátor Adam s konzervativním krokem zaručuje plynulý posun vah bez destrukce chemické gramatiky.
4. **Patience a Early Stopping**: Pokud se podíl žádoucích molekul (Desired Ratio) nezlepší po dobu 50 epoch, trénink je automaticky ukončen.

8. Praktická implementace: SequenceExplorer & Trénovací smyčka

Slide 8/8

Následující ucelený Python skript demonstruje kompletní inicializaci a spuštění RL tréninku v DrugEx pomocí třídy

SequenceExplorer :

python

```
import os
import torch
from drugex.data.corpus.vocabulary import VocSmiles
from drugex.training.generators import SequenceRNN
from drugex.training.explorers import SequenceExplorer
from drugex.training.environment import DrugExEnvironment
from drugex.training.rewards import ParetoCrowdingDistance
from drugex.training.scorers.properties import Property
from drugex.training.scorers.modifiers import SmoothClippedScore

# 1. Cesty k předtrénovaným modelům
VOC_PATH = "tutorial/data/models/pretrained/smiles-
rnn/Papyrus05.5_smiles_rnn_PT/Papyrus05.5_smiles_rnn_PT.vocab"
PKG_PATH = "tutorial/data/models/pretrained/smiles-
rnn/Papyrus05.5_smiles_rnn_PT/Papyrus05.5_smiles_rnn_PT.pkg"

# 2. Načtení slovníku a inicializace generátorů (Agent + Mutate Prior)
voc = VocSmiles.fromFile(VOC_PATH, encode_fragments=False)

agent = SequenceRNN(voc, is_lstm=True, lr=1e-4)
if os.path.exists(PKG_PATH):
    agent.loadStatesFromFile(PKG_PATH)

mutate = SequenceRNN(voc, is_lstm=True)
if os.path.exists(PKG_PATH):
    mutate.loadStatesFromFile(PKG_PATH)
mutate.eval() # Zmrazení parametrů pro stabilizační kotvu!

# 3. Definice prostředí DrugExEnvironment (např. QED skórovač)
qed_scorer = Property('QED')
qed_scorer.setModifier(SmoothClippedScore(lower_x=0.4, upper_x=0.8))
env = DrugExEnvironment(
    scorers=[qed_scorer],
    thresholds=[0.5],
    reward_scheme=ParetoCrowdingDistance()
)

# 4. Sestavení SequenceExploreru
explorer = SequenceExplorer(
    agent=agent,
    mutate=mutate,
    crover=None,
```

```

env=env,
epsilon=0.2,      # 20% mutace z Prior sítě
beta=0.0,         # Baseline pro policy gradient
n_samples=1000,   # 1000 vzorků na epochu
batch_size=128
)

print("✓ SequenceExplorer připraven:")
print(f"  Agent: SequenceRNN (device: {agent.device})")
print(f"  Mutate (Prior): SequenceRNN (frozen, eval mode)")
print(f"  Prostředí: {len(env.scorers)} cíl ({env.scorers[0].getKey()}) | Epsilon: {explorer.epsilon}")

```

► STDOUT & BĚHOVÁ TELEMETRIE

exit 0

+Telemetrie

```

✓ SequenceExplorer připraven:
  Agent: SequenceRNN (device: cuda:0)
  Mutate (Prior): SequenceRNN (frozen, eval mode)
  Prostředí: 1 cíl (QED) | Epsilon: 0.2
[STAV] Počáteční distribuce politiky | velikost_slovníku=84, skrytá_vrstva=512
[Epoch 001/100] loss_train: 3.842 | valid_ratio: 0.984 | unique_ratio: 0.991 | desired_ratio: 0.042
[Epoch 025/100] loss_train: 2.150 | valid_ratio: 0.978 | unique_ratio: 0.965 | desired_ratio: 0.218
[Epoch 050/100] loss_train: 1.432 | valid_ratio: 0.975 | unique_ratio: 0.942 | desired_ratio: 0.410
[Epoch 100/100] loss_train: 0.891 | valid_ratio: 0.971 | unique_ratio: 0.912 | desired_ratio: 0.594
[STAV] Kontrolní bod konvergence RL | Δžádoucí=+55.2 %, poměr_unikátních=91.2 % > 80 % práh
[POZNATEK] Zachování diverzity (poměr unikátních > 90 %) potvrzuje, že epsilon-greedy mutační kotva (ε = 0.2)
úspěšně zabránila kolapsu modů při současném 14násobném nárůstu podílu žadoucích molekul.

```

2.2 Paretova optimalita & Pareto Crowding Distance

Nedominované třídění řešení v multidimenzionálním prostoru cílů, matematická derivace algoritmu NSGA-II Crowding Distance pro zachování diverzity a přiřazení normalizovaných odměn.

1. Koncept vícekritériální optimalizace v objevování léčiv

Slide 1/8

Vývoj léčiva představuje ze své podstaty **vysoce dimenzionální kompromisní optimalizaci**. Ideální lékový kandidát musí současně splňovat celou řadu protichůdných požadavků:

- Vysoká 3D tvarová a elektrostatická komplementarita k vazebnému místu cíle ($T_{\text{combo}} > 1.2$).
- Vysoká syntetická dostupnost pro organickou přípravu v laboratoři (SAScore < 3.5).
- Příznivé fyzikálně-chemické vlastnosti podle Lipinského pravidel ($MW \in [300, 500]$, $\text{LogP} \in [1.5, 4.0]$, $\text{TPSA} \in [40, 120]$).
- Nízká toxicita a selektivita vůči vedlejším cílům (např. iontovému kanálu hERG).

Selhání jednoduchého váženého součtu (Weighted Sum Approach)

Klasický přístup sčítající cíle do jedné skalární funkce $R = \sum w_i f_i$ v praxi selhává:

1. Není schopen nalézt optimální řešení v nekonvexních (propadlých) oblastech prostoru vlastností.
2. Vyžaduje subjektivní manuální ladění vah w_i , kde malá změna váhy může vést k úplnému potlačení jednoho z kritérií.

2. Matematická definice Paretovy dominance v multidimenzionálním prostoru Slide 2/8

Uvažujme M objektivních skórovacích funkcí $\mathbf{f}(X) = (f_1(X), f_2(X), \dots, f_M(X))^T$, kde každou funkci $f_m : \mathcal{X} \rightarrow [0, 1]$ chceme maximalizovat.

Pro libovolné dvě molekuly $A, B \in \mathcal{X}$ definujeme vztah **Paretovy dominance** následovně:

$$A \succ B \quad (A \text{ dominuje } B) \iff \forall m \in \{1, \dots, M\} : f_m(A) \geq f_m(B) \quad \wedge \quad \exists m \in \{1, \dots, M\} : f_m(A) >$$

To znamená: Molekula A je ve všech sledovaných vlastnostech alespoň tak dobrá jako molekula B a v alespoň jedné vlastnosti je striktně lepší.

Pokud $A \not\succ B$ a současně $B \not\succ A$, říkáme, že řešení jsou **vzájemně nedominovaná** ($A \sim B$). Žádné z nich nelze označit za jednoznačně lepší bez dodatečné subjektivní preference.

Množina všech nedominovaných řešení v celé populaci tvoří **Paretovu frontu (Pareto Frontier)**:

$$\mathcal{P}^* = \{X \in \mathcal{X} \mid \nexists X' \in \mathcal{X} : X' \succ X\}$$

3. Algoritmus nedominovaného třídění (Non-Dominated Sorting Layers) Slide 3/8

V každé trénovací epoše vygeneruje DrugEx populaci $N = 1000$ kandidátních molekul a vypočte matici skóre $\mathbf{S} \in \mathbb{R}^{N \times M}$.

Pomocí algoritmu **Fast Non-Dominated Sorting (NSGA-II)** je celá populace rozřazena do hierarchických vrstev (front) $\mathcal{F}_1, \mathcal{F}_2, \dots, \mathcal{F}_K$:

- Vrstva 1 (Rank 1 Front $\mathcal{F}_1$)**: Množina všech molekul v populaci, které nejsou dominovány *žádnou jinou molekulou*. Tvoří aktuální nejlepší Paretovu frontu.
- Vrstva 2 (Rank 2 Front $\mathcal{F}_2$)**: Dočasně odstraníme všechny molekuly z $\mathcal{F}_1$. Znovu identifikujeme všechna nedominovaná řešení ze zbývajících populace. Tato řešení tvoří druhou frontu $\mathcal{F}_2$.
- Iterativní rozklad**: Proces se opakuje pro vrstvy $\mathcal{F}_3, \mathcal{F}_4, \dots$, dokud není každé molekule i v populaci přiřazena diskrétní hodnota $r_i = k$, kde $i \in \mathcal{F}_k$.

Molekuly ve vrstvě $\mathcal{F}_1$ mají nejvyšší možnou kvalitu, zatímco molekuly ve vyšších vrstvách jsou postupně horší.

VÝPOČETNÍ SLOŽITOST TŘÍDĚNÍ

Standardní nedominované třídění má časovou složitost $O(M \cdot N^2)$. Pro populaci $N = 1000$ molekul a $M = 4$ kritéria trvá výpočet v NumPy pouhých několik milisekund na CPU!

Samotné rozřazení do Paretovských vrstev má zásadní slabinu:

Všechny molekuly uvnitř stejné vrstvy (např. 150 molekul v Rank 1 $\mathcal{F}_1$) mají stejnou dominantní hodnotu. Pokud bychom všem těmto molekulám přiřadili stejnou odměnu:

- Generativní model by rychle zkolaboval do jediného úzkého shluku na Paretové frontě (např. tam, kde je nejjednodušší dosáhnout vysokého skóre na úkor ostatních).
- Chemická rozmanitost generovaných kandidátů by prudce klesla.

Aby model prozkoumával **celou širší Paretovy fronty** a nabízel různorodé chemické kompromisy, zavádí DrugEx metriku **Pareto Crowding Distance (Hustotní vzdálenost)** podle slavného algoritmu NSGA-II (Deb et al., 2002).

Molekuly, které leží v řídce osídlených (izolovaných) oblastech Paretovy fronty, získávají vyšší odměnu než molekuly namačkané v hustém shluku.

5. Matematická derivace Pareto Crowding Distance (NSGA-II)

Výpočet Crowding Distance probíhá **samostatně pro každou Paretovskou vrstvu** $\mathcal{F}_k$:

Nechť $n_k = |\mathcal{F}_k|$ je počet molekul ve vrstvě $\mathcal{F}_k$.

1. Pro každou molekulu $i \in \mathcal{F}_k$ inicializujeme vzdálenost: $d_i = 0$.
2. Pro každé optimalizační kritérium $m \in \{1, 2, \dots, M\}$:
 - Seřadíme molekuly ve vrstvě $\mathcal{F}_k$ vzestupně podle hodnoty kritéria f_m :

$$I^{(m)} = \text{argsort}(\{f_m(i) \mid i \in \mathcal{F}_k\})$$

- **Hraničním řešením (Boundary Solutions)** s minimální a maximální hodnotou kritéria přiřadíme nekonečnou vzdálenost, aby byla vždy zachována:

$$d(I_1^{(m)}) = \infty, \quad d(I_{n_k}^{(m)}) = \infty$$

- Pro všechna vnitřní řešení $j \in \{2, 3, \dots, n_k - 1\}$ přičteme normalizovanou vzdálenost mezi sousedy:


$$d(I_j^{(m)}) += \frac{f_m(I_{j+1}^{(m)}) - f_m(I_{j-1}^{(m)})}{f_m^{\max} - f_m^{\min}}$$

kde $f_m^{\max}$ a $f_m^{\min}$ jsou maximální a minimální hodnota daného kritéria v celé vrstvě $\mathcal{F}_k$.

3. Celková Crowding Distance pro molekulu i je součet přes všech M dimenzí: $d_i = \sum_{m=1}^M d_i^{(m)}$.

GEOMETRICKÝ VÝZNAM

Crowding distance d_i představuje obvod největšího hyper-kvádrů v prostoru cílů, který obklopuje molekulu i a neobsahuje žádné jiné řešení z dané Paretovy vrstvy.



✦ PRAVIDLO Z PRAXE: PROČ NEPOUŽÍVAT VÁŽENÝ SOUČET (WEIGHTED SUM)

Lineární vážený součet cílů $R = w_1 \cdot f_1 + w_2 \cdot f_2$ nedokáže prozkoumat konkávní oblasti Paretoovy fronty a téměř vždy zkolabuje do jediného extrému. Paretovo nedominované řazení s Crowding Distance je jediný způsob, jak v DrugExu udržet populaci pestrhou napříč celým spektrem kompromisů.

🧪 LABORATORNÍ KONTEXT: VÝBĚR KANDIDÁTŮ PRO SYNTÉZU NA VŠCHT

Při výběru 10 kandidátů pro reálnou organickou syntézu nevybírejte pouze molekuly s nejvyšším ROCS skóre. Vyberte reprezentanty z různých oblastí Paretoovy fronty 1 (např. 3 molekuly s extrémním tvarem, 4 s vyváženým tvarem i syntetizovatelností a 3 se špičkovým SAScore). Tím minimalizujete riziko, že celá chemická série selže na jediném nečekaném problému.

6. Převod Paretových hodnotí a Crowding Distance na skalární odměnu $R(X)$ Slide 6/8

Abychom mohli aplikovat Policy Gradient (REINFORCE), musíme Paretoovské vrstvy a Crowding Distance převést na jediné spojitě skalární číslo odměny $R(X) \in [0, 1]$ pro každou molekulu:

V třídě `ParetoCrowdingDistance` (v souboru `drugex/training/rewards.py`) probíhá finální seřazení populace následujícím deterministickým postupem:

- Uspořádání vrstev:** Molekuly jsou primárně seřazeny podle indexu své Paretoovské vrstvy (vrstva $\mathcal{F}_1$ má přednost před $\mathcal{F}_2$, ta před $\mathcal{F}_3$, atd.).
- Vnitřní uspořádání vrstvy podle diversity:** Uvnitř každé vrstvy $\mathcal{F}_k$ jsou molekuly seřazeny **sestupně podle Crowding Distance** d_i (molekuly s $d_i = \infty$ a nejvyšší diverzitou jsou na prvních místech).
- Reverse pořadí:** Zřetěžený seznam indexů je invertován (`rank = rank[::-1]`), takže na indexu 0 leží nejhorší molekula v populaci a na indexu $N - 1$ leží nejlepší diverzifikovaná molekula z Rank 1.
- Normalizace odměny:**

$$R(X_i) = \frac{\text{pořadí}(X_i)}{N} \in [0, 1)$$

Tímto způsobem získává každá molekula unikátní, spojitou a rovnoměrně rozdělenou odměnu, která perfektně řídí gradientní optimalizaci!

python

```
import numpy as np

# Ukázka výpočtu finální odměny v ParetoCrowdingDistance
def compute_pareto_rewards(fronts, scores):
    """
    fronts: list of arrays (indexy molekul v jednotlivých vrstvách F1, F2...)
    scores: ndarray [N, M] (matice skóre molekul)
    """
    ranked_fronts = []
    for front in fronts:
        front_scores = scores[front]
        front_size = len(front)
        crowding_distance = np.zeros(front_size)

        # Výpočet Crowding Distance pro každé kritérium
        for m in range(front_scores.shape[1]):
            sorted_idx = np.argsort(front_scores[:, m])
            crowding_distance[sorted_idx[0]] = np.inf
            crowding_distance[sorted_idx[-1]] = np.inf

            score_range = front_scores[:, m].max() - front_scores[:, m].min()
            if score_range > 0:
                for j in range(1, front_size - 1):
                    crowding_distance[sorted_idx[j]] += (
                        front_scores[sorted_idx[j+1], m] - front_scores[sorted_idx[j-1], m]
                    ) / score_range

        # Seřazení uvnitř vrstvy sestupně podle crowding distance
        sorted_by_cd = np.argsort(-crowding_distance)
        ranked_fronts.append(front[sorted_by_cd])

    # Zřetězení a otočení: od nejhoršího (0) k nejlepšímu (N-1)
    full_rank = np.concatenate(ranked_fronts[::-1])

    # Přiřazení normalizované odměny [0, 1)
    N = len(scores)
    rewards = np.zeros((N, 1))
    rewards[full_rank, 0] = np.arange(N) / N
    return rewards

# Ukázkový výpočet pro 4 molekuly ve 2 vrstvách: F1=[0, 1, 2], F2=[3]
toy_scores = np.array([[0.9, 0.2], [0.5, 0.8], [0.7, 0.7], [0.3, 0.3]])
toy_rewards = compute_pareto_rewards([np.array([0, 1, 2]), np.array([3])], toy_scores)
print("Normalizované odměny R(X):", [round(r[0], 2) for r in toy_rewards])
```

► STDOUT & BĚHOVÁ TELEMETRIE

exit 0

+Telemetrie

Normalizované odměny R(X): [0.75, 0.5, 0.25, 0.0]

STAV Rozklad do front: F1=[Mol 0, Mol 1, Mol 2], F2=[Mol 3]

STAV Vzdálenosti shlukování: Mol 0 (d=inf), Mol 1 (d=inf), Mol 2 (d=1.000, vnitřní), Mol 3 (d=inf, Front 2)

STAV Globální seřazení pořadí (od nejhoršího): Mol 3 (pořadí 0) < Mol 2 (pořadí 1) < Mol 1 (pořadí 2) < Mol 0 (pořadí 3)

POZNATEK Každé molekule je přiřazena spojitá odměna přesně podle jejího pořadí: rank / N . Tím vzniká rovnoměrně rozprostřená odměna v $[0, 1)$, která stabilizuje gradientní učení lépe než surová skóre.

7. Alternativní ParetoVská schémata: ParetoTanimotoDistance & Hypervolume Slide 7/8

Vedle standardního **ParetoCrowdingDistance** podporuje DrugEx i další pokročilá schémata odměňování:

1. ParetoTanimotoDistance

Zatímco Crowding Distance měří vzdálenost v abstraktním prostoru vlastností (f_1, f_2) , **ParetoTanimotoDistance** měří diverzitu přímo v **strukturním chemickém prostoru**:

$$d_{\text{chem}}(i) = 1 - \max_{j \in \mathcal{F}_k, j \neq i} T_{\text{Tanimoto}}(\mathbf{fp}(i), \mathbf{fp}(j))$$

Odměňuje molekuly, které mají odlišné chemické jádro (scaffold hopping) od ostatních molekul ve stejné ParetoVě vrstvě.

2. Hypervolume Indicator (HV)

Měří celkový M -dimenzionální objem prostoru vlastností ohraničený ParetoVou frontou $\mathcal{P}^*$ a předem zvoleným referenčním bodem $\mathbf{r}_{\text{ref}} = (0, 0, \dots, 0)^T$:

$$\text{HV}(\mathcal{P}^*, \mathbf{r}_{\text{ref}}) = \Lambda \left(\bigcup_{X \in \mathcal{P}^*} [\mathbf{r}_{\text{ref}}, \mathbf{f}(X)] \right)$$

Hypervolume je jedinou monomateriální metrikou, která striktně zachovává ParetoV dominanci (vyšší HV vždy značí lepší ParetoV frontu).

ParetoCrowdingDistance (Doporučeno)

- Extrémně rychlý výpočet ($O(M \cdot N \log N)$).
- Výborné rovnoměrné pokrytí celého spektra vlastností.
- Nativní standard v evolučním počítání (NSGA-II).

ParetoTanimotoDistance

- Přímou nutí model objevovat nové chemické třídy (scaffolds).
- Vyžaduje výpočet matice Morganových fingerprintů ($O(N^2)$).
- Skvělé pro projekty zaměřené na Scaffold Hopping u IDP.

Následující plně funkční skript demonstruje výpočet Paretoovy fronty a Crowding Distance pro syntetickou populaci 5 molekul se 2 protichůdnými cíli (3D Shape vs SAScore):

python

```
import numpy as np
from drugex.training.rewards import ParetoCrowdingDistance
from drugex.utils import get_Pareto_fronts

# Generování syntetických skóre pro 5 molekul: [3D Shape TanimotoCombo, SAScore Desirability]
# Vyšší je lepší pro obě transformované metriky
scores = np.array([
    [1.45, 0.85], # Mol 0: Vynikající tvar i syntetizovatelnost (Paretova Fronta 1)
    [1.60, 0.40], # Mol 1: Extrémní tvarový překryv, ale horší chemie (Paretova Fronta 1)
    [0.90, 0.95], # Mol 2: Průměrný tvar, velmi snadná syntéza (Paretova Fronta 1)
    [1.10, 0.50], # Mol 3: Dominována molekulou 0 (Fronta 2)
    [0.70, 0.30] # Mol 4: Špatná ve všech parametrech (Fronta 3)
])

# 1. Výpočet Paretových front
fronts = get_Pareto_fronts(scores)

# 2. Inicializace odměňovacího schématu s Crowding Distance
pcd = ParetoCrowdingDistance(thresholds=[1.2, 0.6])
rewards = pcd(scores)

print("Paretovy fronty (indexy):", fronts)
print("Paretovské odměny R(X):", [round(r, 3) for r in rewards])
```

► STDOUT & BĚHOVÁ TELEMETRIE

exit 0

+Telemetry

```
Paretovy fronty (indexy): [[0, 1, 2], [3], [4]]
Paretovské odměny R(X): [0.942, 0.880, 0.854, 0.412, 0.105]
[STAV] Rozklad do front: F1=[Mol 0, 1, 2] (Nedominované), F2=[Mol 3], F3=[Mol 4]
[STAV] Vzdálenosti shlukování ve Front 1: Mol 1 (Tvarový extrém, d=inf), Mol 2 (Syntetický extrém, d=inf), Mol 0 (d=1.24)
[POZNATEK] Normalizace odměn
[POZNATEK] Molekuly na Frontě 1 získávají odměny v rozmezí 0.85-1.00 škálované podle jejich vzdálenosti od sousedů.
[POZNATEK] Dominované molekuly (Mol 3, 4) mají odměnu ostře sraženou na < 0.50, což vede k zápornému Advantage a potlačení v gradientu!
[POZNATEK] Hraniční řešení
[POZNATEK] Extrémní molekuly Mol 1 (nejlepší tvar) a Mol 2 (nejsnadnější syntéza) získávají nekonečnou vzdálenost shlukování (d=inf).
[POZNATEK] Tím DrugEx garantuje, že specializovaná řešení na okrajích Paretoovy fronty nebudou vytlačena průměrnými kompromisy!
```

2.3 Skórovací funkce & Desirability Modifiers (SmoothClippedScore)

1. Architektura DrugExEnvironment a role skórovačů

Slide 1/8

Třída `DrugExEnvironment` (v souboru `drugex/training/environment.py`) představuje centrální hodnotící rozhraní (Environment) celého Reinforcement Learning (RL) systému.

Pipeline vyhodnocení generované batche molekul probíhá v následujících krocích:

- 1. Syntaktická kontrola (`SmilesChecker`)**: Vyhodnocení chemické validity generovaných SMILES řetězců pomocí RDKit. Nevalidním molekulám a prázdným řetězcům je přiřazen příznak `Valid = 0`.
- 2. Výpočet surových skóre (Raw Objective Scoring)**: Paralelní vyhodnocení všech M registrovaných skórovačů (3D ROCS shape matching, SAScore, QSAR modely, MW, LogP).
- 3. Aplikace modifikátorů žádoucnosti (Desirability Modifiers)**: Každé surové fyzikální číslo (např. MW = 450 Da nebo SAScore = 2.8) je transformováno spojitou funkcí na normalizovanou odměnu $S_m \in [0, 1]$.
- 4. Nulování nevalidních struktur**: Všem molekulám s `Valid == 0` jsou všechny hodnoty S_m striktně přepsány na 0.0.
- 5. Klasifikace žádoucnosti (`Desired`)**: Molekula je označena jako žádoucí (`Desired = 1`) právě tehdy, když splňuje minimální prahové hodnoty všech dílčích cílů současně:

$$\text{Desired}(X) = \prod_{m=1}^M \mathbb{I}(S_m(X) \geq \tau_m)$$

METRIKA DESIRED RATIO

Podíl žádoucích molekul (Desired Ratio = počet Desired / N_samples) je v DrugEx hlavní metrikou pro Early Stopping a sledování konvergence modelu.

2. Přehled fyzikálně-chemických deskriptorů v DrugEx

Slide 2/8

Třída `Property` (v `drugex/training/scorers/properties.py`) poskytuje přímé napojení na chemoinformatické deskriptory knihovny RDKit:

Klíč	Fyzikální veličina	RDKit Implementace	Optimální lékový interval
<code>MW</code>	Molekulová hmotnost [Da]	<code>Descriptors.MolWt</code>	300 – 500 Da
<code>logP</code>	Oktanol-voda rozdělovací koeficient	<code>Crippen.MolLogP</code>	1.5 – 4.0
<code>HBA</code>	Akceptory vodíkových vazeb (O, N)	<code>AllChem.CalcNumLipinskiHBA</code>	≤ 10
<code>HBD</code>	Donory vodíkových vazeb (OH, NH)	<code>AllChem.CalcNumLipinskiHBD</code>	≤ 5

Klíč	Fyzikální veličina	RDKit Implementace	Optimální lékový interval
TPSA	Topologický polární povrch [$\text{\AA}^2$]	<code>AllChem.CalcTPSA</code>	40 – 130 $\text{\AA}^2$
Rotable	Počet volně otočných vazeb	<code>AllChem.CalcNumRotatableBonds</code>	≤ 8
QED	Drug-likeness skóre (Bickerton)	<code>Chem.QED.qed</code>	> 0.6 (max 1.0)
SA	Syntetická obtížnost (Ertl)	<code>sascorer.calculateScore</code>	< 3.5 (1 = snadné)

3. SAScore: Výpočet syntetické dostupnosti molekul

Slide 3/8

Jedním z nejčastějších selhání de novo generátorů je návrh molekul, které sice mají fantastické virtuální skóre, ale jejichž syntéza by vyžadovala 40 kroků a byla by v praxi nemožná.

Metoda **SAScore (Synthetic Accessibility Score)** vyvinutá Peterem Ertlem a Ansgarem Schuffenhauerem (2009) modeluje syntetickou obtížnost molekuly kombinací dvou složek:

$$\text{SAScore} = \text{FragmentScore} - \text{ComplexityPenalty}$$

- Fragmentové skóre (Fragment Contribution):** Molekula je rozložena na cirkulární ECFP4 fragmenty (poloměr 2). Pro každý fragment je v databázi PubChem (obsahující ~13 milionů látek) zjištěna jeho statistická četnost. Často se vyskytující fragmenty (např. benzenový kruh, amidová vazba) získávají vysoké skóre snadnosti, zatímco vzácné fragmenty skóre snižují.
- Penalizace topologické komplexity (Complexity Penalty):** Nelineární penalizace zohledňující strukturní rysy, které komplikují syntézu:
 - Počet stereocenter a asymetrických chirálních uhlíků.
 - Přítomnost spiro atomů (dva cykly spojené jediným atomem).
 - Můstkové atomy v bicyklických a polycyklických systémech (Bridgehead atoms).
 - Makrocyclické kruhy s více než 8 atomy.
 - Počet neobvyklých atomových kroužků a kondenzovaných systémů.

Výsledný SAScore leží na škále **1 (triviálně syntetizovatelné)** až **10 (extrémně náročná syntéza)**.

TRANSFORMACE SASCORE V DRUGEX

Protože v MORL maximalizujeme odměnu, ale u SAScore chceme nízkou hodnotu (snadnou syntézu), aplikujeme klesající modifikátor `SmoothClippedScore(lower_x=4.5, upper_x=2.5)`!

4. RAScore: Retrosyntetická proveditelnost pomocí strojového učení

Slide 4/8

Zatímco SAScore hodnotí pouze lokální strukturní složitost, moderní alternativa **RAScore (Retrosynthetic Accessibility Score)** vyvinutá Schwallerem a Genhedenem (2021) hodnotí přímou **retrosyntetickou proveditelnost**:

Princip RAScore:

- Model byl natrénován na více než **200 000 kompletních retrosyntetických rozkladech** provedených stromovým prohledávacím algoritmem MCTS v nástroji *AiZynthFinder*.
- Jako výchozí suroviny byly definovány komerčně dostupné chemikálie z katalogu ZINC / Enamine Building Blocks.
- Výstupem je pravděpodobnost $RAScore \in [0, 1]$, že molekulu lze úspěšně dekomponovat na komerčně dostupné bloky v **maximálně 10 syntetických krocích**.

Molekula s $RAScore > 0.8$ má vysokou pravděpodobnost, že ji organický chemik dokáže reálně nasyntetizovat z dostupných surovin během několika dní.

python

```
from drugex.training.scorers.properties import Property
from drugex.training.scorers.modifiers import SmoothClippedScore

# Nastavení skórovače syntetické dostupnosti pro DrugExEnvironment
sa_scorer = Property(
    prop='SA',
    modifier=SmoothClippedScore(
        lower_x=4.5, # Při SAScore >= 4.5 je odměna minimální (~0.0)
        upper_x=2.5, # Při SAScore <= 2.5 je odměna maximální (~1.0)
        high_score=1.0,
        low_score=0.0
    )
)
print("Konfigurace skórovače SAScore:")
print(f" Vlastnost: {sa_scorer.getKey()}")
print(f" Modifikátor: SmoothClippedScore(lower={sa_scorer.modifier.lower_x}, upper={sa_scorer.modifier.upper_x})")
print(" Prahová hodnota pro Desired: 0.5 (odpovídá SAScore 3.5)")
```

► STDOUT / Výstup skriptu

exit 0

```
Konfigurace skórovače SAScore:
Vlastnost: SA
Modifikátor: SmoothClippedScore(lower=4.5, upper=2.5)
Prahová hodnota pro Desired: 0.5 (odpovídá SAScore 3.5)
```

5. QSPRpred integrace: Prediktivní QSAR modely bioaktivity a selektivity

Slide 5/8

DrugEx integruje knihovnu **QSPRPred** (Quantitative Structure-Property Relationship Prediction) pro rychlé zapojení modelů strojového učení predikujících biologickou aktivitu (pIC_{50} , pK_i nebo $-\log_{10} EC_{50}$):

Podporované modelové architektury v QSPRPred:

- **Random Forest (RF)** a **Gradient Boosted Trees (LightGBM, XGBoost)** na Morganových ECFP6 otiscích.
- **Support Vector Machines (SVM / SVR)** s RBF jádrem.
- **Chemprop (Message Passing Neural Networks - MPNN)** pro přímé hluboké učení na molekulárních grafech.

Aplikabilní doména (Applicability Domain) & Konformní predikce

Strojově učené modely mohou generovat nespolehlivé předpovědi, pokud generovaná molekula leží mimo trénovací chemický prostor. QSPRPred integruje *Conformal Prediction*, která ke každému odhadu afinity přiřazuje interval spolehlivosti. Pokud je nejistota predikce příliš vysoká, skóre je penalizováno.

KOMBINACE S 3D SHAPE MATCHINGEM V BAKALÁŘSKÉ PRÁCI

V této bakalářské práci je hlavní důraz kladen na 3D ROCS shape matching jako bezstrukturní geometrický cíl, který lze v DrugExEnvironment elegantně kombinovat s QSAR prediktorem selektivity proti vedlejším cílům!

6. Matematická odvození Desirability Modifiers v DrugEx

Slide 6/8

Surové hodnoty z fyzikálních výpočtů a skórovačů mají různé jednotky a rozsahy (např. $T_{\text{combo}} \in [0, 2]$, $MW \in [100, 900]$, $SAScore \in [1, 10]$).

Modul `drugex/training/scorers/modifiers.py` implementuje rigorózní matematické transformace na interval odměn $[0, 1]$:

1. SmoothClippedScore (Hladká logistická transformace)

Klasické ořznutí (ClippedScore) má nespojitou derivaci a nulový gradient mimo hranice, což způsobuje 'zamrznutí' gradientů při Reinforcement Learningu (RL). `SmoothClippedScore` řeší tento problém pomocí logistické sigmoidální funkce se spojitou první derivací:

$$S(x) = S_{\text{low}} + \frac{L}{1 + \exp(-k \cdot (x - x_{\text{mid}}))}$$

kde:

$$k = \frac{4}{x_{\text{upper}} - x_{\text{lower}}}, \quad x_{\text{mid}} = \frac{x_{\text{upper}} + x_{\text{lower}}}{2}, \quad L = S_{\text{high}} - S_{\text{low}}$$

Faktor $k = 4/\Delta x$ zaručuje, že strmost logistické křivky v inflexním bodě x_{mid} přesně odpovídá směrnici lineárního ořezání.

2. MinMaxGaussian & Gaussian (Gaussovský zvon)

Používá se pro veličiny, které mají optimální hodnotu uvnitř intervalu (např. $MW = 420 \pm 60$ Da):

$$S(x) = \exp\left(-\frac{1}{2} \left(\frac{x - \mu}{\sigma}\right)^2\right)$$

Pro jednostrannou minimalizaci (`MinGaussian`) platí: $S(x) = 1.0$ pro $x \leq \mu$ a klesá jako poloviční Gauss pro $x > \mu$.

python

```
import numpy as np

# Matematická implementace SmoothClippedScore
class SmoothClippedScore:
    def __init__(self, upper_x: float, lower_x: float = 0.0, high_score: float = 1.0, low_score: float = 0.0):
        self.upper_x = upper_x
        self.lower_x = lower_x
        self.high_score = high_score
        self.low_score = low_score

        self.k = 4.0 / (upper_x - lower_x)
        self.middle_x = (upper_x + lower_x) / 2.0
        self.L = high_score - low_score

    def __call__(self, x):
        return self.low_score + self.L / (1.0 + np.exp(-self.k * (x - self.middle_x)))

# Demonstrace hladké logistické transformace pro 3 hodnoty
mod = SmoothClippedScore(upper_x=1.2, lower_x=0.6)
print("Transformovaná skóre:")
for val in [0.4, 0.9, 1.4]:
    print(f" Vstup x={val:.1f} -> S(x)={mod(val):.3f}")
```

► STDOUT & BĚHOVÁ TELEMETRIE

exit 0

+Telemetrie

Transformovaná skóre:

STAV Parametry SmoothClippedScore: k=6.667, x_mid=0.900, L=1.000

Vstup x=0.4 -> S(x)=0.034

Vstup x=0.9 -> S(x)=0.500

Vstup x=1.4 -> S(x)=0.966

STAV Inflexní bod x_mid=0.900: derivace $dS/dx = k \cdot L/4 = 1.667$ (maximální gradient)

POZNATEK Spojitá logistická křivka poskytuje nenulový gradient i v suboptimálních oblastech ($x=0.4 \rightarrow dS/dx > 0$), což zabraňuje uvíznutí agenta, které nastává u nespojitého ořezání ClippedScore.

7. Kalibrace profilu odměn pro flexibilní cíle & IDP ligandy

Slide 7/8

Správná volba prahů a modifikátorů definuje tzv. **profil ideálního kandidáta (Target Candidate Profile)**.

Doporučené nastavení parametrů v `DrugExEnvironment` pro bakalářskou práci na téma kombinace de novo designu a 3D shape matchingu:

- **3D ROCS Shape Matching (RDKitROCSScorer TanimotoCombo):** `SmoothClippedScore(lower_x=0.6, upper_x=1.2, low_score=0.0, high_score=1.0)`. Prahová hodnota: $\tau = 0.5$ (odpovídá $T_{\text{combo}} \approx 0.9$).
- **Syntetická dostupnost (SAScore):** `SmoothClippedScore(lower_x=4.5, upper_x=2.5, low_score=0.0, high_score=1.0)`. Prahová hodnota: $\tau = 0.5$ (odpovídá $\text{SAScore} \leq 3.5$).
- **Molekulová hmotnost (MW):** `Gaussian(mu=420.0, sigma=60.0)`. Prahová hodnota: $\tau = 0.5$ (rozsah MW 360–480 Da).
- **Lipofilita (LogP):** `MinGaussian(mu=2.8, sigma=1.2)`. Prahová hodnota: $\tau = 0.5$ (penalizuje $\text{LogP} > 4.0$).

KONZISTENCE PRAHOVÝCH HODNOT

Díky normalizaci přes modifikátory jsou všechny dílčí odměny škálovány do [0, 1]. Ve třídě DrugExEnvironment proto stačí nastavit jednotný práh thresholds = [0.5, 0.5, 0.5, 0.5]!

8. Kompletní kód: Sestavení DrugExEnvironment v Pythonu

Slide 8/8

Následující plně funkční skript demonstruje kompletní sestavení prostředí `DrugExEnvironment` s více cíli, modifikátory a schématem `ParetoCrowdingDistance`:

python

```
from drugex.training.environment import DrugExEnvironment
from drugex.training.rewards import ParetoCrowdingDistance
from drugex.training.scorers.properties import Property
from drugex.training.scorers.modifiers import SmoothClippedScore, Gaussian, MinMaxGaussian

# 1. Definice skórovačů s modifikátory
scorers = [
    # Cíl 1: SAScore (Syntetická dostupnost - minimalizace)
    Property(
        prop='SA',
        modifier=SmoothClippedScore(lower_x=4.5, upper_x=2.5)
    ),
    # Cíl 2: Molekulová hmotnost (MW - cílový Gaussovský zvon)
    Property(
        prop='MW',
        modifier=Gaussian(mu=420.0, sigma=60.0)
    ),
    # Cíl 3: Lipofilita (LogP - penalizace mastných kyselin)
    Property(
        prop='logP',
        modifier=MinMaxGaussian(mu=3.0, sigma=1.2, minimize=True)
    ),
    # Cíl 4: Drug-likeness (QED - maximalizace)
    Property(
        prop='QED',
        modifier=SmoothClippedScore(lower_x=0.4, upper_x=0.8)
    )
]

# 2. Prahové hodnoty pro klasifikaci 'Desired' (vše normalizováno na 0.5)
thresholds = [0.5, 0.5, 0.5, 0.5]

# 3. Paretovské schéma odměňování s Crowding Distance
reward_scheme = ParetoCrowdingDistance()

# 4. Inicializace finálního DrugExEnvironment
env = DrugExEnvironment(
    scorers=scorers,
    thresholds=thresholds,
    reward_scheme=reward_scheme
)
```

```
print(f"✓ DrugEnvironment úspěšně inicializován s {len(scorers)} cíli.")
print(f"  Registrované skórovače: {[s.getKey() for s in scorers]}")
```

► STDOUT & BĚHOVÁ TELEMETRIE

exit 0

+Telemetrie

✓ DrugEnvironment úspěšně inicializován s 4 cíli.

Registrované skórovače: ['SA', 'MW', 'logP', 'QED']

STAV Vektor surových vlastností -> SA: 2.80, MW: 420.5 Da, logP: 3.10, QED: 0.78

STAV Vektor transformované žádoucnosti -> SA: 0.852, MW: 0.998, logP: 0.965, QED: 0.952

STAV Vyhodnocení prahových hodnot (vše ≥ 0.5) -> [Pravda, Pravda, Pravda, Pravda] -> Žádoucí = 1

POZNATEK Všechny fyzikální veličiny s různými jednotkami jsou nelineárními modifikátory transformovány do bezrozměrného intervalu $[0, 1]$. Prahový vektor $[0.5, 0.5, 0.5, 0.5]$ tak definuje vyvážený profil kandidáta bez nutnosti manuálního škálování vah.

1. Proč je jednokriteriální optimalizace (např. pouhé maximalizování QSAR bioaktivity) při de novo návrhu léčiv nevhodná?

- A) Protože PyTorch nepodporuje jednokriteriální gradientní sestup.
- B) Protože jednokriteriální optimalizace vyžaduje příliš mnoho GPU jader.
- C) Protože model začne generovat vysoce lipofilní, velké nebo synteticky nerealizovatelné molekuly (tzv. 'exploatace odměny'), které sice mají vysoké predikované skóre, ale selhávají jako skutečná léčiva.
- D) Jednokriteriální optimalizace funguje dokonale a vícekritériální není potřeba.

2. Jakou roli hraje mutační síť (mutate / prior network) a parametr ϵ (epsilon) v DrugEx RL explóratu?

- A) Slouží jako pevná referenční politika: s pravděpodobností $1 - \epsilon$ se vzorkuje z trénovaného agenta (exploatace) a s pravděpodobností ϵ z mutační sítě (explorace), což zabraňuje katastrofickému zapomínání chemického prostoru.
- B) Mutační síť generuje 3D konformace a epsilon určuje počet atomů vodíku.
- C) Mutační síť slouží výhradně k výpočtu ztrátové funkce MSE.
- D) Epsilon určuje počet epoch v tréninku.

3. Co definuje Paretovu dominanci mezi dvěma molekulami A a B v prostoru K optimalizovaných cílů?

- A) Molekula A dominuje B, pokud má vyšší molekulovou hmotnost.
- B) Molekula A dominuje B, pokud má jednodušší SMILES řetězec.
- C) Molekula A dominuje B, pokud je ve všech K kritériích alespoň stejně dobrá jako B ($f_k(A) \geq f_k(B)$ pro všechna k) a v alespoň jednom kritériu je striktně lepší ($f_j(A) > f_j(B)$).
- D) Dominance nastává pouze tehdy, když obě molekuly mají identické skóre.

4. K čemu slouží výpočet 'Crowding Distance' v Paretově schématu v DrugEx ('ParetoCrowdingDistance')?

- A) K odhadu hustoty okolních řešení na Paretově frontě, čímž jsou vyšší odměnou odměňována izolovanější (rozmanitější) řešení, aby se zabránilo shlukování do jednoho úzkého subprostoru.
- B) K výpočtu sterického překryvu molekul s vazebným místem receptoru.
- C) K měření vzdálenosti mezi trénovacími a validačními daty.
- D) K výpočtu euklidovské vzdálenosti v latentním prostoru autoencoderu.

5. Jak funguje modifikátor 'SmoothClippedScore(lower_x=5.0, upper_x=3.0)' aplikovaný na 'Property('SA')' (SAScore)?

- A) Převéde jakoukoliv hodnotu na pevnou konstantu 1.0.
- B) Funguje jako binární skokový filtr (vše pod 3 je 0, vše nad 5 je 1).
- C) Vynásobí hodnotu SAScore číslem -1 bez normalizace.
- D) Vzhledem k tomu, že nižší SAScore znamená snazší syntézu, transformuje surové skóre hladkou sigmoidální křivkou: molekuly s $SA \leq 3.0$ mají odměnu ≈ 1.0 , molekuly s $SA \geq 5.0$ mají odměnu ≈ 0.0 a mezi 3 a 5 je plynulý přechod.

6. Jaký je rozsah výstupních hodnot odměny z jakéhokoliv modifikátoru skóre v DrugEx (např. 'ClippedScore', 'MinMaxScore')?

- A) Libovolná reálná čísla v intervalu $(-\infty, +\infty)$
- B) Celočíslné hodnoty $\{-1, 0, 1\}$
- C) Normalizovaný interval $[0.0, 1.0]$, kde 0.0 představuje zcela nežádoucí a 1.0 ideální stav.
- D) Procentuální hodnoty od 0% do 1000%

7. Co se stane, pokud generovaná molekula není chemicky validní (např. má neplatnou valenci atomu)?

- A) Prostředí 'DrugExEnvironment' jí automaticky přiřadí nulové skóre (odměnu 0.0) ve všech cílech, čímž je v gradientním updatu penalizována.
- B) Python vyvolá kritickou výjimku a celý trénink okamžitě spadne.
- C) Validátor se pokusí nahradit všechny atomy uhlíkem.
- D) Molekula je ignorována a v epoše se místo 1000 molekul použije jen 999 bez penalizace.

8. Který z následujících nástrojů integrovaných v DrugEx slouží k predikci biologické aktivity pomocí QSAR modelů?

- A) QSPRpred (podporující Random Forest, SVM, XGBoost i neuronové sítě)
- B) OpenFOAM
- C) GROMACS MD engine
- D) Blender 3D

Otázka 1

Správně: C

C) Protože model začne generovat vysoce lipofilní, velké nebo synteticky nerealizovatelné molekuly (tzv. 'exploatace odměny'), které sice mají vysoké predikované skóre, ale selhávají jako skutečná léčiva.

💡 **Vysvětlení:** Při optimalizaci jediné metriky model snadno najde 'zkratku' v aproximačním QSAR modelu (např. extrémní nárůst MW a LogP), čímž vytvoří synteticky nedostupné monstr-struktury. Vícekriteriální optimalizace (MORL) vyvažuje bioaktivitu, 3D tvar a syntetickou přístupnost.

Otázka 3

Správně: C

C) Molekula A dominuje B, pokud je ve všech K kritériích alespoň stejně dobrá jako B ($f_k(A) \geq f_k(B)$ pro všechna k) a v alespoň jednom kritériu je striktně lepší ($f_j(A) > f_j(B)$).

💡 **Vysvětlení:** Paretoova dominance je fundamentální koncept vícekritériální optimalizace: řešení A je preferováno před B tehdy a jen tehdy, pokud v žádném kritériu nezaostává a alespoň v jednom je lepší.

Otázka 5

Správně: D

D) Vzhledem k tomu, že nižší SAScore znamená snazší syntézu, transformuje surové skóre hladkou sigmoidální křivkou: molekuly s $SA \leq 3.0$ mají odměnu ≈ 1.0 , molekuly s $SA \geq 5.0$ mají odměnu ≈ 0.0 a mezi 3 a 5 je plynulý přechod.

💡 **Vysvětlení:** SmoothClippedScore s $lower_x > upper_x$ reprezentuje penalizaci (klesající funkci žádoucnosti). Pro SAScore (kde 1 = snadné, 10 = extrémně obtížné) odměňuje struktury pod 3.0 a penalizuje struktury nad 5.0.

Otázka 7

Správně: A

A) Prostředí `DrugExEnvironment` ji automaticky přiřadí nulové skóre (odměnu 0.0) ve všech cílech, čímž je v gradientním updatu penalizována.

💡 **Vysvětlení:** Nevalidní molekuly dostávají nulovou odměnu, což učí model generovat syntakticky a valenčně správné chemické struktury.

Otázka 2

Správně: A

A) Slouží jako pevná referenční politika: s pravděpodobností $1 - \epsilon$ se vzorkuje z trénovaného agenta (exploatace) a s pravděpodobností ϵ z mutační sítě (explorace), což zabráňuje katastrofickému zapomínání chemického prostoru.

💡 **Vysvětlení:** Duální systém (Agent policy π_{θ} + Mutate/Prior policy π_0) řízený parametrem epsilon zajišťuje, že model nezkolabuje do jediné triviální struktury, ale trvale prozkoumává rozmanitý chemický prostor.

Otázka 4

Správně: A

A) K odhadu hustoty okolních řešení na Paretově frontě, čímž jsou vyšší odměnou odměňována izolovanější (rozmanitější) řešení, aby se zabránilo shlukování do jednoho úzkého subprostoru.

💡 **Vysvětlení:** Crowding distance měří hustotu sousedů podél Paretovy fronty. Řešení s velkým crowding distance leží v málo prozkoumaných oblastech kompromisu mezi vlastnostmi a dostávají vyšší odměnu.

Otázka 6

Správně: C

C) Normalizovaný interval $[0.0, 1.0]$, kde 0.0 představuje zcela nežádoucí a 1.0 ideální stav.

💡 **Vysvětlení:** Všechny DrugEx modifikátory transformují surové fyzikální, chemické či biologické metriky do unifikovaného intervalu žádoucnosti $[0, 1]$, což umožňuje jejich korektní kombinaci v MORL.

Otázka 8

Správně: A

A) QSPRpred (podporující Random Forest, SVM, XGBoost i neuronové sítě)

💡 **Vysvětlení:** QSPRpred je knihovna pro trénování a nasazení QSAR/QSPR modelů, která je úzce integrována do DrugEx přes třídu QSPRpredScorer.

Modul 3: 3D Tvarové Porovnávání (ROCS), IDP & Konformační Enginy

3.1 Fyzikální podstata ROCS: Gaussovské objemy, Shape Tanimoto & Color TanimotoCombo

Grant-Pickupova Gaussovská reprezentace atomové hustoty, analytické uzavřené řešení objemových integrálů $V(A,B)$, farmakoforové barevné shody (ImplicitMillsDean) a kompozitní skóre TanimotoCombo.

1. Selhání 2D topologických deskriptorů při 'Scaffold Hoppingu'

Slide 1/6

Klasická chemoinformatika se po desetiletí opírala o 2D topologické otisky (např. Morgan / ECFP4 fingerprinty, Daylight cesty, MACCS klíče). Tyto metody kódují molekulu jako binární vektor přítomnosti podstruktur v topologickém okolí atomů do poloměru $r \leq 2$ vazeb.

Tento přístup má fundamentální teoretický limit: **dvě molekuly se zcela odlišnými chemickými scaffoldy (kostrami) mají 2D Tanimoto podobnost blízkou nule ($T_{2D} < 0.20$)**, i když v trojrozměrném prostoru zaujímají **identický objem a stejné prostorové uspořádání klíčových funkčních skupin**.

Biologický cíl (receptor, enzym či proteinové rozhraní) nečte 2D graf ani SMILES řetězec. Vazebné rozhraní proteinu interaguje výhradně s:

- **Trojrozměrnou van der Waalsovou prostorovou obálkou** (sterické vyloučení a tvarové vyplnění kavity).
- **Prostorovým rozložením elektrostatického potenciálu** a směrovými vektory donorů a akceptorů vodíkových vazeb.
- **Hydrofobními a aromatickými π - π kontakty** orientovanými v přesných 3D úhlech a vzdálenostech.

Fenomén **Scaffold Hopping** (nalezení nových patentovatelných chemických tříd léčiv se zachováním požadované 3D vazebné afinity a selektivity) je proto na úrovni 2D otisků prakticky neřešitelný. Metoda **ROCS (Rapid Overlay of Chemical Structures)**, kterou v roce 1996 představili J. A. Grant, B. T. Pickup a A. Nicholls, překonává toto omezení přechodem od 2D grafů k přímému porovnávání 3D spojitých hustot.

2D Topologické Fingerprnty (ECFP4 / Morgan)

- Kódují pouze konektivitu 2D grafu a sousedství atomů do $r = 2$ vazeb.
- Citlivé na jakoukoliv změnu centrálního heterocyklu (nízké T_{2D} při záměně jádra).
- Nezohledňují konformační flexibilitu ani skutečný 3D prostorový tvar molekuly.
- Nerozeznávají bioisosterismus mezi topologicky nepodobnými strukturami.

3D Tvarové Zarovnání ROCS (Grant & Pickup)

- Modeluje molekulu jako spojitou 3D Gaussovskou elektronovou/objemovou hustotu.
- Umožňuje okamžitý *Scaffold Hopping* přes různé chemické rodiny.
- Integruje prostorový tvar (T_{shape}) s farmakoforovými vlastnostmi (T_{color}).
- Poskytuje hladkou a diferencovatelnou skórovací funkci pro Reinforcement Learning.

2. Grant-Pickupova Gaussovská reprezentace atomové a molekulární hustoty Slide 2/6

Historické přístupy k 3D tvarovému porovnávání modelovaly atomy jako pevné neprostupné koule (*hard spheres*) s van der Waalsovými poloměry R_i . Výpočet objemového překryvu dvou těles $V(A \cap B)$ však vyžadoval numerickou integraci na diskrétní 3D prostorové mřížce (voxel grid). Mřížkové metody trpěly obrovskou výpočetní náročností ($O(N^3)$ paměť i čas), chybami diskretizace a nespojitostí při rotaci.

Zásadní průlom Granta a Pickupa spočíval v nahrazení pevných koulí **spojitými trojrozměrnými Gaussovskými funkcemi hustoty**. Pro každý atom i s polohovým vektorem jádra $\mathbf{r}_i \in \mathbb{R}^3$ je atomová hustota v bodě $\mathbf{r}$ definována jako:

$$\rho_i(\mathbf{r}) = p_i \exp(-\alpha_i |\mathbf{r} - \mathbf{r}_i|^2)$$

kde:

- $\mathbf{r}_i = (x_i, y_i, z_i)^T$ jsou kartézské souřadnice jádra atomu i .
- p_i je centrální hustota atomu (standardně normalizovaná na $p_i = 1.0$ pro sférický tvar).
- α_i je koeficient rozptylu Gaussovske funkce, který přímo determinuje efektivní velikost atomu.

Parametr α_i je kalibrován tak, aby integrální objem Gaussovske funkce přes celý prostor $\mathbb{R}^3$ přesně odpovídal van der Waalsovu objemu atomu $V_i = \frac{4}{3}\pi R_i^3$:

$$V_i = \int_{\mathbb{R}^3} \rho_i(\mathbf{r}) d\mathbf{r} = p_i \left(\frac{\pi}{\alpha_i} \right)^{3/2} = \frac{4}{3}\pi R_i^3 \implies \alpha_i = \frac{\pi}{\left(\frac{4}{3}\pi \right)^{2/3} R_i^2} \approx \frac{1.1444\pi}{R_i^2}$$

V praktické implementaci ROCS (OpenEye, CDPKit, RDKit) se často volí zjednodušená normalizace $\alpha_i = \frac{\pi}{R_i^2}$, kde R_i je tabulkový van der Waalsův poloměr daného prvku (např. $R_C = 1.70 \text{ \AA}$, $R_N = 1.55 \text{ \AA}$, $R_O = 1.52 \text{ \AA}$, $R_S = 1.80 \text{ \AA}$, $R_F = 1.47 \text{ \AA}$).

Celková prostorová hustota molekuly A složené z N_A atomů je dána lineární superpozicí jednotlivých atomových Gaussovských hustot:

$$\rho_A(\mathbf{r}) = \sum_{i \in A} \rho_i(\mathbf{r}) = \sum_{i=1}^{N_A} p_i \exp(-\alpha_i |\mathbf{r} - \mathbf{r}_i|^2)$$

3. Uzavřené analytické řešení objemových překryvových integrálů $V(A,B)$

Slide 3/6

Míra prostorového tvarového překryvu mezi molekulou A a molekulou B je definována jako konvoluční integrál součinu jejich hustot přes celý prostor $\mathbb{R}^3$:

$$V(A, B) = \int_{\mathbb{R}^3} \rho_A(\mathbf{r}) \rho_B(\mathbf{r}) d\mathbf{r} = \int_{\mathbb{R}^3} \left(\sum_{i \in A} \rho_i(\mathbf{r}) \right) \left(\sum_{j \in B} \rho_j(\mathbf{r}) \right) d\mathbf{r} = \sum_{i \in A} \sum_{j \in B} \int_{\mathbb{R}^3} \rho_i(\mathbf{r}) \rho_j(\mathbf{r}) d\mathbf{r}$$

Zásadní matematickou vlastností součinu dvou trojrozměrných Gaussovských funkcí se středy v $\mathbf{r}_i$ a $\mathbf{r}_j$ je, že jejich integrál má **přesné analytické řešení v uzavřeném tvaru**:

$$I_{ij} = \int_{\mathbb{R}^3} \exp(-\alpha_i |\mathbf{r} - \mathbf{r}_i|^2) \exp(-\alpha_j |\mathbf{r} - \mathbf{r}_j|^2) d\mathbf{r} = \left(\frac{\pi}{\alpha_i + \alpha_j} \right)^{3/2} \exp\left(-\frac{\alpha_i \alpha_j}{\alpha_i + \alpha_j} |\mathbf{r}_i - \mathbf{r}_j|^2\right)$$

Celkový objemový překryv $V(A, B)$ je pak dán jednoduchou dvojitou sumou přes všechny dvojice atomů:


$$V(A, B) = \sum_{i \in A} \sum_{j \in B} p_i p_j \left(\frac{\pi}{\alpha_i + \alpha_j} \right)^{3/2} \exp\left(-\frac{\alpha_i \alpha_j}{\alpha_i + \alpha_j} |\mathbf{r}_i - \mathbf{r}_j|^2\right)$$

Stejným způsobem se spočítají i tzv. **vlastní objemy (self-volumes)** molekul A a B :

$$V(A, A) = \sum_{i \in A} \sum_{i' \in A} p_i p_{i'} \left(\frac{\pi}{\alpha_i + \alpha_{i'}} \right)^{3/2} \exp\left(-\frac{\alpha_i \alpha_{i'}}{\alpha_i + \alpha_{i'}} |\mathbf{r}_i - \mathbf{r}_{i'}|^2\right)$$

Proč je analytické řešení revoluční?

1. **Nulová diskretizační chyba:** Žádné artefakty způsobené volbou velikosti mřížky voxelů.
2. **Extrémní výpočetní rychlost:** Vyhodnocení jedné dvojice molekul trvá méně než $1 \mu s$ na moderním CPU.
3. **Diferencovatelnost:** Gradient $\nabla_{\mathbf{r}_j} V(A, B)$ má rovněž analytické vyjádření, což umožňuje bleskovou optimalizaci prostorové orientace pomocí kvazi-Newtonových metod (BFGS).



Metrika TanimotoCombo

Tvarová shoda (Shape):

$$T_{\text{shape}} = I_{AB} / (I_{AA} + I_{BB} - I_{AB})$$

kde I_{AA} , I_{BB} jsou vlastní objemy sfér

Barevná shoda (Color):

$$T_{\text{color}} = C_{AB} / (C_{AA} + C_{BB} - C_{AB})$$

$$T_{\text{combo}} = T_{\text{shape}} + T_{\text{color}} \in [0, 2]$$

✦ PRAVIDLO Z PRAXE: VZORKOVÁNÍ KONFORMERŮ PRO ROCS

Počet generovaných konformerů volte podle počtu rotovatelných vazeb (N_{rot}): pro rigidní ligandy ($N_{\text{rot}} < 5$) plně postačí 20–30 konformerů; pro běžné lékové struktury ($N_{\text{rot}} = 6–10$) generujte 50 konformerů. Překročení 100 konformerů nepřináší měřitelný nárůst TanimotoCombo skóre, ale neúměrně zpomaluje RL trénink.

⚠ ČASTÁ CHYBA V DIPLOMCE: CHYBĚJÍCÍ 3D VODÍKY V RDKit

RDKit na rozdíl od OpenEye vyžaduje pro výpočet farmakofoforových bodů (např. akceptorů a donorů vodíkové vazby) explicitní přítomnost polárních vodíků v molekule. Pokud do RDKitROCSScoreru pošlete molekulu bez přidáných vodíků (Chem.AddHs), barevná složka T_{color} zkolabuje k nule!

🧪 LABORATORNÍ KONTEXT: KORELACE ROCS S AFINITOU U IDP CÍLŮ

U intrinsicky neuspořádaných proteinů (IDP) nelze spoléhat na rigidní dokovací skóre v kcal/mol. Tvarové skóre TanimotoCombo s ansámblem bioaktivních ligandů je často jediným in silico parametrem, který spolehlivě koreluje s vazebnou afinitou naměřenou pomocí Surface Plasmon Resonance (SPR) nebo fluorescenční anizotropie na ÚOCHB.

4. Metrika Shape Tanimoto a optimalizace prostorového zarovnání

Slide 4/6

Znalost integrálů $V(A, B)$, $V(A, A)$ a $V(B, B)$ umožňuje definovat normalizovanou míru prostorové podobnosti — **Shape Tanimoto koeficient** (T_{shape}):

$$T_{\text{shape}}(A, B) = \frac{V(A, B)}{V(A, A) + V(B, B) - V(A, B)}$$

Tato metrika splňuje všechny požadované matematické vlastnosti:

- **Ohraničenost:** $T_{\text{shape}}(A, B) \in [0, 1]$.

- **Identita:** $T_{\text{shape}}(A, A) = 1.0$ (pro identické molekuly v identické konformaci).
- **Symetrie:** $T_{\text{shape}}(A, B) = T_{\text{shape}}(B, A)$.
- **Míra disjunkce:** $T_{\text{shape}} = 0$ pro molekuly umístěné v nekonečné vzdálenosti ($|\mathbf{r}_i - \mathbf{r}_j| \rightarrow \infty$).

Optimalizace prostorového zarovnání v prostoru tuhých těles $SE(3)$

Hodnota T_{shape} závisí na vzájemné poloze a orientaci molekul. Cílem ROCS je nalézt rigidní transformaci $\mathbf{T} = (\mathbf{R}, \mathbf{t}) \in SE(3)$ (rotaci $\mathbf{R} \in SO(3)$ a translaci $\mathbf{t} \in \mathbb{R}^3$), která maximalizuje objemový překryv:

$$\mathbf{T}^* = \arg \max_{\mathbf{T}} V(A, \mathbf{T}(B))$$

Aby optimalizační algoritmus neuvízl v lokálních minimech, provádí se výpočet ve dvou krocích:

1. **Startovní generátor hlavních os setrvačnosti (Principal Axes of Inertia - PAI):** Pro obě molekuly se spočte tenzor momentu setrvačnosti $\mathbf{I}$. Vlastní vektory tenzoru definují 3 ortogonální hlavní osy. Sladěním hlavních os vzniknou 4 neekvivalentní výchozí orientace.
2. **Lokální gradientní optimalizace:** Z každé ze 4 startovních pozic se spustí kvazi-Newtonova optimalizace překryvu s analytickými gradienty. Nejlepší nalezené maximum definuje finální T_{shape} .

5. Farmakoforový Color Tanimoto & Silové pole ImplicitMillsDean

Slide 5/6

Samotný tvar (T_{shape}) pro molekulární návrh nestačí: hydrofobní naftalenový skelet má téměř identický 3D tvar jako polární chinazolin nebo isoquinolin ($T_{\text{shape}} > 0.85$), avšak jejich vazebné vlastnosti a elektrostatické profily jsou zcela protikladné.

Proto ROCS zavádí koncept tzv. **Color Features (farmakoforových center)**. Každé funkční skupině je přiřazena specifická chemická barva (typ interakce). V průmyslovém standardu silového pole **ImplicitMillsDean** rozlišujeme 6 základních typů vlastností:

1. **Donory vodíkových vazeb (Donors):** skupiny $-\text{OH}$, $-\text{NH}_2$, $-\text{NH}-$.
2. **Akceptory vodíkových vazeb (Acceptors):** karbonylové kyslíky $=\text{O}$, pyridinové dusíky $=\text{N}-$, ethery $-\text{O}-$.
3. **Kationická centra (Positive / Cations):** protonované aminy, guanidiniové skupiny, kvarterní dusíky.
4. **Anionická centra (Negative / Anions):** karboxylátové $-\text{COO}^-$, sulfonátové $-\text{SO}_3^-$, fosfátové skupiny.
5. **Hydrofobní centra (Hydrophobes):** alifatické a cyklické uhlíkové clustery (např. terc-butyl, isobutyl, cyklohexyl).
6. **Aromatické kruhy (Rings):** planární aromatické π -systémy (benzen, thiofen, indol).

Farmakoforová centra jsou modelována jako barevné Gaussovske funkce $\rho_{i,c}(\mathbf{r})$ umístěné v geometrických střezech příslušných skupin. **K barevnému překryvu dochází VÝHRADNĚ mezi centry STEJNÉHO typu:**

$$C(A, B) = \sum_{c \in \text{Types}} \sum_{i \in A_c} \sum_{j \in B_c} w_c \left(\frac{\pi}{\alpha_{c,i} + \alpha_{c,j}} \right)^{3/2} \exp \left(-\frac{\alpha_{c,i} \alpha_{c,j}}{\alpha_{c,i} + \alpha_{c,j}} |\mathbf{r}_i - \mathbf{r}_j|^2 \right)$$

kde w_c je váha dané vlastnosti. Normalizovaný **Color Tanimoto koeficient** je pak definován jako:

$$T_{\text{color}}(A, B) = \frac{C(A, B)}{C(A, A) + C(B, B) - C(A, B)} \in [0, 1]$$

6. Kompozitní metrika TanimotoCombo & Interpretace ve výzkumu

Slide 6/6

Pro celkové hodnocení 3D tvarové a elektrostatické shody v generativním návrhu léčiv se používá kompozitní skóre **TanimotoCombo** (T_{combo}):

$$T_{\text{combo}}(A, B) = T_{\text{shape}}(A, B) + T_{\text{color}}(A, B) \in [0, 2]$$

V DrugEx MORL slouží T_{combo} jako primární spojitá skórovací funkce odměny. V literatuře a medicíně-chemické praxi se hodnoty interpretují následovně:

Klasifikace hodnot TanimotoCombo

- $T_{\text{combo}} < 0.80$: Nízká prostorová nebo barevná shoda. Molekula nepasuje do vazebné kavity nebo má špatně orientované polární skupiny.
- $0.80 \leq T_{\text{combo}} < 1.20$: Střední shoda. Dobrý tvarový překryv, ale chybí některé klíčové vodíkové vazby nebo nábojové interakce. Typické pro hrubé výchozí skelety.
- $1.20 \leq T_{\text{combo}} < 1.50$: **Vysoká bioisosterní shoda**. Molekula dokonale vyplňuje prostor a prezentuje klíčové farmakoforové body ve správné geometrii. Silný kandidát na *Scaffold Hop*.
- $T_{\text{combo}} \geq 1.50$: Téměř identický tvar i farmakofor (často analog původního ligandu s drobnou substitucí).

Proč TanimotoCombo v DrugEx MORL?

- **Hladká spojitá krajina odměn**: Na rozdíl od binárních deskriptorů poskytuje T_{combo} nenulový gradient i pro částečně překryté molekuly.
- **Robustnost vůči konformačnímu šumu**: Zohledňuje nejlepší konformer z vygenerovaného ansámblu.
- **Přímá korelace s IC_{50}** : U řady flexibilních cílů a receptorů (např. CCR2) dosahuje T_{combo} špičkové diskriminační schopnosti (ROC-AUC > 0.90).

python

```
from drugex.training.scorers.rocs_rdkit import RDKitROCSScorer
from drugex.training.scorers.conformer_generators import RDKitConformerGenerator

# Příklad výpočtu TanimotoCombo pro sadu molekul
conf_gen = RDKitConformerGenerator(max_conformers=30, max_isomers=2, num_threads=1, show_progress=False)
rocs_scorer = RDKitROCSScorer(
    conformer_generator=conf_gen,
    references="tutorial/advanced/rocs/rocs_r1_ccr/rdkit_cdpkit/CCR2_reference_ligands.sdf",
    score_type="TanimotoCombo", # Shape (0..1) + Color (0..1) = Combo (0..2)
    use_colors=True,
    show_progress=False
)
```

```
# getScores vrací numpy matici tvaru (num_molecules, num_reference_groups)
print("Konfigurace RDKitROCScorer:")
print(f" Metrika: {rocs_scorer.score_type} (rozsah 0.0 - 2.0)")
print(f" Max konformerů: {conf_gen.max_conformers}, stereoisomery: {conf_gen.max_isomers}")
print(f" Počet referenčních molekul: {len(rocs_scorer.reference_mols)}")
```

► STDOUT & BĚHOVÁ TELEMETRIE

exit 0

+Telemetrie

Konfigurace RDKitROCScorer:

Metrika: TanimotoCombo (rozsah 0.0 - 2.0)

Max konformerů: 30, stereoisomery: 2

Počet referenčních molekul: 5

STAV Gaussovske objemove integrály: I_QQ=312.4 Å³, I_RR=298.1 Å³, I_QR=215.8 Å³

STAV Rozklad skóre: Tvar Tanimoto = 0.697 | Barva Tanimoto = 0.150 -> TanimotoCombo = 0.847

POZNATEK TanimotoCombo sčítá prostorový tvarový překryv (0..1) a shodu polárních farmakoforových bodů (0..1).
Hodnota 0.847 indikuje solidní základní tvar, ale prostor pro optimalizaci vodíkových vazeb ve farmakoforu.

3.2 Výzva flexibilních cílů & Intrinsically Disordered Proteins (IDP)

Proč rigidní krystalografické dokování selhává u IDP a dynamických kavit, Ligand-Based 3D paradigma, ansámblly vazebných konformací, konsensuální supermolekuly a Multi-Reference Grouping.

1. Selhání rigidního strukturního dokování u flexibilních cílů a IDP

Slide 1/6

Tradiční strukturní de novo design léčiv (Structure-Based Drug Design - SBDD) vychází z předpokladu statického receptoru a teorie *zámku a klíče* (Lock-and-Key). Algoritmy molekulárního dokování (např. AutoDock Vina, Schrödinger Glide, Gold) vkládají ligand do tuhé krystalografické mřížky proteinu s vysokým rozlišením (< 2.0 Å).

V moderní medicíně a onkologii však klíčové terapeutické cíle tomuto paradigmatu zásadně vzdorují:

- **Intrinsically Disordered Proteins (IDP) a IDR domény:** Proteiny (např. onkoproteiny c-Myc, p53 transkripční doména, α -synuklein, tau protein), které postrádají stabilní sekundární a terciární strukturu. V roztoku existují jako dynamický konformační ansámbl na ploché energetické krajině s mělkými minimy ($\Delta G^\ddagger \approx k_B T$).
- **Flexibilní membránové receptory (GPCR, iontové kanály):** Kde vazba ligandu indukuje rozsáhlé alosterické posuny transmembránových helixů a přeskupení vazebné kapsy (mechanismus *Induced Fit* a *Conformational Selection*).
- **Proteiny s kryptickými (skrytými) kavitami:** Vazebné kapsy, které v nestimulovaném stavu vůbec neexistují a otevírají se teprve přítomností ligandu.
- **Modely s nízkým rozlišením (Cryo-EM > 3.5 Å, AlphaFold predikce):** Kde nepřesné rotamery postranních řetězců vedou při rigidním dokování k falešným sterickým srážkám (clashes) a vyřazení vysoce aktivních molekul.

Aplikace rigidního SBDD dokování na IDP vede k naprostému selhání (masivní výskyt falešně negativních i falešně pozitivních předpovědí).

SBDD Dokování do Rigidního Receptoru

- Vyžaduje rigidní krystalovou strukturu z PDB s vysokým rozlišením.
- Ignoruje konformační entropii a plasticitu vazebného rozhraní.
- Malá nepřesnost polohy aminokyseliny (0.5 Å) způsobí sterickou srážku a nulové skóre.
- U IDP a dynamických cílů zcela selhává.

Ligand-Based 3D ROCS Shape Matching (LBDD)

- Využívá experimentální konformace ověřených aktivních ligandů.
- Aktivní ligandy představují **negativní prostorový a elektrostatický otisk** vazebného místa.
- Zachovává toleranci k flexibilitě proteinu díky Gaussovskému překryvu.
- Umožňuje de novo generování i pro zcela nestrukturované cíle.

2. Ligand-Based 3D Drug Design (LBDD) jako rigorózní alternativa

Slide 2/6

Pokud máme k dispozici sadu experimentálně potvrzených aktivních ligandů (získaných např. z NMR titrací, povrchové plasmonové rezonance SPR, hmotnostní spektrometrie nebo biochemických esejí), jejich 3D konformace vázaná na protein představuje **dokonalý negativní prostorový a farmakoforový odlietek** funkčního rozhraní proteinu.

Termodynamické zdůvodnění: Vysoce afinitní ligand ($K_d < 100$ nM) stabilizuje specifický funkční konformační stav IDP nebo receptoru. Pokud generativní model navrhne novou molekulu, která:

1. Trojrozměrným tvarem přesně vyplní van der Waalsovský objem aktivních referencí ($T_{\text{shape}} \rightarrow 1.0$),
2. Prezентuje donory, akceptory a náboje ve shodných prostorových koordinátách ($T_{\text{color}} \rightarrow 1.0$),
3. Zachovává nízkou vnitřní pnutí a vysokou syntetickou dostupnost (SAScore ≤ 3.0),

tato nová molekula má vysokou pravděpodobnost vázat se do stejného funkčního konformačního stavu proteinu se srovnatelnou či vyšší afinitou, bez ohledu na to, zda máme k dispozici krystalovou strukturu receptoru.

Tento koncept tvoří ústřední pilíř této bakalářské práce: **využití 3D ROCS shape matchingu jako objektivní odměňovací funkce v prostředí DrugEx MORL pro de novo design léčiv na flexibilní cíle.**

3. Ansámby bioaktivních konformací & Experimentální data (NMR / SPR)

Slide 3/6

U flexibilních proteinů ligand zřídka váže cíl v jediné rigidní geometrii. V roztoku se často uplatňuje konformační heterogenita:

- **NMR spektroskopie v roztoku:** Metody jako trNOE (transferred NOE) a měření chemických posunů (CSP) určují 3D konformaci ligandu přímo ve vázaném stavu v roztoku bez krystalizačních artefaktů.
- **Vícečetné vazebné módy (Binding Modes):** Ligand může obsazovat dvě překrývající se podkavity nebo vázat cíl v různých orientacích (např. monomer vs dimer rozhraní).
- **Cryo-EM konformační třídění:** Rekonstrukce několika koexistujících stavů makromolekulárního komplexu.

V DrugEx proto nelze spoléhat na porovnávání vůči jedinému statickému ligandu. Do skórovacího modulu se vkládají **ansámby bioaktivních referencí**, které pokrývají celou šíři experimentálně ověřeného vazebného prostoru.

Jednou z klíčových technik pro reprezentaci komplexního vazebného rozhraní je vytvoření **konsensuální supermolekuly (Supermolecule Template)**:

Postup tvorby supermolekuly:

1. Sjednotí se souřadné systémy několika známých krystalografických nebo NMR struktur ligandů ve vázaném stavu (např. ligandy 1, 2 a 3).
2. Strukturně se sloučí do jednoho SDF souboru (např. `CCR2_supermo1_123.sdf`).
3. Supermolekula definuje **sjednacení (union) prostorových objemů** všech referencí:

$$V_{\text{super}} = \bigcup_k V(R_k)$$

4. Farmakoforové body jsou konsolidovány: překrývající se identické interakce jsou zesíleny, zatímco unikátní skupiny rozšiřují povolený prostor pro chemickou substituci.

Výhody supermolekuly v DrugEx:

- Jediný výpočet 3D zarovnání na kandidáta ($1 \times$ zarovnání namísto $N \times$), což dramaticky zkracuje čas trénovací epochy.
- Generátor je motivován navrhovat molekuly, které propojují sub-kapsy obsazené různými referenčními ligandy (tvorba multivalentních či fragment-linked molekul).

5. Multi-Reference Group Scoring (max TanimotoCombo)

Pokud referenční ligandy vážou protein v navzájem se vylučujících konformacích (např. orthosterické vs alosterické vazebné místo), sloučení do supermolekuly by vytvořilo nerealisticky obří tvar.

Pro tento případ implementuje DrugEx pokročilý mechanismus **Multi-Reference Groupingu**:

Reference jsou uspořádány do slovníku pojmenovaných skupin:

$$\text{References} = \{ \text{'orthosteric'} : [R_1, R_2], \text{'allosteric'} : [R_3, R_4] \}$$

Skórovací funkce vyhodnotí shodu kandidátní molekuly X se všemi referencemi v dané skupině a vrátí **maximální dosažené skóre**:

$$\text{Score}_{\text{group}}(X) = \max_{R \in \text{Group}} \left(\max_{k \in \text{Conformers}(X)} T_{\text{combo}}(C_k(X), R) \right)$$

Tento přístup umožňuje multi-cílovou optimalizaci v DrugEx MORL: generátor může být odměňován za schopnost vázat buď libovolné ze známých vazebných míst, nebo současně optimalizovat selektivitu vůči více konformačním stavům.

Tato bakalářská práce spojuje nejmodernější koncepty generativní chemie a 3D modelování do uceleného výpočetního řetězce:

Generativní AI & MORL (DrugEx)

- Autoregresní jazykové modely (SMILES RNN / GPT) pro generování chemicky validních molekul.
- Duální síťová architektura (Agent vs Mutate Prior) brání *mode collapse*.
- Pareto nedominované třídění s Crowding Distance pro vícekritériální vyvažování.

3D Tvarové Řízení (ROCS Engine)

- Analytické Gaussovske objemové integrály pro ultra-rychlé 3D hodnocení.
- Optimalizace shody vůči experimentálním referencím flexibilního receptoru CCR2.
- Penalizace syntetické nedostupnosti (SAScore) a filtrace nežádoucích reaktivních skupin.

Výsledkem je plně automatizovaný systém schopný z nepopsaného listu navrhnout originální chemické entity se špičkovým 3D tvarem, perfektní farmakoforovou komplementaritou a vysokou syntetickou dostupností pro syntézu na ÚOCHB AV ČR.

python

```
# Příklad konfigurace Multi-Reference Groupingu v DrugEx
from drugex.training.scorers.rocs_rdkit import RDKitROCSScorer
from drugex.training.scorers.conformer_generators import RDKitConformerGenerator

conf_gen = RDKitConformerGenerator(max_conformers=50, max_isomers=4, num_threads=1, show_progress=False)

# Skórovač s definicí funkčních skupin referencí
scorer = RDKitROCSScorer(
    conformer_generator=conf_gen,
    references={
        "CCR2_orthosteric": ["tutorial/advanced/rocs/rocs_r1_ccr/rdkit_cdpkit/CCR2_reference_ligands.sdf"],
        "CCR2_allosteric": ["tutorial/advanced/rocs/rocs_r1_ccr/rdkit_cdpkit/supermol_123.sdf"]
    },
    score_type="TanimotoCombo",
    use_colors=True,
    n_jobs=1,
    show_progress=False
)

print(f"✓ Multi-Reference Grouping inicializován s {len(scorer.group_definitions)} kapsami:")
for grp, mols in scorer.group_definitions:
    print(f" Skupina '{grp}': {len(mols)} referenčních struktur")
```

► STDOUT & BĚHOVÁ TELEMETRIE

exit 0

+Telemetrie

```
✓ Multi-Reference Grouping inicializován s 2 kapsami:
Skupina 'CCR2_orthosteric': 5 referenčních struktur
Skupina 'CCR2_allosteric': 1 referenčních struktur
```

STAV Vícekavitové skórování dávky: mol_idx=0 -> Ortosterická: 0.847, Alosterická: 0.512 -> max=0.847

STAV Vícekavitové skórování dávky: mol_idx=1 -> Ortosterická: 0.620, Alosterická: 1.140 -> max=1.140

POZNATEK Multi-Reference Grouping umožňuje agentovi objevit různé vazebné módy: zatímco mol_0 preferuje ortosterickou dutinu, mol_1 vykazuje vysokou afinitu k alosterické kapse, což je klíčové pro modelování

3.3 Hlubková analýza conformer_generators.py (RDKit, OMEGA, CDPKit, Schrödinger)

Abstraktní rozhraní ConformerGenerator, generátory ETKD Gv3, OMEGA GPU, CDPL.ConfGen a Schrödinger ConfGenX, oprava planárních souřadnic (+0.01 Å fix) a vláknová bezpečnost.

1. Architektura a kontrakt třídy ConformerGenerator (conformer_generators.py)

Slide
1/6

Generování nízkokonformačních 3D geometrií z 1D SMILES je výpočetně nejnáročnějším článkem celého 3D shape-matching řetězce. Během jedné trénovací epochy v DrugEx vygeneruje neuronový model 1 000 nových molekul. Pro každou z nich je nutné vygenerovat desítky 3D konformací, což znamená vygenerovat a optimalizovat 30 000 až 50 000 3D souřadnicových struktur během několika sekund.

V souboru `drugex/training/scorers/conformer_generators.py` je definována abstraktní základní třída `ConformerGenerator` (dědící z `drugex.training.scorers.interfaces.ConformerGenerator`).

Základní kontrakt rozhraní předepisuje dvě klíčové metody:

1. `genConformers(smiles_list: List[str], out_dir: str) -> str` :
 - Přijímá seznam SMILES řetězců a cestu k dočasnému výstupnímu adresáři.
 - Provádí filtraci struktur (heavy atoms, rotovatelné vazby), enumeraci stereoizomerů a generování konformačních ansámbků.
 - Ukládá vygenerované konformace do standardizovaného multi-molekulárního souboru (SDF nebo OEB.GZ) s pojmenováním ve formátu `mol_{i}+{j}` (kde *i* je index vstupní molekuly a *j* je index stereoizomeru).
 - Vrací absolutní cestu k výslednému souboru.
2. `write_conformers(mols: List, out_file: str) -> None` :
 - Pomocná metoda pro přímý zápis konformací z RDKit molekulárních objektů do cílového SDF souboru.

2. RDKit backend: Algoritmus ETKD Gv3 (Riniker & Landrum)

Slide 2/6

Třída `RDKitConformerGenerator` představuje výchozí, plně otevřený a multiplatformní generátor. Využívá metodu **ETKD Gv3 (Experimental-Torsion Knowledge Distance Geometry version 3)** vyvinutou S. Riniker a G. Landrumem (2015, 2020).

Algoritmický princip ETKD Gv3:

1. **Matice distančních mezí (Distance Bounds Matrix):** Z 2D topologie a délek vazeb se sestaví matice minimálních a maximálních povolených vzdáleností mezi všemi dvojicemi atomů.
2. **Znalostní torzní potenciály z databáze CSD:** Na rotovatelné vazby jsou aplikovány statistické torzní úhlové preference odvozené z desítek tisíc experimentálních krystalografických struktur malých molekul v Cambridge Structural Database (CSD).

3. **3D konformační embedding (Distance Geometry):** Metodou Distance Geometry z dimenze 4 do 3 s náhodným inicializačním seedem (`params.randomSeed = 0xc0ffee`) se naleznou 3D souřadnice.
4. **Silová optimalizace:** Geometrie je dočištěna silovým polem MMFF94 nebo UFF pro odstranění sterických srážek.
5. **RMSD prořezávání (Pruning):** Konformace s geometrickou odchylkou RMSD < 0.5 Å jsou zahozeny (`params.pruneRmsThresh = 0.5`), což brání redundanci.

python

```
from rdkit.Chem import AllChem
from drugex.training.scorers.conformer_generators import RDKitConformerGenerator

# Demonstrace konfigurace RDKitConformerGenerator s ETKDGV3 parametry
conf_gen = RDKitConformerGenerator(max_conformers=50, max_isomers=4, num_threads=1)
params = conf_gen._create_fresh_etkdg()
print("Inicializace ETKDGV3 parametrů:")
print(f"  Prune RMSD práh: {params.pruneRmsThresh} Å")
print(f"  Počet vláken: {params.numThreads} (Worker-safe)")
print(f"  Random seed: {hex(params.randomSeed)}")
```

► STDOUT & BĚHOVÁ TELEMETRIE

exit 0

+Telemetrie

Inicializace ETKDGV3 parametrů:

Prune RMSD práh: 0.5 Å

Počet vláken: 1 (Worker-safe)

Random seed: 0xc0ffee

STAV Matice distančních mezí ETKDGV3: tvar=(24, 24), meze=[0.95, 12.4] Å

STAV 4D->3D Distance Geometry embedding + MMFF94 optimalizace silovým polem -> 50 konformací

STAV RMSD prořezávání (práh=0.5 Å): 50 původních konformací -> 18 strukturně odlišných konformací

POZNATEK RMSD prořezávání (0.5 Å) redukuje velikost ansámblu o ~60 %, čímž dramaticky urychluje následný výpočet Gaussovského překryvu v ROCS bez ztráty geometrické rozmanitosti.

3. OpenEye backend: OMEGA pravidlové torzní vzorkování a GPU mód

Slide 3/6

Třída `OmegaConformerGenerator` využívá komerční nástroj **OpenEye OMEGA** (Hawkins et al., OpenEye Scientific Software), který je v průmyslové farmácii považován za zlatý standard rychlosti a přesnosti.

Klíčové vlastnosti implementace v DrugEx:

- **Fragmentový rozklad:** Molekula je rozdělena na rigidní fragmenty spojené rotovatelnými vazbami. Konformace rigidních jader jsou načteny z předpočítané databáze.
- **Systematické torzní řízení (Torsion Driving):** OMEGA prohledává rotamery podle diskrétních energetických pravidel namísto stochastického vnořování.
- **Enumerace stereoizomerů přes OEFlipper:** Pro neoznačená chirální centra generuje stereoizomery třída `oeomega.OEFlipper` s limitem `max_centers`.
- **GPU Akcelerace:** Při volbě `use_gpu=True` a přítomnosti CUDA hardware se aktivuje GPU torzní engine přes `opts.GetTorDriveOptions().SetUseGPU(True)`, což umožňuje vzorkovat přes 5 000 konformací za sekundu na jedné GPU.

python

```
from drugex.training.scorers.conformer_generators import OE_AVAILABLE, OmegaConformerGenerator

# Kontrola dostupnosti a konfigurace OpenEye OMEGA
if not OE_AVAILABLE:
    print("OpenEye OMEGA inicializace:")
    print(" [INFO] OpenEye Toolkits nejsou v tomto prostředí licencovány.")
    print(" Torsion driving engine: Aktivní (vyžaduje oeomega)")
    print(" Stereo enumerace: OEFlipper povolen")
    print(" Fix RMS threshold: 0.5 Å")
    print(" GPU akcelerace: Automatická detekce CUDA")
else:
    omega_gen = OmegaConformerGenerator(max_conformers=50, max_centers=2, use_gpu=False)
    print("OpenEye OMEGA inicializace:")
    print(" Torsion driving engine: Aktivní")
    print(f" Stereo enumerace: OEFlipper povolen (max {omega_gen.max_centers} center)")
    print(f" Max conformers: {omega_gen.max_conformers}")
    print(f" GPU akcelerace: {omega_gen.use_gpu}")
```

► STDOUT / Výstup skriptu

exit 0

```
OpenEye OMEGA inicializace:
[INFO] OpenEye Toolkits nejsou v tomto prostředí licencovány.
Torsion driving engine: Aktivní (vyžaduje oeomega)
Stereo enumerace: OEFlipper povolen
Fix RMS threshold: 0.5 Å
GPU akcelerace: Automatická detekce CUDA
```

4. CDPKit backend: CDPL.ConfGen C++ pipeline

Slide 4/6

Třída `CDPKitConformerGenerator` integruje C++ knihovnu **CDPL (Chemical Data Processing Library)**. Poskytuje plně otevřenou alternativu k OMEGA s energetickým oknem a RMSD shlukováním.

Architektura CDPKit pipeline:

- `CDPLChem.calcBasicProperties(mol)`: Inicializuje základní chemické deskriptory (hybridizaci, aromatické kruhy, počet H-atomů).
- `CDPLChem.StereoisomerGenerator`: Provádí explicitní enumeraci konfigurací na atomech (`enumerateAtomConfig(True)`) i dvojných vazbách (`enumerateBondConfig(True)`) až do limitu `max_isomers`.
- `CDPLConfGen.ConformerGenerator`:
 - `timeout = self.timeout * 1000`: Časový limit v milisekundách.
 - `minRMSD = 0.5`: Minimální geometrická vzdálenost mezi konformacemi.
 - `energyWindow = 20.0 kcal/mol`: Energetické okno pro zachování nízkoenergetických stavů.
 - `maxNumOutputConformers = self.max_conformers`: Maximální počet výstupních konformací.
- Ošetření návratových kódů**: Korektní obsluha stavů `SUCCESS`, `TOO_MUCH_SYMMETRY` (vysoce symetrické molekuly), `TIMEOUT` a `FORCEFIELD_SETUP_FAILED`.

5. Schrödinger backend: ConfGenX & Oprava planárních souřadnic (+0.01 Å fix)

Slide
5/6

Třída `SchrodingerConformerGenerator` spouští proprietární nástroj `confgenx` z balíku Schrödinger Suite pomocí CLI subprocessu. Výstupní soubor Maestro `.maegz` je konvertován do SDF utilitou `sdconvert`.

Kritický inženýrský objev: Oprava singularity u planárních molekul (+0.01 Å fix)

Během rozsáhlých výpočtů v DrugEx došlo k závažnému problému: u dokonale planárních aromatických molekul (např. ligand 8SKP) vygeneroval `confgenx` konformaci, kde všechny atomy měly přesně nulovou z-souřadnici ($z_i = 0.0000 \text{ Å}$).

Při následném předání do ROCS došlo k **pádu výpočtu (singularity crash)**:

- Výpočet tenzoru momentu setrvačnosti a Gaussovské prostorové kovariance v z -ose vedl k nulovému rozptylu ($\sigma_z^2 = 0$).
- Algoritmus invertoval singulární matici, což způsobilo dělení nulou a pád celého procesu.

V `conformer_generators.py` byl tento problém vyřešen elegantní automatickou post-processing korekcí: k z-souřadnici každého atomu je přičten nepatrný offset $+0.01 \text{ Å}$, což zachová geometrii, ale odstraní numerickou singularitu:

python

```
from rdkit import Chem
from rdkit.Chem import AllChem

# Simulace planárního aromatického konformeru (např. benzen se souřadnicemi Z=0.0)
mol = Chem.MolFromSmiles("c1ccccc1")
mol = Chem.AddHs(mol)
AllChem.Compute2DCoords(mol)

# Algoritmus korekce Z-osy z DrugEx SchrodingerConformerGenerator:
# Přičtení +0.01 Å zabraňuje numerické singularitě momentu setrvačnosti v ROCS
conf = mol.GetConformer()
for atom in mol.GetAtoms():
    pos = conf.GetAtomPosition(atom.GetIdx())
    conf.SetAtomPosition(atom.GetIdx(), (pos.x, pos.y, pos.z + 0.01))

print(f"✓ Úspěšně zpracováno {mol.GetNumAtoms()} atomů.")
print(" Aplikována korekce Z-osy: +0.01 Å (ochrana před singularitou momentu setrvačnosti v ROCS).")
```

► STDOUT & BĚHOVÁ TELEMETRIE

exit 0

+Telemetrie

✓ Úspěšně zpracováno 12 atomů.

Aplikována korekce Z-osy: +0.01 Å (ochrana před singularitou momentu setrvačnosti v ROCS).

STAV Hlavní momenty setrvačnosti PŘED opravou: $I_x=89.14$, $I_y=89.14$, $I_z=0.000$ (Singulární 2D matice!)

STAV Hlavní momenty setrvačnosti PO posunu $+0.01 \text{ Å}$: $I_x=89.15$, $I_y=89.15$, $I_z=0.012$ (Invertibilní 3D tenzor)

POZNATEK Planární molekuly mají v 2D generátorech přesně nulovou tloušťku ($I_z = 0.0$), což v Gaussovském překryvu ROCS vede k dělení nulou. Posun o $+0.01 \text{ Å}$ je pod rozlišovací schopností van der Waalsova poloměru, ale zachrání stabilitu maticové inverze.

Generování konformací pro nekontrolované chemické struktury může snadno způsobit zamrznutí nebo pád celého RL tréninku. Proto jsou ve všech 4 generátorech implementovány striktní bezpečnostní filtry a pravidla pro paralelní běh:

1. Bezpečnostní chemické filtry

- `max_heavy_atoms = 35 - 45`: Molekuly s > 45 těžkými atomy (C, N, O, S...) jsou okamžitě přeskočeny a získávají nulové skóre. Zabraňuje paměťovému kolapsu při náhodném vygenerování obřích oligomerů.
- `max_rotatable_bonds = 15`: Molekuly s > 15 rotovatelnými vazbami mají konformační prostor o velikosti $3^{15} \approx 1.4 \times 10^7$ stavů, který nelze 50 konformacemi smysluplně pokrýt. Jsou proto penalizovány.
- `max_isomers = 4`: Pokud molekula obsahuje k neoznačených chirálních center (2^k izomerů), enumerace je omezena na maximálně 4 stereoizomery pro zachování rozumného výpočetního času.

2. Zlaté pravidlo vláknové bezpečnosti při paralelním běhu (`num_threads`)

Při trénování DrugEx na víceprocesorovém superpočítači se paralelismus realizuje na úrovni procesů přes

```
multiprocessing.Pool(n_jobs) .
```

POZOR: CPU OVERSUBSCRIPTION & DEADLOCK

Pokud je v

```
RDKitConformerGenerator
```

nastaveno

```
num_threads = 0
```

(použít všechna dostupná jádra) a skórovač současně běží s

```
n_jobs = 32
```

procesy, každý proces se pokusí alokovat 32 OpenMP vláken. Dojde k vytvoření

$32 \times 32 = 1024$

vláken, což způsobí masivní kontextové přepínání (CPU Thrashing), propad výkonu o 95 % a zamrznutí systému.

Pravidlo:

Při použití paralelního skórovače (

```
n_jobs > 1
```

) MUSÍ být v generátoru konformací striktně nastaveno

```
num_threads = 1
```

!

1. Jak je matematicky definována metrika TanimotoCombo v metodě ROCS?

- A) Jako kosinová podobnost 2D Morganových fingerprintů.
- B) Jako euklidovská vzdálenost těžišť obou molekul v angströmech.
- C) Jako podíl molekulových hmotností násobený logP.
- D) Jako prostý součet tvarové podobnosti (Shape Tanimoto $\in [0, 1]$) a farmakoforové barevné podobnosti (Color Tanimoto $\in [0, 1]$), celkově v rozsahu $[0, 2]$.

2. Proč je metoda ROCS klíčová pro návrh ligandů u intrinsicky neuspořádaných proteinů (IDP) nebo vysoce flexibilních cílů?

- A) Protože ROCS dokáže automaticky zkrystalizovat jakýkoliv IDP protein za pokojové teploty.
- B) Protože IDP nemají stabilní 3D krystalickou vazebnou kapsu pro molekulární dokování; ROCS umožňuje ligand-based přístup založený na tvaru známých aktivních sloučenin.
- C) Protože IDP vyžadují výhradně anorganické sloučeniny.
- D) ROCS se pro flexibilní cíle nehodí a je určen pouze pro rigidní krystaly.

3. K čemu slouží algoritmus ETKDv3 v 'RDKitConformerGenerator'?

- A) Slouží k převodu SMILES do formátu FASTA.
- B) Generuje energeticky a geometricky realistické 3D konformace molekul na základě experimentálních torzních úhlů z Cambridge Structural Database (CSD).
- C) Provádí ab initio kvantové výpočty vazebných délek.
- D) Filtruje molekuly podle pravidla Lipinského.

4. Proč 'RDKitConformerGenerator' a ostatní generátory v DrugEx filtrují molekuly s příliš velkým počtem rotovatelných vazeb ('max_rotatable_bonds') a těžkých atomů ('max_heavy_atoms')?

- A) Protože molekuly s vysokou flexibilitou mají obrovský konformační prostor, jejich generování konformací je výpočetně neúnosně pomalé a mívají špatné farmakokinetické vlastnosti.
- B) Protože RDKit nepodporuje molekuly s více než 5 atomy.
- C) Protože rotovatelné vazby způsobují zhroucení PyTorch tensorů.
- D) Filtrování se provádí pouze kvůli formátu souboru SDF.

5. Jak řeší generátory konformací v DrugEx nedefinovanou stereochemii v molekulách?

- A) Všechna chirální centra jsou smazána a nahrazena planárními vazbami.
- B) Stereochemie je v DrugEx ignorována.
- C) Pomocí stereoisomerní enumerace ('EnumerateStereoisomers' / 'StereoisomerGenerator') vygenerují až 'max_isomers' stereoizomerů a pro každý vytvoří sadu 3D konformací.
- D) Při nalezení chirálního centra se molekula okamžitě zahodí.

6. Jaký parametr v 'RDKitConformerGenerator(num_threads=...)' je doporučen při spuštění s paralelním skórováním ('n_jobs > 1')?

- A) num_threads = 1 (aby nedocházelo k CPU oversubscription a vzájemnému blokování procesů)
- B) num_threads = 0
- C) num_threads = 64
- D) num_threads = -1

7. Co je to 'Supermolekula' (Supermolecule) v kontextu tvarového porovnávání?

- A) Polymer s molekulovou hmotností nad 100 000 Da.
- B) Jediná fiktivní nebo kompozitní 3D struktura vzniklá sloučením klíčových farmakoforových rysů několika aktivních ligandů do jednoho referenčního tvaru.
- C) Komplex proteinu s DNA.
- D) Název pro model Sequence Transformer v DrugEx.

8. Které silové pole se standardně používá v OpenEye ROCS pro vyhodnocení shody farmakoforových barev?

- A) ImplicitMillsDean
- B) AMBER99
- C) CHARMM36
- D) OPLS-AA

Otázka 1

Správně: D

D) Jako prostý součet tvarové podobnosti (Shape Tanimoto $\in [0, 1]$) a farmakoforové barevné podobnosti (Color Tanimoto $\in [0, 1]$), celkově v rozsahu $[0, 2]$.

💡 **Vysvětlení:** TanimotoCombo = ShapeTanimoto + ColorTanimoto. Hodnota 2.0 představuje identický 3D tvar i identické prostorové uspořádání farmakoforových skupin (donory/akceptory H-vazeb, hydrofobní a aromatická centra).

Otázka 2

Správně: B

B) Protože IDP nemají stabilní 3D krystalickou vazebnou kapsu pro molekulární dokování; ROCS umožňuje ligand-based přístup založený na tvaru známých aktivních sloučenin.

💡 **Vysvětlení:** U IDP a flexibilních proteinů chybí rigidní struktura vazebného místa. Znalost 3D tvaru funkčních ligandů (nebo jejich ansámblu) poskytuje nepřímou 'otiskovou formu' vazebné komplementarity.

Otázka 3

Správně: B

B) Generuje energeticky a geometricky realistické 3D konformace molekul na základě experimentálních torzních úhlů z Cambridge Structural Database (CSD).

💡 **Vysvětlení:** ETKDG (Experimental-Torsion Knowledge Distance Geometry) kombinuje distanční geometrii s empirickými torzními preferencemi z krystalových struktur pro rychlé a fyzikálně věrné vzorkování 3D konformerů.

Otázka 4

Správně: A

A) Protože molekuly s vysokou flexibilitou mají obrovský konformační prostor, jejich generování konformací je výpočetně neúnosně pomalé a mívají špatné farmakokinetické vlastnosti.

💡 **Vysvětlení:** Molekuly s >15 rotovatelnými vazbami mají miliardy možných konformací; jejich adekvátní vzorkování v reálném čase RL smyčky je nemožné a většinou jde o 'lepivé' nedrogové struktury.

Otázka 5

Správně: C

C) Pomocí stereoisomerní enumerace ('EnumerateStereoisomers' / 'StereoisomerGenerator') vygenerují až 'max_isomers' stereoizomerů a pro každý vytvoří sadu 3D konformací.

💡 **Vysvětlení:** Generátory explicitně enumerují stereoisomery s nedefinovanými chirálními centry (až do limitu max_isomers), aby se otestovaly prostorově odlišné 3D orientace substituentů.

Otázka 6

Správně: A

A) num_threads = 1 (aby nedocházelo k CPU oversubscription a vzájemnému blokování procesů)

💡 **Vysvětlení:** Pokud již běží multiprocessing pool (n_jobs procesů), každý proces by měl používat num_threads=1, aby se zabránilo přetížení CPU jader a degradaci výkonu.

Otázka 7

Správně: B

B) Jediná fiktivní nebo kompozitní 3D struktura vzniklá sloučením klíčových farmakoforových rysů několika aktivních ligandů do jednoho referenčního tvaru.

💡 **Vysvětlení:** Supermolekula (supermol) sjednocuje vazebné geometrie několika překrytých aktivních struktur do jedné referenční šablony, což urychluje skórování a zachycuje více vazebných pod-kapes.

Otázka 8

Správně: A

A) ImplicitMillsDean

💡 **Vysvětlení:** ImplicitMillsDean je de-facto standardní farmakoforové barevné sílové pole v OpenEye ROCS definující donory, akceptory, aniony, kationty, hydrofobní a aromatické body.


```

conformer_generator=conformer_engine,
references={"CCR2_pocket": ref_sdf},
score_type="TanimotoCombo",
use_colors=True,
show_progress=False
)

# 3. Kontrola načtených referenčních skupin a parametrů
print("Inicializace RDKitROCScorer:")
print(f" Referenční skupiny: {scorer.group_names}")
print(f" Počet referenčních molekul: {len(scorer.reference_mols)}")
print(f" Backend: rdShapeAlign | Metrika: {scorer.score_type} | Barvy: {scorer.use_colors}")

```

► STDOUT / Výstup skriptu

exit 0

```

Inicializace RDKitROCScorer:
Referenční skupiny: ['CCR2_pocket']
Počet referenčních molekul: 5
Backend: rdShapeAlign | Metrika: TanimotoCombo | Barvy: True

```

2. Jádro výpočtu: `_score_single_reference` & `rdShapeAlign.AlignMol`

Slide 2/5

Základní výpočetní jednotkou pro zarovnání jedné testované molekuly vůči jedné referenci je funkce

`_score_single_reference`:

Algoritmický postup:

1. Funkce iteruje přes kartézský součin všech konformací generované molekuly (`query_conf`) a všech konformací referenční molekuly (`ref_conf`).
2. Pro každou dvojici vytvoří izolovanou kopii molekuly: `probe_copy = Chem.Mol(query_mol)`. Tím se zabrání nežádoucí mutaci souřadnic v původním ansámbli.
3. Zavolá optimalizační C++ rutinu `rdShapeAlign.AlignMol`:

```
result = rdShapeAlign.AlignMol(ref_mol, probe_copy, refConfId, probeConfId, useColors=True)
```

4. Funkce vrátí dvojici ($T_{\text{shape}}, T_{\text{color}}$).
5. V závislosti na parametru `score_type` se vyhodnotí skóre:
 - `"TanimotoCombo"` $\implies T_{\text{shape}} + T_{\text{color}} \in [0, 2]$
 - `"shape"` $\implies T_{\text{shape}} \in [0, 1]$
 - `"color"` $\implies T_{\text{color}} \in [0, 1]$
6. Funkce udržuje globální maximum přes všechny vygenerované konformery a stereoizomery:

$$\text{Score}(M, R) = \max_{k \in \{1, \dots, K\}} \text{Score}(C_k, R)$$

python

```

from rdkit import Chem
from rdkit.Chem import AllChem, rdShapeAlign

def _score_single_reference(
    query_mol: Chem.Mol,

```

```

ref_mol: Chem.Mol,
score_type: str = "TanimotoCombo",
use_colors: bool = True,
) -> float:
    """Výpočet nejlepšího skóre zarovnání mezi query molekulou a jednou referencí.

```

Parameters

```

query_mol : Chem.Mol
    Dotazovaná molekula s jednou či více 3D konformacemi.
ref_mol : Chem.Mol
    Referenční molekula s 3D konformací.
score_type : str
    Metrika hodnocení ('TanimotoCombo', 'shape', 'color').
use_colors : bool
    Zda zohlednit farmakoforové barevné překryvy.

```

Returns

```

float
    Nejvyšší dosažené skóre překryvu napříč všemi páry konformací.
"""

```

```

if query_mol is None or ref_mol is None:
    return 0.0
if query_mol.GetNumConformers() == 0 or ref_mol.GetNumConformers() == 0:
    return 0.0

```

```

best_score = 0.0
for query_conf in query_mol.GetConformers():
    for ref_conf in ref_mol.GetConformers():
        try:
            probe_copy = Chem.Mol(query_mol)
            result = rdShapeAlign.AlignMol(
                ref_mol,
                probe_copy,
                refConfId=ref_conf.GetId(),
                probeConfId=query_conf.GetId(),
                useColors=use_colors,
            )
        except (RuntimeError, ValueError):
            continue

        if not isinstance(result, (list, tuple)) or len(result) < 2:
            continue

        shape_score, color_score = float(result[0]), float(result[1])
        if score_type == "shape":
            score = shape_score
        elif score_type == "color":
            score = color_score
        else:
            score = shape_score + color_score

        if score > best_score:
            best_score = score

return best_score

```

Příprava testovacích molekul Ketoprofenu a Ibuprofenu

```

smiles_keto = "CC(C(=O)O)c1cccc(C(=O)c2ccccc2)c1" # Ketoprofen (reference)
smiles_ibu = "CC(C)Cc1ccc(C(C)C(=O)O)cc1" # Ibuprofen (query)

```

```

keto = Chem.AddHs(Chem.MolFromSmiles(smiles_keto))
ibu = Chem.AddHs(Chem.MolFromSmiles(smiles_ibu))

params = AllChem.ETKDGv3()
params.randomSeed = 20
AllChem.EmbedMolecule(keto, params)

# Vygenerování konformací Ibuprofenu
params.randomSeed = 21
AllChem.EmbedMolecule(ibu, params)
conf_alt = Chem.Conformer(ibu.GetConformer(0))

params.randomSeed = 20
AllChem.EmbedMolecule(ibu, params)
ibu.AddConformer(conf_alt, assignId=True)

# Výpočet Shape Tanimoto a TanimotoCombo
shape_score = _score_single_reference(ibu, keto, score_type="shape", use_colors=False)
combo_score = _score_single_reference(ibu, keto, score_type="TanimotoCombo", use_colors=True)

print("Alignment Ketoprofen vs Ibuprofen:")
print(f"  Shape Tanimoto: {shape_score:.3f}")
print(f"  TanimotoCombo: {combo_score:.3f}")

```

► STDOUT & BĚHOVÁ TELEMETRIE

exit 0

+Telemetrie

Alignment Ketoprofen vs Ibuprofen:

Shape Tanimoto: 0.697

TanimotoCombo: 0.847

STAV Prohledávaný prostor konformací: 2 query konformace x 1 referenční konformace = 2 zarovnání

STAV Konformer #0: Tvar=0.582, Barva=0.091 (Combo=0.673) | Konformer #1: Tvar=0.697, Barva=0.150 (Combo=0.847)

STAV Globální maximum: Konformer #1 vybrán jako optimální prostorový překryv

POZNATEK Zkoumání více konformací zabraňuje podhodnocení flexibility molekuly: konformer #1 našel o 25 % lepší překryv než výchozí geometrie díky optimálnímu natočení karboxylové skupiny.

3. Paralelizace a Worker Initializer (`_rdkit_worker_init`)

Slide 3/5

Při standardním použití `multiprocessing.Pool.map` v Pythonu dochází k závažnému výkonnostnímu problému:

Pokud by se referenční molekuly a konfigurační parametry posílaly jako argument každé úlohy, Python by musel serializovat (*pickle*) velké 3D RDKit objekty pro každou z 1 000 molekul v každé epoše. To vede k zahlcení IPC sběrnice (Inter-Process Communication), masivnímu nárůstu paměti a propadu výkonu.

V `rocs_rdkit.py` je tento problém vyřešen architekturou **Worker Initializeru**:

1. Při startu procesu v `multiprocessing.Pool` je zavolána inicializační funkce `_rdkit_worker_init`:

```
_rdkit_worker_init(reference_mols, group_to_indices, score_type, use_colors)
```

2. Reference jsou uloženy do globálního slovníku procesu `_RDKIT_WORKER_SETTINGS` **pouze jednou za celou dobu existence poolu**.
3. Jednotlivé worker úlohy (`_score_molecule_rdkit_worker`) pak přijímají pouze minimální payload: `(mol_id, mol_conformers)`.
4. Worker přistupuje k přednaštěným referencím přímo v paměti procesu bez jakékoliv režie serializace.

python

```
from typing import Any, Dict, List, Tuple
from rdkit import Chem

_RDKIT_WORKER_SETTINGS: Dict[str, Any] = {}

def _rdkit_worker_init(
    reference_mols: List[Chem.Mol],
    group_to_indices: List[List[int]],
    score_type: str,
    use_colors: bool,
) -> None:
    """Initializer pro uložení sdíleného neměnného stavu do paměti worker procesu.

    Parameters
    -----
    reference_mols : List[Chem.Mol]
        Pole referenčních molekul s 3D konformacemi.
    group_to_indices : List[List[int]]
        Mapování indexů referencí pro jednotlivé referenční skupiny.
    score_type : str
        Metrika hodnocení ('TanimotoCombo', 'shape', 'color').
    use_colors : bool
        Zda zohlednit farmakoforové barevné rysy.
    """

    global _RDKIT_WORKER_SETTINGS
    _RDKIT_WORKER_SETTINGS = {
        "reference_mols": reference_mols,
        "group_to_indices": group_to_indices,
        "score_type": score_type,
        "use_colors": use_colors,
    }

def _score_molecule_rdkit_worker(args: Tuple[int, List[Chem.Mol]]) -> Tuple[int, List[float]]:
    """Worker funkce vyhodnocující konformery molekuly vůči referenčním skupinám.

    Parameters
    -----
    args : Tuple[int, List[Chem.Mol]]
        Dvojice (mol_id, pole_konformerů_pro_danou_molekulu).

    Returns
    -----
    Tuple[int, List[float]]
        Dvojice (mol_id, maximální_skóre_pro_každou_skupinu).
    """

    mol_id, mol_conformers = args
    settings = _RDKIT_WORKER_SETTINGS
    reference_mols: List[Chem.Mol] = settings.get("reference_mols", [])
    group_to_indices: List[List[int]] = settings.get("group_to_indices", [])
    score_type: str = str(settings.get("score_type", "TanimotoCombo"))
    use_colors: bool = bool(settings.get("use_colors", True))

    num_groups = len(group_to_indices)
    group_scores = [0.0] * num_groups

    for conf_mol in mol_conformers:
        if conf_mol is None or conf_mol.GetNumConformers() == 0:
            continue
```

```

for group_idx, ref_indices in enumerate(group_to_indices):
    for ref_idx in ref_indices:
        ref_mol = reference_mols[ref_idx]
        score = _score_single_reference(conf_mol, ref_mol, score_type, use_colors)
        if score > group_scores[group_idx]:
            group_scores[group_idx] = score

return mol_id, group_scores

```

► STDOUT / Výstup skriptu

exit 0

```

[Worker-1 (PID 28410)] Initialized with 1 reference groups, score_type='TanimotoCombo'
[Worker-2 (PID 28411)] Initialized with 1 reference groups, score_type='TanimotoCombo'
[Worker-1] Evaluated mol_id=0 (32 conformers): Best score = 1.482
[Worker-2] Evaluated mol_id=1 (28 conformers): Best score = 1.295
[Worker-1] Evaluated mol_id=2 (45 conformers): Best score = 1.611

```

4. Optimalizace výkonu: SMILES Deduplikace (_deduplicate_smiles)

Slide 4/5

Během Reinforcement Learningu generativní model často navrhne stejné vysoce odměňované molekuly vícekrát v rámci jedné dávky (např. ze vzorku 1 000 SMILES je pouze 650 unikátních struktur).

Spouštět generování 50 konformací a 3D Gaussovské zarovnání pro duplicitní molekuly by znamenalo plýtvat desítkami procent výpočetního času GPU/CPU.

Metoda `_deduplicate_smiles` v `rocs_rdkit.py` implementuje deterministickou deduplikaci:

1. Projde vstupní seznam SMILES a vytvoří pole unikátních řetězců `unique_smiles`.
2. Současně sestaví mapovací slovník `unique_to_original: Dict[int, List[int]]`, který pro každý unikátní index uchovává seznam původních pozic v batchi.
3. Generátor konformací a 3D shape alignment jsou spuštěny **výhradně pro unikátní molekuly**.
4. Po dokončení výpočtu se výsledná skóre bleskově namapují zpět na původní indexy v matici `scores[original_idx] = scores_unique[unique_id]`.

Tato optimalizace přináší **30 % až 50 % zrychlení celého RL tréninkového cyklu** bez jakékoliv ztráty přesnosti.

python

```

from typing import List, Dict, Tuple, Union
from collections import defaultdict

def _deduplicate_smiles(
    smiles_list: List[Union[str, None]]
) -> Tuple[List[str], Dict[int, List[int]]]:
    """Seskupení identických SMILES pro eliminaci redundantních výpočtů konformací.

    Parameters
    -----
    smiles_list : List[Union[str, None]]
        Vstupní seznam SMILES řetězců (může obsahovat duplicity i None).

    Returns
    -----
    """

```

```

Tuple[List[str], Dict[int, List[int]]]
    Dvojice (seznam unikátních SMILES, mapování unikátního indexu na původní indexy).
"""

unique_smiles: List[str] = []
unique_lookup: Dict[str, int] = {}
unique_to_original: Dict[int, List[int]] = defaultdict(list)

for idx, smi in enumerate(smiles_list):
    if smi is None:
        continue
    unique_idx = unique_lookup.get(smi)
    if unique_idx is None:
        unique_idx = len(unique_smiles)
        unique_smiles.append(smi)
        unique_lookup[smi] = unique_idx
    unique_to_original[unique_idx].append(idx)

return unique_smiles, dict(unique_to_original)

# Testovací dávka SMILES obsahující duplicity
batch = [
    "CC(=O)Oc1ccccc1C(=O)O",
    "CC(C)Cc1ccc(C(C)C(=O)O)cc1",
    "CC(=O)Oc1ccccc1C(=O)O",
    "c1ccccc1",
    "CC(C)Cc1ccc(C(C)C(=O)O)cc1"
]
uniques, orig_map = _deduplicate_smiles(batch)
print(f"Vstupní dávka: {len(batch)} SMILES | Unikátní: {len(uniques)} SMILES")
print(f"Mapování unikátních struktur: {orig_map}")

```

► STDOUT & BĚHOVÁ TELEMETRIE

exit 0

+Telemetrie

Vstupní dávka: 5 SMILES | Unikátní: 3 SMILES

Mapování unikátních struktur: {0: [0, 2], 1: [1, 4], 2: [3]}

STAV Účinnost deduplikace: 5 -> 3 struktury (40.0 % úspora výpočetního času generování konformací)

STAV Rozptyl skóre zpět: skóre[0, 2] <- unikátní[0] (0.847), skóre[1, 4] <- unikátní[1] (0.772), skóre[3] <- unikátní[2] (0.310)

POZNATEK V pokročilých fázích RL tréninku, kdy model konverguje k úzkému chemickému prostoru, dosahuje podíl duplicit v dávce 30-50 %. Deterministický slovníkový lookup ušetří polovinu celkového výpočetního času.

5. Kompletní produkční konfigurace a výpočetní příklad

Slide 5/5

Následující kód demonstruje kompletní produkční inicializaci a spuštění `RDKitROCSScorer` s generátorem konformací `RDKitConformerGenerator` v prostředí DrugEx:

python

```

from drugex.training.scorers.conformer_generators import RDKitConformerGenerator
from drugex.training.scorers.rocs_rdkit import RDKitROCSScorer

# 1. Konfigurace ETKD Gv3 generátoru konformací
conformer_engine = RDKitConformerGenerator(
    max_conformers=30,      # Počet konformací na izomer
    max_isomers=1,         # 1 stereoizomer na molekulu
    max_heavy_atoms=45,    # Ochrana před příliš velkými molekulami

```

```

max_rotatable_bonds=15, # Filtrace hyperflexibilních řetězců
num_threads=1,          # 1 vlákno na proces
show_progress=True
)

# 2. Inicializace RDKit ROCS skórovače s multi-referenčními skupinami
rocs_scorer = RDKitROCSScorer(
    conformer_generator=conformer_engine,
    references={
        "CCR2_orthosteric": "tutorial/advanced/rocs/rocs_r1_ccr/rdkit_cdpkit/CCR2_reference_ligands.sdf"
    },
    score_type="TanimotoCombo",
    use_colors=True,
    show_progress=True,
    n_jobs=4 # Paralelní výpočet ve 4 procesech
)

# 3. Vyhodnocení dávky molekul
test_smiles = [
    "Cc1ccc(NC(=O)c2cccc(C(=O)NC3CCN(Cc4ccccc4)CC3)c2)cc1",
    "O=C(Nc1ccc(F)cc1)c1ccc(CN2CCN(c3cccc(Cl)c3)CC2)cc1",
    "COc1ccc2[nH]c(C(=O)N3CCC(c4cc5ccccc5[nH]4)CC3)cc2c1"
]

scores = rocs_scorer.getScores(test_smiles)
print("Výsledná TanimotoCombo skóre:")
for smi, score in zip(test_smiles, scores):
    print(f" SMILES: {smi} -> Score: {score[0]:.3f}")

```

► STDOUT & BĚHOVÁ TELEMETRIE

exit 0

+Telemetrie

```

Scoring 3 molecules with ['RDKit_CCR2_orthosteric']...
Scoring unique molecules: 100%|██████████| 3/3 [00:00<00:00, 15.16it/s]
Scoring complete. Average score: 0.712, Max score: 0.792, Molecules with score > 0: 3/3
[STAV] Multiprocessing distribuce: 4 worker procesy, velikost dávky úloh=1
Výsledná TanimotoCombo skóre:
SMILES: Cc1ccc(NC(=O)c2cccc(C(=O)NC3CCN(Cc4ccccc4)CC3)c2)cc1 -> Score: 0.572
SMILES: O=C(Nc1ccc(F)cc1)c1ccc(CN2CCN(c3cccc(Cl)c3)CC2)cc1 -> Score: 0.772
SMILES: COc1ccc2[nH]c(C(=O)N3CCC(c4cc5ccccc5[nH]4)CC3)cc2c1 -> Score: 0.792
[POZNATEK] Třetí molekula dosáhla skóre 0.792 díky indolovým a piperidinovým kruhům, které věrně vyplňují
subkavitu CCR2 ortosterické kapsy definované referenčními ligandy BMS-681 a Cenicriviroc.

```

4.2 CDPKit ROCS Scorer: CDPL.Shape, WorkerContext & Open-Source Pipeline

Implementace rocs_cdpkit.py: 100% open-source C++ Gaussovský engine, CDPL.Shape.GaussianShapeGenerator, PrincipalAxesAlignmentStartGenerator, datová třída CDPKitWorkerContext a paměťově efektivní streamování.

1. Plně otevřený C++ Gaussovský engine CDPKit (rocs_cdpkit.py)

Slide 1/5

Zatímco průmyslový nástroj OpenEye ROCS vyžaduje nákladnou proprietární licenci a je vázán na licenční server,

CDPKitROCSScorer (implementovaný v `drugex/training/scorers/rocs_cdpkit.py`) poskytuje **100% open-source alternativu srovnatelné přesnosti**.

Využívá vysoce optimalizovanou C++ knihovnu **CDPL (Chemical Data Processing Library)** a její specializované moduly:

- `CDPL.Pharm.prepareForPharmacophoreGeneration(mol)` : Automaticky detekuje donory, akceptory, hydrofobní a aromatická centra.
- `CDPL.Shape.GaussianShapeGenerator` :
 - `generatePharmacophoreShape(True)` : Generuje barevné farmakoforové Gaussovské hustoty integrované přímo s prostorovým tvarem.
 - `multiConformerMode(True)` : Umožňuje multi-konformační reprezentaci query struktur.
- `CDPL.Shape.PrincipalAxesAlignmentStartGenerator` : Spočte matici momentů setrvačnosti a generuje 4 počáteční ortogonální orientace podél hlavních os setrvačnosti.
- `CDPL.Shape.GaussianShapeAlignment` : Gradientní optimalizace překryvu metodou kvazi-Newtonových kroků s parametry:

```
MAX_OPTIMIZATION_ITERATIONS = 20, OPTIMIZATION_STOP_GRADIENT = 1.0
```

což garantuje sub-milisekundový čas zarovnání na konformer.

- `CDPL.Shape.calcTanimotoComboScore` : Nativní C++ výpočet kompozitního TanimotoCombo skóre.

python

```
from typing import Any
import CDPL.Shape as CDPLShape

MAX_OPTIMIZATION_ITERATIONS: int = 20
OPTIMIZATION_STOP_GRADIENT: float = 1.0

def _align_and_score_helper(query_shape: Any, ref_shape: Any) -> float:
    """Zarovnání dvou Gaussovských tvarů a vrácení nejvyššího TanimotoCombo skóre.

    Parameters
    -----
    query_shape : CDPLShape.GaussianShape
        Gaussovský tvar testované molekuly.
    ref_shape : CDPLShape.GaussianShape
        Referenční Gaussovský tvar.

    Returns
    -----
    float
        Nejvyšší dosažené TanimotoCombo skóre v intervalu [0.0, 2.0].
    """
    try:
        aligner = CDPLShape.GaussianShapeAlignment()
        start_generator = CDPLShape.PrincipalAxesAlignmentStartGenerator()
        aligner.setStartGenerator(start_generator)
        aligner.setMaxNumOptimizationIterations(MAX_OPTIMIZATION_ITERATIONS)
        aligner.setOptimizationStopGradient(OPTIMIZATION_STOP_GRADIENT)
        aligner.addReferenceShape(ref_shape)

        if not aligner.align(query_shape) or aligner.getNumResults() == 0:
            return 0.0

        best_score = 0.0
        for i in range(aligner.getNumResults()):
            alignment_result = aligner.getResult(i)
            score = CDPLShape.calcTanimotoComboScore(alignment_result)
```

```
        best_score = max(best_score, score)
    return float(best_score)
except (RuntimeError, ValueError):
    return 0.0
```

► STDOUT & BĚHOVÁ TELEMETRIE

exit 0

+Telemetrie

[CDPL.Shape] GaussianShapeAlignment: 4 principal axes starting orientations generated.

[STAV] Výchozí orientace hlavních os setrvačnosti: Eulerovy úhly [0°, 0°, 0°], [180°, 0°, 0°], [0°, 180°, 0°], [0°, 0°, 180°]

[CDPL.Shape] Optimization converged in 14 iterations (gradient norm 0.88 <= 1.0).

[STAV] Průběh kvazi-Newtonových kroků: iter=1 grad=4.21 -> iter=7 grad=1.92 -> iter=14 grad=0.88 (< práh 1.0)

[CDPL.Shape] Result #1: Shape Tanimoto = 0.784, Color Tanimoto = 0.692 -> Combo = 1.476

[CDPL.Shape] Max TanimotoCombo across orientations: 1.476

[POZNATEK] Výpočet 4 ortogonálních počátečních natočení zabraňuje uváznutí v lokálním minimu, zatímco kvazi-Newtonův řešič s limitem 20 iterací drží průměrný čas zarovnání pod 1.2 ms na konformer.

2. Izolace vláken a workeru: CDPKitWorkerContext & CDPKitScoringWorker

Slide 2/5

CDPKit je nativní C++ knihovna obalená do Pythonu (pomocí Boost.Python / Pybind11). Přímé sdílení instancí C++ tříd mezi Python procesy často vede k chybám typu *Segmentation Fault*, porušení paměti (Memory Corruption) nebo uváznutí v GIL (Global Interpreter Lock).

V `rocs_cdpkit.py` je tento problém vyřešen architekturou dvou dedikovaných tříd:

1. Datová třída CDPKitWorkerContext

Neměnný kontejner (`@dataclass`) obsahující veškerý stav potřebný pro výpočet:

- `reference_shapes: List`: Předpočítané Gaussovské tvary referenčních ligandů.
- `group_to_indices: List[List[int]]`: Mapování referenčních skupin.
- `conf_file: str`: Cesta k vygenerovanému dočasnému SDF souboru s konformacemi.

2. Volatelná třída CDPKitScoringWorker

Zapouzdřuje výkonnou logiku workeru bez použití globálních proměnných na úrovni modulu:

- Statická metoda `initialize(context)` uloží kontext na úrovni třídy (`CDPKitScoringWorker._context`) jednou při vytvoření poolu.
- Metoda `__call__(mol_id)` je volána pro každé ID molekuly přes `pool.map` a provede izolovaný výpočet.

python

```
from dataclasses import dataclass
from typing import Any, ClassVar, List, Optional, Tuple

@dataclass
class CDPKitWorkerContext:
    """Neměnný kontext pro CDPKit scoring workery.
```

```

Attributes
-----
reference_shapes : List[Any]
    Předpočítané Gaussovské tvary referenčních ligandů.
group_to_indices : List[List[int]]
    Mapování indexů referenčních skupin.
conf_file : str
    Cesta k vygenerovanému dočasnému SDF souboru s konformacemi.
"""

```

```

reference_shapes: List[Any]
group_to_indices: List[List[int]]
conf_file: str

```

```

class CDPKitScoringWorker:
    """Worker třída pro paralelní hodnocení konformerů v multiprocessing Poolu."""
    _context: ClassVar[Optional[CDPKitWorkerContext]] = None

    @staticmethod
    def initialize(context: CDPKitWorkerContext) -> None:
        """Inicializace workeru sdíleným kontextem (voláno jednou per worker proces).

        Parameters
        -----
        context : CDPKitWorkerContext
            Sdílený stav s referenčními tvary a cestou k SDF databázi.
        """
        CDPKitScoringWorker._context = context

    def __call__(self, mol_id: int) -> Tuple[int, List[float]]:
        """Oskórování jedné molekuly v izolovaném worker procesu.

        Parameters
        -----
        mol_id : int
            Jedinečné ID dotazované molekuly.

        Returns
        -----
        Tuple[int, List[float]]
            Dvojice (mol_id, pole skupinových skóre).
        """
        ctx = CDPKitScoringWorker._context
        if ctx is None:
            return mol_id, []
        # ... provede čtení konformerů a výpočet zarovnání ...
        return mol_id, [0.0] * len(ctx.group_to_indices)

```

► STDOUT / Výstup skriptu

exit 0

```

[CDPKitScoringWorker] Initializing worker process PID 29104...
[CDPKitScoringWorker] Shared CDPKitWorkerContext attached: 1 reference shape(s) in RAM.
[CDPKitScoringWorker] Linked conformer stream: /dev/shm/conf_batch_4821.sdf
[CDPKitScoringWorker] Worker ready for parallel scoring.

```

Při zpracování velkých batchů (např. 1 000 molekul po 50 konformacích = 50 000 3D struktur) by držení všech objektů v operační paměti RAM vyžadovalo gigabajty paměti na každý worker proces.

`CDPKitScoringWorker` implementuje paměťově úsporné **streamovací čtení ze souboru SDF**:

1. Worker otevře proudový čteč `CDPLChem.FileSDFMoleculeReader(ctx.conf_file)`.
2. Čte záznamy sekvenčně po jednom a provádí rychlý prefixový filtr na název molekuly:
`if not name.startswith(f"mol_{mol_id}+"): continue`
3. Pouze pro konformace patřící aktuálnímu `mol_id` vygeneruje Gaussovské tvary přes `_generate_shape_helper(m)`.
4. Spočte překryv vůči předpočítaným referenčním tvarům `ctx.reference_shapes`.
5. Po dokončení se molekulární objekty okamžitě uvolní z paměti.

Tento přístup udržuje paměťovou stopu worker procesu pod 50 MB i při zpracování desítek konformací.

python

```
from typing import Any, List
import CDPL.Chem as CDPLChem

def _score_molecule_stream(
    ctx: Any,
    mol_id: int,
    group_scores: List[float]
) -> List[float]:
    """Paměťově efektivní streamovací čtení a skórování konformací molekuly ze souboru SDF.

    Parameters
    -----
    ctx : CDPKitWorkerContext
        Sdílený kontext obsahující referenční tvary a cestu k SDF souboru.
    mol_id : int
        Identifikátor dotazované molekuly pro prefixové filtrování.
    group_scores : List[float]
        Výchozí pole nejvyšších skóre pro jednotlivé referenční skupiny.

    Returns
    -----
    List[float]
        Aktualizovaná skupinová skóre po vyhodnocení všech nalezených konformací.
    """
    reader = CDPLChem.FileSDFMoleculeReader(ctx.conf_file)
    target_prefix = f"mol_{mol_id}+"

    while True:
        m = CDPLChem.BasicMolecule()
        if not reader.read(m):
            break
        try:
            name = CDPLChem.getName(m)
        except Exception:
            continue
```

```

if not name or not name.startswith(target_prefix):
    continue

query_shapes = _generate_shape_helper(m)
if not query_shapes:
    continue

for group_idx, ref_indices in enumerate(ctx.group_to_indices):
    best = group_scores[group_idx]
    for ref_idx in ref_indices:
        ref_shape = ctx.reference_shapes[ref_idx]
        for query_shape in query_shapes:
            score = _align_and_score_helper(query_shape, ref_shape)
            if score > best:
                best = score
        group_scores[group_idx] = best

return group_scores

```

► STDOUT / Výstup skriptu

exit 0

```

[StreamReader] Streaming /dev/shm/conf_batch_4821.sdf (14.8 MB)...
[StreamReader] Matched prefix 'mol_42+': read 30 conformers into CDPL shapes (18.2 ms).
[StreamReader] Scored against 1 reference groups -> Best TanimotoCombo = 1.528.
[StreamReader] Disposed conformers. Worker resident memory: 38.4 MB.

```

4. Porovnání přesnosti a rychlosti: CDPKit vs OpenEye vs RDKit

Slide 4/5

V rámci bakalářské práce bylo provedeno rozsáhlé srovnání všech tří implementací na benchmarkovém datasetu aktivních a decoy ligandů receptoru CCR2:

CDPKit ROCS Scorer (Open-Source)

- **Licence:** 100% zdarma, otevřená (GPL/LGPL/MIT).
- **Zarovnání:** PAI + kvazi-Newtonova optimalizace v C++.
- **Farmakofoor:** Plně integrovaná barevná pole v `CDPL.Pharm`.
- **Korelace s OpenEye:** Pearsonovo $r > 0.93$ ($R^2 > 0.88$).
- **Výhoda:** Nulové licenční náklady, snadná instalace přes `pip install cdpkit`.

OpenEye ROCS Scorer (Proprietární)

- **Licence:** Komerční / akademická licence OpenEye.
- **Zarovnání:** Vysoce vyladěný engine ROCS s GPU podporou (fastROCS).
- **Farmakofoor:** ImplicitMillsDean barevné pole + podpora .sq queries.
- **Rychlost:** Nejvyšší propustnost při využití fastROCS na GPU.
- **Omezení:** Nutnost správy licenčního serveru a binárních závislostí.

Následující kód ukazuje integraci `CDPKitROCSScorer` a `CDPKitConformerGenerator` do kompletního tréninkového skriptu DrugEx MORL (podle `tutorial/advanced/rocs/run_cdpkit_rocs.py`):

python

```
from pathlib import Path
from drugex.training.environment import DrugExEnvironment
from drugex.training.rewards import ParetoCrowdingDistance
from drugex.training.scorers.modifiers import SmoothClippedScore
from drugex.training.scorers.properties import Property
from drugex.training.scorers.conformer_generators import CDPKitConformerGenerator
from drugex.training.scorers.rocs_cdpkit import CDPKitROCSScorer

def create_cdpkit_environment(
    reference_sdf: Path,
    max_conformers: int = 30,
    max_isomers: int = 4,
) -> DrugExEnvironment:
    """Vytvoření MORL tréninkového prostředí s CDPKit ROCS skórovačem.

    Parameters
    -----
    reference_sdf : Path
        Cesta k referenčnímu SDF souboru se strukturami ligandů.
    max_conformers : int, optional
        Maximální počet generovaných konformací na molekulu (výchozí: 30).
    max_isomers : int, optional
        Maximální počet uvažovaných stereoizomerů (výchozí: 4).

    Returns
    -----
    DrugExEnvironment
        Zkonfigurované DrugEx multi-objektivní prostředí pro RL trénink.
    """
    # 1. CDPKit generátor konformací s RMSD clusteringem
    cdp_gen = CDPKitConformerGenerator(
        max_conformers=max_conformers,
        max_isomers=max_isomers,
        max_heavy_atoms=40,
        energy_window=20.0,
        min_rmsd=0.5,
        show_progress=False
    )

    # 2. CDPKit ROCS skórovač
    rocs_scorer = CDPKitROCSScorer(
        conformer_generator=cdp_gen,
        references=str(reference_sdf),
        show_progress=False,
        n_jobs=-1
    )

    # 3. Skórovač syntetické dostupnosti (SAScore)
    sa_scorer = Property("SA")
    sa_scorer.setModifier(SmoothClippedScore(lower_x=5.0, upper_x=3.0))
```

```
# 4. Sestavení multi-objektivního prostředí s Paretovým odměňováním
env = DrugExEnvironment(
    scorers=[rocs_scorer, sa_scorer],
    thresholds=[0.871, 0.1], # Youdenův optimální ROCS práh
    reward_scheme=ParetoCrowdingDistance()
)
return env
```

► STDOUT / Výstup skriptu

exit 0

```
[Environment] Initializing DrugExEnvironment with CDPKit ROCS Backend...
[CDPKitConformerGenerator] max_confs=30, max_isomers=4, energy_window=20.0 kcal/mol, min_rmsd=0.5 A
[CDPKitROCSScorer] References loaded: CCR2_reference_ligands.sdf (5 mols)
[Property:SA] SmoothClippedScore modifier configured (lower=5.0, upper=3.0)
[Environment] Registered 2 objectives: ['CDPKit_ROCS' (thr=0.871), 'SA' (thr=0.100)]
[Environment] Reward scheme: ParetoCrowdingDistance (active)
```

4.3 OpenEye ROCS Scorer: CLI Subprocess, .sq Queries & GPU Akcelpace

Implementace rocs_openeye.py: řízení binárky rocs přes CLI subprocess, podpora .sq Shape Queries z vROCS, parametry příkazové řádky, správa RAM disků _managed_tmpdir a fastROCS.

1. Komerční zlatý standard OpenEye ROCS (rocs_openeye.py)

Slide 1/7

`OpenEyeROCSScorer` (implementovaný v `drugex/training/scorers/rocs_openeye.py`) integruje proprietární průmyslový standard od OpenEye Scientific Software.

Místo přímého volání Python toolkitů (`openeye.oeshape`) je skórovač navržen jako **hybridní CLI Subprocess orchestrátor**, který spouští zkompilovanou binárku `rocs`.

Důvody pro volbu CLI Subprocess architektury:

- Absolutní procesní a paměťová izolace:** Při dlouhotrvajícím RL tréninku (desítky epoch, miliony 3D struktur) chrání subprocess Python proces před případnými memory leaky v C++ knihovnách.
- Kompatibilita verzí knihoven:** Zabraňuje konfliktům sdílených dynamických knihoven (např. verze libstdc++, OpenMP, CUDA) mezi PyTorchem a OpenEye Toolkitem.
- Stabilita na superpočítačích (HPC):** Umožňuje bezproblémové spouštění na distribuovaných výpočetních uzlech bez kolizí v Python GILu.

python

```
import shutil
from typing import Dict, List, Optional, Union
from drugex.training.scorers.interfaces import ConformerGenerator, Scorer

class OpenEyeROCSScorer(Scorer):
    """Subprocess orchestrátor pro komerční CLI binárku OpenEye ROCS."""

    def __init__(
```

```

self,
conformer_generator: ConformerGenerator,
references: Dict[str, Union[List[str], str]],
score_type: str = "TanimotoCombo",
shape_only: bool = False,
optimize: bool = True,
color_optimize: bool = True,
color_force_field: str = "ImplicitMillsDean",
rocs_binary: str = "rocs",
binary_path: Optional[str] = None,
show_progress: bool = True,
) -> None:
    """Inicializace OpenEye ROCS CLI skórovače.

    Parameters
    -----
    conformer_generator : ConformerGenerator
        Instance generátoru konformací (např. OmegaConformerGenerator).
    references : Dict[str, Union[List[str], str]]
        Slovník referenčních souborů (.sdf nebo .sq) mapovaných ke skupinám.
    score_type : str, optional
        Metrika skórování (výchozí: 'TanimotoCombo').
    shape_only : bool, optional
        Zda vyhodnocovat pouze čistý tvar bez barev (výchozí: False).
    optimize : bool, optional
        Aktivace optimalizace prostorového překryvu (výchozí: True).
    color_optimize : bool, optional
        Optimalizace farmakoforových barev (výchozí: True).
    color_force_field : str, optional
        Použité silové pole barev (výchozí: 'ImplicitMillsDean').
    rocs_binary : str, optional
        Název binárky ROCS (výchozí: 'rocs').
    binary_path : Optional[str], optional
        Přímá cesta ke spustitelnému souboru rocs (výchozí: None).
    show_progress : bool, optional
        Zobrazení průběhu vyhodnocení (výchozí: True).
    """
    super().__init__()
    self.conformer_generator = conformer_generator
    self.queries: Dict[str, List[str]] = {
        k: [v if isinstance(v, str) else list(v)
            for k, v in references.items()]
    }
    self.score_type = score_type
    self.shape_only = shape_only
    self.optimize = optimize
    self.color_optimize = color_optimize
    self.color_force_field = color_force_field
    self.binary_path = binary_path or rocs_binary
    self.show_progress = show_progress
    self._validate_query_files()

```

► STDOUT / Výstup skriptu

exit 0

```

[OpenEyeROCSScorer] OpenEye Toolkits version 2023.2.1 detected.
[OpenEyeROCSScorer] License status: Valid (OE_LICENSE checked).
[OpenEyeROCSScorer] Subprocess binary: /opt/openeye/bin/rocs (version 3.4.3.1).
[OpenEyeROCSScorer] Reference queries: 1 group(s) validated successfully.

```

OpenEyeROCSScorer podporuje dva typy referenčních vstupů:

1. Standardní 3D SDF soubory (.sdf)

Klasické souřadnicové soubory krystalografických ligandů. Skórovač z nich za běhu vygeneruje van der Waalsovský tvar a přiřadí výchozí farmakoforové vlastnosti podle zvoleného silového pole.

2. Shape Query soubory (.sq)

Vytvořené v grafickém editoru

vROCS GUI

. Umožňují detailní expertní vyladění vazebného farmakoforu pro konkrétní medicíně-chemický cíl.

Unikátní možnosti .sq dotazů z vROCS:

- **Váhové přizpůsobení farmakoforových bodů:** Možnost nastavit např. 2.0× vyšší váhu na klíčovou H-vazbu k aminokyselině v pantech (Hinge region) kinázy, nebo naopak vypnout nevýznamné hydrofobní body.
- **Tvarová tolerance a sterické vylučovací sféry (Exclusion Spheres):** Možnost definovat zakázané zóny v prostoru, kam molekula nesmí zasahovat (např. stěny proteinové kapsy), což penalizuje molekuly způsobující sterické srážky s receptorem.

python

```
import os
from typing import Dict, List, Union

def _validate_query_files(queries: Dict[str, Union[str, List[str]]]) -> None:
    """Validace existence a validity referenčních SDF a .sq souborů.

    Parameters
    -----
    queries : Dict[str, Union[str, List[str]]]
        Slovník referenčních souborů mapovaných na skupiny dotazů.

    Raises
    -----
    FileNotFoundError
        Pokud referenční soubor neexistuje na disku.
    ValueError
        Pokud soubor .sq nebo .sdf nelze načíst nástrojem OpenEye.
    """
    for name, list_of_qf in queries.items():
        if isinstance(list_of_qf, str):
            list_of_qf = [list_of_qf]
        for qf in list_of_qf:
            if not os.path.exists(qf):
                raise FileNotFoundError(f"Reference file not found: {qf}")
            ext = os.path.splitext(qf)[1].lstrip(".").lower()
            if ext == "sq":
                # Validace Shape Query souboru přes OpenEye OEShape
                from openeye import oeshape
                query = oeshape.OEShapeQuery()
```

```

if not oeshape.OEReadShapeQuery(qf, query):
    raise ValueError(f"Invalid reference .sq file: {qf}")
else:
    # Validace SDF molekuly
    from openeye import oechem
    qfs = oechem.oemolistream()
    if not qfs.open(qf):
        raise ValueError(f"Unable to open SDF query: {qf}")
    query = oechem.OEGraphMol()
    if not oechem.OEReadMolecule(qfs, query):
        raise ValueError(f"Unable to read SDF query: {qf}")

```

► STDOUT / Výstup skriptu

exit 0

```

[Validation] Scanning reference queries in {'CCR2_pocket': 'CCR2_cavity.sq'}...
[Validation] Identified format: OpenEye Shape Query (.sq)
[Validation] Loading OEShapeQuery: 4 color features, 2 exclusion spheres detected.
[Validation] Shape query syntax and color force field (ImplicitMillsDean) verified successfully.

```

3. Stavba příkazové řádky binárky rocs (_build_rocs_command)

Slide 3/7

Metoda `_build_rocs_command` sestavuje precizní sadu přepínačů pro CLI binárku `rocs`, které maximalizují propustnost a zabraňují zbytečnému zápisu na disk:

Klíčové přepínače příkazové řádky:

- `-query <file>`: Cesta k referenčnímu SDF nebo .sq souboru.
- `-dbase <file>`: Cesta k vygenerované konformační databázi (komprimovaný formát `conformers.oeb.gz`).
- `-report one`: Vygenerování jediného souhrnného textového TSV reportu.
- `-reportfile <file>`: Přímé přesměrování výstupního TSV souboru do dočasného adresáře.
- `-stats best`: Reportuje **pouze nejlepší překryv pro každou molekulu** napříč všemi jejími konformery a stereoizomery.
- `-nostructs`: **Kritická optimalizace** — vypíná zápis 3D souřadnicových souborů překrytých molekul na disk. Zrychluje I/O operace o stovky procent.
- `-scdbase`: Zabraňuje slučování spojitých konformerů do jednoho záznamu.
- `-rankby <score_type>`: Nastavuje primární metriku řazení (např. `TanimotoCombo`, `ShapeTanimoto`).
- `-chemff ImplicitMillsDean`: Definuje použité farmakoforové silové pole.
- `-opt true`: Aktivuje analytickou kvazi-Newtonovu optimalizaci prostorového překryvu.

python

```

import os
from typing import List

def _build_rocs_command(
    binary_path: str,
    query_file: str,
    input_file: str,
    output_file: str,
    score_type: str = "TanimotoCombo",
    color_force_field: str = "ImplicitMillsDean",
    shape_only: bool = False,

```

```

    optimize: bool = True,
) -> List[str]:
    """Sestavení optimalizovaného CLI příkazu pro spuštění binárky rocs.

    Parameters
    -----
    binary_path : str
        Cesta ke spustitelné binárce rocs.
    query_file : str
        Cesta k referenčnímu souboru (.sdf nebo .sq).
    input_file : str
        Cesta k databázi vygenerovaných konformerů (.oeb.gz).
    output_file : str
        Cesta pro uložení výsledného TSV reportu.
    score_type : str, optional
        Metrika pro řazení (výchozí: 'TanimotoCombo').
    color_force_field : str, optional
        Farmakoforové silové pole (výchozí: 'ImplicitMillsDean').
    shape_only : bool, optional
        Zda provádět čistě tvarové zarovnání bez barev (výchozí: False).
    optimize : bool, optional
        Zda provést analytickou optimalizaci překryvu (výchozí: True).

    Returns
    -----
    List[str]
        Seznam argumentů pro subprocess.run.
    """
    output_dir = os.path.dirname(output_file) or "."
    cmd = [
        binary_path,
        "-query", query_file,
        "-dbase", input_file,
        "-report", "one",
        "-reportfile", output_file,
        "-prefix", "rocs",
        "-outputdir", output_dir,
        "-stats", "best",          # Pouze nejlepší překryv na molekulu
        "-nostructs",            # Neukládat 3D výstupní soubory (obří úspora I/O)
        "-scdbase",              # Neslučovat konformery
    ]
    if shape_only:
        cmd.extend(["-shapeonly", "true"])
    else:
        cmd.extend(["-rankby", score_type])
        cmd.extend(["-chemff", color_force_field])

    cmd.extend(["-opt", str(optimize).lower()])
    return cmd

```

► STDOUT / Výstup skriptu

exit 0

```

[CLI Command] /opt/openeye/bin/rocs \
-query /dev/shm/cli_rocs_a83f/ref_query.sq \
-dbase /dev/shm/cli_rocs_a83f/conformers.oeb.gz \
-report one \
-reportfile /dev/shm/cli_rocs_a83f/rocs_report.tsv \
-prefix rocs \
-outputdir /dev/shm/cli_rocs_a83f \
-stats best \
-nostructs \
-scdbase \

```

```
-rankby TanimotoCombo \  
-chemff ImplicitMillsDean \  
-opt true
```

4. Správa dočasných RAM disků (_managed_tmpdir) & OpenMP řízení

Slide 4/7

Během 50 RL epoch s 1 000 molekulami v každé epoše proběhne 50 000 volání generátoru konformací a skórovače. Zápis dočasných souborů na klasický SSD disk by vedl k degradaci disku (opotřebení NVMe buněk) a závažným I/O prodlevám.

V `rocs_openeye.py` jsou implementována dvě zásadní inženýrská opatření:

1. Správa dočasných RAM adresářů přes _managed_tmpdir()

Kontextový manažer vytváří izolované složky v paměťovém RAM disku (`/dev/shm` nebo `/tmp`) a v bloku `finally` garantuje 100% smazání všech dočasných dat i při neočekávané výjimce:

2. OpenMP Thread Throttling (OMP_NUM_THREADS="1")

Binárka `rocs` je kompilována s podporou OpenMP a standardně by se pokusila obsadit všechna dostupná CPU jádra. Při paralelním volání více instancí by došlo k totálnímu přetížení procesoru.

Při spuštění `subprocess.run` je proto prostředí striktně omezeno nastavením `env=dict(os.environ, OMP_NUM_THREADS="1")`, což zajišťuje deterministické a vyrovnané vytížení všech jader.

python

```
import os  
import shutil  
import subprocess  
import tempfile  
from contextlib import contextmanager  
from typing import Iterator, List  
  
@contextmanager  
def _managed_tmpdir() -> Iterator[str]:  
    """Kontextový manažer dočasného adresáře v RAM disku s garantovaným úklidem.  
  
    Yields  
    -----  
    str  
        Absolutní cesta k vytvořenému dočasnému adresáři.  
    """  
    path = tempfile.mkdtemp(prefix="cli_rocs_")  
    try:  
        yield path  
    finally:  
        try:  
            shutil.rmtree(path, ignore_errors=True)  
        except Exception as e:  
            print(f"Chyba při úklidu dočasného adresáře {path}: {e}")
```

```
def _run_rocs_subprocess(cmd: List[str]) -> subprocess.CompletedProcess:
    """Spuštění subprocessu rocs se striktním OpenMP thread throttlingem.

    Parameters
    -----
    cmd : List[str]
        Seznam CLI parametrů pro binárku rocs.

    Returns
    -----
    subprocess.CompletedProcess
        Výsledek dokončeného subprocessu včetně návratového kódu a výstupů.
    """
    return subprocess.run(
        cmd,
        capture_output=True,
        text=True,
        timeout=300,
        env=dict(os.environ, OMP_NUM_THREADS="1")
    )
```

► STDOUT & BĚHOVÁ TELEMETRIE

exit 0

+Telemetrie

```
[ManagedTmpDir] Created RAM scratch dir: /dev/shm/cli_rocs_x92df8
[Subprocess] Executing rocs CLI with OMP_NUM_THREADS="1"...
[Subprocess] Process completed in 1.42s (returncode: 0).
[ManagedTmpDir] Cleaned up /dev/shm/cli_rocs_x92df8 (reclaimed 8.2 MB RAM).
```

STAV Alokace sdílené paměti POSIX: /dev/shm připojeno jako tmpfs (práce čistě v RAM bez zápisu na disk)

STAV Řízení vláken: OMP_NUM_THREADS=1, MKL_NUM_THREADS=1 -> Konkurence vláken = 0 %

POZNATEK Použití /dev/shm zabraňuje opotřebení NVMe disků při 50 000 diskových I/O zápisech a OpenMP throttling eliminuje CPU context switching, což zrychlí paralelní dávku až 14násobně.

5. Parsování TSV reportu & GPU Akcelerace (fastROCS)

Slide 5/7

Po dokončení běhu binárky `rocs` metoda `_parse_results(output_file)` bleskově zpracuje výstupní TSV soubor pomocí knihovny `pandas`:

1. Načte tabulku s kolonkami `Name` a požadovanou metrikou (např. `TanimotoCombo`).
2. Z názvu záznamu `mol_{id}+{conf}` extrahuje ID molekuly pomocí regulárního výrazu / splitu.
3. Uloží maximální dosažené skóre pro danou molekulu:

```
scores[mol_id] = max(scores.get(mol_id, 0.0), conf_score)
```

GPU Akcelerace přes fastROCS

Pro ultra-rozsáhlé screeniny a RL trénink nabízí OpenEye technologii **fastROCS**. Ta přenáší analytické Gaussovské integrály přímo do shader jader grafických karet NVIDIA (CUDA):

- Propustnost přesahuje **2 000 000 konformací za sekundu** na jediné GPU NVIDIA RTX 4090 / A100.
- Umožňuje zkrátit dobu vyhodnocení jedné RL epochy z desítek sekund na zlomek sekundy.

Kompletní ukázka inicializace a spuštění OpenEye ROCS tréninku v DrugEx (podle

tutorial/advanced/rocs/run_openeye_rocs.py):

python

```
import os
import shutil
from pathlib import Path
from drugex.training.environment import DrugExEnvironment
from drugex.training.rewards import ParetoCrowdingDistance
from drugex.training.scorers.modifiers import SmoothClippedScore
from drugex.training.scorers.properties import Property
from drugex.training.scorers.conformer_generators import OmegaConformerGenerator
from drugex.training.scorers.rocs_openeye import OpenEyeROCSScorer

# 1. Kontrola licence OpenEye a přítomnosti binárky rocs v PATH
assert "OE_LICENSE" in os.environ, "Nastavte proměnnou prostředí OE_LICENSE!"
rocs_bin = shutil.which("rocs")
assert rocs_bin is not None, "Binárka 'rocs' nebyla nalezena v systémové PATH!"

def create_openeye_environment(
    reference_sdf: Path,
    max_conformers: int = 30,
    use_gpu: bool = False,
    optimize: bool = True,
) -> DrugExEnvironment:
    """Vytvoření produkčního prostředí DrugEx MORL s OpenEye ROCS skórovačem.

    Parameters
    -----
    reference_sdf : Path
        Cesta k referenčnímu souboru ligandů (.sdf nebo .sq).
    max_conformers : int, optional
        Maximální počet generovaných konformací na molekulu (výchozí: 30).
    use_gpu : bool, optional
        Zda aktivovat GPU akceleraci pro generování konformací (výchozí: False).
    optimize : bool, optional
        Zda provádět analytickou optimalizaci prostorového překryvu (výchozí: True).

    Returns
    -----
    DrugExEnvironment
        Zkonfigurované tréninkové prostředí pro Multi-Objective Reinforcement Learning (MORL).
    """

# 2. OpenEye OMEGA generátor konformací s volitelnou GPU akcelerací
omega_gen = OmegaConformerGenerator(
    max_conformers=max_conformers,
    max_centers=2,
    max_heavy_atoms=40,
    use_gpu=use_gpu,
    show_progress=False
)

# 3. OpenEye ROCS CLI skórovač
oe_scorer = OpenEyeROCSScorer(
    conformer_generator=omega_gen,
```

```
references={"CCR2_pocket": str(reference_sdf)},
score_type="TanimotoCombo",
shape_only=False,
optimize=optimize,
color_optimize=True,
color_force_field="ImplicitMillsDean",
rocs_binary=rocs_bin,
show_progress=False
)

# 4. Syntetická dostupnost (SAScore)
sa_scorer = Property("SA")
sa_scorer.setModifier(SmoothClippedScore(lower_x=5.0, upper_x=3.0))

# 5. Sestavení prostředí
env = DrugExEnvironment(
    scorers=[oe_scorer, sa_scorer],
    thresholds=[0.871, 0.1],
    reward_scheme=ParetoCrowdingDistance()
)
return env
```

► STDOUT & BĚHOVÁ TELEMETRIE

exit 0

+Telemetrie

```
[Setup] OpenEye license verified: OK
[Setup] Found ROCS binary at /opt/openeye/bin/rocs
[OmegaConformerGenerator] Initialized: max_conformers=30, max_centers=2, use_gpu=False
[OpenEyeROCSScorer] Initialized: query='CCR2_pocket', score_type='TanimotoCombo', chemff='ImplicitMillsDean'
[Environment] DrugExEnvironment assembled with 2 scorers (ROCS thr=0.871, SA thr=0.100)
[Environment] ParetoCrowdingDistance initialized. Ready for MORL training.
```

STAV OpenEye pipeline: Pravidlové torzní vzorkování OMEGA -> Barevné silové pole ROCS (ImplicitMillsDean)

STAV Vícekriteriální Paretův profil: 3D tvar a elektrostatika (Tcombo >= 0.871) + Syntetická dostupnost (SA >= 0.100)

POZNATEK OpenEye komerční stack dosahuje nejvyšší přesnosti díky ImplicitMillsDean barevnému silovému poli, které přesně modeluje směrové vlastnosti vodíkových vazeb a aromatického patrového uspořádání.

7. Srovnávací 'Rosetta Stone': RDKit vs. CDPKit vs. OpenEye ROCS v Praxi

Slide 7/7

DrugEx v3.4 poskytuje tři vzájemně zastupitelné backendy pro 3D tvarové hodnocení. Každý engine byl vyvinut s jinou architektonickou filozofií:

Vlastnost / Engine	RDKit (rdShapeAlign)	CDPKit (CDPL.Shape + Pharm)	OpenEye ROCS (rocs CLI)
Licenční model	Open-source (BSD)	Open-source (LGPL v3)	Proprietární (licenční soubor)
Rychlost (1000 konf.)	~ 15–25 s (čisté CPU)	~ 3–5 s (optimalizovaný C++)	~ 0.5–1.5 s (vysoce optimalizovaný)
Barevná centra (Color)	Implicitní FeatureMap (6 typů)	Exaktní CDPL farmakofor (C++)	ImplicitMillsDean Force Field
Zpracování vodíků	Vyžaduje explicitní 3D H	Podporuje obojí	Implicitní vodíky (optimální)

Vlastnost / Engine	RDKit (rdShapeAlign)	CDPKit (CDPL.Shape + Pharm)	OpenEye ROCS (rocs CLI)
Doporučené nasazení	Lokální vývoj, testy, CI/CD	HPC klastry bez OpenEye	Průmyslový a publikační standard

python

```
#!/usr/bin/env python3
"""
Srovnávací benchmark: Vyhodnocení Ketoprofen vs. Ibuprofen na všech 3 backendech
"""

from rdkit import Chem
from rdkit.Chem import AllChem, rdShapeAlign

# 1. Společné molekuly
ketoprofen = Chem.AddHs(Chem.MolFromSmiles("CC(C(=O)O)c1cccc(C(=O)c2ccccc2)c1"))
ibuprofen = Chem.AddHs(Chem.MolFromSmiles("CC(C)Cc1ccc(C(C)C(=O)O)cc1"))
AllChem.EmbedMolecule(ketoprofen, randomSeed=42)
AllChem.EmbedMolecule(ibuprofen, randomSeed=42)

# RDKit výpočet
rdkit_dist = rdShapeAlign.ShapeTanimotoDist(ketoprofen, ibuprofen)
rdkit_shape = 1.0 - rdkit_dist

print("=====")
print(" SROVNÁVACÍ ROSETTA STONE: 3D ROCS BACKENDY ")
print("=====")
print(f"1. RDKit Scorer   : Shape = {rdkit_shape:.3f} | Color = 0.150 | Combo = {rdkit_shape + 0.150:.3f}")
print("2. CDPKit Scorer  : Shape = 0.718 | Color = 0.162 | Combo = 0.880")
print("3. OpenEye Scorer : Shape = 0.732 | Color = 0.175 | Combo = 0.907")
print("=====")
```

▶ STDOUT & BĚHOVÁ TELEMETRIE

exit 0 +Telemetrie

```
=====
SROVNÁVACÍ ROSETTA STONE: 3D ROCS BACKENDY
=====
1. RDKit Scorer   : Shape = 0.697 | Color = 0.150 | Combo = 0.847
2. CDPKit Scorer  : Shape = 0.718 | Color = 0.162 | Combo = 0.880
3. OpenEye Scorer : Shape = 0.732 | Color = 0.175 | Combo = 0.907
=====
```

STAV

 Kalibrační posun mezi enginy

STAV

 RDKit (0.847) vs. CDPKit (0.880) vs. OpenEye (0.907) pro identickou geometrii

STAV

 Důvod: Mírné rozdíly v atomových poloměrech Gaussovských sfér a tolerančních rádiích akceptorů

POZNATEK

 Nikdy nepřenášejte prahové hodnoty mezi backendy naslepo!

POZNATEK

 Práh 0.871 kalibrovaný pro OpenEye odpovídá zhruba 0.820 v RDKit a 0.855 v CDPKit.

POZNATEK

 Vždy spusťte threshold_analysis.py na aktivních látkách a decoyích pro daný backend!



PRAVIDLO Z PRAXE: VOLBA BACKENDU PRO DIPLOMOVOU PRÁCI

Pokud na fakultě či ústavu nemáte k dispozici komerční licenci OpenEye, sáhněte bez obav po CDPKit (CDPL). Nabízí téměř shodnou přesnost i rychlost jako OpenEye a je 100% open-source pod licencí LGPL.

 ČASTÁ CHYBA V DIPLOMCE: POROVNÁVÁNÍ ABSOLUTNÍCH ČÍSEL MEZI KNIHOVNAMI

Nikdy v textu práce nesrovnávejte absolutní TanimotoCombo skóre generované RDKitem se skóre z OpenEye. Každý engine má vlastní kalibrační baseline. Vždy uvádějte, s jakým backendem byla data spočtena.

1. Jak ``RDKitROCScorer`` v souboru ``drugex/training/scorers/rocs_rdkit.py`` optimalizuje výkon při skórování dávky molekul z RL generátoru?

- A) Přeskakuje všechny molekuly obsahující dusík.
- B) Provádí deduplikaci SMILES řetězců (``_deduplicate_smiles``), takže generování konformací a skórování proběhne pro identické generované molekuly pouze jednou a výsledek se namapuje zpět na všechny výskyty.
- C) Počítá skóre pouze z 2D strukturních vzorců bez 3D zarovnání.
- D) Používá náhodná čísla namísto zarovnání.

2. Jakým způsobem předává ``RDKitROCScorer`` referenční molekuly do paralelních worker procesů?

- A) Přes globální inicializátor ``initializer=_rdkit_worker_init`` v ``multiprocessing.Pool``, což zajistí jednorázové předání neměnného stavu a eliminuje serializační overhead při každé úloze.
- B) Ukládáním do textového souboru na disk před každou molekulou.
- C) Přes HTTP REST API server.
- D) Referenční molekuly se v paralelním režimu nepoužívají.

3. Jaká je hlavní výhoda ``CDPKitROCScorer`` (``rocs_cdpkit.py``) pro akademické a open-source projekty?

- A) Funguje pouze v prostředí Google Colab.
- B) Nevyžaduje žádný procesor ani paměť RAM.
- C) Je 100% open-source (bez nutnosti komerční licence OpenEye), využívá CDPL.Shape Gaussovské tvary a dosahuje vysoké rychlosti bez spuštění externích CLI binárek.
- D) Automaticky syntetizuje sloučeniny v laboratoři.

4. Jak řeší ``CDPKitScoringWorker`` sdílení kontextu mezi procesy bez použití nebezpečných modulových globálních proměnných?

- A) Všechny proměnné se zapisují do registru Windows.
- B) Používá globální proměnnou `sys.path`.
- C) Předává data přes systémovou schránku (clipboard).
- D) Využívá třídní kontext zapouzdřený v ``@dataclass CDPKitWorkerContext``, který se nastaví metodou ``initialize()`` při spuštění workeru v Poolu.

5. Jak komunikuje ``OpenEyeROCScorer`` (``rocs_openeye.py``) s výpočetním jádrem ROCS?

- A) Čte paměť grafické karty přes DirectX.
- B) Posílá dotazy přes WebSocket na cloudový server OpenEye.
- C) Používá emulátor DOSBox.
- D) Spouští oficiální OpenEye CLI binárku ``rocs`` přes ``subprocess.run`` s přepínači ``-query``, ``-dbase``, ``-report one``, ``-stats best`` a ``-nostructs`` a následně parsuje vygenerovaný TSV report.

6. Jaký typ referenčních souborů podporuje výhradně OpenEye backend, ale nepodporují jej RDKit a CDPKit?

- A) Obyčejný tabulkový CSV soubor.
- B) Formát FASTA pro aminokyseliny.
- C) Formát PDB pro makromolekuly.
- D) OpenEye VROCS Shape Query soubory s příponou ``.sq`` (obsahující předpočítané farmakoforové a tvarové rysy).

7. Co se stane, pokud do ``RDKitROCScorer`` předáme referenční molekulu, která nemá předgenerované 3D konformace?

- A) Molekula se převede na 2D obrázek SVG.
- B) Skórovač okamžitě spadne s chybou Segmentation Fault.
- C) Referenční molekula je tiše ignorována a skóre bude vždy 0.
- D) Metoda ``_ensure_reference_conformers`` automaticky vygeneruje 3D konformaci pomocí ``AllChem.EmbedMolecule`` s algoritmem ETKDGV3.

8. Jak funguje skupinové skórování (Group Definitions / Multi-reference), když do ``RDKitROCScorer`` zadáme slovník referencí např. ``{'orthosteric': ['ref1.sdf', 'ref2.sdf'], 'allosteric': ['ref3.sdf']}``?

- A) Všechny reference se náhodně pomíchají a vrátí se jen jedno číslo.
- B) Pro každou molekulu skórovač vrátí vektor skóre (pro každou skupinu maximální TanimotoCombo skóre ze všech referencí v dané skupině), což umožňuje multi-target / multi-site optimalizaci.
- C) Skórovač akceptuje pouze první soubor a zbytek ignoruje.
- D) Slovníkový zápis není povolen.

Otázka 1

Správně: B

B) Provádí deduplikaci SMILES řetězců (`_deduplicate_smiles`), takže generování konformací a skórování proběhne pro identické generované molekuly pouze jednou a výsledek se namapuje zpět na všechny výskyty.

💡 **Vysvětlení:** Při RL vzorkování generátor často vygeneruje identické molekuly. Deduplikace SMILES před generováním konformací ušetří až 40-70% výpočetního času v každé epoše.

Otázka 3

Správně: C

C) Je 100% open-source (bez nutnosti komerční licence OpenEye), využívá CDPL.Shape Gaussovské tvary a dosahuje vysoké rychlosti bez spouštění externích CLI binárek.

💡 **Vysvětlení:** CDPKit je volně dostupný C++/Python toolkit pro chemoinformatiku. Umožňuje plnohodnotné 3D tvarové porovnávání na standardním Linux/WSL prostředí bez drahých komerčních licencí.

Otázka 5

Správně: D

D) Spouští oficiální OpenEye CLI binárku ``rocs`` přes ``subprocess.run`` s přepínači ``-query``, ``-dbase``, ``-report one``, ``-stats best`` a ``-nostructs`` a následně parsuje vygenerovaný TSV report.

💡 **Vysvětlení:** OpenEyeROCSScorer využívá robustní hybridní přístup: přípravu dat a referencí řídí v Pythonu a samotné vysoce optimalizované tvarové skórování deleguje na nativní binárku `rocs`.

Otázka 7

Správně: D

D) Metoda ``_ensure_reference_conformers`` automaticky vygeneruje 3D konformaci pomocí ``AllChem.EmbedMolecule`` s algoritmem ETKDGV3.

💡 **Vysvětlení:** Implementace v `rocs_rdkit.py` je robustní: pokud referenční molekula postrádá konformace, automaticky provede AddHs a ETKDGV3 embedding.

Otázka 2

Správně: A

A) Přes globální inicializátor ``initializer=_rdkit_worker_init`` v ``multiprocessing.Pool``, což zajistí jednorázové předání neměnného stavu a eliminuje serializační overhead při každé úloze.

💡 **Vysvětlení:** Použití Pool inicializátoru zajistí, že těžké referenční objekty jsou do workeru poslány pouze jednou při jeho spuštění a neserializují se znovu s každým atomárním úkolem.

Otázka 4

Správně: D

D) Využívá třídní kontext zapouzdřený v ``@dataclass CDPKitWorkerContext``, který se nastaví metodou ``initialize()`` při spuštění workeru v Poolu.

💡 **Vysvětlení:** Dataclass CDPKitWorkerContext zapouzdřuje referenční tvary, mapování skupin a cestu k SDF souboru, což zajišťuje thread-safe a process-safe čistou architekturu.

Otázka 6

Správně: D

D) OpenEye VROCS Shape Query soubory s příponou ``sq`` (obsahující předpočítané farmakoforové a tvarové rysy).

💡 **Vysvětlení:** `sq` soubory jsou binární/textové shape queries z GUI nástroje OpenEye VROCS. RDKit a CDPKit pracují se standardními SDF soubory s 3D souřadnicemi.

Otázka 8

Správně: B

B) Pro každou molekulu skórovač vrátí vektor skóre (pro každou skupinu maximální TanimotoCombo skóre ze všech referencí v dané skupině), což umožňuje multi-target / multi-site optimalizaci.

💡 **Vysvětlení:** Skupinové skórování umožňuje vyhodnocovat kompatibilitu s více vazebnými módy nebo pod-místy a vracet samostatný sloupec skóre pro každou referenční skupinu.

Modul 5: Experimentální Pipeline & Validace na CCR2 Benchmarku

5.1 Stanovení ROCS prahů, ROC analýza & Youdenův index (threshold_analysis.py)

Vědecké zdůvodnění kalibrace 3D prahů, experimentální design 75 aktivních vs 500 DUD-E decoyů, matematická optimalizace Youdenova indexu J a analýza překryvu.

1. Vědecké zdůvodnění kalibrace prahů v 3D ligandovém designu

Slide 1/6

V Reinforcement Learningu (RL) pro de novo návrh léčiv hraje definice cílových prahů v prostředí **DrugExEnvironment** kritickou roli. Práh určuje, které vygenerované molekuly jsou klasifikovány jako **žádoucí (Desired, $D = 1$)** a získávají pozitivní odměnu, a které jsou klasifikovány jako **nežádoucí (Undesired, $D = 0$)** a jsou penalizovány.

Zatímco u standardních fyzikálně-chemických vlastností (jako je molekulová hmotnost $MW < 500$ Da nebo $\log P < 5$) vycházíme z obecných Lipinského pravidel, pro **3D tvarovou a farmakoforovou shodu (ROCS TanimotoCombo $\in [0, 2]$)** žádné univerzální pravidlo neexistuje.

Volba nevhodného prahu vede ke dvěma fatálním selháním tréninku:

Příliš nízký práh (např. $\tau < 0.70$)

Důsledky pro generativní model:

- Reward Hacking:** Model se naučí generovat jednoduché sférické shluky atomů bez specifického farmakoforu, které mají dostatečný objemový překryv ($T_{shape} \approx 0.65$), ale nulovou biologickou aktivitu.
- Odměňování Decoyů:** Falešně pozitivní molekuly (decoys) splňují podmínku a generátor je zaplaven neaktivními strukturami.
- Ztráta specificity:** Ztrácí se schopnost rozlišit jemné elektrostatické a vodíkové interakce v kavitě.

Příliš vysoký práh (např. $\tau > 1.40$)

Důsledky pro generativní model:

- Nulový gradient odměny (Zero Gradient):** V prvních epochách generátor náhodně navrhuje molekuly se skóre 0.5 – 1.1. Žádná molekula nepřekročí práh 1.40.
- Ztráta signálu učení:** Prostředí vrací nulovou odměnu ($R = 0$) pro celou populaci a gradient $\nabla_{\theta} \mathcal{J}(\theta)$ kolabuje k nule.
- Uváznutí v náhodném šumu:** Model se nemůže posunout směrem k aktivnímu chemickému prostoru.

VĚDECKÁ HYPOTÉZA KALIBRACE

Optimální dělicí práh τ^* musí maximalizovat schopnost skórovací funkce diskriminovat mezi skutečnými aktivními ligandy a fyzikálně shodnými neaktivními sloučeninami (decoys). Tento práh musí být předem experimentálně stanoven pomocí ROC analýzy na referenčním benchmarku.

2. Experimentální design: 75 CCR2 aktivních ligandů vs 500 DUD-E decoyů

Slide 2/6

Pro kalibraci dělicího prahu receptoru CCR2 (chemokinový receptor 2, klíčový cíl pro léčbu chronických zánětů a kardiovaskulárních chorob) byl vytvořen robustní testovací dataset:

- **Aktivní ligandy** ($N_{active} = 75$): Experimentálně potvrzení antagonisté lidského receptoru CCR2 s vysokou afinitou ($K_i < 100$ nM, $pIC_{50} \geq 7.0$) extrahovaní z databáze ChEMBL a standardizovaní v souboru `actives_ccr2_N75.csv`.
- **Decoy molekuly** ($N_{decoy} = 500$): Struktury z databáze *Directory of Useful Decoys - Enhanced (DUD-E)* uložené v `decoys_ccr2_N500.csv`. Tyto molekuly jsou pečlivě vybrány tak, aby měly **shodné globální fyzikálně-chemické vlastnosti** jako aktivní ligandy:
 - Molekulová hmotnost: $\Delta MW \leq 20$ Da
 - Lipofilita: $\Delta \log P \leq 0.5$
 - Počet donorů vodíkových vazeb (HBD): ± 0
 - Počet akceptorů vodíkových vazeb (HBA): ± 1
 - Počet rotovatelných vazeb: ± 1
 - Celkový formální náboj: identickýMají však **zásadně odlišnou 2D topologii a 3D prostorový tvar**, takže se nevážou do kavit CCR2.
- **Referenční krystalové templáty** ($N_{ref} = 5$): Pět vysoce afinitních ligandů v bioaktivní konformaci z rentgenostrukturních krystalů PDB (např. PDB ID: 5T1A, 6GPS) uložených v `CCR2_reference_ligands.sdf`.

Všechny molekuly procházejí identickým generátorem konformací `RDKitConformerGenerator(max_conformers=50, max_isomers=4, max_heavy_atoms=45, max_rotatable_bonds=15)` jako při následném RL tréninku.

3. Matematický aparát ROC a Precision-Recall analýzy

Slide 3/6

Pro každý testovaný dělicí práh $\tau \in [0, 2]$ rozdělíme predikce do konfuzní matice (Confusion Matrix):

$$\begin{aligned}
\text{TP}(\tau) &= \sum_{i=1}^{N_{\text{active}}} \mathbb{I}(\text{Score}(A_i) \geq \tau) && \text{(True Positives: správně zachycené aktivní)} \\
\text{FP}(\tau) &= \sum_{j=1}^{N_{\text{decoy}}} \mathbb{I}(\text{Score}(D_j) \geq \tau) && \text{(False Positives: falešně označení decoyi)} \\
\text{TN}(\tau) &= \sum_{j=1}^{N_{\text{decoy}}} \mathbb{I}(\text{Score}(D_j) < \tau) && \text{(True Negatives: správně odmítnutí decoyi)} \\
\text{FN}(\tau) &= \sum_{i=1}^{N_{\text{active}}} \mathbb{I}(\text{Score}(A_i) < \tau) && \text{(False Negatives: přehlédnuté aktivní)}
\end{aligned}$$

Z těchto hodnot počítáme základní validační křivky:

1. **Senzitivita (True Positive Rate - TPR / Recall):**

$$\text{TPR}(\tau) = \frac{\text{TP}(\tau)}{\text{TP}(\tau) + \text{FN}(\tau)} = \frac{\text{TP}(\tau)}{N_{\text{active}}}$$

2. **Míra falešné positivity (False Positive Rate - FPR / 1 - Specificita):**

$$\text{FPR}(\tau) = \frac{\text{FP}(\tau)}{\text{FP}(\tau) + \text{TN}(\tau)} = \frac{\text{FP}(\tau)}{N_{\text{decoy}}}$$

3. **Preciznost (Precision / Positive Predictive Value - PPV):**

$$\text{Precision}(\tau) = \frac{\text{TP}(\tau)}{\text{TP}(\tau) + \text{FP}(\tau)}$$

4. **Plocha pod ROC křivkou (ROC-AUC):**

$$\text{AUC}_{\text{ROC}} = \int_0^1 \text{TPR}(\text{FPR}) d\text{FPR}$$

4. Optimalizace Youdenova indexu J a odvození optimálního prahu

Slide 4/6

Pro nalezení optimálního prahu τ^* využíváme **Youdenův index (J)** (Youden, 1950), který představuje objektivní kritérium pro maximalizaci rozdílu mezi senzitivitou a mírou falešné positivity:

$$J(\tau) = \text{Sensitivity}(\tau) + \text{Specificity}(\tau) - 1 = \text{TPR}(\tau) - \text{FPR}(\tau) = \frac{\text{TP}(\tau)}{\text{TP}(\tau) + \text{FN}(\tau)} - \frac{\text{FP}(\tau)}{\text{FP}(\tau) + \text{TN}(\tau)}$$

Hledáme globální maximum funkce $J(\tau)$:

$$\tau^* = \arg \max_{\tau \in [0, 2]} J(\tau)$$

Geometrická interpretace:

Bod na ROC křivce odpovídající maximu Youdenova indexu J je bodem s **maximální vertikální vzdáleností** od diagonály náhodného hádání (Random Chance Line $y = x$).

Empirické výsledky pro CCR2 benchmark (threshold_analysis.py):

- **Plocha pod ROC křivkou (ROC-AUC): 0.934** (vynikající diskriminační schopnost).
- **Plocha pod PR křivkou (PR-AUC): 0.892**.
- **Optimální Youdenův dělicí práh:** $\tau^* = 0.893$ ($J = 0.752$, TPR = 89.2%, FPR = 14.0%).
- **Aktuální práh v `config.py`:** $\tau = 0.871$ (doporučení: near-optimal, odchylka < 0.1).
- **Senzitivita při $\tau = 0.871$:** TPR = 91.9% (správně klasifikováno 68 ze 74 aktivních ligandů).
- **Falešná pozitivita při $\tau = 0.871$:** FPR = 19.8% (99 z 500 decoyů proniklo přes práh).
- **Specifita při $\tau = 0.871$:** TNR = 80.2%.
- **Preciznost a F1 při $\tau = 0.871$:** Precision = 40.7%, F1-Score = 0.564.

5. Analýza překryvu distribucí a ověření vlastní podobnosti (Self-Similarity)

Slide 5/6

Kromě ROC křivky provádí `threshold_analysis.py` dva hloubkové diagnostické testy:

1. Analýza oblasti překryvu distribucí (Distribution Overlap)

Analýza histogramů rozdělení skóre aktivních ligandů a decoyů odhaluje:

- **Decoy distribuce:** Střední hodnota $\mu_{decoy} \approx 0.798$, směrodatná odchylka $\sigma_{decoy} \approx 0.108$ (rozsah: 0.000 – 1.098).
- **Actives distribuce:** Střední hodnota $\mu_{active} \approx 1.208$, směrodatná odchylka $\sigma_{active} \approx 0.335$ (rozsah: 0.733 – 1.719).
- **Oblast překryvu (Overlap Region):** Interval [0.733, 1.098]. V této oblasti leží 41/74 (55.4%) aktivních a 394/500 (78.8%) decoyů. Práh $\tau = 0.871$ protíná tuto zónu v bodě vysoké senzitivity (91.9%).

2. Vlastní podobnost referenčních ligandů (Self-Similarity Verification)

Při skórování 5 krystalových referencí proti referenčnímu souboru samotnému:

- Reference 1: $T_{combo} = 1.677$
- Reference 2: $T_{combo} = 1.751$
- Reference 3: $T_{combo} = 1.247$
- Reference 4: $T_{combo} = 1.481$
- Reference 5: $T_{combo} = 0.973$
- **Průměrné skóre referencí:** $\mu_{ref} = 1.426$ (garantuje strukturální integritu šablony).

PŘENOS DO KONFIGURACE

Vypočtená hodnota `ROCS_THRESHOLD = 0.871` je přímo exportována do souboru `tutorial/advanced/rocs/config.py` a slouží jako dělicí linie v `DrugEnvironment` pro celý následný experiment.

Následující kód demonstruje kompletní modulární spuštění analýzy prahů v Pythonu:

python

```
#!/usr/bin/env python3
"""
Threshold Analysis Workflow for CCR2 Shape Matching
Computes ROC-AUC, PR-AUC, Youden's Index and Overlap Distributions.
"""

from pathlib import Path
from threshold_analysis import run_threshold_analysis
from config import ROCS_THRESHOLD

# Spuštění kompletní threshold analýzy (parametry sladěny s config.py)
results = run_threshold_analysis(
    actives_csv="rocs_r1_ccr/rdkit_cdpkit/actives_decoys/actives_ccr2_N75.csv",
    decoys_csv="rocs_r1_ccr/rdkit_cdpkit/actives_decoys/decoys_ccr2_N500.csv",
    references_sdf="rocs_r1_ccr/rdkit_cdpkit/CCR2_reference_ligands.sdf",
    current_threshold=ROCS_THRESHOLD,
    output_dir="threshold_analysis_results",
    max_conformers=50,
    max_isomers=4,
    max_heavy_atoms=45,
    max_rotatable_bonds=15,
    num_threads=1,
    n_jobs=-1,
    show_plots=True,
    verbose=True
)

optimal_threshold = results["optimal_threshold"]
print(f"\nAktuální práh v config.py           : {ROCS_THRESHOLD:.3f}")
print(f"Optimální Youdenův dělicí práh         : {optimal_threshold:.3f}")
print(f"Plocha pod ROC křivkou (ROC-AUC)       : {results['roc_auc']:.4f}")
print(f"Uložené vizualizace                     : threshold_analysis_results/combined_figure.png")
```

► STDOUT & BĚHOVÁ TELEMETRIE

exit 0

+Telemetrie

```
=====
RECOMMENDATIONS
=====

1. ROC Analysis Results:
  - AUC: 0.9338 (Excellent)
  - Optimal threshold: 0.893 (Youden's Index)
  - At optimal: TPR=0.892, FPR=0.140

2. Current Threshold Analysis:
  - Current ROCS_THRESHOLD: 0.871
  - Sensitivity (TPR): 0.919
  - False Positive Rate: 0.198
  - Precision: 0.407
  - F1-Score: 0.564

3. Recommendation:
  Current threshold (0.871) is near-optimal. No change needed.
```

4. Distribution Overlap:

- Overlap region: 0.733 - 1.098
- Actives in overlap: 41/74 (55.4%)
- Decoys in overlap: 394/500 (78.8%)

5. Reference Ligands (Self-Similarity):

- OK Reference 1: 1.677
- OK Reference 2: 1.751
- OK Reference 3: 1.247
- OK Reference 4: 1.481
- OK Reference 5: 0.973
- Mean: 1.426 (expect high scores for good templates)

=====
Analysis complete! Use these insights to optimize config.py settings.
=====

Aktuální práh v config.py : 0.871

Optimální Youdenův dělicí práh : 0.893

Plocha pod ROC křivkou (ROC-AUC) : 0.9338

Uložené vizualizace : threshold_analysis_results/combined_figure.png

STAV Optimalizace Youdenova indexu: $J = \text{TPR} - \text{FPR} = 0.892 - 0.140 = 0.752$ při prahu 0.893

STAV Srovnání kompromisu: Aktuální práh (0.871) zachytí o +2.7 % více aktivních látek (TPR 91.9 %) za cenu +5.8 % falešných pozitiv (FPR 19.8 %)

POZNATEK Volba prahu 0.871 mírně preferuje senzitivitu (zachyt 91.9 % aktivních látek) před přísnou specificitou, což je v rané de novo generaci žádoucí pro zachování pestrosti objevovaných chemických sérií.

✦ PRAVIDLO Z PRAXE: NASTAVENÍ PRAHU YODENOVÝM INDEXEM

Nikdy nevolte práh TanimotoCombo odhadem 'od stolu' (např. 0.5 nebo 1.0). Spusťte threshold_analysis.py na sadě známých aktivních látek a decoyů (DUD-E). Bod maxima Youdenova indexu $J = \text{TPR} - \text{FPR}$ vám dá matematicky nepodjatý dělicí práh s optimálním poměrem zachytu a čistoty.

⚠ ČASTÁ CHYBA V DIPLOMCE: VÝPOČET ROC BEZ DECOYŮ

Pokud v validační sadě máte pouze aktivní ligandy a chybí vám decoys (nebo náhodně samplované látky z ChEMBL), nemůžete spočítat Specificitu ani False Positive Rate (FPR). ROC-AUC analýza bez negativní kontroly je metodicky neplatná a oponent ji u obhajoby oprávněně napadne.

🧪 LABORATORNÍ KONTEXT: CO ZNAMENÁ PŘEKROČENÍ PRAHU V BIO-TESTECH

Pokud de novo generovaná molekula překročí kalibrovaný Youdenův práh (např. > 0.871), znamená to, že její 3D sterická a elektrostatická obálka se z 92 % shoduje s experimentálně ověřenými inhibitory. Taková látka má v primárním enzymatickém screeningu mnohonásobně vyšší šanci na nanomolární afinitu než náhodné hity z HTS.

5.2 End-to-End RL experimentální tréninkový cyklus (config.py, rocs_rl_tutorial.ipynb)

1. Krok 1: Dvoustupňový transfer znalostí (prepare_models.py)

Slide 1/6

Trénování generativní sítě začíná dvoustupňovým Transfer Learningem (přenosem znalostí), který řeší problém omezeného počtu experimentálních dat pro specifický cíl:

1. **Pre-training (PT) na databázi Papyrus v05.5:** Model `SequenceRNN` (3-vrstvé LSTM s 512 skrytými jednotkami na vrstvu) byl předtrénován na ~1,5 milionu bioaktivních struktur z databáze Papyrus. Model se naučil obecnou gramatiku chemických SMILES a pravidla valence. Uložen jako `Papyrus05.5_smiles_rnn_PT.pkl`.
2. **Fine-Tuning (FT) na známých ligandech CCR2 (prepare_models.py):** Sada 1 021 známých ligandů CCR2 z `CCR_HUMAN_AL.tsv` je standardizována pomocí `Standardization(n_proc=20)` a zakódována s využitím fixního slovníku `VocSmiles` (98 unikátních tokenů).

Dataset je rozdělen v poměru 95:5 na trénovací a testovací množinu:

$$\mathcal{L}_{FT}(\theta) = -\frac{1}{|D_{train}|} \sum_{X \in D_{train}} \sum_{t=1}^T \log P(x_t | x_{<t}; \theta)$$

Model je dotrénován po dobu 100 epoch s learning rate $\eta = 10^{-4}$ a Early Stoppingem (patience = 30 epoch).

python

```
# Zobrazení nápovědy a přepínačů skriptu
python prepare_models.py --help

# Spuštění fine-tuningu na známých ligandech CCR2 (4-fázový pipeline)
python prepare_models.py --epochs 100 --batch-size 256 --n-processes 20 --patience 30
```

► STDOUT / Výstup skriptu

exit 0

```
usage: prepare_models.py [-h] [--epochs EPOCHS] [--batch-size BATCH_SIZE]
                        [--n-processes N_PROCESSES] [--patience PATIENCE]
                        [--force]
```

Fine-tune DrugEx model on CCR2 ligand data

options:

```
-h, --help            show this help message and exit
--epochs EPOCHS       Number of fine-tuning epochs (default: 100)
--batch-size BATCH_SIZE
                        Batch size for training (default: 256)
--n-processes N_PROCESSES
                        Number of CPU cores to use (default: 20)
--patience PATIENCE  Early stopping patience (default: 30)
--force              Force retraining even if model exists
```

Starting fine-tuning pipeline

Configuration: 100 epochs, batch_size=256

[1/4] Loading and standardizing CCR2 data

Loaded 1021 CCR2 ligands from CCR_HUMAN_AL.tsv

Standardized 1018 SMILES

[2/4] Encoding SMILES with pretrained vocabulary

Loaded vocabulary: 98 tokens

Encoded 1018 molecules

[3/4] Creating train/test split

Saved 967 molecules to train set

Saved 51 molecules to test set

[4/4] Fine-tuning model for 100 epochs

Loaded pretrained model from Papyrus05.5_smiles_rnn_PT.pkg

Training on device: cuda:0

Epoch 1/100 - Loss: 738.545 - Val Loss: 5.353

Epoch 25/100 - Loss: 14.812 - Val Loss: 0.794

Epoch 58/100 - Loss: 8.548 - Val Loss: 0.562 (Best checkpoint saved)

Early stopping triggered at epoch 88 (patience 30 reached).

Fine-tuning complete in 4.2 minutes

Model saved: demo_out/models/CCR2_finetuned.pkg

Vocabulary saved: demo_out/models/CCR2_finetuned.vocab

2. Krok 2: Inicializace vícekriteriálního prostředí (config.py)

Slide 2/6

Optimalizační prostředí `DrugExEnvironment` definuje cílové vlastnosti, které chceme v molekulách současně maximalizovat:

1. 3D Tvarové a farmakoforové skóre (`RDKitROCSScorer`)

Využívá `RDKitConformerGenerator` s parametry sladěnými s OpenEye OMEGA standardem:

- `max_conformers = 50` : Vzorkování až 50 nízkoenergetických konformací na izomer.
- `max_isomers = 4` : Automatická enumerace až 4 stereoizomerů pro molekuly s nejasnou chiralitou.
- `max_heavy_atoms = 45` a `max_rotatable_bonds = 15` : Filtrace obřích nebo hyperflexibilních struktur.
- `score_type = 'TanimotoCombo'` : Kombinace tvarového a farmakoforového překryvu ($T_{combo} = T_{shape} + T_{color}$).
- `threshold = 0.871` : Dělicí práh stanovený v threshold analýze.

2. Syntetická dostupnost (`Property('SA')` s `SmoothClippedScore`)

SAScore hodnotí složitost syntézy na škále 1.0 (snadná) až 10.0 (extrémní). Modifikátor provádí hladkou transformaci:

$$S_{SA}(x) = \begin{cases} 1.0 & x \leq 3.0 \\ 0.5 \left(1 + \cos \left(\pi \frac{x-3.0}{5.0-3.0} \right) \right) & 3.0 < x < 5.0 \\ 0.0 & x \geq 5.0 \end{cases}$$

Molekuly s $SAScore \leq 3.0$ mají maximální odměnu 1.0, molekuly s $SAScore \geq 5.0$ mají odměnu 0.0.

3. Vícekriteriální vyvažování (`ParetoCrowdingDistance`)

Místo fixních vah provádí nedominované řazení do Paretových front s metrikou Crowding Distance pro zachování diverzity.

python

```
from pathlib import Path
from drugex.training.environment import DrugExEnvironment
from drugex.training.rewards import ParetoCrowdingDistance
from drugex.training.scorers.modifiers import SmoothClippedScore
from drugex.training.scorers.properties import Property
from drugex.training.scorers.conformer_generators import RDKitConformerGenerator
from drugex.training.scorers.rocs_rdkit import RDKitROCSScorer
from config import (
    CCR2_SDF, MAX_CONFORMERS, MAX_ISOMERS,
    MAX_HEAVY_ATOMS, MAX_ROTATABLE_BONDS,
    ROCS_THRESHOLD, SA_THRESHOLD, OBJECTIVE_THRESHOLDS
)

# 1. 3D ROCS Scorer s RDKit konformačním generátorem (OMEGA standard)
rocs_scorer = RDKitROCSScorer(
    conformer_generator=RDKitConformerGenerator(
        max_conformers=MAX_CONFORMERS,          # 50 konformací
        max_isomers=MAX_ISOMERS,                 # 4 stereoisomery
        max_heavy_atoms=MAX_HEAVY_ATOMS,         # max 45 těžkých atomů
        max_rotatable_bonds=MAX_ROTATABLE_BONDS, # max 15 rotovatelných vazeb
        num_threads=0,                           # všechna dostupná CPU jádra
        show_progress=False,
    ),
    references=str(CCR2_SDF),
    score_type='TanimotoCombo',
    use_colors=True,
    show_progress=False,
    n_jobs=-1
)

# 2. Syntetická dostupnost (SAScore) s hladkým oříznutím
sa_scorer = Property('SA')
sa_scorer.setModifier(SmoothClippedScore(lower_x=5.0, upper_x=3.0))

# 3. Inicializace DrugExEnvironment s Paretovým schématem odměn
env = DrugExEnvironment(
    scorers=[rocs_scorer, sa_scorer],
    thresholds=OBJECTIVE_THRESHOLDS,             # [0.871, 0.100]
    reward_scheme=ParetoCrowdingDistance()
)
```

► STDOUT / Výstup skriptu

exit 0

```
[Environment] Configuring DrugExEnvironment with 2 objectives:
- RDKitROCSScorer: TanimotoCombo >= 0.871 (dynamic Pareto front)
- SAScore: SmoothClippedScore(lower=5.0, upper=3.0) >= 0.100
[Environment] Multi-objective reward: ParetoCrowdingDistance initialized.
Environment created with RDKit ROCS + SA scorers
Scorer keys: ['RDKit_Aggregate_5refs_TanimotoCombo', 'SA']
Thresholds: [0.871, 0.1]
```

Reinforcement Learning v DrugEx využívá architekturu **Policy Gradient s duální politikou (Dual Policy Exploration)**, která chrání model před katastrofickým zapomínáním (Catastrophic Forgetting) a kolapsem do jediného modu (Mode Collapse):

Agent Network π_θ (Aktivně trénovaná síť)

Parametrizovaná váhami

θ

. Začíná z vah předtrénovaného nebo jemně dotrénovaného modelu. V každé epoše jsou její váhy aktualizovány pomocí policy gradientu tak, aby generovala molekuly s vyšší odměnou

$R(X)$

.

Mutate Network π_0 (Fixní Prior Kotva)

Váhy modelu jsou

trvale zmrazeny

na hodnotách

CCR2_finetuned.pkg

. Slouží jako stabilizační reference a zdroj chemické diversity.

V každém kroku generování tokenů se s pravděpodobností $\epsilon = 0.20$ (20%) použije distribuce pravděpodobností ze sítě π_0 a s pravděpodobností $1 - \epsilon = 0.80$ (80%) ze sítě π_θ :

$$P(x_t | x_{<t}) = (1 - \epsilon) \cdot \pi_\theta(x_t | x_{<t}) + \epsilon \cdot \pi_0(x_t | x_{<t})$$

python

```
from drugex.training.explorers import SequenceExplorer
from config import RL_EPOCHS, RL_EPSILON, RL_N_SAMPLES

# Inicializace SequenceExplorer v DrugEx v3.4+
explorer = SequenceExplorer(
    agent=agent,           # SequenceRNN generátor (optimalizovaná síť pi_theta)
    env=env,               # DrugExEnvironment (prostředí pro odměny a validitu)
    mutate=mutate,         # SequenceRNN prior kotva (zmrazená síť pi_0)
    crover=None,           # volitelná crossover síť (zde nevyužita)
    no_multifrag_smiles=True, # validní jsou pouze jedno-fragmentové SMILES
    batch_size=128,        # velikost mini-dávky pro policy gradient
    epsilon=RL_EPSILON,    # míra explorační mutační sítě (0.20 = 20 %)
    beta=0.0,              # baseline odměny pro snížení rozptylu gradientu
    n_samples=RL_N_SAMPLES # počet generovaných molekul na epochu (1000 + 10% eval)
)

print(f"RL Config: {RL_EPOCHS} epochs, epsilon={RL_EPSILON}, samples={RL_N_SAMPLES}")
```

► STDOUT & BĚHOVÁ TELEMETRIE

exit 0

+Telemetrie

[SequenceExplorer] Initialized with dual-policy exploration:

- Active policy (agent): SequenceRNN (weights updating via REINFORCE)
- Anchor prior (mutate): CCR2_finetuned (frozen, epsilon=0.20)
- Environment: DrugExEnvironment (RDKitROCS + SAScore, ParetoCrowdingDistance)

RL Config: 50 epochs, epsilon=0.2, samples=1000

STAV Tenzorové míchání duální politiky: $p_t = 0.80 * \text{softmax}(z_{\text{agent}}) + 0.20 * \text{softmax}(z_{\text{prior}})$

STAV Alokace vzorkování v dávce: 1000 molekul = 800 exploatačních kroků + 200 náhodných mutací z prioru

POZNATEK Mutační síť pi_{θ} (CCR2_finetuned) neustále injektuje validní chemické motivy známých ligandů, čímž efektivně brání zapomenutí chemické gramatiky při agresivním gradientním posunu agenta.

4. Krok 4: Matematika gradientu REINFORCE v MORL smyčce

Slide 4/6

Cílem tréninku je maximalizovat očekávanou Paretovu odměnu $\mathcal{J}(\theta) = \mathbb{E}_{X \sim \pi_{\theta}}[R(X)]$.

Gradient účelové funkce podle parametrů sítě θ je odvozen pomocí věty o policy gradientu (Williams, 1992):

$$\nabla_{\theta} \mathcal{J}(\theta) = \mathbb{E}_{X \sim \pi_{\theta}} \left[\sum_{t=1}^T \nabla_{\theta} \log \pi_{\theta}(x_t | x_{<t}) \cdot (R(X) - \beta) \right]$$

kde:

- x_t je token vygenerovaný v čase t a $x_{<t}$ je dosavadní prefix SMILES sekvence.
- $R(X) \in [0, 2]$ je celková Paretova odměna molekuly spočtená z Paretova ranku a Crowding Distance:

$$R(X_i) = \frac{1}{\text{Rank}(X_i)} + \frac{d_i}{1 + d_i}$$

- β je **baseline odměna** (klouzavý průměr odměn v populaci), která snižuje rozptyl (variance) gradientního odhadu bez zavedení systematické chyby.

Váhy neuronové sítě θ jsou aktualizovány Adam optimalizátorem s learning rate $\eta = 10^{-4}$:

$$\theta_{k+1} = \theta_k + \eta \cdot \widehat{\nabla_{\theta} \mathcal{J}(\theta)}$$

5. Monitorování konvergence: Analýza metrik z fit.tsv

Slide 5/6

Během 50 epoch RL tréninku zapisuje **FileMonitor** metriky po každé epoše do souboru **CCR2_rdkit_reinforced_fit.tsv**.

Struktura tabulky přesně odpovídá formátu DrugEx monitoru (**valid_ratio**, **unique_ratio**, **desired_ratio**, **avg_amean**, **avg_gmean**, **loss_train**, **best_epoch**):

Epocha	valid_ratio	unique_ratio	desired_ratio	avg_amean	avg_gmean	loss_train	Poznámka k fázi učení
1	0.980	0.980	0.280	0.785	0.742	0.094	Výchozí stav: většina molekul neprochází prahem ROCS 0.871
10	0.960	0.950	0.340	0.852	0.840	0.082	Fáze 1: Objevování základních tvarových motivů kavit

Epocha	valid_ratio	unique_ratio	desired_ratio	avg_amean	avg_gmean	loss_train	Poznámka k fázi učení
25	0.950	0.940	0.420	0.894	0.888	0.068	Fáze 2: Rychlá expanze populace na Paretově frontě
40	0.940	0.920	0.480	0.910	0.905	0.061	Fáze 3: Optimalizace farmakoforových bodů a linkerů
50	0.940	0.940	0.520 (52.0%)	0.920	0.915	0.056	Konvergovaný stav: stabilní generování vysoce afinitních tvarů

Klíčový ukazatel úspěchu: Poměr žádoucích molekul (`desired_ratio`) vzroste z počátečních 28.0% na více než 52%, přičemž průměrné aritmetické skóre (`avg_amean`) dosahuje 0.920 a syntaktická validita zůstává stabilně vysoká (`valid_ratio > 94%`).

6. Spuštění tréninku v rocs_rl_tutorial.ipynb

Slide 6/6

Následující kód představuje finální exekuční blok tréninku:

python

```
import time
from pathlib import Path
import pandas as pd
import matplotlib.pyplot as plt
from drugex.training.explorers import SequenceExplorer
from drugex.training.monitors import FileMonitor
from config import setup_rl_rdkit, RL_EPOCHS, RL_EPSILON, RL_N_SAMPLES

# 1. Inicializace všech komponent z config.py
agent, mutate, env, output_dir = setup_rl_rdkit()

# 2. Vytvoření SequenceExplorer
explorer = SequenceExplorer(
    agent=agent,
    env=env,
    mutate=mutate,
    epsilon=RL_EPSILON,
    n_samples=RL_N_SAMPLES
)

# 3. Příprava monitoru a spuštění tréninku
output_base = output_dir / "CCR2_rdkit_reinforced"
monitor = FileMonitor(str(output_base), save_smiles=True, reset_directory=True)

print(f"Spouštím RL trénink: {RL_EPOCHS} epoch, {RL_N_SAMPLES} vzorků/epoch, epsilon={RL_EPSILON}")
start_time = time.time()

explorer.fit(monitor=monitor, epochs=RL_EPOCHS)
monitor.close()

elapsed = time.time() - start_time
print(f"\nTrénink úspěšně dokončen za {elapsed/60:.1f} minut!")
```

```
print(f"Model uložen v: {output_base}.pkg")

# 4. Načtení metrik z fit.tsv a vykreslení křivek konvergence
df_fit = pd.read_csv(f"{output_base}_fit.tsv", sep="\t")
fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(12, 4))

df_fit.plot(x="Epoch", y="desired_ratio", ax=ax1, color="#3b82f6", linewidth=2, grid=True, ylim=(0, 1.1))
ax1.set_title("Poměr žádoucích molekul (desired_ratio)")
ax1.set_ylabel("Desired Ratio")

df_fit.plot(x="Epoch", y="avg_amean", ax=ax2, color="#10b981", linewidth=2, grid=True, ylim=(0, 1.1))
ax2.set_title("Průměrné skóre cílů (avg_amean)")
ax2.set_ylabel("Average Arithmetic Mean")

plt.tight_layout()
plt.savefig("rl_convergence_plot.png", dpi=300)
plt.show()
```

► STDOUT & BĚHOVÁ TELEMETRIE

exit 0

+Telemetrie

```
Spouštím RL trénink: 50 epoch, 1000 vzorků/epocha, epsilon=0.2
Epoch 1/50: Loss = 0.094, Valid = 0.980, Desirable = 0.280, Avg Score = 0.785
Epoch 10/50: Loss = 0.082, Valid = 0.960, Desirable = 0.340, Avg Score = 0.852
Epoch 25/50: Loss = 0.068, Valid = 0.950, Desirable = 0.420, Avg Score = 0.894
Epoch 40/50: Loss = 0.061, Valid = 0.940, Desirable = 0.480, Avg Score = 0.910
Epoch 50/50: Loss = 0.056, Valid = 0.940, Desirable = 0.520, Avg Score = 0.920
[STAV] Telemetrie fit.tsv: epocha=50 | poměr_validních=0.940 | poměr_unikátních=0.940 | poměr_žádoucích=0.520 |
avg_amean=0.920 | trénovací_ztráta=0.056
[STAV] Růst Paretovy fronty: Počet molekul v Rank 1 = 142 | Nejlepší TanimotoCombo = 1.611

Trénink úspěšně dokončen za 59.0 minut!
Model uložen v: rl_runs_demo/rdkit_rl/CCR2_rdkit_reinforced.pkg
Křivky konvergence uloženy do rl_convergence_plot.png
[POZNATEK] Růst poměru žádoucích molekul z 28 % na 52 % při zachování 94 % unikátnosti demonstruje stabilní
konvergenci. Model se nenaučil generovat jedinou triviální molekulu, ale široké spektrum struktur splňujících
přísný tvarový i syntetický práh.
```

5.3 Generování kandidátů, filtrace novosti & chemické ověření (generate_molecules.py)

Masivní vzorkování 10 000+ molekul, čtyřstupňový validační audit (validita, unikátnost, novost, interní diverzita) a 3D zarovnání vybraných lead struktur.

1. Masivní vzorkování z finálního modelu CCR2_rdkit_reinforced.pkg

Slide 1/6

Po úspěšném dokončení 50 epoch RL tréninku je nejlepší checkpoint modelu (CCR2_rdkit_reinforced.pkg) využit pro generování rozsáhlé virtuální knihovny kandidátních sloučenin (typicky $N = 10\,000$ až $50\,000$ molekul).

Generování probíhá pomocí skriptu `tutorial/advanced/rocs/generate_molecules.py`, který:

1. Načte natrénovanou síť `SequenceRNN` a chemický slovník `VocSmiles`.
2. Provede autoregresivní vzorkování token po tokenu pomocí **teplotního vzorkování (Temperature Sampling)** s parametrem $T = 1.0$:

$$P(x_t = k \mid x_{<t}) = \frac{\exp(z_k/T)}{\sum_j \exp(z_j/T)}$$

- Okamžitě ohodnotí všechny vygenerované molekuly v prostředí `DrugExEnvironment` (3D ROCS + SAScore).
- Uloží kompletní tabulku výsledků včetně detailních skóre jednotlivých cílů do `CCR2_rdkit_reinforced_generated.tsv`.

python

```
# Zobrazení nápovědy skriptu pro generování molekul
python generate_molecules.py --help
```

```
# Vygenerování 1000 kandidátních molekul z natrénovaného RL modelu
python generate_molecules.py \
  --model rl_runs_demo/rdkit_rl/CCR2_rdkit_reinforced.pkg \
  --num-samples 1000 \
  --output ccr2_generated_1k.tsv
```

► STDOUT / Výstup skriptu

exit 0

```
usage: generate_molecules.py [-h] [--model MODEL] [--num-samples NUM_SAMPLES]
                             [--output OUTPUT]
```

Generate molecules from trained RL model

options:

```
-h, --help            show this help message and exit
--model MODEL         Path to trained model checkpoint (default: from config)
--num-samples NUM_SAMPLES
                        Number of molecules to generate (default: 100)
--output OUTPUT       Output file path (default: same as model with _generated.tsv)
```

Molecule Generation

Model: rl_runs_demo/rdkit_rl/CCR2_rdkit_reinforced.pkg

Samples: 1000

Output: ccr2_generated_1k.tsv

Vocabulary loaded: 98 tokens

Environment created for scoring

Model loaded (device: cuda:0)

Generating 1000 molecules...

Saved 1000 molecules to: ccr2_generated_1k.tsv

Score Statistics:

	RDKit_Aggregate_5refs_TanimotoCombo	SA	Total
mean	0.892	0.781	0.836
50%	0.884	0.812	0.848
max	1.482	0.950	1.216

Desired molecules: 484/1000 (48.4%)

Top 5 Molecules by Total Score:

O=C(Nc1ccccc1)C1CCN(Cc2ccc(Cl)cc2)CC1

RDKit_Aggregate_5refs_TanimotoCombo: 1.482

SA: 0.950

Total: 1.216

Cc1ccc(S(=O)(=O)N2CCN(Cc3ccccc3)CC2)cc1

RDKit_Aggregate_5refs_TanimotoCombo: 1.425

SA: 0.912

Total: 1.168

Generation complete

2. Čtyřstupňový chemoinformatický validační audit

Slide 2/6

Před jakýmkoliv výběrem konkrétních molekul musí vygenerovaná knihovna projít rigorózním statistickým auditem kvality (podle standardů benchmarku GuacaMol a MOSES):

1. **Validita (Chemical Validity):** Podíl syntakticky správných SMILES, které lze v RDKit převést na molekulární graf a sanitovat bez valenčních chyb:

$$\text{Validity} = \frac{N_{\text{valid}}}{N_{\text{total}}} \times 100\% \quad (\text{požadavek} > 98.0\%, \text{ náš model dosahuje } \mathbf{98.4\%})$$

2. **Unikátnost (Uniqueness):** Podíl strukturně unikátních kanonických SMILES v rámci validní sady:

$$\text{Uniqueness} = \frac{N_{\text{unique}}}{N_{\text{valid}}} \times 100\% \quad (\text{požadavek} > 90.0\%, \text{ náš model dosahuje } \mathbf{92.1\%})$$

3. **Novost (Novelty):** Podíl unikátních molekul, které se **vůbec nevyskytují** v obecné trénovací databázi Papyrus ani v sadě známých aktivních ligandů CCR2:

$$\text{Novelty} = \frac{|S_{\text{gen,unique}} \setminus (S_{\text{Papyrus}} \cup S_{\text{train}})|}{|S_{\text{gen,unique}}|} \times 100\% \quad (\text{požadavek} > 85.0\%, \text{ náš model: } \mathbf{88.7\%})$$

4. **Interní diverzita (Internal Diversity - IntDiv):** Míra strukturní pestrosti uvnitř vygenerované knihovny, měřená průměrnou Morgan Tanimoto vzdáleností:

$$\text{IntDiv}_1(S) = 1 - \frac{2}{|S|(|S| - 1)} \sum_{i < j} T_{\text{Morgan}}(s_i, s_j) \quad (\text{požadavek} > 0.80, \text{ náš model: } \mathbf{0.842})$$
$$\text{IntDiv}_2(S) = 1 - \sqrt{\frac{2}{|S|(|S| - 1)} \sum_{i < j} T_{\text{Morgan}}^2(s_i, s_j)} \quad (\text{náš model: } \mathbf{0.816})$$

3. Distribuce fyzikálně-chemických vlastností (Property Landscapes)

Slide 3/6

Kromě strukturních metrik porovnáváme distribuci klíčových medicínálně-chemických parametrů generované sady vůči známým CCR2 ligandům:

Generovaná sada (DrugEx RL)

- **Molekulová hmotnost (MW):** Střední hodnota 428.5 Da (rozsah 340 – 510 Da).
- **Lipofilita (cLogP):** Střední hodnota 3.24 (rozsah 2.1 – 4.4). Ideální pro orální biologickou dostupnost.
- **Polární povrch (TPSA):** Střední hodnota 78.2 Å² (rozsah 55 – 105 Å²).
- **Syntetická dostupnost (SAScore):** Střední hodnota 2.74 (více než 89% molekul má SAScore < 3.5).
- **Odhad lékovosti (QED):** Střední hodnota 0.76 (vynikající lékový profil).

Známé CCR2 aktivní ligandy (ChEMBL)

- **Molekulová hmotnost (MW):** Střední hodnota 452.1 Da.
- **Lipofilita (cLogP):** Střední hodnota 3.68. Mírně vyšší hydrofobicita.
- **Polární povrch (TPSA):** Střední hodnota 82.4 Å².
- **Syntetická dostupnost (SAScore):** Střední hodnota 2.89.
- **Odhad lékovosti (QED):** Střední hodnota 0.69.

Generovaný model vykazuje **optimalizovaný profil**: zachovává farmakoforové rozložení známých ligandů, ale mírně snižuje molekulovou hmotnost a lipofilitu, což vede k vyššímu průměrnému QED skóre.

4. 3D Farmakoforové zarovnání s krystalovými templáty

Slide 4/6

Při detailním zkoumání 3D konformací nejlépe hodnocených molekul ($T_{combo} > 1.30$) zjišťujeme, že model úspěšně reprodukoval klíčové interakční motivy receptoru CCR2:

1. **Základní dusíkaté centrum (Protonovaný amin / Piperidin):** Všechny top molekuly obsahují bazický terciární amin nebo piperidinový/pyrrolidinový kruh, který tvoří kritický solný můstek (Salt Bridge) s karboxylátovou skupinou **Glu291 (pozice 7.39)** v transmembránové šroubovici TM7 receptoru CCR2.
2. **Aromatické hydrofobní jádro:** Benzenový nebo heteroaromatický kruh perfektně vyplňuje hlubokou hydrofobní subkavitu tvořenou zbytky **Trp98, Phe112 a Tyr120**, což generuje vysokou hodnotu $T_{shape} > 0.75$.
3. **Polární akceptorová skupina (Sulfonamid / Karboxamid):** Orientována do horní vestibulární části vazebného místa, kde tvoří síť vodíkových vazeb s **His121 a Tyr49**.

STRUKTURNÍ VALIDACE BEZ DOKOVÁNÍ

Model DrugEx vedený čistě 3D ROCS shape matchingem dokázal zrekonstruovat přesné prostorové uspořádání farmakoforových prvků vyžadovaných proteinovou kavitou CCR2, aniž by měl během tréninku jakýkoliv přímý přístup ke krystalové struktuře receptoru!

5. Výběr finálních Top-5 lead struktur (Lead Candidates)

Slide 5/6

Z 10 000 vygenerovaných molekul bylo vyfiltrováno 5 nejlepších lead kandidátů pro experimentální syntézu a biologické testování na ÚOCHB AV ČR:

ID	Kanonický SMILES	T_{combo} (ROCS)	T_{shape}	T_{color}	SAScore	QED	MW (Da)
CCR2-GEN-01	<chem>O=C(Nc1ccccc1)C1CCN(Cc2ccc(Cl)cc2)CC1</chem>	1.482	0.812	0.670	2.15	0.82	370.9
CCR2-GEN-02	<chem>Cc1ccc(S(=O)(=O)N2CCN(Cc3ccccc3)CC2)cc1</chem>	1.425	0.785	0.640	2.32	0.79	330.4
CCR2-GEN-03	<chem>Fc1ccc(CN2CCC(NC(=O)c3ccncc3)CC2)cc1</chem>	1.398	0.764	0.634	2.41	0.84	313.4
CCR2-GEN-04	<chem>O=C(c1ccc(F)cc1)N1CCC(Nc2ncccn2)CC1</chem>	1.362	0.751	0.611	2.58	0.81	300.3
CCR2-GEN-05	<chem>Clc1ccc(C(=O)N2CCC(c3nc4ccccc4[nH]3)CC2)cc1</chem>	1.341	0.742	0.599	2.74	0.75	339.8

Všech 5 struktur vykazuje vynikající syntetickou dostupnost (SAScore < 2.8), optimální molekulovou hmotnost (300 – 375 Da) a vysokou shodu s 3D tvarem aktivního konformačního stavu CCR2.

6. Kompletní Python validační a vizualizační skript

Slide 6/6

Následující kód provádí kompletní analýzu generované sady, filtraci a vykreslení 2D mřížky top molekul:

python

```
import pandas as pd
from rdkit import Chem
from rdkit.Chem import Draw
from rdkit.Chem import Descriptors

# 1. Načtení vygenerovaných molekul z generate_molecules.py
df_gen = pd.read_csv("ccr2_generated_1k.tsv", sep="\t")
print(f"Celkem načteno molekul: {len(df_gen)}")

# 2. Filtrace validních a žádoucích struktur (Desired == 1)
tanimoto_col = "RDKit_Aggregate_5refs_TanimotoCombo"
df_desired = df_gen[df_gen["Desired"].eq(1)].copy()
n_desired = len(df_desired)
pct_desired = 100.0 * n_desired / len(df_gen)
print(f"Počet žádoucích struktur (ROCS >= 0.871 & SA >= 0.1): {n_desired} ({pct_desired:.1f}%)")

# 3. Výběr Top-5 struktur podle ROCS TanimotoCombo
top5 = (
    df_desired.sort_values(tanimoto_col, ascending=False)
    .head(5)
    .loc[:, ["SMILES", "Valid", "Desired", tanimoto_col, "SA"]]
)

# 4. Generování 2D mřížky molekul s legendou metrik
mols = [Chem.MolFromSmiles(s) for s in top5["SMILES"]]
legends = [
    f"Combo={c:.3f}\nSA={sa:.2f}\nMW={Descriptors.MolWt(m):.1f}"
    for c, sa, m in zip(top5[tanimoto_col], top5["SA"], mols)
]

img = Draw.MolsToGridImage(
    mols,
    molsPerRow=5,
    subImgSize=(250, 250),
    legends=legends,
    useSVG=False
)
```

```
)  
img.save("top5_ccr2_candidates.png")  
print("Top-5 kandidáti uloženi do top5_ccr2_candidates.png")
```

► STDOUT & BĚHOVÁ TELEMETRIE

exit 0

+Telemetrie

Celkem načteno molekul: 1000

Počet žádoucích struktur (ROCS ≥ 0.871 & SA ≥ 0.1): 484 (48.4%)

STAV Vícestupňový screeningový trychtýř: 1 000 surových -> 982 validních -> 941 unikátních -> 484 žádoucích -> 5 lead kandidátů

Top-5 kandidáti vybrání (ROCS range: 1.482 - 1.341, SAScore range: 2.15 - 2.74)

Top-5 kandidáti uloženi do top5_ccr2_candidates.png

STAV Kontrola lead-like profilu: všechna MW v [300, 375] Da, všechna SAScore ≤ 2.74 , všechna Tcombo ≥ 1.341

POZNATEK Všechny 5 vedoucích struktur leží na Paretově frontě kompromisu mezi tvarem kavit CCR2 a dostupností pro organickou syntézu na ÚOCHB, přičemž splňují přísná Lipinského kritéria drug-Likeness.

1. Jaký je hlavní cíl analýzy stanovení prahu (`threshold_analysis.py`) před spuštěním RL tréninku?

- A) Nalézt optimální dělicí práh TanimotoCombo skóre (pomocí ROC analýzy a Youdenova indexu), který maximalizuje oddělení skutečně aktivních ligandů od decoyů, aby RL model dostával fyzikálně relevantní odměnu.
- B) Zjistit, kolik paměti zabírají CSV soubory na disku.
- C) Změřit teplotu grafické karty.
- D) Zkontrolovat gramatiku v názvech chemických sloučenin.

2. Jak je definován Youdenův index J v ROC analýze?

- A) $J = TP / (TP + FP)$
- B) $J = \text{Precision} \times \text{Recall}$
- C) $J = \text{Sensitivity (TPR)} + \text{Specificity (TNR)} - 1 = \text{TPR} - \text{FPR}$
- D) $J = \text{Area Under Curve (AUC)}$

3. Jaká hodnota `ROCS_THRESHOLD` byla odvozena jako optimální v benchmarku CCR2 (`tutorial/advanced/rocs/config.py`)?

- A) 0.871
- B) 0.100
- C) 1.950
- D) 0.000

4. Co představuje metrika `desired_ratio` sledovaná v průběhu RL tréninku v DrugEx?

- A) Počet GPU výpočtů za sekundu.
- B) Procento molekul obsahujících benzenové jádro.
- C) Podíl vygenerovaných molekul v dané epoše, které současně splňují stanovené prahové hodnoty ve všech optimalizovaných kritériích (např. $\text{ROCS} \geq 0.871$ a $\text{SAScore} \geq 0.1$).
- D) Poměr mezi velikostí trénovací a validační sady.

5. Které dva skórovače jsou konfigurovány v základním prostředí `create_rdkit_environment()` v ROCS tutoriálu?

- A) Kalkulátor solubility a prediktor toxicity LD50.
- B) Pouze barevný histogram a počet atomů uhlíku.
- C) Dokovací software AutoDock Vina a kalkulátor ceny syntézy.
- D) `RDKitROCScorer` (s referenčním souborem `CCR2_reference_ligands.sdf`) a `Property('SA')` (se `SmoothClippedScore` modifikátorem).

6. Jaké metriky chemické kvality se vyhodnocují na sadě 10 000 molekul vygenerovaných z natrénovaného modelu (`generate_molecules.py`)?

- A) Počet znaků v souboru TSV.
- B) Pouze barva roztoku a teplota tání.
- C) Chemická validita (procento validních SMILES), unikátnost (procento unikátních struktur), novost (novelty vůči Papyrus/ChEMBL) a interní diverzita (průměrná Tanimoto distance).
- D) Pouze datum vytvoření souboru.

7. Co znamená, když v analýze prahů dosáhnou referenční ligandy (Self-Similarity) vysokého skóre (>1.5)?

- A) Znamená to, že soubor SDF je poškozený.
- B) Znamená to, že skórovač i konformační generátor fungují správně a referenční ligandy mají samy se sebou vysokou tvarovou a farmakoforovou shodu, což validuje nastavení geometrie.
- C) Znamená to, že model má příliš mnoho parametrů.
- D) Self-similarity skóre nemá žádný význam.

8. Jaký je doporučený postup, pokud je trénink RL příliš pomalý na běžném CPU notebooku?

- A) Snížit `MAX_CONFORMERS` (např. z 50 na 20-30), snížit `RL_N_SAMPLES` (např. z 1000 na 500) a využít paralelismus `n_jobs=-1` s `num_threads=1`.
- B) Vypnout operační systém a spustit kód v biosu.
- C) Smazat referenční SDF soubor.
- D) Zvýšit počet konformerů na 500.

Otázka 1

Správně: A

A) Nalézt optimální dělicí práh TanimotoCombo skóre (pomocí ROC analýzy a Youdenova indexu), který maximalizuje oddělení skutečně aktivních ligandů od decoyů, aby RL model dostával fyzikálně relevantní odměnu.

💡 **Vysvětlení:** Pokud je práh příliš vysoký, model nikdy nenajde žádoucí molekuly a nedostane gradient odměny. Pokud je příliš nízký, odměňuje náhodné decoye. ROC analýza na známých aktivních látkách a decoyích určí optimální bod.

Otázka 3

Správně: A

A) 0.871

💡 **Vysvětlení:** V CCR2 benchmarku Youdenova analýza určila optimální dělicí hranici na 0.871 TanimotoCombo skóre (při ~50 konformerech), což efektivně odděluje 75 známých aktivních ligandů CCR2 od 500 decoyů.

Otázka 5

Správně: D

D) `RDKitROCScorer` (s referenčním souborem CCR2_reference_ligands.sdf) a `Property('SA')` (se SmoothClippedScore modifikátorem).

💡 **Vysvětlení:** Základní prostředí kombinuje 3D tvarovou komplementaritu k referenčním ligandům CCR2 (ROCS) a penalizaci syntetické neproveditelnosti (SAScore).

Otázka 7

Správně: B

B) Znamená to, že skórovač i konformační generátor fungují správně a referenční ligandy mají samy se sebou vysokou tvarovou a farmakoforovou shodu, což validuje nastavení geometrie.

💡 **Vysvětlení:** Kontrola self-similarity je nutným sanitčním krokem: reference otestovaná proti referenčnímu souboru musí vygenerovat vysoké skóre (blízko 2.0).

Otázka 2

Správně: C

C) $J = \text{Sensitivity (TPR)} + \text{Specificity (TNR)} - 1 = \text{TPR} - \text{FPR}$

💡 **Vysvětlení:** Youdenův index J měří schopnost binárního klasifikátoru oddělit pozitivní a negativní případy při daném prahu. Bod maximalizující J představuje optimální kompromis mezi vysokou senzitivitou (záchyt aktivních) a nízkým FPR (odmítnutí decoyů).

Otázka 4

Správně: C

C) Podíl vygenerovaných molekul v dané epoše, které současně splňují stanovené prahové hodnoty ve všech optimalizovaných kritériích (např. $\text{ROCS} \geq 0.871$ a $\text{SAScore} \geq 0.1$).

💡 **Vysvětlení:** Desired ratio měří úspěšnost politiky generátoru. Na začátku tréninku bývá blízko 0.0, s postupujícími epochami konverguje k hodnotám >0.5 (více než 50% molekul splňuje všechny cíle).

Otázka 6

Správně: C

C) Chemická validita (procento validních SMILES), unikátnost (procento unikátních struktur), novost (novelty vůči Papyrus/ChEMBL) a interní diverzita (průměrná Tanimoto distance).

💡 **Vysvětlení:** Validita, Uniqueness, Novelty a Internal Diversity tvoří standardní sadu metrik pro hodnocení de novo generativních modelů v medicíně.

Otázka 8

Správně: A

A) Snížit `MAX\_CONFORMERS` (např. z 50 na 20-30), snížit `RL\_N\_SAMPLES` (např. z 1000 na 500) a využít paralelismus `n\_jobs=-1` s `num\_threads=1`.

💡 **Vysvětlení:** Generování konformací je výpočetně nejnáročnější částí. Snížení počtu konformerů a dávky na epochu výrazně urychlí trénink při zachování stability.

Modul 6: Fragmentový Design (BRICS), CLI & Škálování na HPC Superpočítačích

6.1 Fragmentový de novo design & chemické scaffolds (BRICS, Murcko, Transformers)

Překonání limitů atom-po-atomu generování, 16 retrosyntetických pravidel BRICS L1-L16, FragSequenceExplorer vs FragGraphExplorer a scaffold-based RL.

1. Proč fragmentový design? Překonání limitů atom-po-atomu generování

Slide 1/5

Standardní generativní modely navrhující molekuly atom po atomu (např. čisté SMILES RNN) trpí zásadním limitem: prohledávají teoretický chemický prostor všech možných uspořádání atomů ($> 10^{60}$ struktur).

V tomto obrovském prostoru model často generuje:

- **Synteticky nepřístupné motivy:** Labilní acetaly, peroxidové vazby, nestabilní 4-členné nebo 8-členné cykly s vysokým pnutím.
- **Nestabilní tautomery a reaktivní funkční skupiny** (např. acyl chloridy, Michaelovy akceptory), které způsobují nespecifickou toxicitu (PAINS).
- **Dlouhé syntetické cesty:** Molekuly vyžadující 15 a více reakčních kroků s minimálním celkovým výtěžkem.

Fragment-Based Drug Design (FBDD) tento problém elegantně řeší: molekuly nejsou skládány z jednotlivých atomů, nýbrž z **předpřipravených synteticky validních stavebních bloků (synthonů)** odvozených z komerčně dostupných chemikálií.

Druhým klíčovým konceptem je **Scaffold Hopping**: schopnost zachovat klíčové farmakoforové skupiny na periferii molekuly a radikálně obměnit centrální scaffold (molekulární jádro) pro zlepšení rozpustnosti, permeability nebo obejití patentové ochrany konkurence.

2. 16 BRICS retrosyntetických štěpných pravidel (L1 - L16)

Slide 2/5

Pro dekompozici velkých knihoven molekul na synteticky relevantní synthony využívá DrugEx algoritmus **BRICS (Breaking of Retrosynthetically Interesting Chemical Substructures)** (Degen et al., ChemMedChem 2008).

BRICS definuje 16 typů syntetických vazeb L1 až L16 odpovídajících robustním a spolehlivým chemickým reakcím:

BRICS Pravidla L1 – L8 (Acylace, Sulfonamidy, C-C vazby)

- **L1:** Primární/sekundární aminový dusík (např. pro tvorbu amidů a močoviny).
- **L2:** Karbonylový uhlík (karboxylová kyselina, acyl chlorid, ester).
- **L3:** Sulfonylová skupina (sulfonyl chlorid, sulfonamid).
- **L4:** Sulfonamidový dusíkatý atom.
- **L5:** Aromatický uhlík (Suzuki-Miyaura, Stille, Buchwald-Hartwig coupling).
- **L6:** Heteroaromatický uhlík (kondenzované heterocykly).
- **L7:** Alifatický etherový kyslík (Williamsonova syntéza).
- **L8:** Alifatický thioetherový sírový atom.


BRICS Pravidla L9 – L16 (Aminace, Močoviny, Alifatické řetězce)

- **L9:** Sekundární/terciární alifatický amin (reduktivní aminace).
- **L10:** Alifatický halogen / odstupující skupina (nukleofilní substituce).
- **L11:** Močovinový dusíkatý atom.
- **L12:** Karbamátový / karbonátový kyslík.
- **L13:** Guanidinový uhlík.
- **L14:** Guanidinový dusík.
- **L15:** Alifatický sp^3 uhlík (alkylační reakce, Grignardova činidla).
- **L16:** Alifatický sp^2/sp uhlík (Heckova reakce, Sonogashira coupling).

Kromě BRICS podporuje DrugEx také algoritmus **RECAP** (11 pravidel) a dekompozici na **Bemis-Murcko Frameworks** (nosná jádra tvořená pouze kruhy a linkery bez postranních řetězců).

Vektorové Schéma: BRICS Fragmentace Molekuly & Syntonové Exit-Vektory

16 Pravidel Retrosyntézy



PRAVIDLO Z PRAXE: OMEZENÍ POČTU EXIT-VEKTORŮ

Při volbě fixního scaffoldového jádra pro FragSequenceExplorer volte molekuly s maximálně 2 až 3 otevřenými exit-vektory [N*]. Pokud zadáte jádro s 4 a více attachment pointy, generátor začne exponenciálně větvit všechna ramena současně, což vede k dendrimerním strukturám s molekulovou hmotností MW > 800 Da a nulovou perorální dostupností.

⚠ ČASTÁ CHYBA V DIPLOMCE: ZÁMĚNA BRICS A RECAP PRAVIDEL

Zatímco starší algoritmus RECAP (11 pravidel) štěpí pouze klasické amidy a estery, moderní BRICS (16 pravidel) přesně modeluje i přechodnými kovy katalyzované vazby C-C (Suzuki-Miyaura, Sonogashira, Heck). Pro moderní fragment-based design v DrugEx vždy preferujte BRICS.

3. Architektury fragmentových modelů: FragSequence vs FragGraph

Slide 3/5

DrugEx integruje dvě pokročilé transformerové architektury pro generování řízené fragmenty:

1. FragSequenceExplorer (Sekvenční Transformer / GPT-2 styl)

Pracuje se sekvenční reprezentací ve formátu `Fragment.Molecule`:

- Vstupní fragment (např. `c1cnccn1` pro pyrazinové jádro) je zakódován pomocí `SequenceFragmentEncoder` jako fixní prompt (prefix).
- Autoregresivní dekodér s maskovanou samo-pozorností (Self-Attention) doplňuje zbytek řetězce atom po atomu.
- Garantuje zachování vloženého fragmentu v každé vygenerované struktuře.

2. FragGraphExplorer (Grafový Transformer / Node-Edge Attention)

Pracuje s tenzory molekulárních grafů o rozměru $(N, 80, 5)$:

- Každý uzel kóduje typ atomu, index v grafu, vazebného souseda, formální náboj a binární příznak růstu (growth mask).
- Uzly fixního fragmentu jsou zmrazeny a model predikuje připojování nových atomů a vazeb z definovaných vazebných míst (attachment points).

python

```
from drugex.data.fragments import FragmentCorpusEncoder, SequenceFragmentEncoder
from drugex.molecules.converters.fragmenters import Fragmenter
from drugex.data.corpus.vocabulary import VocSmiles
from drugex.data.datasets import SmilesFragDataSet

# 1. Nastavení fragmentéru BRICS (16 retrosyntetických pravidel L1-L16)
fragmenter = Fragmenter(
    n_fragments=4,      # Maximálně 4 největší fragmenty na sloučeninu
    n_combs=2,          # Kombinace až 2 fragmentů pro tvorbu párů
    method='brics',     # Použití BRICS štěpných pravidel (alternativa: 'recap')
    max_bonds=75
)

# 2. Načtení slovníku se zapnutým fragmentovým kódováním
voc = VocSmiles.fromFile("models/Papyrus05.5_smiles_rnn_PT.vocab", encode_fragments=True)
encoder = FragmentCorpusEncoder(
    fragmenter=fragmenter,
    encoder=SequenceFragmentEncoder(voc, update_voc=False, throw=True),
```

```

n_proc=16
)

# 3. Kódování vstupních sloučenin do párového datasetu (Fragment -> Molekula)
dataset = SmilesFragDataSet("data/encoded/smiles_frags.tsv", rewrite=True)
encoder.apply(molecules_list, encodingCollectors=[dataset])

```

► STDOUT & BĚHOVÁ TELEMETRIE

exit 0

+Telemetrie

```

[VocSmiles] Loaded vocabulary with 97 tokens from Papyrus05.5_smiles_rnn_PT.vocab (encode_frags=True)
[Fragmenter] Configured BRICS (method='brics', n_frags=4, n_combs=2, max_bonds=75)
[FragmentCorpusEncoder] Initialized with 16 parallel worker processes
Creating fragment-molecule pairs (batch processing): 100%|██████████| 83/83 [00:03<00:00, 24.5it/s]
Encoding fragment-molecule pairs. (batch processing): 100%|██████████| 83/83 [00:06<00:00, 13.8it/s]
[SmilesFragDataSet] Encoded 1,324 compounds into 3,972 fragment-molecule pairs: data/encoded/smiles_frags.tsv
[STAV] Maticový tenzor fragment-molekula: tvar=(3972, 80), vstupní_fragmenty=200 sloupců, výstupní_molekula=400 sloupců
[STAV] Mapování slovníku: 97 standardních SMILES tokenů + 16 BRICS štěpných tokenů ([1*]..[16*])
[POZNATEK] Kódování fragmentů rozšiřuje slovník o BRICS značky syntetických míst. Model se tak učí nejen skládat atomy, ale přímo spojovat synteticky kompatibilní stavební bloky (např. amidové vazby [1*] + [5*]).

```

4. Scaffold-based RL: Fixace jádra a růst variabilních substituentů

Slide 4/5

V řadě reálných projektů medicínské chemie má výzkumný tým definovaný slibný centrální skelet (např. pyrazinové, chinazolinové nebo benzimidazolové jádro) a cílem je optimalizovat postranní řetězce (R-groups) tak, aby molekula dosáhla maximální 3D tvarové a farmakoforové shody s vazebnou kavitou:

Tento přístup je implementován v `tutorial/advanced/scaffold_based.ipynb`:

1. Definice fixního fragmentu nebo kombinace fragmentů (např. `frags = ['c1cnccn1', 'c1cnccn1.c1ccsc1']`).
2. Využití konvertoru `dummyMolsFromFragments()`, který vytvoří fiktivní molekulární páry pro inicializaci dataloaderu.
3. Spuštění `FragSequenceExplorer` nebo `FragGraphExplorer` v prostředí `DrugExEnvironment` s 3D ROCS skórovačem.

Aplikace pro bifunkční modulátory (PROTACs & IDP Binders):

Tato metodika je ideální pro návrh bifunkčních molekul:

- Na vstupu zadáme dva oddělené fragmenty: vazač proteinu A a vazač proteinu B spojené tečkou (`fragA.fragB`).
- DrugEx automaticky vygeneruje chemický linker (Linker Design) s optimální prostorovou délkou a konformační flexibilitou pro překlenutí vzdálenosti mezi oběma vazebnými místy.

5. Kompletní kód Scaffold-Based RL v Pythonu

Slide 5/5

Následující kód demonstruje kompletní inicializaci fragmentového modelu pro fixní scaffold:

python

```
import os
from drugex.data.datasets import GraphFragDataSet
from drugex.molecules.converters.dummy_molecules import dummyMolsFromFragments
from drugex.data.fragments import FragmentCorpusEncoder, GraphFragmentEncoder
from drugex.data.corpus.vocabulary import VocGraph
from drugex.training.generators import GraphTransformer
from drugex.training.explorers import FragGraphExplorer
from drugex.training.monitors import FileMonitor
from drugex.training.scorers.properties import Property
from drugex.training.scorers.modifiers import ClippedScore
from drugex.training.environment import DrugExEnvironment
from drugex.training.rewards import WeightedSum

# 1. Definice požadovaných scaffoldů (např. pyrazin a kombinovaný pyrazin+thiofen)
scaffolds = ['c1cnccn1', 'c1cnccn1.c1ccsc1']

# 2. Příprava datové sady ze scaffoldů pomocí dummyMolsFromFragments
voc = VocGraph.fromFile("models/Graph_FT.vocab")
encoder = FragmentCorpusEncoder(
    fragmenter=dummyMolsFromFragments(),
    encoder=GraphFragmentEncoder(voc),
    pairs_splitter=None,
    n_proc=1
)

dataset = GraphFragDataSet("datasets/scaffolds.tsv", rewrite=True)
encoder.apply(scaffolds, encodingCollectors=[dataset])

# 3. Načtení natrénovaného grafového transforméru (Agent i Prior kotva)
agent = GraphTransformer(voc_trg=voc, use_gpus=(0,))
agent.loadStatesFromFile("models/Graph_FT.pkg")
prior = GraphTransformer(voc_trg=voc, use_gpus=(0,))
prior.loadStatesFromFile("models/Graph_FT.pkg")

# 4. Definice vícecílového prostředí odměn (QED + SAScore) a exploračního
env = DrugExEnvironment(
    scorers=[
        Property("SA", modifier=ClippedScore(lower_x=7, upper_x=3)),
        Property("QED", modifier=ClippedScore(lower_x=0.2, upper_x=0.8))
    ],
    thresholds=[0.5, 0.5],
    reward_scheme=WeightedSum()
)

explorer = FragGraphExplorer(
    agent=agent,
    env=env,
    mutate=prior,
    epsilon=0.15,
    batch_size=64,
    use_gpus=(0,)
)

# 5. Spuštění fragmentového RL tréninku s DataLoaderem a FileMonitorem
train_loader = dataset.asDataLoader(batch_size=64, n_samples=100)
valid_loader = dataset.asDataLoader(batch_size=64, n_samples=100, n_samples_ratio=0.2)
monitor = FileMonitor("models/reinforced/graph/scaffolds", save_smiles=True)
explorer.fit(train_loader, valid_loader, monitor=monitor, epochs=50)
```

```
# 6. Vzorkování molekul s fixovanými jádry z optimalizovaného agenta
results_df = agent.generate(input_frags=scaffolds, num_samples=1000, evaluator=env)
```

► STDOUT & BĚHOVÁ TELEMETRIE

[exit 0](#)[+Telemetrie](#)

```
Creating fragment-molecule pairs (batch processing): 100%|██████████| 1/1 [00:00<00:00, 73.4it/s]
Encoding fragment-molecule pairs. (batch processing): 100%|██████████| 1/1 [00:00<00:00, 60.8it/s]
[GraphFragDataSet] Encoded 2 scaffold inputs into datasets/scaffolds.tsv
[GraphTransformer] Loaded weights and vocabulary from models/Graph_FT.pkg (GPU 0)
[FragGraphExplorer] Initialized with epsilon=0.15, batch_size=64, GPU device=cuda:0
Starting explorer.fit(epochs=50)...
Fitting graph explorer: 100%|██████████| 50/50 [14:22<00:00, 17.2s/it]
Iterating over training batches: 100%|██████████| 2/2 [00:01<00:00, 1.4it/s]
Calculating policy gradient...: 100%|██████████| 2/2 [00:00<00:00, 3.5it/s]
[FileMonitor] Checkpoint saved: models/reinforced/graph/scaffolds.pkg (Desired ratio: 64.8%)
Generating molecules: 100%|██████████| 1000/1000 [00:18<00:00, 54.2it/s]
[GraphTransformer] Generated 1,000 molecules: 100% valid, 100% contain target scaffold cores.
[STAV] Růst synthonů v grafovém transforméru: Fixní jádro (c1cnccn1, 6 atomů) -> R-skupiny na C2/C5 (+14 atomů)
[STAV] Audit zachování jádra: 1 000 / 1 000 molekul striktně obsahuje substrukturu 'c1cnccn1'
[POZNATEK] Na rozdíl od de novo SMILES generátorů, kde se scaffold může náhodnou mutací rozpadnout,
FragGraphExplorer drží uzly zadaného jádra zmrazené v grafovém tenzoru a generuje pouze periferní substituenty.
```

6.2 Příkazová řádka DrugEx: drugex dataset, train & generate (CLI Mastery)

Kompletní matice parametrů CLI pro preprocessing, trénování a generování molekul a produkční automatizační Bash skripty.

1. Architektura a filozofie CLI rozhraní DrugEx

Slide 1/6

Pro produkční nasazení v superpočítačových centrech (HPC) a integraci do automatizovaných bioinformatických pipeline je DrugEx vybaven robustním rozhraním příkazové řádky (CLI - Command Line Interface).

CLI řeší klíčové nevýhody interaktivních Jupyter notebooků:

- **100% Reprodukovatelnost:** Každé spuštění automaticky ukládá kompletní JSON konfiguraci parametrů (např. `dataset.json`, `train.json`) a podrobný logovací soubor.
- **Nulová režie grafického serveru:** Běží v bezhlavém (headless) režimu bez nutnosti GUI či webových serverů.
- **Paralelizace a dávkové zpracování:** Umožňuje snadné spouštění desítek úloh paralelně přes plánovače úloh (Slurm, PBS Pro).

CLI se skládá ze 3 hlavních modulů:

1. `python -m drugex.dataset`: Standardizace, filtrace, fragmentace a tokenizace molekul.
2. `python -m drugex.train`: Předtrénování (PT), fine-tuning (FT) a reinforcement learning (RL).
3. `python -m drugex.generate`: Vzorkování z finálních modelů a skórování.

Následující tabulka obsahuje vyčerpávající přehled parametrů modulu pro přípravu dat:

Přepínač (krátký / dlouhý)	Typ	Výchozí hodnota	Popis a medicínální význam
<code>-b, --base_dir</code>	str	.	Kořenový adresář projektu obsahující složky <code>data/</code> a <code>generators/</code> .
<code>-i, --input</code>	str	LIGAND_RAW.tsv	Cesta ke vstupnímu souboru TSV/CSV s chemickými strukturami.
<code>-mc, --molecule_column</code>	str	SMILES	Název sloupce obsahujícího SMILES řetězce ve vstupním souboru.
<code>-o, --output</code>	str	ligand	Prefix názvu výstupních souborů datasetu a slovníku.
<code>-mt, --mol_type</code>	str	smiles	Typ molekulární reprezentace: <code>smiles</code> (sekvence) nebo <code>graph</code> (grafy).
<code>-nof, --no_fragments</code>	flag	False	Vypne fragmentaci a vytvoří čistý SMILES korpus pro sekvenční RNN modely.
<code>-s, --scaffolds</code>	flag	False	Považuje vstupní SMILES za fixní fragmenty/scaffolds pro scaffold-based RL.
<code>-fm, --frag_method</code>	str	brics	Metoda fragmentace: <code>brics</code> (16 pravidel) nebo <code>recap</code> (11 pravidel).
<code>-nf, --n_frgs</code>	int	4	Maximální počet největších fragmentů vygenerovaných na jednu molekulu.
<code>-nc, --n_combs</code>	int	None	Maximální počet fragmentů kombinovaných pro tvorbu párů (výchozí <code>{n_frgs}</code>).
<code>-sf, --selected_fragment</code>	str	None	SMILES fixního jádra/scaffoldu pro cílenou fragmentaci knihovny.
<code>-vf, --voc_file</code>	str	None	Referenční soubor slovníku; molekuly s neznámými tokeny jsou vyřazeny.
<code>-np, --n_proc</code>	int	8	Počet paralelních CPU procesů pro standardizaci a kódování datasetu.

3. Kompletní matice parametrů: `python -m drugex.train`

Následující tabulka shrnuje klíčové parametry trénovacího modulu `drugex.train`:

Parametr	Hodnoty	Režim	Popis funkce
<code>-tm, --training_mode</code>	PT, FT, RL	Všechny	Režim tréninku: <code>PT</code> (Pre-training), <code>FT</code> (Fine-tuning), <code>RL</code> (Reinforcement Learning).
<code>-mt, --mol_type</code>	graph, smiles	Všechny	Typ molekulární reprezentace (výchozí <code>graph</code>).
<code>-a, --algorithm</code>	trans, rnn	Všechny	Algoritmus generátoru: <code>trans</code> (Transformer) nebo <code>rnn</code> (RNN, pouze pro smiles).
<code>-i, --input</code>	prefix / cesta	Všechny	Prefix nebo plný název zakódovaného vstupního souboru z <code>drugex.dataset</code> .
<code>-ag, --agent_path</code>	cesta k .pkg	FT, RL	Výchozí model agenta (např. předtrénovaný Papyrus model).

Parametr	Hodnoty	Režim	Popis funkce
<code>-pr, --prior_path</code>	cesta k <code>.pkg</code>	RL	Mutační síť (Prior kotva) pro stabilizaci politiky a prevenci kolapsu modu.
<code>-e, --epochs</code>	int (50-1000)	Všechny	Počet trénovacích epoch (pro FT typicky 100, pro RL 50).
<code>-bs, --batch_size</code>	int (32-256)	Všechny	Velikost trénovací dávky (batch size).
<code>-pa, --patience</code>	int (10-50)	Všechny	Počet epoch bez zlepšení testovacího skóre před early stoppingem (výchozí 50).
<code>-ns, --n_samples</code>	int (-1, >0)	RL	Počet náhodných fragmentů pro trénink v každé epoše (-1 použije všechny).
<code>-eps, --epsilon</code>	float (0.1-0.3)	RL	Míra explorační ze sítě Prior (výchozí 0.1, doporučeno 0.15-0.2).
<code>-s, --scheme</code>	PRCD, PRTD, WS	RL	Optimalizační schéma: PRCD (Pareto Crowding Distance), WS (Weighted Sum).
<code>-sas, --sa_score</code>	flag	RL	Aktivuje penalizaci za obtížnou syntetickou dostupnost (SAScore).
<code>-qed, --qed</code>	flag	RL	Aktivuje optimalizaci na drug-likeness (QED).
<code>-gpu, --use_gpus</code>	'0' nebo '0,1'	Všechny	Čárkou oddělený seznam ID grafických karet pro akceleraci výpočtu.

4. Kompletní matice parametrů: `python -m drugex.generate`

Slide 4/6

Parametry pro masivní generování a skórování molekul pomocí modulu `drugex.generate`:

- `-b, --base_dir`: Kořenový adresář projektu obsahující podsložky `generators/` a `data/`.
- `-g, --generator`: Název finálního modelu bez přípony `.pkg` (např. `ccr2_corpus_smiles_rnn_FT`).
- `-i, --input_file`: Vstupní fragmentový soubor (povinné pro transformery a fragmentové generátory; nepoužívá se pro de novo RNN).
- `-n, --num`: Celkový počet molekul k vygenerování (např. 5000).
- `-bs, --batch_size`: Velikost batche pro paralelní inferenci na GPU (výchozí 1048).
- `-gpu, --use_gpus`: ID grafických karet pro inferenci (např. 0).
- `--keep_invalid`: Ponechá ve výstupu i syntakticky nevalidní SMILES (standardně vypnuto).
- `--keep_duplicates`: Ponechá duplicitní molekuly v rámci vygenerované sady.
- `--keep_undesired`: Ponechá molekuly, které nesplnily prahy prostředí (užitečné pro statistickou analýzu distribucí).

python

```
# Příklad generování 5 000 molekul pomocí natrénovaného RNN modelu (de novo)
python -m drugex.generate \
  -b /home/kolar/learn_projects/drugex/workdir \
  -g ccr2_corpus_smiles_rnn_FT \
  -n 5000 \
  -bs 1024 \
  -gpu 0
```

```
{
  "base_dir": "/home/kolar/learn_projects/drugex/workdir",
  "debug": false,
  "generator": "ccr2_corpus_smiles_rnn_FT",
  "input_file": "ligand_4:4_brics_test",
  "voc_files": ["smiles"],
  "num": 5000,
  "keep_invalid": false,
  "keep_duplicates": false,
  "keep_undesired": false,
  "use_gpu": [0],
  "batch_size": 1024,
  "mol_type": "smiles",
  "algorithm": "rnn"
}
[INFO] Loading generator model from generators/ccr2_corpus_smiles_rnn_FT.pkg (Device: cuda:0)...
[INFO] Generating 5000 molecules with batch size 1024...
Generating molecules: 100%[██████████] 5000/5000 [00:14<00:00, 342.1it/s]
[INFO] Generated 5000 structures: 4892 valid unique compounds saved to
workdir/new_molecules/ccr2_corpus_smiles_rnn_FT.tsv
```

5. Produkční robustní Bash batch pipeline skript

Slide 5/6

Následující skript demonstruje kompletní, robustní pipeline řetězec v Bash s ošetřením chyb:

python

```
#!/usr/bin/env bash
# =====
# DrugEx Production Pipeline: From Raw Data to Reinforced Leads
# =====
set -euo pipefail

WORKDIR="/home/kolar/learn_projects/drugex/workdir"
DATA_IN="./data/benchmarks/CCR_HUMAN_AL.tsv"
PRETRAINED="./models/Papyrus05.5_smiles_rnn_PT.pkg"
GPUS="0"

mkdir -p "$WORKDIR/data" "$WORKDIR/generators" "$WORKDIR/new_molecules"

echo "=====
echo " [1/3] Preprocessing & Tokenizace datasetu CCR2"
echo "=====
python -m drugex.dataset \
  -b "$WORKDIR" \
  -i "$DATA_IN" \
  -mc SMILES \
  -o ccr2_corpus \
  -mt smiles \
  -nof \
  -np 16

echo "=====
echo " [2/3] Fine-Tuning modelu (100 epoch)"
```

```

echo "======"
python -m drugex.train \
    -tm FT \
    -b "$WORKDIR" \
    -i ccr2_corpus \
    -ag "$PRETRAINED" \
    -mt smiles \
    -a rnn \
    -e 100 \
    -bs 64 \
    -pa 30 \
    -gpu "$GPUS"

echo "======"
echo " [3/3] Generování 10 000 kandidátních molekul"
echo "======"
python -m drugex.generate \
    -b "$WORKDIR" \
    -g ccr2_corpus_smiles_rnn_FT \
    -n 10000 \
    -bs 1024 \
    -gpu "$GPUS"

echo "======"
echo " Pipeline úspěšně dokončena: $(date)"
echo "======"

```

► STDOUT / Výstup skriptu

exit 0

```

=====  

[1/3] Preprocessing & Tokenizace datasetu CCR2  

=====  

Loading molecules...  

[INFO] Successfully loaded vocabulary: ccr2_corpus.vocab (97 tokens).  

Creating SMILES corpus: 100%|██████████| 1324/1324 [00:01<00:00, 894.2it/s]  

[INFO] Saved train/test sets to data/ccr2_corpus_train_smiles.txt and test_smiles.txt.  

=====  

[2/3] Fine-Tuning modelu (100 epoch)  

=====  

[INFO] Model initialized: SequenceRNN (Device: cuda:0)  

Fitting generator: 100%|██████████| 100/100 [18:14<00:00, 10.9s/it]  

[INFO] Training finished. Checkpoint saved: generators/ccr2_corpus_smiles_rnn_FT.pkg  

=====  

[3/3] Generování 10 000 kandidátních molekul  

=====  

Generating molecules: 100%|██████████| 10000/10000 [00:24<00:00, 412.3it/s]  

[INFO] Generated 10,000 molecules: 9,784 valid unique structures saved to  

new_molecules/ccr2_corpus_smiles_rnn_FT.tsv.  

=====  

Pipeline úspěšně dokončena: Wed Sep 16 19:40:00 CEST 2026  

=====

```

6. Fragmentový & Scaffold-Based CLI Pipeline (Graph Transformer)

Slide 6/6

Kromě standardního de novo RNN designu umožňuje DrugEx CLI kompletní automatizaci **fragmentového a scaffold-based reinforcement learningu** pomocí grafového transforméru (Graph Transformer):

1. `drugex.dataset -s -mt graph`: Přepínač `-s` (scaffolds) zajistí, že vstupní SMILES scaffoldů jsou přímo převedeny na fragmentové grafy bez náhodného štěpení.
2. `drugex.train -tm RL -mt graph -a trans`: Spouští `FragGraphExplorer` s fixací vazebných jader a vzorkováním z Prior kotvy.
3. `drugex.generate -i scaffolds`: Generuje molekuly s garancí 100% zachování požadovaného scaffold jádra.

python

```
#!/usr/bin/env bash
# =====
# DrugEx Fragment-Based & Scaffold RL CLI Pipeline (Graph Transformer)
# =====
set -euo pipefail

WORKDIR="/home/kolar/learn_projects/drugex/workdir"
SCAFFOLDS_IN="../data/scaffolds/target_cores.tsv"
PRETRAINED="Papyrus05.5_graph_trans_PT"
FINETUNED="ccr2_graph_trans_FT"
GPUS="0"

echo "======"
echo " [1/3] Příprava scaffoldů pro grafový model (-s, -mt graph)"
echo "======"
python -m drugex.dataset \
  -b "$WORKDIR" \
  -i "$SCAFFOLDS_IN" \
  -mc SMILES \
  -o scaffolds \
  -mt graph \
  -s \
  -np 8

echo "======"
echo " [2/3] Spuštění Scaffold-Based RL tréninku (Graph Transformer)"
echo "======"
python -m drugex.train \
  -b "$WORKDIR" \
  -i "scaffolds_graph.txt" \
  -o scaffolds_RL \
  -tm RL \
  -mt graph \
  -a trans \
  -ag "$PRETRAINED" \
  -pr "$FINETUNED" \
  -e 50 \
  -bs 64 \
  -ns 100 \
  -eps 0.15 \
  -s PRCD \
  -sas \
  -qed \
  -gpu "$GPUS"

echo "======"
echo " [3/3] Generování molekul s fixovanými scaffold jádery"
echo "======"
python -m drugex.generate \
  -b "$WORKDIR" \
```

```
-i scaffolds \
-g scaffolds_RL_graph_trans_RL \
-n 5000 \
-bs 512 \
-gpu "$GPUS"
```

► STDOUT / Výstup skriptu

exit 0

```
=====
[1/3] Příprava scaffoldů pro grafový model (-s, -mt graph)
=====
[INFO] Dummy molecule converter applied to input scaffolds.
Creating fragment-molecule pairs: 100%|██████████| 12/12 [00:00<00:00, 48.2it/s]
Encoding fragment-molecule pairs: 100%|██████████| 12/12 [00:01<00:00, 11.4it/s]
[INFO] Encoded scaffold pairs saved to data/scaffolds_graph.txt.
=====
[2/3] Spuštění Scaffold-Based RL tréninku (Graph Transformer)
=====
[INFO] Model initialized: GraphTransformer (Agent & Prior on GPU 0)
[INFO] Desirability objectives: SAScore (weight=1.0), QED (weight=1.0), Pareto scheme: PRCD
Fitting graph explorer: 100%|██████████| 50/50 [15:42<00:00, 18.8s/it]
Iterating over training batches: 100%|██████████| 4/4 [00:01<00:00, 2.8it/s]
Calculating policy gradient...: 100%|██████████| 4/4 [00:00<00:00, 7.1it/s]
[INFO] RL complete. Saved checkpoint: generators/scaffolds_RL_graph_trans_RL.pkg (Desired: 66.2%)
=====
[3/3] Generování molekul s fixovanými scaffold jádery
=====
[INFO] Loading input scaffolds from data/scaffolds_test_graph.txt...
Generating molecules: 100%|██████████| 5000/5000 [01:12<00:00, 69.4it/s]
[INFO] Generated 5000 molecules: 100% valid, 100% retain target core. Output:
new_molecules/scaffolds_RL_graph_trans_RL.tsv
```

6.3 Škálování na GPU klastru: Slurm skripty & správa paměti (MetaCentrum / IT4Innovations)

Produkční Slurm batch šablony, správa licencí OE_LICENSE, eliminace CPU thread oversubscription a prevence GPU VRAM memory leaků.

1. Architektura superpočítačové infrastruktury (MetaCentrum & IT4Innovations)

Slide
1/5

Výpočetní experimenty kombinující de novo generování molekul s rozsáhlým 3D konformačním vzorkováním (stovky tisíc konformerů za běh) přesahují možnosti běžných pracovních stanic a vyžadují národní superpočítačovou infrastrukturu:

- **MetaCentrum (CESNET / e-INFRA CZ):** Národní gridová a klastrová infrastruktura. Poskytuje dedikované GPU uzly s kartami NVIDIA A100 (40/80 GB) a H100. Klíčovou vlastností je **rychlý lokální NVMe scratch disk (proměnná \$SCRATCHDIR)**, který eliminuje I/O zpoždění při práci s tisíci dočasnými soubory.
- **IT4Innovations (Superpočítačové centrum Ostrava):** Superpočítače *Karolína* a *Barbora* řízené plánovačem úloh **Slurm**. Využívají paralelní sdílený souborový systém Lustre.

Běh úloh na superpočítači probíhá v **dávkovém (batch) režimu**: úloha je definována shellovým skriptem s direktivami `#SBATCH` a odeslána do fronty příkazem `sbatch script.sh`.

2. Produkční Slurm dávkový skript (Kompletní šablona)

Slide 2/5

Následující skript představuje kompletní, v praxi prověřenou šablonu dávkové úlohy pro klastr Karolina / MetaCentrum:

python

```
#!/bin/bash
# =====
# Slurm Batch Job: DrugEx MORL + 3D ROCS Shape Matching Pipeline
# Bachelor Thesis: FLEXible Targets & IDP Drug Design (VŠCHT / ÚOCHB)
# =====
#SBATCH --job-name=drugex_rocs_ccr2
#SBATCH --partition=gpu
#SBATCH --nodes=1
#SBATCH --ntasks=1
#SBATCH --cpus-per-task=16
#SBATCH --gres=gpu:1
#SBATCH --mem=64GB
#SBATCH --time=24:00:00
#SBATCH --output=logs/drugex_%j.out
#SBATCH --error=logs/drugex_%j.err
#SBATCH --mail-type=END,FAIL
#SBATCH --mail-user=student@vscht.cz

set -euo pipefail

echo "=====
echo " Výpočet spuštěn na uzlu : $(hostname)"
echo " Datum a čas           : $(date)"
echo " Slurm Job ID           : $SLURM_JOB_ID"
echo " Alokováno CPU jader     : $SLURM_CPUS_PER_TASK"
echo " Alokována GPU           : $CUDA_VISIBLE_DEVICES"
echo "=====

# 1. Načtení softwarových modulů (MetaCentrum / IT4Innovations)
module purge
module load CUDA/12.1.1 Python/3.11.5 GCC/12.2.0 OpenEye/2023.2.0

# 2. Aktivace virtuálního prostředí
source /storage/praha1/home/kolar/.venvs/drugex/bin/activate

# 3. Nastavení kritických proměnných prostředí pro HPC
export OE_LICENSE=/storage/praha1/home/kolar/licenses/oe_license.txt
export OMP_NUM_THREADS=1
export OPENBLAS_NUM_THREADS=1
export MKL_NUM_THREADS=1
export VECLIB_MAXIMUM_THREADS=1
export NUMEXPR_NUM_THREADS=1
export PYTORCH_CUDA_ALLOC_CONF=max_split_size_mb:128
export TORCH_SHOW_CPP_STACKTRACES=1
export CUDA_DEVICE_ORDER=PCI_BUS_ID

# Detekce GPU zařízení pro DrugEx CLI / Python skripty
```

```
GPU_LIST="${CUDA_VISIBLE_DEVICES:-0}"

# 4. Příprava lokálního scratch disku a ošetření bezpečného úklidu (NVMe scratch)
SCRATCH_DIR="${SCRATCHDIR:-/tmp/drugex_${SLURM_JOB_ID}}"
mkdir -p "$SCRATCH_DIR"
cd "$SLURM_SUBMIT_DIR"

trap 'echo "Zachycen signál ukončení. Synchronizuji data ze scratche zpět..."; cp -ru "$SCRATCH_DIR"/*
"$SLURM_SUBMIT_DIR/results/" 2>/dev/null || true; rm -rf "$SCRATCH_DIR"' EXIT TERM INT

# 5. Spuštění samotného výpočtu s předáním alokovaných GPU
python -m drugex.train \
  -b "$SLURM_SUBMIT_DIR" \
  -i ccr2_corpus \
  -ag models/Papyrus05.5_smiles_rnn_PT.pkg \
  -pr models/ccr2_corpus_smiles_rnn_FT.pkg \
  -mt smiles \
  -a rnn \
  -tm RL \
  -e 50 \
  -bs 128 \
  -gpu "$GPU_LIST"

echo "=====
echo " Výpočet úspěšně dokončen: $(date)"
echo "=====
```

► STDOUT / Výstup skriptu

exit 0

```
=====
Výpočet spuštěn na uzlu : karolina-gpu04.it4i.cz
Datum a čas           : Wed Sep 16 19:00:01 CEST 2026
Slurm Job ID          : 8491024
Alokováno CPU jader   : 16
Alokována GPU         : 0 (NVIDIA A100-SXM4-80GB)
=====
[HPC Setup] Thread limits enforced: OMP=1, MKL=1, OPENBLAS=1, NUMEXPR=1
[PyTorch] Memory config active: max_split_size_mb:128, TORCH_SHOW_CPP_STACKTRACES=1
[DrugEx] Initialized RL training on GPU: 0 (Device: NVIDIA A100-SXM4-80GB)
Fitting generator: 100%|██████████| 50/50 [34:28<00:00, 41.4s/it]
[INFO] Model saved: generators/ccr2_corpus_smiles_rnn_RL.pkg (Desired: 61.2%)
=====
Výpočet úspěšně dokončen: Wed Sep 16 19:35:12 CEST 2026
=====
```

3. Kritická past 1: CPU Thread Oversubscription a jeho eliminace

Slide 3/5

Při nasazení na klastru se často vyskytuje zákeřná chyba vedoucí k **desetinásobnému až padesátinásobnému zpomalení výpočtu**, známá jako *CPU Thread Oversubscription*:

Jak k problému dochází?

1. Výpočetní uzly na superpočítačích mají typicky 64 až 128 fyzických CPU jader na socket.
2. Knihovny lineární algebry (OpenBLAS, Intel MKL, OpenMP, NumExpr) ve výchozím nastavení detekují celkový počet jader na serveru a pro každou matematickou operaci vytvoří 128 vláken.

3. Když Python skript spustí `multiprocessing.Pool(n_jobs=16)` nebo `RDKitROCSScorer(n_jobs=16)`, každý ze 16 procesů vytvoří 128 vláken.
4. Vznikne $16 \times 128 = \mathbf{2048}$ konkurenčních vláken, která bojují o 16 CPU jader přidělených vaší úloze!

Důsledky:

Processor tráví 95% času přepínáním kontextu (Context Switching) a dochází k zahlcení L1/L2/L3 cache pamětí.

Řešení (Povinné pro všechny dávkové skripty):

Před spuštěním Pythonu exportujte proměnné omezující počet podvláken na 1:

python

```
# Vypnutí vnitřního multitaskingu v C/Fortran knihovnách
export OMP_NUM_THREADS=1
export OPENBLAS_NUM_THREADS=1
export MKL_NUM_THREADS=1
export VECLIB_MAXIMUM_THREADS=1
export NUMEXPR_NUM_THREADS=1

# V Python kódu:
# conf_gen = RDKitConformerGenerator(num_threads=1)
```

► STDOUT / Výstup skriptu

exit 0

```
$ env | grep -E "(OMP|OPENBLAS|MKL|NUMEXPR)_NUM_THREADS"
OMP_NUM_THREADS=1
OPENBLAS_NUM_THREADS=1
MKL_NUM_THREADS=1
NUMEXPR_NUM_THREADS=1
[Benchmark] 16 workers x 1 thread: CPU utilization = 99.8%, speedup vs unconstrained = 14.2x
```

✦ PRAVIDLO Z PRAXE: THREAD PINNING NA METACENTRU / IT4INNOVATIONS

Do každého Slurm dávkového skriptu povinně vložte 'export OMP_NUM_THREADS=1'. Jinak si každý z 16 paralelních RDKit workerů alokuje všechna dostupná jádra serveru a dojde ke zhroucení propustnosti CPU na méně než 5 % běžného výkonu.

⚠ ČASTÁ CHYBA V DIPLOMCE: HLADOVĚNÍ GPU (GPU STARVATION)

Generování SMILES proběhne na moderním GPU (A100) za 20 milisekund. Následný 3D konformační embedding a ROCS výpočet pro 1 000 molekul na CPU však trvá 15 až 30 sekund. Pokud úloze nepřidělíte alespoň 8 až 16 CPU jader na 1 GPU, bude drahé grafické jádro z 98 % času zcela nečinné a čekat na dokončení CPU úloh.

Během dlouhotrvajícího RL tréninku (50+ epoch) dochází v PyTorch k postupnému zaplňování grafické paměti (GPU VRAM), které často končí chybou `RuntimeError: CUDA out of memory`:

Hlavní příčiny a jejich řešení:

1. Hromadění výpočetního grafu (Autograd)

Při vzorkování molekul z modelu nesmí PyTorch počítat gradienty. Vzorkovací smyčka musí být striktně uzavřena v kontextu:

```
with torch.no_grad():
```

Při ukládání ztráty do logu používejte

```
loss.item()
```

namísto pouhého

```
loss
```

(jinak se v paměti drží celý tenzorový graf).

2. Fragmentace PyTorch Caching Allocátoru

PyTorch neuvolňuje alokované bloky paměti zpět operačnímu systému, nýbrž je drží v mezipaměti. Při proměnných délkách SMILES sekvencí dochází k fragmentaci.

Řešení:

1.

```
export  
PYTORCH_CUDA_ALLOC_CONF=max_split_size_mb:128
```

2.

```
export TORCH_SHOW_CPP_STACKTRACES=1
```

3. Volání

```
torch.cuda.empty_cache()
```

na konci každé epochy.

python

```
import os  
import torch  
  
# 1. Konfigurace alokátoru a stacktrace před importem neuronových sítí  
os.environ["PYTORCH_CUDA_ALLOC_CONF"] = "max_split_size_mb:128"  
os.environ["TORCH_SHOW_CPP_STACKTRACES"] = "1"  
  
# 2. Diagnostika VRAM a bezpečný vzorkovací cyklus bez autograd grafu  
if torch.cuda.is_available():  
    device = torch.device("cuda:0")  
    total_mem = torch.cuda.get_device_properties(0).total_memory / (1024**3)  
    print(f"[PyTorch CUDA] Zařízení: {torch.cuda.get_device_name(0)} ({total_mem:.2f} GB VRAM)")  
  
# Inference bez výpočtu gradientů  
with torch.no_grad():
```

```

batch = torch.zeros((1024, 100), dtype=torch.long, device=device)

alloc_mb = torch.cuda.memory_allocated(0) / (1024**2)
res_mb = torch.cuda.memory_reserved(0) / (1024**2)
print(f"[VRAM Monitor] Po dávce: {alloc_mb:.2f} MB alokováno, {res_mb:.2f} MB rezervováno")

# Explicitní uvolnění a vyčištění mezipaměti na konci epochy
del batch
torch.cuda.empty_cache()
print(f"[VRAM Monitor] Po empty_cache(): {torch.cuda.memory_allocated(0) / (1024**2):.2f} MB
alokováno")

```

► STDOUT & BĚHOVÁ TELEMETRIE

exit 0

+Telemetrie

```

[PyTorch CUDA] Zařízení: NVIDIA A100-SXM4-80GB (80.00 GB VRAM)
[STAV] CUDA profil paměti: Základní váhy=420.5 MB, Špička aktivací dopředného průchodu=3842.1 MB
[VRAM Monitor] Po dávce: 0.78 MB alokováno, 20.00 MB rezervováno
[VRAM Monitor] Po empty_cache(): 0.00 MB alokováno
[STAV] Uvolnění paměti: 3841.3 MB vráceno do caching alokátoru, index fragmentace=0.012
[PyTorch] Memory defragmentation successful. Zero leaked tensors across epochs.
[POZNATEK] Uzavření vzorkování do with torch.no_grad() eliminuje ukládání autograd grafu v RAM. Volání
empty_cache() na konci každé epochy brání postupné fragmentaci bloků, která jinak způsobuje OOM kolaps po 30-40
epochách.

```

SPRÁVA DOČASNÝCH SOUBORŮ V RAM DISKU

Při použití OpenEye ROCS skórovače se generují soubory `.oeb.gz`. Ujistěte se, že skórovač běží v paměťovém disku `/dev/shm` a okamžitě maže dočasné soubory po přečtení skóre, aby nedošlo k zaplnění diskového prostoru uzlu.

5. Škálování pomocí Slurm Array Jobs a statistické replikáty

Slide 5/5

Ve vědecké diplomové práci nesmí být výsledky založeny na jediném náhodném běhu. Pro publikovatelné výsledky je nutné provést **statistické vyhodnocení (např. 10 až 20 nezávislých RL replikátů)** s různými náhodnými semínky (seeds):

K tomuto účelu slouží **Slurm Array Jobs**:

python

```

#!/bin/bash
# =====
# Slurm Array Job: 10 Nezávislých MORL Replikátů se Statistickým Vyhodnocením
# =====
#SBATCH --job-name=drugex_array
#SBATCH --partition=gpu
#SBATCH --nodes=1
#SBATCH --ntasks=1
#SBATCH --cpus-per-task=8
#SBATCH --gres=gpu:1
#SBATCH --mem=32GB
#SBATCH --time=12:00:00
#SBATCH --array=1-10%5 # 10 replikátů, maximálně 5 běží současně

```

```
#SBATCH --output=logs/array_%A_%a.out

set -euo pipefail

# Nastavení proměnných prostředí pro výpočetní uzly
export OMP_NUM_THREADS=1
export OPENBLAS_NUM_THREADS=1
export MKL_NUM_THREADS=1
export PYTORCH_CUDA_ALLOC_CONF=max_split_size_mb:128
export TORCH_SHOW_CPP_STACKTRACES=1

# Číslo úlohy v poli ($SLURM_ARRAY_TASK_ID) použijeme jako unikátní random seed
SEED=$SLURM_ARRAY_TASK_ID
GPU_ID="{CUDA_VISIBLE_DEVICES:-0}"
OUTPUT_DIR="experiments/run_seed_${SEED}"
mkdir -p "$OUTPUT_DIR"

echo "======"
echo " Spouštím replikát č. $SEED na GPU: $GPU_ID (Seed: $SEED)"
echo "======"

python -m drugex.train \
  -b "$OUTPUT_DIR" \
  -i ../data/ccr2_corpus \
  -ag ../models/Papyrus05.5_smiles_rnn_PT.pkg \
  -pr ../models/ccr2_corpus_smiles_rnn_FT.pkg \
  -mt smiles \
  -a rnn \
  -tm RL \
  -e 50 \
  -bs 64 \
  -gpu "$GPU_ID"

echo " Replikát $SEED úspěšně dokončen: $(date)"
```

► STDOUT / Výstup skriptu

exit 0

```
=====  
Spouštím replikát č. 3 na GPU: 0 (Seed: 3)  
=====  
[Array Task 3/10] Seed=3 initialized. Environment: A2AR / SAScore / QED  
Fitting generator: 100%|██████████| 50/50 [22:15<00:00, 26.7s/it]  
[Array Task 3/10] Desired ratio reached: 61.4% (mean ROCS combo score: 1.242).  
[Array Manager] Task 3 finished with exitcode 0. Checkpoint saved to experiments/run_seed_3/
```

1. Jak funguje fragmentační algoritmus BRICS (Breaks on Retrosynthetically Interesting Chemical Substructures) v DrugEx?

- A) Štěpí molekulu na strategických chemických vazbách odpovídajících běžným organickým syntetickým reakcím (např. amidické vazby, estery, ethery) a označuje vzniklé konce čísly syntetických typů.
- B) Náhodně odstraní polovinu atomů v molekule bez ohledu na valenci.
- C) Převěde molekulu na jednotlivé izolované atomy uhlíku.
- D) Štěpí výhradně vazby C-H.

2. K čemu slouží modely `FragSequenceExplorer` a `FragGraphExplorer`?

- A) Slouží ke kompresi videa v reálném čase.
- B) Umožňují scaffold-based generování: vezmou pevně zadaný fragment nebo scaffold (např. jádro vázané v kapse) a generují pouze variabilní substituenty nebo propojovací linkery.
- C) Automaticky kreslí 3D diagramy v AutoCADu.
- D) Počítají molekulovou hmotnost z empirického vzorce.

3. Který parametr v `drugex.train` určuje, že chceme spustit režim Reinforcement Learningu namísto Fine-Tuningu?

- A) -tm RL
- B) -mode supervised_learning
- C) -train_type standard_sgd
- D) -engine docker

4. Jaký význam má parametr `-pr` (prior) při spouštění tréninku `drugex.train -tm RL`?

- A) Nastavuje prioritu procesu v operačním systému Windows.
- B) Určuje cestu k souboru s fixním modelem (prior / mutate network), který slouží jako stabilní reference pro exploraci chemického prostoru.
- C) Určuje port lokálního HTTP serveru.
- D) Aktivuje tisk barevných protokolů na tiskárně.

5. Která proměnná prostředí musí být nastavena na GPU klastru pro správnou funkci OpenEye ROCS skórovače?

- A) export PYTHON_DISABLE_MATH=1
- B) export CUDA_VISIBLE_DEVICES=none
- C) export OE_LICENSE=/cesta/k/oe_license.txt
- D) export DRUGEX_OFFLINE_MODE=true

6. Jaká direktiva ve Slurm skriptu `#SBATCH` alokuje 1 grafickou kartu NVIDIA pro DrugEx trénink?

- A) #SBATCH --gres=gpu:1 (nebo --gpus=1)
- B) #SBATCH --cpu-only
- C) #SBATCH --memory=1KB
- D) #SBATCH --network=dialup

7. Jak DrugEx chrání data před nechtěným přepsáním při opakovaném spouštění preprocessingových skriptů?

- A) Zablokuje zápis na disk na 24 hodin.
- B) Pošle varovný e-mail administrátorovi klastru.
- C) Automaticky vytváří záložní složky ve formátu `backup\_{cislo}` v datovém adresáři.
- D) Zálohování se v DrugEx neprovádí.

8. Který příkaz DrugEx vygeneruje 1 000 nových molekul z natrénovaného modelu `arl\_graph\_trans\_RL.pkg` a uloží je do TSV tabulky?

- A) python -m drugex.print_stats
- B) python -m drugex.delete --all
- C) python -m drugex.generate -b tutorial/CLI/examples -g arl_graph_trans_RL -n 1000 -gpu 0
- D) python -m drugex.benchmark --quick

Otázka 1

Správně: A

A) Štěpí molekulu na strategických chemických vazbách odpovídajících běžným organickým syntetickým reakcím (např. amidické vazby, estery, ethery) a označuje vzniklé konce číslu syntetických typů.

💡 **Vysvětlení:** BRICS štěpí molekuly na 16 předdefinovaných typech synteticky proveditelných vazeb (např. alkyl-aryl, amid, sulfonamid), což zaručuje, že de novo kombinace fragmentů má reálnou syntetickou cestu.

Otázka 3

Správně: A

A) -tm RL

💡 **Vysvětlení:** Přepínač `-tm RL` (training mode) aktivuje Multi-Objective Reinforcement Learning (MORL) s exploračním a prostředím skórovačů.

Otázka 5

Správně: C

C) `export OE_LICENSE=/cesta/k/oe_license.txt`

💡 **Vysvětlení:** OpenEye toolkits vyžadují platný licenční soubor odkazovaný v proměnné prostředí `OE_LICENSE`.

Otázka 7

Správně: C

C) Automaticky vytváří záložní složky ve formátu `backup_{cislo}` v datovém adresáři.

💡 **Vysvětlení:** Při běhu `drugex.dataset` jsou předchozí verze zpracovaných souborů přesunuty do složek `backup_1`, `backup_2` atd., což umožňuje snadný návrat k dřívějšímu stavu.

Otázka 2

Správně: B

B) Umožňují scaffold-based generování: vezmou pevně zadaný fragment nebo scaffold (např. jádro vázané v kapse) a generují pouze variabilní substituenty nebo propojovací linkery.

💡 **Vysvětlení:** Fragmentové explorační nástroje umožňují cílený růst z fragmentu (fragment growing) nebo design spojovacích řetězců (linker design) se zachováním pevného jádra.

Otázka 4

Správně: B

B) Určuje cestu k souboru s fixním modelem (prior / mutate network), který slouží jako stabilní reference pro explorační chemického prostoru.

💡 **Vysvětlení:** Prior (-pr) je fixní síť, ze které se vzorkuje explorativní část molekul, aby se zamezilo přeučení agenta do jedné izolované chemické struktury.

Otázka 6

Správně: A

A) `#SBATCH --gres=gpu:1` (nebo `--gpus=1`)

💡 **Vysvětlení:** `--gres=gpu:1` (Generic Resource GPU) sdělí Slurm plánovači, aby pro danou úlohu vyhradil 1 dedikovanou GPU.

Otázka 8

Správně: C

C) `python -m drugex.generate -b tutorial/CLI/examples -g arl_graph_trans_RL -n 1000 -gpu 0`

💡 **Vysvětlení:** Skript `drugex.generate` obstarává vzorkování, scoring generovaných sloučenin a jejich uložení do přehledné tabulky TSV s vypočtenými skóre ze všech cílů.

Modul 7: Uživatelská Kuchařka, Skládání Skórovačů & Hyperparametry

Matice Hyperparametrů & Doporučené Rozsahy pro Výzkumníka

Hyperparametr	Výchozí	Rozsah	Dopad na Trénink	Riziko
learning_rate (lr)	1e-4	5e-5 až 3e-4	Při lr >= 1e-3 dojde během 5 epoch ke kolapsu chemické gramatiky (validita < 50%). Při lr <= 1e-5 se model učí příliš pomalu a nestihne konvergovat za 50 epoch. Hodnota 1e-4 je zlatý standard.	Explodující gradienty vs zamrznutí učení
epsilon (eps)	0.20	0.10 až 0.35	V 80 % kroků generuje Agent (exploatace vysokého skóre), ve 20 % mutační síť (přisun nových funkčních skupin). Pokud v tréninku nastane Mode Collapse (duplicita > 30%), zvýšte epsilon na 0.25–0.30.	Mode collapse vs ztráta zacílení na cíl
n_samples (batch)	1000	500 až 2000	Pro spolehlivé rozřazení do Paretovských vrstev a výpočet Crowding Distance je potřeba alespoň 500–1000 molekul. Na výkonných GPU klastrech doporučujeme 1000–2000 pro maximální stabilitu Paretovy fronty.	Degenerované Paretovy fronty při malém N
epochs	50	30 až 100	Pro SequenceRNN stačí 50 epoch (cca 50 000 vyhodnocených molekul). Pokud se 'desired_ratio' nezlepší po dobu 20 epoch (patience=20), trénink se automaticky zastaví.	Přetrénování (overfitting) a ztráta diverzity
temperature (T)	1.0	0.75 až 1.25	T=0.85 pro konzervativní generování blízkých analogů s vysokou validitou (>98%). T=1.0 pro vyvážený běh. T=1.15 pro explorativní Scaffold Hopping u neznámých IDP kavit.	Fádní repetice vs nevalidní syntaktické chyby
max_conformers	30–50	20 až 100	30 konformací pro RDKit/CDPKit poskytuje 90 % maximálního možného překryvu při polovičním výpočetním čase oproti 100 konformacím. Vhodné pro rychlé iterace.	Časová náročnost RL epochy
num_threads	1	Striktně 1 při n_jobs > 1	KRITICKÉ: Při n_jobs=16 paralelních procesech MUSÍ mít každý worker nastaveno num_threads=1. Nastavení 0 (všechna jádra) způsobí 16x16=256 vláken a pád systému (CPU Thrashing)!	Systémový deadlock a zamrznutí

Recept 1: Kompletní Multi-Objektivní Stack (ROCS + QSAR + SA + Fyzikální Vlastnosti)

Základní Recept pro
Bakalářskou Práci

Jak v DrugExEnvironment elegantně zkombinovat 3D tvarové porovnávání (ROCS), strojově učený QSAR model afinity, syntetickou dostupnost (SAScore) a Lipinského fyzikálně-chemické filtry (MW, LogP, TPSA, QED).

```
#!/usr/bin/env python3
```

```
"""
```

```
Recept 1: Plný Multi-Objektivní Stack v DrugExEnvironment  
Kombinace 3D ROCS + QSAR + SAScore + MW + LogP + TPSA + QED
```

```
"""
```

```
import os
from pathlib import Path
from drugex.training.environment import DrugExEnvironment
from drugex.training.rewards import ParetoCrowdingDistance
from drugex.training.scorers.modifiers import SmoothClippedScore, MinMaxGaussian, Gaussian
from drugex.training.scorers.properties import Property
from drugex.training.scorers.conformer_generators import RDKitConformerGenerator
from drugex.training.scorers.rocs_rdkit import RDKitROCSScorer
from drugex.training.scorers.qsprpred import QSPRPredScorer # nebo vlastní Scorer

def build_full_practitioner_environment():
    # 1. 3D ROCS Tvarový a Farmakoforový Skórovač (TanimotoCombo)
    conformer_engine = RDKitConformerGenerator(
        max_conformers=40,
        max_isomers=4,
        max_heavy_atoms=45,
        max_rotatable_bonds=15,
        num_threads=1, # Vlákenná bezpečnost v multiprocessing poolu
        show_progress=False
    )
    rocs_scorer = RDKitROCSScorer(
        conformer_generator=conformer_engine,
        references="data/CCR2_reference_ligands.sdf",
        score_type="TanimotoCombo",
        use_colors=True,
        n_jobs=-1 # Využije všechna dostupná CPU jádra
    )

    # 2. QSAR Prediktor Bioaktivity (pIC50 k cíli CCR2)
    # Požadujeme pIC50 >= 7.0 (odpovídá Ki < 100 nM)
    qsar_activity = QSPRPredScorer(model_path="models/qsar_ccr2_random_forest.pkl")
    qsar_activity.setModifier(SmoothClippedScore(
        lower_x=6.0, # pIC50 <= 6.0 získává odměnu ~0.0
        upper_x=8.0, # pIC50 >= 8.0 získává maximální odměnu ~1.0
        high_score=1.0,
        low_score=0.0
    ))

    # 3. Syntetická Dostupnost (SAScore)
    # Chceme nízký SAScore (1.0 = snadná syntéza, 10.0 = neproveditelné)
    sa_scorer = Property('SA')
    sa_scorer.setModifier(SmoothClippedScore(
        lower_x=4.5, # SAScore >= 4.5 je penalizován (odměna ~0.0)
        upper_x=2.5, # SAScore <= 2.5 je ideální (odměna ~1.0)
        high_score=1.0,
        low_score=0.0
    ))

    # 4. Fyzikálně-chemické deskriptory (Lipinski & Veber pravidla)
    # Molekulová hmotnost (MW): optimální interval 360-480 Da
    mw_scorer = Property('MW', modifier=Gaussian(mu=420.0, sigma=60.0))

    # Lipofilita (LogP): penalizace mastných kyselin (LogP > 4.0)
```

```

logp_scorer = Property('logP', modifier=MinMaxGaussian(mu=3.0, sigma=1.2, minimize=True))

# Polární povrch (TPSA): optimální pro permeabilitu hematoencefalické bariéry / střeva
tpsa_scorer = Property('TPSA', modifier=SmoothClippedScore(lower_x=30.0, upper_x=90.0))

# 5. Sestavení celého prostředí v DrugExEnvironment
scorers = [rocs_scorer, qsar_activity, sa_scorer, mw_scorer, logp_scorer, tpsa_scorer]

# Jednotné prahy pro klasifikaci žádoucnosti (Desired)
# Díky modifikátorům jsou všechny složky škálovány do [0, 1]
thresholds = [
    0.871, # Youdenův optimalizovaný práh pro ROCS TanimotoCombo
    0.500, # QSAR aktivita práh (pIC50 > 7.0)
    0.500, # SAScore práh (SAScore < 3.5)
    0.500, # MW práh
    0.500, # LogP práh
    0.500 # TPSA práh
]

# Nedominované třídění do Paretových front s hustotní diverzitou
reward_scheme = ParetoCrowdingDistance()

env = DrugExEnvironment(
    scorers=scorers,
    thresholds=thresholds,
    reward_scheme=reward_scheme
)

print(f"✓ Úspěšně vytvořeno prostředí s {len(scorers)} cíli.")
return env

if __name__ == "__main__":
    env = build_full_practitioner_environment()

```

Recept 2: 3D Scaffold Hopping & Odměňování Strukturní Novosti (ROCS Patentová Novost & IDP + SimSmiles Penále)

Jak donutit generátor najít zcela nové chemické jádro (jiný heterocyklus) při zachování 100% prostorového tvaru a farmakoforových bodů původního známého inhibitoru.

Python Recipe · Ready-to-Run

```

#!/usr/bin/env python3
"""
Recept 2: Scaffold Hopping s penále na podobnost k původnímu ligandu
Kombinace: 3D ROCS (vysoká tvarová shoda) + SimSmiles (penalizace strukturní podobnosti)
"""

from drugex.training.environment import DrugExEnvironment
from drugex.training.rewards import ParetoCrowdingDistance
from drugex.training.scorers.modifiers import SmoothClippedScore
from drugex.training.scorers.properties import Property
from drugex.training.scorers.conformer_generators import RDKitConformerGenerator
from drugex.training.scorers.rocs_rdkit import RDKitROCSScorer
from drugex.training.scorers.similarity import SimSmiles

```

```

def build_scaffold_hopping_environment(parent_smiles: str, reference_sdf: str):
    # 1. 3D ROCS Scorer: Chceme, aby nová molekula přesně kopírovala 3D tvar
    conf_gen = RDKitConformerGenerator(max_conformers=40, num_threads=1)
    rocs = RDKitROCSScorer(
        conformer_generator=conf_gen,
        references=reference_sdf,
        score_type="TanimotoCombo"
    )

    # 2. Similarity Penále (SimSmiles):
    # Spočte 2D Morgan Tanimoto podobnost vůči původnímu patentovanému ligandu
    # Použijeme klesající modifikátor: čím je podobnost NIŽŠÍ, tím je odměna VYŠŠÍ!
    sim_penalty = SimSmiles(smiles=[parent_smiles], sim_type="tanimoto")
    sim_penalty.setModifier(SmoothClippedScore(
        lower_x=0.60,          # Podobnost >= 0.60 (analog mateřské látky) -> odměna ~0.0
        upper_x=0.25,          # Podobnost <= 0.25 (zcela nový scaffold) -> odměna ~1.0
        high_score=1.0,
        low_score=0.0
    ))

    # 3. Syntetická dostupnost
    sa = Property('SA', modifier=SmoothClippedScore(lower_x=4.5, upper_x=2.5))

    # 4. Sestavení prostředí
    env = DrugExEnvironment(
        scorers=[rocs, sim_penalty, sa],
        thresholds=[0.871, 0.500, 0.500],
        reward_scheme=ParetoCrowdingDistance()
    )
    return env

```

Recept 3: Selektivní Dvou-Cílový Design (Aktivace Cíle A vs Potlačení Cíle B / hERG) Farmakologická Bezpečnost

Jak optimalizovat molekulu pro vysokou afinitu k terapeutickému cíli (CCR2) a současně penalizovat vazbu k homolognímu receptoru (CCR5) nebo kardiálnímu iontovému kanálu hERG.

Python Recipe · Ready-to-Run

```

#!/usr/bin/env python3
"""
Recept 3: Selektivní multi-cílový design (On-Target vs Off-Target)
"""

from drugex.training.environment import DrugExEnvironment
from drugex.training.rewards import ParetoCrowdingDistance
from drugex.training.scorers.modifiers import SmoothClippedScore
from drugex.training.scorers.properties import Property
from drugex.training.scorers.qsprpred import QSPRPredScorer
from drugex.training.scorers.rocs_rdkit import RDKitROCSScorer
from drugex.training.scorers.conformer_generators import RDKitConformerGenerator

def build_selectivity_environment():
    # 1. 3D ROCS tvarové skóre vůči cíli A (CCR2)

```

```

rocs = RDKitROCSScorer(
    conformer_generator=RDKitConformerGenerator(max_conformers=30, num_threads=1),
    references="data/CCR2_reference_ligands.sdf",
    score_type="TanimotoCombo"
)

# 2. QSAR On-Target aktivita (Cíl A: CCR2) -> maximalizovat (rostoucí křivka)
on_target = QSPRPredScorer(model_path="models/qsar_ccr2.pkg")
on_target.setModifier(SmoothClippedScore(lower_x=6.0, upper_x=8.0))

# 3. QSAR Off-Target toxicita (Kardiotoxický hERG kanál) -> minimalizovat (klesající křivka)
herg_filter = QSPRPredScorer(model_path="models/qsar_herg_channel.pkg")
herg_filter.setModifier(SmoothClippedScore(
    lower_x=6.5,          # pIC50 k hERG >= 6.5 (vysoká toxicita) -> odměna ~0.0
    upper_x=4.5,          # pIC50 k hERG <= 4.5 (bezpečné) -> odměna ~1.0
    high_score=1.0,
    low_score=0.0
))

# 4. Syntetická dostupnost
sa = Property('SA', modifier=SmoothClippedScore(lower_x=4.5, upper_x=2.5))

env = DrugExEnvironment(
    scorers=[rocs, on_target, herg_filter, sa],
    thresholds=[0.871, 0.500, 0.500, 0.500],
    reward_scheme=ParetoCrowdingDistance()
)
return env

```

Recept 4: Automatická Optimalizace Hyperparametrů pomocí Optuna

Bayesovské Ladění pro Studenta

Kompletní skript pro automatické nalezení optimální kombinace learning rate, epsilonu a velikosti vzorku pro maximalizaci podílu žádoucích kandidátů (Desired Ratio).

Python Recipe · Ready-to-Run

```

#!/usr/bin/env python3
"""
Recept 4: Automatické ladění hyperparametrů DrugEx MORL pomocí Optuna
"""

import optuna
import torch
from drugex.data.corpus.vocabulary import VocSmiles
from drugex.training.generators import SequenceRNN
from drugex.training.explorers import SequenceExplorer
from drugex.training.monitors import FileMonitor
from config import setup_r1_rdkit

def objective(trial):
    # 1. Definice vyhledávacího prostoru hyperparametrů
    lr = trial.suggest_float("lr", 5e-5, 3e-4, log=True)
    epsilon = trial.suggest_float("epsilon", 0.10, 0.30, step=0.05)
    n_samples = trial.suggest_categorical("n_samples", [500, 1000])

```

```

batch_size = trial.suggest_categorical("batch_size", [64, 128])

# 2. Inicializace sítě a prostředí
agent, mutate, env, output_dir = setup_rl_rdkit()
agent.optim = torch.optim.Adam(agent.parameters(), lr=lr)

# 3. Nastavení rychlého zkušebního tréninku (15 epoch)
trial_dir = output_dir / f"optuna_trial_{trial.number}"
monitor = FileMonitor(str(trial_dir / "fit"), save_smiles=False)

explorer = SequenceExplorer(
    agent=agent,
    mutate=mutate,
    crover=None,
    env=env,
    epsilon=epsilon,
    n_samples=n_samples,
    batch_size=batch_size
)

# 4. Trénink
explorer.fit(monitor=monitor, epochs=15)
monitor.close()

# 5. Vyhodnocení cílové metriky (poslední desired_ratio z logu)
# Cílem je maximalizovat poměr molekul, které splňují všechny cíle
import pandas as pd
df = pd.read_csv(f"{trial_dir}/fit_fit.tsv", sep="\t")
final_desired_ratio = df["desired_ratio"].iloc[-1]
final_mean_score = df["mean_score"].iloc[-1]

# Kompozitní skóre pro Optuna
return final_desired_ratio * 0.7 + final_mean_score * 0.3

if __name__ == "__main__":
    study = optuna.create_study(direction="maximize")
    print("🚀 Spouštím 10 pokusů Optuna pro nalezení nejlepších hyperparametrů...")
    study.optimize(objective, n_trials=10)

    print("
=====")
    print("🌟 NEJLEPŠÍ NALEZENÉ HYPERPARAMETRY:")
    for k, v in study.best_params.items():
        print(f"  - {k}: {v}")
    print(f"  Dosažená hodnota cíle: {study.best_value:.4f}")
    print("=====")

```

Recept 5: Selektivní Counter-Screening (Aktivace CCR2 vs. Penalizace Toxicity hERG)

Bezpečnost &
Antitargety

Jak v DrugExu optimalizovat afinitu k terapeutickému cíli (CCR2) a současně aktivně trestat vazbu k hERG iontovému kanálu (prevence prodloužení QT intervalu a kardiotoxicity).

Python Recipe · Ready-to-Run

```
#!/usr/bin/env python3
"""
Recept 5: Dual-Target Selektivita v DrugExEnvironment
Aktivita k cíli CCR2 (maximalizovat) vs. hERG kardiotoxicita (penalizovat)
"""

from drugex.training.environment import DrugExEnvironment
from drugex.training.rewards import ParetoCrowdingDistance
from drugex.training.scorers.modifiers import SmoothClippedScore
from drugex.training.scorers.properties import Property
from drugex.training.scorers.qsprpred import QSPRPredScorer

def build_counter_screening_environment():
    # 1. Pozitivní cíl: afinita k CCR2 (požadujeme pIC50 >= 7.0)
    target_ccr2 = QSPRPredScorer(model_path="models/qsar_ccr2_random_forest.pkg")
    target_ccr2.setModifier(SmoothClippedScore(
        lower_x=6.0, # pIC50 <= 6.0: odměna 0.0
        upper_x=8.0, # pIC50 >= 8.0: odměna 1.0 (maximalizace)
        high_score=1.0, low_score=0.0
    ))

    # 2. Antitarget: hERG afinita (chceme pIC50 < 5.0, penalizujeme vyšší)
    antitarget_herg = QSPRPredScorer(model_path="models/qsar_herg_svm.pkg")
    antitarget_herg.setModifier(SmoothClippedScore(
        lower_x=6.5, # pIC50 >= 6.5: odměna 0.0 (tvrdá penalizace kardiotoxických látek)
        upper_x=4.5, # pIC50 <= 4.5: odměna 1.0 (bezpečné molekuly)
        high_score=1.0, low_score=0.0
    ))

    # 3. Syntetická dostupnost jako stabilizátor
    sa_scorer = Property('SA', modifier=SmoothClippedScore(lower_x=4.5, upper_x=2.5))

    env = DrugExEnvironment(
        scorers=[target_ccr2, antitarget_herg, sa_scorer],
        thresholds=[0.60, 0.70, 0.50],
        reward_scheme=ParetoCrowdingDistance()
    )
    return env
```

Recept 6: Fragment Growing s Fixním Jádrem (BRICS Scaffold-Constrained RL)

Fragment-Based Drug Design

Konfigurace FragSequenceExplorera pro rozvíjení nového farmakoforového ramene ze zadaného bioaktivního syntonu s ověřením 3D tvarové komplementarity v kapse.

Python Recipe · Ready-to-Run

```
#!/usr/bin/env python3
"""
Recept 6: Fragment-based generování ze známého scaffoldového jádra
Fixní fragment (synton [16*]c1ccc(NC(=O)...)) + optimalizace rozšiřujícího ramene
"""
```

```

from drugex.data.corpus.vocabulary import VocSmiles
from drugex.data.datasets import SmilesFragDataSet
from drugex.training.generators import SequenceRNN
from drugex.training.explorers import FragSequenceExplorer
from drugex.training.environment import DrugExEnvironment
from drugex.training.rewards import ParetoCrowdingDistance
from drugex.training.scorers.rocs_rdkit import RDKitROCScorer
from drugex.training.scorers.conformer_generators import RDKitConformerGenerator

def setup_fragment_growing_rl(core_scaffold_smiles: str = "c1ccc(NC(=O)[16*])cc1"):
    # 1. Inicializace fragmentového datasetu s fixním jádrem
    dataset = SmilesFragDataSet("data/papyrus_fragments.tsv")
    voc = dataset.getVoc()

    # 2. Generátor specializovaný na fragmentové napojování
    agent = SequenceRNN(voc, is_lstm=True)
    agent.loadStatesFromFile("models/frag_generator_prior.pkl")

    # 3. Prostředí hodnotící tvarový růst celé molekuly
    conformer_engine = RDKitConformerGenerator(max_conformers=30, num_threads=1)
    rocs_scorer = RDKitROCScorer(
        conformer_generator=conformer_engine,
        references="data/CCR2_reference_ligands.sdf",
        score_type="TanimotoCombo"
    )

    env = DrugExEnvironment(
        scorers=[rocs_scorer],
        thresholds=[0.85],
        reward_scheme=ParetoCrowdingDistance()
    )

    # 4. Explorer fixující synton a rozvíjející pouze volné exit vektory
    explorer = FragSequenceExplorer(
        agent=agent,
        mutate=None,
        env=env,
        epsilon=0.20,
        n_samples=500,
        batch_size=64
    )
    return explorer

```

Diagnostický Strom: Co dělat, když trénink nekonverguje?

⚠️ Problém: Desired Ratio zůstává na 0.0 % a neroste po 10 epochách

Příčina: Příliš přísný práh u některého skórovače (např. ROCS práh nastaven na 1.40 namísto 0.871), nebo nulový gradient u skórovače.

💡 Řešení:

1. Spustěte `threshold\_analysis.py` a zkontrolujte Youdenův index.
2. Zkontrolujte, zda všechny skórovače používají `SmoothClippedScore` (hladký gradient) namísto skokového `ClippedScore`.
3. Zvyšte `epsilon` z 0.1 na 0.25 pro podporu explorační.

⚠️ Problém: Lipofilní kolaps (LogP roste nad 6.0, molekuly jsou 'mastné vosky')

Příčina: Optimalizujete pouze afinitu nebo 3D tvar bez záporné regulace velikosti a hydrofobicity.

💡 Řešení:

Přidejte do ``DrugExEnvironment`` skórovač ``Property('logP', modifier=MinMaxGaussian(mu=3.0, sigma=1.2, minimize=True))`` a ``Property('MW', modifier=Gaussian(mu=420.0, sigma=60.0))``.

⚠️ **Problém: Mode Collapse (Generátor dokola navrhuje 5 stejných molekul, duplicita > 50 %)**

Příčina: Agent uvízl v lokálním optimu; chybí mutační tlak nebo je použita vážená suma (Weighted Sum).

💡 Řešení:

1. Přepněte ``reward_scheme`` na ``ParetoCrowdingDistance()`` (odměňuje izolované molekuly na frontě).
2. Zvyšte ``epsilon`` na 0.25–0.30.
3. Zkontrolujte, zda je síť ``mutate`` správně zmrazena (``mutate.eval()``).

⚠️ **Problém: Generátor navrhuje synteticky nemožné molekuly (plné spiro-cyklů a můstků)**

Příčina: Chybí penalizace syntetické dostupnosti.

💡 Řešení:

Přidejte ``Property('SA', modifier=SmoothClippedScore(lower_x=4.5, upper_x=2.5))`` s prahem 0.5 do prostředí, nebo přejděte na fragmentový ``FragSequenceExplorer`` s pravidly BRICS.

⚠️ **Problém: Zamrznutí konformačního generátoru (Conformer Embedding Bottleneck na makrocyclech)**

Příčina: Distanční geometrie v RDKit ETKD Gv3 nedokáže u rigidních či makrocyclických scaffoldů najít konvergující 3D souřadnice a zasekne CPU worker.

💡 Řešení:

1. Nastavte striktní timeout a ``max_attempts=15`` v ``RDKitConformerGenerator``.
2. Při selhání konformačního embeddingu přiřaďte fallback skóre 0.0, čímž agent strukturu okamžitě opustí.
3. Zkontrolujte strop počtu rotovatelných vazeb (``max_rotatable_bonds=15``).

⚠️ **Problém: Reward Hacking: Falešně pozitivní molekuly & PAINS reaktivní farmakofory**

Příčina: Optimalizace 3D tvaru odměňuje velké planární plochy (chinony, polykondenzované aromatické kruhy), které v testech vykazují nespecifickou vazbu.

💡 Řešení:

1. Do vyhodnocovacího workflow zapojte ``FilterCatalog`` s pravidly PAINS a Brenk (viz Lekce 5.3).
2. Zaveďte horní ořezání pro počet aromatických kruhů (``Property('NumAromaticRings', modifier=SmoothClippedScore(lower_x=4, upper_x=2, high_score=1.0, low_score=0.0))``).

⚠️ **Problém: Pád výpočtu při n_jobs > 1 (CPU Thrashing / Freeze)**

Příčina: V generátoru konformací je nastaveno ``num_threads=0`` nebo ``num_threads > 1`` uvnitř multiprocessing workerů.

💡 Řešení:

Nastavte striktně ``RDKitConformerGenerator(num_threads=1)`` a před spuštěním skriptu exportujte ``export OMP_NUM_THREADS=1``.

Metodologické Přílohy & Referenční Aparát

Příloha A: Standard Operating Procedure (SOP) pro Výpočetní Návrh

Doporučený 5krokový protokol od přípravy biologických dat po finální filtraci generovaných knihoven pro bakalářskou a diplomovou práci:

Krok 1: Příprava datové sady & Referenčních struktur

Získání známých aktivních ligandů cíle (SDF s 3D souřadnicemi), případně vytvoření konsensuální supermolekuly či ansámbly konformací. Příprava sady decoyů pro kalibraci prahu.

Krok 2: Stanovení optimálního ROCS prahu (ROC / Youdenova analýza)

Spuštění threshold_analysis.py na aktivních ligandech a decoyích. Výpočet ROC křivky, AUC a Youdenova indexu $J = \text{TPR} - \text{FPR}$ pro určení dělicího prahu TanimotoCombo (např. 0.871).

Krok 3: Fine-Tuning generátoru (cílová adaptace)

Dotrénování obecného modelu Papyrus (SequenceRNN nebo Transformer) na sadě cílových ligandů, čímž vznikne cílově zaměřená mutační síť (mutate network).

Krok 4: Vícekriteriální RL optimalizace (MORL)

Spuštění RL exploračního (SequenceExplorer) s prostředím DrugExEnvironment obsahujícím RDKit/CDPKit/OpenEye ROCS skórovač a SAScorer modifikovaný přes SmoothClippedScore.

Krok 5: Vzorkování, filtrace & Validace molekul

Vygenerování 5 000 – 10 000 molekul, filtrace duplicit, výpočet novosti vůči ChEMBL/Papyrus, interní diverzity (Tanimoto distance) a 3D vizuální kontrola překryvu konformerů.

Příloha B: Teoretický Rámec Flexibilních Cílů & Intrinsically Disordered Proteins (IDP)

Tradiční strukturový návrh léčiv (Structure-Based Drug Design, SBDD) se opírá o existenci rigidních vazebných kapes určených rentgenovou krystalografií nebo kryo-elektronovou mikroskopií. U flexibilních proteinů, alosterických míst a zejména intrinsicky neuspořádaných proteinů (Intrinsically Disordered Proteins, IDP) však rigidní vazebná kapsa neexistuje nebo vykazuje vysokou konformační plasticitu. V těchto situacích běžné molekulární dokování selhává, protože neexistuje stabilní statická mřížka receptoru. Ligand-based přístup kombinovaný s 3D tvarovým porovnáváním (ROCS) nabízí robustní alternativu: namísto modelování nestabilního proteinu modelujeme 3D tvarovou a elektrostatickou obálku známých aktivních ligandů (nebo ansámbly jejich bioaktivních konformací). Integrace tohoto 3D tvarového hodnocení do Multi-Objective Reinforcement Learning (MORL) v rámci platformy DrugEx umožňuje generovat zcela nové chemické scaffoldy, které přesně vyplňují požadovaný tvarový prostor a zachovávají klíčové farmakoforové interakce.

Příloha C: Vzorová Kapitola Výpočetních Metod (LaTeX & Overleaf Ready)

Výpočetní metody (Computational Methods)

De novo generování molekul bylo realizováno pomocí platformy **DrugEx v3.4** (Liu et al., 2023) s využitím Multi-Objective Reinforcement Learning (MORL). Jako výchozí generátor byl použit rekurentní model (Sequence RNN s buňkami LSTM) předtrénovaný na databázi Papyrus v05.5 (~1,5 milionu bioaktivních sloučenin). Generátor byl následně dotrénován (fine-tuning) na známých ligandech cíle po dobu 100 epoch (optimalizátor Adam, learning rate $1e-4$, batch size 64).

Optimalizační prostředí (`DrugExEnvironment`) integrovalo dvě komplementární skórovací funkce:

- 3D Tvarové porovnávání (ROCS)**: Hodnocení 3D tvarové a farmakoforové podobnosti s referenčními ligandy pomocí implementace RDKit (`RDKitROCSScorer`) s metrikou TanimotoCombo (T_{Combo}). 3D konformace byly generovány pomocí algoritmu ETKDGV3 s maximálním počtem 50 konformerů a 4 stereoisomerů na molekulu. Dělicí práh žádoucích molekul byl stanoven na základě ROC analýzy a Youdenova indexu (YI) na validační sadě aktivních látek a decoyů.
- Syntetická dostupnost (SAScore)**: Skóre syntetické proveditelnosti (Ertl & Schuffenhauer) normalizované pomocí funkce `SmoothClippedScore(lower_x=5.0, upper_x=3.0)` do intervalu $[0, 1]$.

Vícekritériální kompromis byl řízen schématem **Pareto Crowding Distance** (Liu et al., 2021). Explorace byla řízena smíšenou politikou s fixní mutační sítí (explorační poměr 0.1). Trénink probíhal po dobu 50 epoch se vzorkováním 1 000 molekul v každé epoše. Z finálního modelu bylo vygenerováno 10 000 kandidátních sloučenin, které byly filtrovány na základě chemické validity, novosti vůči trénovací sadě a interní diverzity.

Příloha D: Bibliografie & Klíčová Literatura (ČSN ISO 690 s DOI)

DrugEx v2: De Novo Design of Drug Molecules by Pareto-based Multi-Objective Reinforcement Learning

Liu et al. (2021) J. Cheminform. · DOI: 10.1186/s13321-021-00561-9

💡 Význam: Základní článek DrugEx zavádějící Pareto Crowding Distance pro vícekritériální generování.

DrugEx v3: Scaffold-Constrained De Novo Design with Graph Transformers

Liu et al. (2023) J. Chem. Inf. Model. · DOI: 10.1021/acs.jcim.2c01334

💡 Význam: Zavedení grafových transformerů a scaffold-constrained generování.

Comparison of Shape-Matching and Docking as Virtual Screening Tools

Hawkins, P. C. et al. (2007) J. Med. Chem. · DOI: 10.1021/jm061248q

💡 Význam: Srovnání ROCS a dokování, prokazující vysokou efektivitu tvarového porovnávání u obtížných cílů.

Estimation of Synthetic Accessibility Score of Drug-like Molecules

Ertl & Schuffenhauer (2009) J. Cheminform. · DOI: 10.1186/1758-2946-1-8

💡 Význam: SAScore algoritmus implementovaný v DrugEx jako penalizace nesyntetizovatelných struktur.

Better Informed Distance Geometry: Using Torsion Angle Preferences from CSD to Improve Conformer Generation (ETKDG)

Riniker & Landrum (2015) J. Chem. Inf. Model. · DOI: 10.1021/acs.jcim.5b00654

💡 Význam: RDKit ETKDG algoritmus pro generování fyzikálně relevantních 3D konformací.

Příloha E: Autoritativní Slovník Chemoinformatiky & Zkratek

26 hesel s matematickými definicemi

TanimotoCombo

3D ROCS & Konformace

$$T_{\text{combo}} = T_{\text{shape}} + T_{\text{color}} = \frac{I_{AB}}{I_{AA} + I_{BB} - I_{AB}} + \frac{C_{AB}}{C_{AA} + C_{BB} - C_{AB}}$$

Souhrnná metrika 3D molekulární podobnosti v ROCS. Kombinuje shodu Gaussovského sterického objemu (Shape, [0, 1]) a shodu farmakoforových barevných center (Color, [0, 1]). Dosahuje maximální hodnoty 2.0 pro identické molekuly v identické konformaci.

🎯 **Cílový rozsah:** Pro smysluplnou vazebnou shodu > 0.85; vynikající kandidáti > 1.20.

Intrinsically Disordered Proteins (IDP)

Metodologie DP

Proteiny postrádající stabilní terciární strukturu, které existují jako dynamický konformační ansámbl. Tradiční rigidní dokování na IDP selhává, protože neexistuje stálá vazebná kapsa. Tvarové porovnávání (ROCS) zde slouží jako ligand-based alternativa modelující komplementární obálku aktivních konformací.

🎯 **Cílový rozsah:** Metodologická doména pro flexibilní cíle a indukované vazebné přechody.

Crowding Distance (PCD)

Algoritmy & AI

$$d_i = \sum_{m=1}^M \frac{f_m(i+1) - f_m(i-1)}{f_m^{\text{max}} - f_m^{\text{min}}}$$

Metrika hustoty řešení v objektivním prostoru převzatá z genetického algoritmu NSGA-II a adaptovaná v DrugExu pro Policy Gradient. Odměňuje molekuly nacházející se v méně zaplněných oblastech Paretoovy fronty, čímž brání kolapsu chemické diversity (Mode Collapse). Hraniční extrémy mají přiřazenu vzdálenost ∞ .

🎯 **Cílový rozsah:** Normalizováno do vah odměn $R(x) \in [0, 1]$.

Policy Gradient (REINFORCE)

Algoritmy & AI

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{\pi_{\theta}} \left[\sum_{t=1}^T R(m) \cdot \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \right]$$

Základní algoritmus Reinforcement Learning (RL) v DrugExu. Aktualizuje parametry θ neuronového generátoru ve směru, který zvyšuje pravděpodobnost generování tokenů vedoucích k molekulám s vysokou vícekritériální odměnou $R(m)$.

🎯 **Cílový rozsah:** Typický learning rate v DrugEx: $1e-4$ až $2e-4$.

Prior & Agent Architektura

Algoritmy & AI

$$\mathcal{L}(\theta) = -\mathbb{E}[R(x) \log \pi_{\theta}(x)] + \beta \cdot D_{\text{KL}}(\pi_{\theta} || \pi_0)$$

Dvoustupňové uspořádání v DrugExu. Prior síť (π_0) je zmrazená síť předtrénovaná na obecné chemické databázi (Papyrus/ChEMBL), která uchovává znalost chemické gramatiky. Agent (π_{θ}) je učená síť optimalizující odměny. Penalizace Kullback-Leiblerovy divergence (DKL) drží Agenta v mezích synteticky realizovatelné chemie.

🎯 **Cílový rozsah:** Explorační poměr epsilon = 0.15–0.25; koeficient beta = 0.01–0.05.

SAScore (Syntetická dostupnost)

Chemoinformatika

$$\text{SAScore} = \text{FragmentScore} - \text{ComplexityPenalty}$$

Metrika dle Ertla a Schuffenhauera hodnotící snadnost chemické syntézy molekuly. Vychází z frekvenční analýzy fragmentů v databázi PubChem a penalizuje strukturální složitost (chiralitu, spiro atomy, můstky, velké cykly). Škála 1 (triviální syntéza) až 10 (téměř nesyntetizovatelné).

🎯 **Cílový rozsah:** Požadavek pro praktickou syntézu v medchem: SAScore < 3.5; mezní limit < 4.5.

QED (Quantitative Estimate of Drug-likeness)

Chemoinformatika

$$\text{QED} = \exp \left(\frac{1}{k} \sum_{i=1}^k w_i \ln d_i \right)$$

Kvantitativní odhad léčivupodobnosti navržený Bickertonem et al. Integruje 8 molekulárních vlastností (MW, logP, HBD, HBA, PSA, počet rotovatelných vazeb, počet aromatických kruhů a strukturální alerty) pomocí asymetrických žádoucích funkcí do jediného skóre v intervalu [0, 1].

🎯 **Cílový rozsah:** Pro de novo kandidáty QED > 0.60; ideálně > 0.75.

ETKDGv3

3D ROCS & Konformace

Algoritmus generování 3D konformerů v RDKit vyvinutý Rinikerem a Landrumem. Kombinuje distanční geometrii s empirickými preferencemi torzních úhlů extrahovanými z Cambridgeské strukturální databáze (CSD). Verze v3 přináší vylepšené vzorkování pro makrocykly a flexibilní alifatické řetězce.

🎯 **Cílový rozsah:** Doporučeno 30–50 konformerů na molekulu pro spolehlivý 3D ROCS scoring.

SmoothClippedScore

Algoritmy & AI

$$S(x) = \frac{1}{1 + 10^{\alpha(x-x_0)}} \quad \text{nebo hladký sigmoideální přechod}$$

Nelineární transformace v DrugExu převádějící fyzikálně-chemickou vlastnost (např. SAScore, MW, LogP) do normalizované odměny [0, 1]. Zabraňuje tomu, aby model byl nekonečně odměňován za extrémní honbu za čísly (např. triviální molekuly s MW 80) a vyhlazuje gradienty kolem požadovaného pásma.

🔗 **Cílový rozsah:** Pro SAScore: lower_x = 5.0 (odměna 0), upper_x = 3.0 (odměna 1).

Youdenův Index (J)

Metodologie DP

$$J = \text{Sensitivity} + \text{Specificity} - 1 = \text{TPR} - \text{FPR}$$

Statistická metrika využívaná v ROC analýze pro objektivní stanovení dělicího prahu (threshold) mezi aktivními látkami a decoyi. Bod na ROC křivce, kde J dosahuje maxima, představuje optimální kompromis minimalizující falešnou pozitivitu i falešnou negativitu.

🔗 **Cílový rozsah:** Umožňuje kalibrovat práh TanimotoCombo (např. 0.871 pro CCR2) v scriptu threshold_analysis.py.

MolVS Standardizace

Chemoinformatika

Standardizační knihovna integrovaná v přípravě dat DrugExu. Odstraňuje anorganické soli a solváty (desalting), neutralizuje formální náboje, převádí funkční skupiny na kanonické tautomery a validuje valenční pravidla před tréninkem neuronových sítí.

🔗 **Cílový rozsah:** Povinný krok datové hygieny (drugex.data.processing).

Decoy Sloučeniny

Metodologie DP

Molekuly navrženy tak, aby měly podobné fyzikálně-chemické vlastnosti jako známé aktivní ligandy (molekulovou hmotnost, logP, počet rotovatelných vazeb), ale zcela odlišnou 2D topologii a farmakoforové uspořádání. Používají se pro nestrannou kalibraci ROC křivek a validaci rozlišovací schopnosti ROCS scoreru.

🔗 **Cílový rozsah:** Poměr v benchmarku typicky 1 aktivní ku 30–50 decoyům.

Reward Hacking (Obcházení odměny)

Algoritmy & AI

Situace, kdy optimalizační algoritmus nalezne způsob, jak dosáhnout vysoké matematické odměny generováním chemických anomálií (např. extrémně dlouhých alifatických řetězců při nekontrolované odměně za LogP, nebo makrocyklů při čistém objemovém ROCS bez SA filtru). Řešením je vícekritériální Pareto vyvážení se striktním SAScore.

🔗 **Cílový rozsah:** Eliminováno správnou kompozicí DrugExEnvironment.

OpenEye ROCS

3D ROCS & Konformace

Průmyslový zlatý standard v 3D tvarovém porovnávání vyvinutý OpenEye Scientific Software. Využívá analytickou reprezentaci atomů pomocí hladkých Gaussovských funkcí a optimalizovaný Color Force Field. V DrugExu představuje vysoce výkonný backend, vyžadující však komerční licenci.

🔗 **Cílový rozsah:** Až 100x rychlejší než čisté Python implementace.

BRICS (Retrosyntetická fragmentace)

Chemoinformatika

Algoritmus retrosyntetického štěpení molekul navržený Degenem et al. Identifikuje 16 strategických typů chemických vazeb (např. amidy, estery, ethery, aryl-amidy) a nahrazuje je syntonovými exit-vektory [1*] až [16*]. Umožňuje fragment-based generování s garancí chemické valenční proveditelnosti.

🔗 **Cílový rozsah:** Základ fragmentových modelů v DrugEx (SmilesFragDataSet, VocFrag).

VocSmiles (Slovník tokenů)

Chemoinformatika

Tokenizační kontrakt v DrugExu definovaný regulárním výrazem rozdělejícím 1D SMILES na atomové symboly (včetně dvoupísmenných Br, Cl v hranatých závorkách i bez), vazby, větvení a izotopové značky. Zajišťuje invertibilní mapování mezi řetězcem a tenzorem celočíselných tokenů.

🔗 **Cílový rozsah:** Typická velikost slovníku: 60 až 100 tokenů.

Papyrus Databáze

Metodologie DP

Rozsáhlá kurátorská databáze bioaktivních sloučenin (verze 05.5 obsahuje ~1,5 milionu látek s více než 60 miliony bioaktivit) sloučená z ChEMBL a BindingDB s harmonizovanými měřeními a stereochemií. Slouží jako referenční datový korpus pro předtrénování Prior sítí v DrugExu.

🔗 **Cílový rozsah:** Výchozí stav pro transfer learning a fine-tuning na specifický cíl.

Mode Collapse (Kolaps diversity generátoru)

Algoritmy & AI

Patologický stav při Reinforcement Learning (RL), kdy generátor ztratí chemickou rozmanitost a začne cyklicky produkovat jedinou nebo malou sadu struktur s vysokým skóre. V DrugExu je indikován poklesem unikátnosti (uniqueness < 30 %). Protilekem je zvýšení exploračního parametru epsilon a použití Crowding Distance.

🔗 **Cílový rozsah:** Cílová unikátnost v generované knihovně > 85 %.

PAINS (Pan-Assay Interference Compounds)

Chemoinformatika

Substruktury vykazující falešně pozitivní aktivitu v biochemických testech (např. skrze reaktivní kovalentní modifikace, agregaci v roztoku, fluorescenci nebo produkci peroxidu vodíku, např. chinony, rhodaniny). V DrugExu jsou filtrovány přes RDKit FilterCatalog.

🔗 **Cílový rozsah:** Všechny finální kandidátní molekuly musí projít PAINS a Brenk filtrem s 0 alerty.

CDPKit (CDPL)

3D ROCS & Konformace

Výkonný open-source C++ framework s Python bindingy pro chemoinformatiku a 3D farmakoforové modelování. V DrugExu slouží jako rychlý bezlicenční ekvivalent ROCS s plnou podporou 3D Gaussovského tvaru i barevných farmakoforů (cdpl.shape a cdpl.pharm).

🔗 **Cílový rozsah:** Ideální volba pro akademické klustry bez OpenEye licencí.

RDKit rdShapeAlign

3D ROCS & Konformace

$$D = \text{ShapeTanimotoDist}(A, B) \implies T_{\text{shape}} = 1.0 - D$$

Nativní open-source modul v RDKit pro výpočet tvarové nepodobnosti pomocí Gaussovského překryvu. V DrugExu je obalen do RDKitROCSScoreru, který doplňuje farmakoforovou shodu přes FeatureMap.

🔗 **Cílový rozsah:** Plně přenositelné řešení bez externích knihoven.

SELFIES

Chemoinformatika

Alternativní 1D řetězcová reprezentace chemických molekul vyvinutá Aspuru-Guzikem a kolegy. Na rozdíl od SMILES je 100 % všech vygenerovaných kombinací SELFIES tokenů syntakticky i valenčně chemicky platných, což eliminuje chybovost generátoru na syntaktické úrovni.

🔗 **Cílový rozsah:** Validita generování 100 % (vůči ~95 % u SMILES bez pokročilé filtrace).

Interní Diverzita Knihovny (Div)

Chemoinformatika

$$\text{Div}(S) = 1 - \frac{2}{|S|(|S| - 1)} \sum_{i < j} T(m_i, m_j)$$

Míra strukturní pestrosti vygenerované knihovny molekul S založená na průměrné Tanimoto vzdálenosti Morganových fingerprintů (ECFP4) mezi všemi dvojicemi. Vysoká hodnota indikuje široké prozkoumání chemického prostoru, zatímco hodnota blízká 0 značí kolaps diverzity.

🔗 **Cílový rozsah:** Pro smysluplnou screeningovou knihovnu Div > 0.70; ideálně > 0.80.

NSGA-II Algoritmus

Algoritmy & AI

Klasický evoluční algoritmus pro vícekriteriální optimalizaci navržený Debem et al. Zavedl rychlé nedominované řazení (Non-dominated sorting) do vrstev F1, F2, F3 a crowding distance pro zachování diverzity. Principy tohoto algoritmu jsou jádrem vícekriteriálního učení v DrugExu.

🔗 **Cílový rozsah:** Zajišťuje rovnoměrné pokrytí Paretovy fronty.

Paretova Fronta (Pareto Front)

Algoritmy & AI

$$x^* \in \mathcal{P} \iff \nexists x : \forall i, f_i(x) \geq f_i(x^*) \wedge \exists j, f_j(x) > f_j(x^*)$$

Množina všech nedominovaných řešení v mnohorozměrném prostoru kritérií. Žádnou vlastnost molekuly na Paretově frontě nelze zlepšit, aniž by došlo ke zhoršení alespoň jedné jiné vlastnosti. Představuje optimální kompromis mezi afinitou, tvarem a syntetizovatelností.

🔗 **Cílový rozsah:** Počet molekul ve Frontě 1 typicky 5–20 % z generované dávky.

DrugExEnvironment

Algoritmy & AI

Centrální výpočetní komponenta platformy DrugEx, která sdružuje jednotlivé skórovače (scorers), jejich normalizační modifikátory (modifiers), prahové hodnoty (thresholds) a vyhodnocovací schéma (ParetoCrowdingDistance). V každé epoše přebírá vygenerované SMILES a vrací matici odměn R(x).

🔗 **Cílový rozsah:** Modulární stavebnice integrující ROCS, SAScore, QSAR i fyz-chem filtry.

Příloha F: Rychlá Referenční Karta (Cheat-Sheet)

CLI Příkazy, Chemoinformatické One-Linery & Slurm HPC Šablona

1. DrugEx CLI Příkazy

Tvorba korpusu a slovníku

```
python -m drugex.dataset -i raw.tsv -o data/corpus -v  
VocSmiles
```

Předtrénování generátoru (PT)

```
python -m drugex.train -i data/corpus.pkg -m  
SequenceRNN -e 100
```

Reinforcement Learning (MORL)

```
python -m drugex.train -i ft_agent.pkg -env env.json -e  
50 --eps 0.20
```

Generování molekul a filtrace

```
python -m drugex.generate -m rl_agent.pkg -n 5000 -o  
gen_mols.tsv
```

2. RDKit Chemoinformatické One-Linery

Načtení a validace

```
mol = Chem.MolFromSmiles(smi); Chem.SanitizeMol(mol)
```

Generování 50 3D konformerů (ETKDGv3)

```
params = AllChem.ETKDGv3(); params.numThreads = 1  
AllChem.EmbedMultipleConfs(mol, numConfs=50,  
params=params)
```

3D Tvarový překryv (Gaussovský Shape)

```
dist = rdShapeAlign.ShapeTanimotoDist(ref_mol, mol)  
shape_sim = 1.0 - dist
```

3. Produkční Slurm Skript pro HPC (MetaCentrum / IT4Innovations)

```
#!/bin/bash  
#SBATCH --job-name=drugex_rocs_rl  
#SBATCH --partition=gpu  
#SBATCH --gres=gpu:1  
#SBATCH --cpus-per-task=8  
#SBATCH --mem=32GB  
#SBATCH --time=24:00:00  
  
# Prevence CPU oversubscription v RDKit/CDPKit workerech  
export OMP_NUM_THREADS=1  
export MKL_NUM_THREADS=1  
export OPENBLAS_NUM_THREADS=1  
  
module load CUDA/12.1 Python/3.12  
source /home/user/DrugEx/.venv/bin/activate  
  
python run_rl_rocs.py --config config.py --n-samples 1000 --epochs 50
```