



DrugEx Hub · De Novo Drug Design & ROCS Shape-Matching

Kompletní Výuková Příručka, Metodologický Manuál a Teoretické Základy pro
Bakalářskou Práci (VŠCHT Praha / ÚOCHB AV ČR) — Kombinace de novo generování
molekul a 3D tvarového porovnávání pro flexibilní cíle a IDP.

Bakalářská Práce: David Kolář

Vysoká škola chemicko-technologická v Praze (VŠCHT Praha)

Ústav organické chemie a biochemie AV ČR (ÚOCHB AV ČR)

Softwarová platforma: DrugEx v3.4 (feature/rocs-scoring) · OpenEye ROCS / CDPKit / RDKit

Modul 1: De Novo Generování & Molekulární Reprezentace

1.1 Molekulární reprezentace, tokenizace & slovník (VocSmiles)

Hlubková taxonomie molekulárních reprezentací (1D SMILES/SELFIES/DeepSMILES vs 2D molekulární grafy vs fragmentové vaky BRICS), tokenizační smlouva VocSmiles s rozpadem regulárních výrazů, řídicí tokeny a 5-stupňový standardizační protokol SmilesStandardizer.

1. Paradigma molekulárních reprezentací v chemoinformatice a generativní AI Slide 1/8

Výpočetní reprezentace chemické struktury představuje fundamentální most mezi fyzikálně-chemickou realitou molekuly a matematickým aparátem strojového učení. V klasické chemoinformatice a QSAR modelování dominovaly po desetiletí fixní binární nebo celočíselné vektorové otisky (např. **Morganovy / ECFP4 fingerprinty**, **MACCS keys**, topologické indexy). Tyto deskriptory sice excelují v rychlém vyhledávání substrukturní podobnosti v miliardových databázích, mají však zásadní omezení pro de novo návrh léčiv: jsou **jednosměrné (nerozbalitelné)**. Z fixního 2048-bitového vektoru nelze deterministicky ani generativně zrekonstruovat původní molekulární strukturu.

Generativní de novo design léčiv vyžaduje **invertibilní, spojitě či diskrétní generovatelné reprezentace**, které umožňují algoritmu postupně syntetizovat nové chemické entity atom po atomu nebo fragment po fragmentu. V současné generativní chemoinformatice rozlišujeme tři dominantní úrovně reprezentací:

- **1D Lineární řetězce (String Notations):** Linearizace molekulárních struktur do textových sekvencí znaků a tokenů (SMILES, DeepSMILES, SELFIES). Umožňují přímé nasazení nejmodernějších architektur z oblasti zpracování přirozeného jazyka (NLP), jako jsou rekurentní neuronové sítě (LSTM/GRU) a kauzální autoregresní transformery (GPT).
- **2D Atribuované molekulární grafy (Attributed Molecular Graphs):** Formální popis molekuly jako grafu $G = (V, E)$, kde uzly reprezentují atomy s vektory fyzikálně-chemických příznaků a hrany reprezentují kovalentní vazby s informací o jejich řádu a stereochemii.
- **Fragmentové a synthonové reprezentace (Bag of Fragments / Synthon Graphs):** Dekompozice molekul na synteticky dostupné stavební bloky definované standardizovanými štěpnými pravidly (např. BRICS, RECAP). Generování pak probíhá kombinací celých syntetických fragmentů, což zásadně redukuje chemický prostor na synteticky snadno realizovatelné kandidáty.

VÝZNAM PRO BAKALÁŘSKOU PRÁCI NA VŠCHT / ÚOCHB

Při návrhu ligandů pro flexibilní cíle a IDP proteiny je volba reprezentace kritická: 1D sekvenční modely (SequenceRNN) poskytují obrovskou chemickou flexibilitu a rychlost pro rozsáhlý screening, zatímco fragmentové a grafové modely (GraphTransformer) umožňují rigorózní zachování pevných scaffoldů (scaffold-constrained generation) a 100% syntaktickou validitu.

Lineární řetězcové reprezentace převádějí trojrozměrný či dvoudimenzionální chemický graf do jednodimenzionální sekvence symbolů. Každá z moderních notací řeší kompromis mezi lidskou čitelností, kompaktností a syntaktickou robustností:

1. SMILES (Simplified Molecular Input Line Entry System)

Vyvinutý Davidem Weiningerem v roce 1988. Využívá linearizaci molekulárního grafu pomocí upraveného průchodu do hloubky (DFS - Depth-First Search). Cykly jsou rozpojeny a označeny shodnými numerickými indexy na místech rozpojení (např. c1ccccc1 pro benzen, %12 pro dvojčíselná čísla kruhů). Větvení je značeno kulatými závorkami (...). Stereochemie na tetraedrických centrech je kódována pomocí @ (proti směru hodinových ručiček) a @@ (ve směru), cis/trans izomerie na dvojných vazbách pomocí / a \.

Hlavní slabina: Gramatická křehkost (syntactic fragility). Náhodná mutace jediného tokenu (např. smazání uzavírací závorky nebo nespárovaný index kruhu) způsobí okamžitou nevaliditu celého řetězce.

2. DeepSMILES (O'Boyle & Dalke, 2018)

Navržen speciálně pro hluboké neuronové sítě. Nahrazuje párové závorky operátorem uzavření s explicitním počtem kroků zpět a párová čísla cyklů nahrazuje jedním symbolem udávajícím délku kruhu. Tím eliminuje chyby způsobené nespárovanými závorkami.

3. SELFIES (Self-Referencing Embedded Strings, Krenn et al., 2020)

Formální bezkontextová stavová gramatika inspirovaná Chomského hierarchií. Každý token je interpretován jako stavový přechod v závislosti na aktuální volné valenci molekulárního fragmentu. **Garantuje 100% syntaktickou a valenční validitu** pro jakýkoliv náhodně sestavený řetězec tokenů.

Nevýhoda SELFIES: Výrazně delší sekvence tokenů, vyšší paměťová náročnost a obtížnější integrace s fragmentovými bázemi typu BRICS.

SMILES (Standard v DrugEx)

- **Kompaktnost:** Krátké sekvence (typicky 20–60 tokenů na molekulu léčiva).
- **Podpora knihoven:** Nativní integrace v RDKit, OpenEye, CDKit, ChEMBL a Papyrus.
- **Reprezentace fragmentů:** Přirozené kódování synthonů s dummy atomy ([1*], [2*]).
- **Nevýhoda:** Vyžaduje předtrénování na velkém korpusu k osvojení chemické gramatiky.

SELFIES (Stavová gramatika)

- **Syntaktická robustnost:** 100% matematická validita všech vygenerovaných řetězců.
- **Bezpečnost:** Žádné neuzavřené kruhy ani nespárované závorky.
- **Délka sekvencí:** Až o 50–100% více tokenů na molekulu, což zvyšuje výpočetní nároky transformerů ($O(N^2)$ pozornost).
- **Fragmentace:** Složitější definice retrosyntetických štěpných vazeb BRICS.

Molekuly nejsou ve své fyzikální podstatě lineární texty, ale prostorové topologické sítě. V DrugEx se vedle sekvenčních modelů uplatňuje také grafové a fragmentové paradigma:

1. Formální definice atribuovaného molekulárního grafu

Molekula je reprezentována uspořádanou dvojicí $G = (V, E)$, kde:

- $V = \{v_1, v_2, \dots, v_N\}$ je množina N těžkých atomů (uzlů). Každému uzlu náleží vektor atomových vlastností $\mathbf{x}_i \in \mathbb{R}^{d_v}$ (atomové číslo, formální náboj, hybridizace sp, sp^2, sp^3 , počet připojených vodíků, aromatický status, explicitní valence). Celá molekula je popsána maticí uzlů $\mathbf{X} \in \mathbb{R}^{N \times d_v}$.
- $E = \{e_{ij}\}$ je množina kovalentních vazeb (hran). Vazby jsou kódovány tenzorem sousednosti $\mathbf{A} \in \mathbb{R}^{N \times N \times d_e}$, kde d_e kóduje typ vazby (jednoduchá, dvojná, trojná, aromatická, žádná).

2. Fragmentové štěpení BRICS (Degen et al., 2008)

Při fragmentovém generování (např. `GraphTransformer` nebo `FragSequenceExplorer` v DrugEx) je výchozí molekula rozštěpena podle 16 retrosynteticky validních chemických pravidel (BRICS - *Biochemical Properties Reacting and Inherent Chemistry Structure*). Štěpí se strategické vazby jako např.:

1. L1–L1: Vazby C–C mezi alifatickými uhlíky
2. L3–L5: Amidové vazby (karbonyl–dusík)
3. L4–L11: Etherové a thioetherové vazby
4. L6–L13: Esterové a sulfonamidové vazby

Místa rozpojení jsou označena **dummy atoms (tzv. attachment points / synthony)** s indexem štěpného pravidla (např. `[1*]c1ccccc1` nebo `[3*]C(=O)N[5*]`). Model pak generuje molekulu spojováním komplementárních synthonových bloků, což garantuje vysokou syntetickou proveditelnost.

python

```
from rdkit import Chem
from rdkit.Chem import BRICS

# Ukázka dekompozice molekuly na BRICS fragmenty
smiles = "Cc1ccc(NC(=O)c2cccc(C(=O)N3CCN(Cc4ccccc4)CC3)c2)cc1"
mol = Chem.MolFromSmiles(smiles)

# Rozštěpení na synteticky dostupné stavební bloky (synthony)
frags = BRICS.BRICSDecompose(mol)
print("Extrahované BRICS fragmenty s attachment points:")
for f in frags:
    print(f"  Synthon: {f}")
```

Při volbě architektury pro diplomovou či bakalářskou práci je nutné zohlednit výpočetní náročnost, validitu a chemické chování jednotlivých reprezentací:

Kritérium	1D SMILES (SequenceRNN)	1D SMILES (SequenceTransformer)	2D Grafy (GraphTransformer)	BRICS Fragmenty
Paměťová složitost	$O(T)$ (lineární)	$O(T^2)$ (kvadratická pozornost)	$O(N^2 \cdot d)$ (tenzory sousednosti)	$O(F)$ (krátké sekvenční syntony)
Rychlost vzorkování	> 2 000 mol/s (GPU batch)	~ 800 mol/s	~ 200 mol/s	~ 600 mol/s
Validita struktur	92–98% (po pre-trainingu)	95–99%	100% (valenčně maskováno)	98–100%
Scaffold-constrained design	Obtížné (prefixové maskování)	Střední (in-filling / prefix)	Přirozené (uchycení na jádro)	Vynikající (substituce fragmentů)
Syntetická dostupnost (SAScore)	Variabilní (nutno řídit v MORL)	Střední až vysoká	Vysoká (řízená pravidly spojování)	Extrémně vysoká (BRICS pravidla)

5. Tokenizační kontrakt DrugEx: VocSmiles & Regulární výrazy

Standardní znaková tokenizace běžná v klasickém NLP (např. rozklad po jednotlivých písmenech) je v chemickém modelování hrubou chybou. Pokud bychom řetězec C1c1cccc1 rozdělili po písmenech na `['C', '1', 'c', '1', ...]`, model by interpretoval `'C'` jako alifatický uhlík a `'1'` jako izolovaný neznámý token, namísto atomu chloru.

```
r'([^\]{1,6})|Br|Cl|Si|Na|Ca|Fe|@@|@|/|\|%d{2}|d|=|#|$|:|~|.|[a-zA-Z])'
```

Tento regulární výraz provádí rozklad v rigorózně definovaném pořadí priorit:

- Explicitní atomové bloky v hranatých závorkách:** `\[[^\]]{1,6}\]` zachycuje složité ionty a chirální atomy (např. `[NH+]`, `[C@@H]`, `[O-]`, `[Se+]`, `[1*]`).
- Dvoupísmenné halogeny a kovy:** `Br`, `Cl`, `Si`, `Na`, `Ca`, `Fe`. V interní implementaci DrugEx se navíc před tokenizací provádí elegantní substituce: `Cl -> L` a `Br -> R`, což zabráňuje jakékoliv kolizi s alifatickým uhlíkem `C` či borem `B`.
- Stereochemické operátory:** `@@` (ve směru hodinových ručiček / clockwise), `@` (proti směru / counter-clockwise), `/` a `\` (geometrická konfigurace *E/Z*).

4. **Indexy kruhů:** Dvouciferná čísla uvozená procentem `%\d{2}` (např. `%10`, `%12`) následovaná jednocifernými čísly `\d`.
5. **Řády vazeb a speciální znaky:** `=` (dvojná vazba), `#` (trojná vazba), `$` (čtyřná vazba), `:` (aromatická vazba), `~` (libovolná vazba), `.` (oddělovač fragmentů/solí).
6. **Jednopísmenné organické prvky:** Alifatické atomy (`C, N, O, S, P, F, I, B`) a aromatické atomy (`c, n, o, s, p`).

python

```
import re

# Ukázka interního rozkladu sekvence ve VocSmiles
def tokenize_smiles(smiles: str) -> list:
    # 1. Substituce dvoupísmenných halogenů pro jednoznačnost
    s = smiles.replace('Cl', 'L').replace('Br', 'R')
    # 2. Regulární výraz pro atomové bloky v závorkách
    regex = r'([^\[\]\{\},1,6])'
    tokens = []
    for word in re.split(regex, s):
        if not word:
            continue
        if word.startswith('('):
            tokens.append(word)
        else:
            for char in word:
                tokens.append(char)
    # 3. Přidání ukončovacího tokenu a reverze substituce
    tokens = [t.replace('L', 'Cl').replace('R', 'Br') for t in tokens]
    return tokens + ['EOS']

raw_smiles = "Cc1ccc(Cl)c([C@@H](N)C(=O)[O-])c1"
print("Tokenizovaný řetězec:", tokenize_smiles(raw_smiles))
```

6. Řídicí tokeny (Control Tokens) & Celočíselné indexování

Slide 6/8

Pro trénování hlubokých neuronových sítí v PyTorch musí být diskretní tokeny převedeny na celočíselné indexy (LongTensor) a zarovnané do matic fixní dimenze $\mathbb{R}^{B \times L}$, kde B je velikost batche a L je maximální délka sekvence (standardně v DrugEx $L = 100$).

Ve třídě `SequenceVocabulary` / `VocSmiles` je definována pevná množina **řídících tokenů (Control Tokens)**:

Indexace ve VocSmiles : $\langle \text{PAD} \rangle \rightarrow 0$, $\langle \text{GO/START} \rangle \rightarrow 1$, $\langle \text{EOS/END} \rangle \rightarrow 2$, $\langle \text{UNK} \rangle \rightarrow 3$

Význam a fungování jednotlivých řídicích tokenů:

- `<PAD>` (**Padding, index 0 / `'_'`**): Slouží k doplnění kratších sekvencí na jednotnou délku batche. Při výpočtu cross-entropy ztráty a pozornosti transformeru je tento index maskován (`padding_idx=0`), takže do gradientů nepřispívá žádným signálem.

- **<GO> / <START> (Start of Sequence)**: Iniciační token vkládaný na začátek generované sekvence. V autoregresním vzorkování funguje jako spouštěč, který budí vnitřní skrytý stav sítě h_0 .
- **<EOS> / <END> (End of Sequence)**: Ukončovací token. Jakmile model vygeneruje tento token, autoregresní smyčka pro danou molekulu okamžitě zastaví generování dalších atomů a zbytek tenzoru vyplní paddingem.
- **<UNK> (Unknown Token)**: Záchytný token pro neznámé či vzácné chemické prvky (např. radioaktivní izotopy nebo neobvyklé kovy), které se nevyskytovaly v trénovacím korpusu.

python

```
from drugex.data.corpus.vocabulary import VocSmiles
import torch

# Inicializace slovníku VocSmiles
voc = VocSmiles(encode_frags=False, max_len=100, min_len=10)
print(f"Velikost chemického slovníku |V|: {voc.size}")
print(f"Řídící tokeny slovníku: {voc.control}")

# Ukázka kódování tokenů do PyTorch tenzoru
sample_tokens = [['GO', 'c', '1', 'c', 'c', 'c', 'c', 'c', '1', 'EOS']]
encoded_tensor = voc.encode(sample_tokens)
print(f"Zakódovaný tenzor tvaru {encoded_tensor.shape}")
print(encoded_tensor[0, :12])

# Zpětné dekódování tenzoru na čistý SMILES
decoded_smiles = voc.decode(encoded_tensor[0], is_tk=False, is_smiles=True)
print(f"Dekódovaný SMILES: {decoded_smiles}")
```

7. 5-Stupňová sanitace chemické struktury: SmilesStandardizer & CleanSMILES Slide 7/8

Trénovací databáze (např. ChEMBL, PubChem, ZINC či Papyrus) obsahují miliony molekul pocházejících z různých experimentálních laboratoří. Tyto struktury často obsahují krystalizační soli, protiionty, nestandardní protonační stavy, těžké izotopy nebo redundantní tautomerické formy.

Pokud by byl generativní model trénován na nekonzistentních datech, naučil by se generovat neplatné chemické směsi. DrugEx proto v modulu `drugex/molecules/converters/standardizers.py` implementuje rigorózní **5-stupňový standardizační protokol**:

1. **Desalting & Disconnection kovů (MetalDisconnector)**: Kovalentně navázané ionty alkalických kovů (Na^+ , K^+) a přechodných kovů (Zn^{2+} , Fe^{3+}) jsou odpojeny na samostatné iontové páry. Následně `LargestFragmentChooser` vybere největší spojitý organický fragment a odstraní krystalizační molekuly rozpouštědel (H_2O , $DMSO$, $EtOH$) a protiionty (Cl^- , Br^- , TFA^-).
2. **Neutralizace nábojů (Uncharger)**: Protonace a deprotonace funkčních skupin do neutrálního nebo fyziologického stavu (např. $R - COO^- \rightarrow R - COOH$, $R - NH_3^+ \rightarrow R - NH_2$), pokud to neporušuje valenční pravidla kvartérních dusíků.
3. **Tautomerická a funkční normalizace (Normalizer)**: Transformace nestandardních funkčních skupin (např. nitro skupiny $R - N(=O) = O \rightarrow R - [N+](=O)[O-]$, azidy, 1,3-dipolární systémy, keto-enol tautomerie) do jednotného kanonického zápisu.
4. **Odstranění izotopů & Validace prvků**: Náhrada těžkých izotopů (2H , 3H , ^{13}C , ^{15}N) standardními atomy a striktní kontrola, že molekula obsahuje minimálně jeden atom uhlíku (`[#6]`) a žádné reziduální soli.

5. **Kanonizace SMILES & Stereochemická validace** (`Chem.CanonSmiles`): Generování unikátního kanonického SMILES řetězce podle Morganova algoritmu číslování atomů.

STANDARDIZACE V BAKALÁŘSKÉ PRÁCI

Při přípravě ligandů pro 3D ROCS shape matching je správná standardizace klíčová: RDKit vyžaduje konzistentní protonační stav, aby konformační generátor (ETKDGv3) a farmakoforový skórovač (ImplicitMillsDean) správně přiřadily vodíkové donory a akceptory!

8. Praktická implementace: Načtení dat, VocSmiles & Sanitace v Pythonu

Slide 8/8

Následující ucelený skript demonstruje kompletní pipeline: od sanitace surového SMILES řetězce přes standardizátor `DefaultStandardizer` až po tokenizaci a kontrolu slovníku `VocSmiles`:

```
python

import torch
from rdkit import Chem
from rdkit.Chem.MolStandardize import rdMolStandardize
from drugex.molecules.converters.standardizers import DefaultStandardizer, CleanSMILES
from drugex.data.corpus.vocabulary import VocSmiles

# 1. Testovací surová molekula se solí (hydrochlorid) a nestandardním zápisem
raw_smiles = "[Na+].[O-]C(=O)c1ccc(C(=O)NC[C@@H](N)C(=O)[O-])cc1.Cl"
print(f"Vstupní surový SMILES: {raw_smiles}")

# 2. Aplikace 5-stupňového standardizátoru DrugEx
standardizer = DefaultStandardizer()
clean_smiles = standardizer(raw_smiles)
print(f"Sanitovaný kanonický SMILES: {clean_smiles}")

# 3. Inicializace slovníku a rozpad na tokeny
voc = VocSmiles(encode_frags=False, max_len=100, min_len=5)
tokens = voc.splitSequence(clean_smiles)
print(f"Rozložené chemické tokeny ({len(tokens)} ks): {tokens}")

# 4. Kódování do PyTorch tenzoru
tensor = voc.encode([tokens])
print(f"PyTorch LongTensor shape: {tensor.shape}")

# 5. Ověření deterministické rekonstrukce
reconstructed = voc.decode(tensor[0], is_tk=False, is_smiles=True)
print(f"Zrekonstruovaný SMILES: {reconstructed}")
assert Chem.CanonSmiles(clean_smiles) == Chem.CanonSmiles(reconstructed), "Chyba v rekonstrukci!"
print("✓ Validace úspěšná: Reprezentace je 100% invertibilní.")
```

1.2 Generativní modely: Sequence RNN, Sequence & Graph Transformer

1. Autoregresní pravděpodobnostní modelování chemického jazyka

Slide 1/9

Generování molekuly jako lineárního SMILES řetězce $X = (x_1, x_2, \dots, x_T)$ lze formalizovat jako odhad sdružené pravděpodobnosti výskytu sekvence tokenů $P(X)$. Pomocí řetízkového pravidla pravděpodobnosti rozkládáme sdruženou pravděpodobnost na součin podmíněných pravděpodobností:

$$P(X; \theta) = P(x_1, x_2, \dots, x_T; \theta) = \prod_{t=1}^T P(x_t \mid x_1, x_2, \dots, x_{t-1}; \theta) = \prod_{t=1}^T P(x_t \mid x_{<t}; \theta)$$

kde $x_t \in \mathcal{V}$ je token vygenerovaný v čase t , $x_{<t}$ představuje dosud vygenerovaný prefix sekvence a θ jsou trénovatelné parametry neuronové sítě.

Při trénování (supervizované učení) aplikujeme režim **Teacher Forcing**: v každém časovém kroku t předkládáme síti skutečný historický prefix $x_{<t}$ z trénovací databáze a minimalizujeme zápornou logaritmickou věrohodnost (NLL / Cross-Entropy Loss):

$$\mathcal{L}_{\text{NLL}}(\theta) = - \sum_{t=1}^T \log P(x_t^* \mid x_{<t}^*; \theta)$$

Při inferenci (generování de novo) síť funguje **autoregresně**: v každém kroku t model predikuje pravděpodobnostní rozdělení nad celým slovníkem $\mathcal{V}$, náhodně vzorkuje další token $\hat{x}_t \sim P(\cdot \mid \hat{x}_{<t})$ a tento token vrací na svůj vlastní vstup v čase $t + 1$.

2. SequenceRNN: Tenzorová algebra LSTM a GRU buněk

Slide 2/9

V základní konfiguraci DrugEx (soubor `drugex/training/generators/sequence_rnn.py`) využívá generátor **SequenceRNN** třívrstvou architekturu:

- Vkládací vrstva (Embedding Layer):** $\mathbf{E} \in \mathbb{R}^{|\mathcal{V}| \times d_{\text{emb}}}$ mapuje diskrétní token x_t na spojitý vektor $\mathbf{e}_t \in \mathbb{R}^{128}$.
- 3-vrstvá rekurentní páteř (Stacked LSTM / GRU):** $d_{\text{hidden}} = 512$. Udrží skrytý stav $\mathbf{h}_t^{(l)}$ pro každou vrstvu $l \in \{1, 2, 3\}$.
- Lineární projekční hlava:** $\mathbf{W}_{\text{out}} \in \mathbb{R}^{512 \times |\mathcal{V}|}$ mapuje výstupní stav $\mathbf{h}_t^{(3)}$ na vektor logitů $\mathbf{z}_t \in \mathbb{R}^{|\mathcal{V}|}$.

Rovnice 6-hradlové LSTM buňky (Long Short-Term Memory)

V každé vrstvě a časovém kroku t počítá LSTM následující tenzorové operace:

$\mathbf{f}_t = \sigma(\mathbf{W}_f \mathbf{x}_t + \mathbf{U}_f \mathbf{h}_{t-1} + \mathbf{b}_f)$	(Forget Gate — co zapomenout z minula)
$\mathbf{i}_t = \sigma(\mathbf{W}_i \mathbf{x}_t + \mathbf{U}_i \mathbf{h}_{t-1} + \mathbf{b}_i)$	(Input Gate — jaké nové informace uložit)
$\tilde{\mathbf{c}}_t = \tanh(\mathbf{W}_c \mathbf{x}_t + \mathbf{U}_c \mathbf{h}_{t-1} + \mathbf{b}_c)$	(Candidate Memory — kandidátní paměťový obsah)
$\mathbf{c}_t = \mathbf{f}_t \odot \mathbf{c}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{c}}_t$	(Cell State — aktualizovaný stav buňky)
$\mathbf{o}_t = \sigma(\mathbf{W}_o \mathbf{x}_t + \mathbf{U}_o \mathbf{h}_{t-1} + \mathbf{b}_o)$	(Output Gate — co propustit do skrytého stavu)
$\mathbf{h}_t = \mathbf{o}_t \odot \tanh(\mathbf{c}_t)$	(Hidden State — výstupní vektor do další vrstvy)

kde $\sigma(z) = \frac{1}{1+e^{-z}}$ je logistická sigmoidální funkce a $\odot$ značí Hadamardův součin prvek po prvku.

LSTM VS GRU V DRUGEX

LSTM buňka disponuje odděleným stavem $\mathbf{c}_t$ (cell state), což jí umožňuje udržet informaci o otevření cyklu (např. 'c1...') přes desítky mezilehlých substituentů až po jeho úspěšné uzavření ('...c1'). GRU má méně parametrů a rychlejší trénink, ale LSTM dosahuje vyšší validity na složitých polycyklických scaffoldových strukturách.

3. Autoregresní vzorkování & Teplotní škálování (Temperature Sampling)

Slide 3/9

Výstupem lineární projekce v čase t je vektor surových logitů $\mathbf{z}_t = (z_{t,1}, z_{t,2}, \dots, z_{t,|\mathcal{V}|})^T$. Pro převod logitů na pravděpodobnostní rozdělení se aplikuje **teplotně modifikovaná funkce Softmax** s hyperparametrem teploty $T > 0$:

$$P(x_t = v \mid \mathbf{x}_{<t}; T) = \frac{\exp\left(\frac{z_{t,v}}{T}\right)}{\sum_{j=1}^{|\mathcal{V}|} \exp\left(\frac{z_{t,j}}{T}\right)}$$

Vliv teploty T na chemické vlastnosti generovaných molekul:

- $T \rightarrow 0$ (**Greedy / Argmax vzorkování**): Rozdělení kolabuje do Diracova delta impulzu na logitu s nejvyšší hodnotou. Model generuje deterministicky nejpravděpodobnější, ale repetitivní a fádní molekuly s minimální diverzitou.
- $T = 1.0$ (**Standardní vzorkování**): Věrná reprodukce statistického rozdělení chemického prostoru trénovací sady Papyrus. Optimální rovnováha mezi validitou ($> 95\%$) a chemickou novostí.
- $T > 1.2$ (**Vysoká entropie / Explorace**): Rozdělení se vyrovnává (blíží se rovnoměrnému). Model zkouší vzácné chemické kombinace a exotické kruhové systémy, roste však riziko syntaktických chyb (neuzavřené kruhy, valenční kolize) a validita klesá pod 80%.

python

```
import torch
import torch.nn.functional as F

def sample_with_temperature(logits: torch.Tensor, temperature: float = 1.0) -> int:
    """Vzorkování tokenů z logitů s aplikací teplotního faktoru T."""
    if temperature <= 0.0:
        return torch.argmax(logits, dim=-1).item()

    scaled_logits = logits / temperature
    probabilities = F.softmax(scaled_logits, dim=-1)
    # Multinomiální stochastické vzorkování
    sampled_token_idx = torch.multinomial(probabilities, num_samples=1).item()
    return sampled_token_idx
```

4. SequenceTransformer: GPT Architektura pro chemické sekvence

Slide 4/9

Zatímco rekurentní sítě zpracovávají sekvenci krok za krokem, `SequenceTransformer` (třída `SequenceTransformer` / `GPT2Layer` v `drugex/training/generators/sequence_transformer.py`) využívá paralelní architekturu založenou na čisté pozornosti (Self-Attention):

Strukturní parametry SequenceTransformeru v DrugEx:

- Počet vrstev transformeru: $N_{\text{layer}} = 12$
- Dimenze vnoření a modelu: $d_{\text{model}} = d_{\text{emb}} = 512$
- Počet pozornostních hlav: $N_{\text{head}} = 8$ (dimenze každé hlavy $d_k = d_v = 512/8 = 64$)
- Vnitřní dimenze feed-forward sítě: $d_{\text{inner}} = 1024$
- Aktivace: GELU (Gaussian Error Linear Unit) s Layer Normalization před každým podblokem.

Poziční kódování (Positional Encoding)

Protože transformer sám o sobě neobsahuje žádnou rekurentní smyčku ani konvoluci, je permutativně invariantní. Informaci o pořadí atomů v řetězci dodáváme přičtením pozičního vektoru:

$$\mathbf{h}_0 = \text{Embedding}(X) + \text{PositionalEmbedding}(\text{pos})$$

kde poziční kódování využívá buď trénovatelné vektory, nebo harmonické funkce:

$$\text{PE}_{(\text{pos}, 2i)} = \sin\left(\frac{\text{pos}}{10000^{2i/d_{\text{model}}}}\right), \quad \text{PE}_{(\text{pos}, 2i+1)} = \cos\left(\frac{\text{pos}}{10000^{2i/d_{\text{model}}}}\right)$$

5. Multi-Head Self-Attention a Kauzální Maskování (Causal Masking)

Slide 5/9

Základním výpočetním blokem je **Multi-Head Self-Attention**. Vstupní matice reprezentací $\mathbf{H} \in \mathbb{R}^{T \times d_{\text{model}}}$ je lineárně promítnuta do tří matic: Dotazů (Query **Q**), Klíčů (Key **K**) a Hodnot (Value **V**):

$$\mathbf{Q} = \mathbf{H}\mathbf{W}_Q, \quad \mathbf{K} = \mathbf{H}\mathbf{W}_K, \quad \mathbf{V} = \mathbf{H}\mathbf{W}_V, \quad \mathbf{W}_Q, \mathbf{W}_K, \mathbf{W}_V \in \mathbb{R}^{d_{\text{model}} \times d_{\text{model}}}$$

Skalární součin $\mathbf{Q}\mathbf{K}^T$ měří míru vzájemné závislosti mezi každým párem tokenů v sekvenci.

Kauzální dolní trojúhelníková maska (Causal Lower-Triangular Mask)

Při generování SMILES zleva doprava nesmí atom na pozici t vidět budoucí atomy na pozicích $t + 1, t + 2, \dots, T$. Proto DrugEx aplikuje kauzální masku $\mathbf{M} \in \mathbb{R}^{T \times T}$:

$$M_{ij} = \begin{cases} 0 & \text{pro } j \leq i \\ -\infty & \text{pro } j > i \end{cases}$$

Pozornost jedné hlavy je pak definována jako:

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax} \left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d_k}} + \mathbf{M} \right) \mathbf{V}$$

Díky přičtení hodnoty $-\infty$ se po aplikaci funkce softmax pravděpodobnost nahlížení do budoucích tokenů stane přesně nulovou ($e^{-\infty} = 0$).

python

```
import torch

def create_causal_mask(seq_len: int) -> torch.Tensor:
    """Vytvoření kauzální horní trojúhelníkové masky s hodnotami -inf."""
    mask = torch.triu(torch.full((seq_len, seq_len), float('-inf')), diagonal=1)
    return mask

# Ukázka masky pro sekvenci délky 4 tokeny
mask_4 = create_causal_mask(4)
print("Kauzální maska M (0 = povoleno, -inf = maskováno):")
print(mask_4)
```

6. GraphTransformer: 2D Generování molekulárních grafů z fragmentů

Slide 6/9

GraphTransformer (v souboru `drugex/training/generators/graph_transformer.py`) představuje vrchol strukturně-řízeného generování. Na rozdíl od sekvenčních modelů generuje molekulu přímo jako topologický graf $G = (V, E)$ z výchozích BRICS synthonů.

Vstupní tenzor reprezentuje graf s rozměry $[B, N_{\text{max}}, 5]$, kde $N_{\text{max}} = 80$ uzlů a 5 kanálů kóduje:

- Kanál 0 (Atom Type):** Celočíslný index typu atomu z grafového slovníku `VocGraph` (např. `'4C'`, `'3N'`, `'2O'`, `'1Cl'` — číslo značí maximální valenci prvku).
- Kanál 1 (Current Locus):** Index aktuálního uzlu, ke kterému se připojuje nový fragment.
- Kanál 2 (Previous Locus):** Index uzlu, ze kterého vazba vychází.
- Kanál 3 (Bond Order):** Typ kovalentní vazby (0 = žádná, 1 = jednoduchá, 2 = dvojná, 3 = trojná, 4 = aromatická).

5. **Kanál 4 (Is Growth)**: Binární příznak, zda uzel náleží k pevnému výchozímu fragmentu nebo je nově dogenerován.

Architektura kombinuje **AtomLayer Transformer** pro modelování globálního chemického kontextu s rekurentní buňkou **GRUCell**, která provádí postupné dekódování vazeb a přípojných míst (loci).

VÝHODA GRAPHTRANSFORMERU PRO BAKALÁŘSKOU PRÁCI

GraphTransformer umožňuje definovat fixní jádro (např. známý farmakoforový scaffold vázající se do kapsy CCR2) a generátor navrhuje pouze substituenty a propojovací linkery na definovaných růstových bodech!

7. Valenční maskování a chemická garance validity v GraphTransformeru

Slide 7/9

Klíčovou inovací DrugEx GraphTransformeru je **dynamické valenční maskování (Dynamic Valence Masking)** během vzorkování. Zatímco SMILES generátor se musí valenční pravidla naučit statisticky, GraphTransformer je vynucuje deterministicky:

V každém kroku růstu t model udržuje tenzor zbývajících volných valencí pro každý atom:

$$\mathbf{v}_{\text{rom}}(i) = \mathbf{v}_{\text{max}}(i) - \sum_{j \in \mathcal{N}(i)} \text{order}(e_{ij})$$

kde $\mathbf{v}_{\text{max}}(i)$ je maximální valenční kapacita atomu i (např. 4 pro uhlík, 3 pro neutrální dusík, 2 pro kyslík) a $\mathcal{N}(i)$ je množina sousedních atomů.

Pokud $\mathbf{v}_{\text{rom}}(i) = 0$, logity pro vytvoření další vazby k atomu i jsou okamžitě přepsány hodnotou $-\infty$:

$$\text{Logit}_{\text{bond}}(i, j) = \begin{cases} z_{i,j} & \text{pokud } \mathbf{v}_{\text{rom}}(i) \geq \text{order} \wedge \mathbf{v}_{\text{rom}}(j) \geq \text{order} \\ -\infty & \text{jinak} \end{cases}$$

Díky tomu **nemůže nikdy vzniknout pětivazný uhlík, třívazný kyslík ani chemicky nevalidní struktura**. Validita výstupních grafů je tak 100%.

8. Komparativní srovnání generativních architektur

Slide 8/9

Shrnutí silných stránek a doporučených aplikačních scénářů jednotlivých architektur v DrugEx:

SequenceRNN / SequenceTransformer (1D)

Doporučené použití:

- Hromadné de novo generování nepředpojatých knihoven (Unconstrained De Novo Design).
- Rychlý screening obrovského chemického prostoru v rané fázi projektu.
- Výpočetně efektivní trénink na běžných GPU (SequenceRNN vystačí s 4–8 GB VRAM).
- Nejjednodušší integrace s MORL zpětnovazebním učením.

GraphTransformer (2D Fragment-Based)

Doporučené použití:

- Scaffold-constrained design & Linker design (připojování substituentů na fixní farmakoforové jádro).
- Projekty s přísnými požadavky na 100% valenční čistotu a syntetickou proveditelnost (BRICS).
- Optimalizace 'hit-to-lead' u známých inhibitorů flexibilních cílů / IDP.

9. PyTorch & DrugEx implementace generátorů

Slide 9/9

Následující kód ukazuje inicializaci modelů `SequenceRNN` a `SequenceTransformer` v DrugEx a vzorkování kandidátních molekul:

python

```
import torch
from drugex.data.corpus.vocabulary import VocSmiles
from drugex.training.generators import SequenceRNN, SequenceTransformer

# 1. Načtení chemického slovníku
voc = VocSmiles.fromFile("data/Papyrus05.5_smiles_voc.txt", encode_frags=False)

# 2. Inicializace 3-vrstvého SequenceRNN s LSTM buňkami
rnn_generator = SequenceRNN(
    voc=voc,
    embed_size=128,
    hidden_size=512,
    is_lstm=True,
    lr=1e-3
)
print(f"SequenceRNN inicializován na zařízení: {rnn_generator.device}")

# 3. Autoregresní vygenerování 5 nových SMILES sekvencí
rnn_generator.eval()
with torch.no_grad():
    sampled_smiles = rnn_generator.sample(batch_size=5)

print("Vygenerované molekuly ze SequenceRNN:")
for i, smi in enumerate(sampled_smiles):
    print(f" [{i+1}] {smi}")
```

1.3 Transfer Learning: Pre-training na Papyrus & Target Fine-Tuning

Dvoustupňový transfer learning, pre-training na 1,5M bioaktivních sloučenin Papyrus v05.5, cílový fine-tuning na ligandy CCR2/IDP, prevence katastrofického zapomínání a vytvoření fixní sítě Mutate/Prior (π_0).

1. Výzva chemického prostoru a filozofie Transfer Learningu

Slide 1/7

Velikost farmakologicky relevantního chemického prostoru malých molekul splňujících Lipinského pravidla ($MW < 500$, $\text{LogP} < 5$) se odhaduje na 10^{33} až 10^{60} možných struktur.

V praktickém výzkumu léčiv (včetně výzkumu flexibilních cílů a IDP proteinů na VŠCHT / ÚOCHB) narážíme na **datový paradox časně fáze vývoje**:

- Pro nově identifikovaný proteinový cíl máme k dispozici pouze **desítky až stovky známých aktivních sloučenin** z pilotních biologických esejí.
- Trénovat hlubokou neuronovou síť (s miliony parametrů) od nuly na pouhých 100 molekulách vede k okamžitému a fatálnímu přeučení (overfitting) a neschopnosti generovat smysluplnou chemii.

Řešením je **Transfer Learning (přenosem induktivního učení)**:

- Fáze 1 (Pre-training / Obecný chemický jazyk)**: Model se na obrovském korpusu (~1,5 mil. sloučenin) naučí univerzální pravidla chemické valence, aromaticity, stability a stability kruhů.
- Fáze 2 (Target Fine-Tuning / Cílová adaptace)**: Předtrénovaný model je jemně dotrénován na malé sadě bioaktivních ligandů daného cíle s nízkou rychlostí učení, čímž se jeho distribuce posune do požadovaného farmakoforového podprostoru.

2. Pre-Training na celém bioaktivním prostoru: Databáze Papyrus v05.5

Slide 2/7

V ekosystému DrugEx slouží jako standardní pre-trainingová báze databáze **Papyrus v05.5** (Bequis et al., *J. Cheminform.* 2022).

Papyrus v05.5 integruje a harmonizuje data z ChEMBL, PubChem, BindingDB a patentové literatury:

- Obsahuje více než **1,5 milionu unikátních bioaktivních sloučenin** s vysokou úrovní standardizace.
- Všechny molekuly jsou desaltovány, neutralizovány a převedeny na kanonický SMILES.
- Slovník `Papyrus05.5_smiles_voc.txt` pokrývá kompletní organickou abecedu (84 unikátních chemických tokenů).

Průběh a parametry předtrénování

Model (např. `SequenceRNN`) je trénován po dobu 50–100 epoch s optimalizátorem Adam ($lr = 10^{-3}$, batch size 512). Cílem je minimalizace ztráty Cross-Entropy napříč celou databází:

$$\mathcal{L}_{\text{CE}}(\theta) = -\frac{1}{|\mathcal{D}|} \sum_{X \in \mathcal{D}} \frac{1}{|X|} \sum_{t=1}^{|X|} \log P(x_t | x_{<t}; \theta)$$

Výsledkem je **obecný generátor (General Prior)**, který dosahuje validity generovaných molekul > 98% a dokáže syntetizovat rozmanité chemické třídy napříč celým známým chemickým prostorem.

VÝPOČETNÍ EFEKTIVITA

Předtrénovaný model Papyrus v05.5 stačí vytrénovat jednou (nebo stáhnout předpřipravený checkpoint .pkg) a následně jej opakovaně využívat pro libovolné biologické cíle!

3. Fine-Tuning na cílových ligandech (CCR2 & Flexibilní / IDP receptory)

Slide 3/7

Ve druhém kroku přizpůsobujeme generátor specifickému farmakologickému cíli (např. chemokinovému receptoru CCR2 nebo konformačnímu ansámbli IDP proteinu).

Trénovací sada pro fine-tuning typicky obsahuje **50 až 1 000 experimentálně ověřených ligandů** (např. sloučeniny s $p\text{IC}_{50} > 6.0$).

Kritické zásady správného Fine-Tuning:

- Snížení rychlosti učení (Learning Rate):** Rychlost učení se snižuje o řád, typicky na $lr = 10^{-4}$ nebo 5×10^{-5} . Vysoký learning rate by v několika krocích zničil obecné chemické znalosti získané z 1,5 milionu molekul.
- Omezený počet epoch s časným zastavením (Early Stopping):** Trénink probíhá pouze 30–100 epoch. Průběžně se sleduje validační ztráta na 20% zadržené sadě.
- Konzistentní slovník:** Fine-tuning MUSÍ využívat identický slovník `VocSmiles` jako pre-training model. Pokud by cílové ligandy obsahovaly token mimo slovník (např. vzácný bor), taková molekula je předem odfiltrována metodou `voc.removeIfNew()`.

python

```
import torch
from torch.utils.data import DataLoader
from drugex.data.corpus.vocabulary import VocSmiles
from drugex.data.datasets import SequenceDataSet
from drugex.training.generators import SequenceRNN

# 1. Načtení slovníku a předtrénovaného obecného modelu
voc = VocSmiles.fromFile("data/Papyrus05.5_smiles_voc.txt", encode_fragments=False)
model = SequenceRNN(voc, is_lstm=True, lr=1e-4) # Snížený LR pro fine-tuning!
model.loadStatesFromFile("models/Papyrus05.5_general_rnn.pkg")

# 2. Příprava cílových ligandů CCR2
target_dataset = SequenceDataSet("data/benchmarks/actives_ccr2_N75.csv", voc=voc)
train_loader = DataLoader(target_dataset, batch_size=32, shuffle=True)

# 3. Fine-tuning smyčka (zkrácená ukázka)
print("Zahájení cílového fine-tuningu na ligandy CCR2...")
model.train()
for epoch in range(1, 51):
    epoch_loss = 0.0
    for batch in train_loader:
        model.optim.zero_grad()
        loss = -model.likelihood(batch.to(model.device)).mean()
        loss.backward()
        model.optim.step()
        epoch_loss += loss.item()
    if epoch % 10 == 0:
        print(f"Epocha {epoch}/50 | Ztráta: {epoch_loss/len(train_loader):.4f}")

# 4. Uložení dotrénovaného modelu
model.saveStatesToFile("models/ccr2_finetuned_rnn.pkg")
print("✓ Fine-tuning dokončen. Model uložen.")
```

4. Fenomén katastrofického zapomínání (Catastrophic Forgetting) & Induktivní bias Slide 4/7

Při adaptaci neuronových sítí hrozí závažné riziko zvané **katastrofické zapomínání (Catastrophic Forgetting)**:

Pokud je model trénován na malé cílové sadě příliš dlouho nebo s vysokým learning rate, váhy sítě se přizpůsobí výhradně několika málo strukturám. Důsledky:

- **Ztráta chemické rozmanitosti:** Generátor začne generovat pouze triviální variace (např. přidávání methylových skupin) jedné a téže molekuly.
- **Kolaps chemické gramatiky:** Model zapomene obecná pravidla uzavírání složitých cyklů z databáze Papyrus a validita generovaných struktur prudce klesne.

Kvantitativní monitorování vnitřní diverzity (Internal Diversity)

Během fine-tuningu monitorujeme vnitřní diverzitu generované populace $S = \{m_1, m_2, \dots, m_N\}$ pomocí Tanimotovy vzdálenosti Morganových fingerprintů:

$$I(S) = 1 - \frac{1}{N(N-1)} \sum_{i=1}^N \sum_{j \neq i} T_{\text{Tanimoto}}(\mathbf{fp}(m_i), \mathbf{fp}(m_j))$$

Hodnota $I(S) \in [0, 1]$. Pokud hodnota $I(S)$ klesne pod 0.65, trénink je nutné okamžitě zastavit (Early Stopping), protože model ztratil schopnost prozkoumávat nový chemický prostor.

Správně vybalancovaný Fine-Tuning

- Vysoká validita (> 95%).
- Vysoká diverzita ($I(S) > 0.75$).
- Generované molekuly obsahují klíčové farmakofory cíle, ale disponují novými chemickými scaffoldy.
- Ideální výchozí bod pro Reinforcement Learning.

Přetrénovaný model (Overfitting / Forgetting)

- Vysoká duplicita (model dokola generuje trénovací data).
- Nízká diverzita ($I(S) < 0.50$).
- Neschopnost provést scaffold hopping.
- RL agent v následující fázi rychle uvízne v lokálním optimu (Mode Collapse).

5. Vznik sítě Mutate / Prior (π_0) pro budoucí fázi zpětnovazebního učení

Slide 5/7

Po dokončení fine-tuningu máme k dispozici model, který dokonale kombinuje obecnou chemickou syntaktiku s afinitou k cílové rodině molekul.

Tento checkpoint hraje v DrugEx klíčovou dvojroli:

1. **Inicializace Agentu (π_θ):** Vzniká učící se agent, jehož váhy θ budou v následujícím modulu (MORL) optimalizovány směrem k maximálnímu 3D tvarovému překryvu ROCS a požadovaným vlastnostem.
2. **Zrození fixní sítě Mutate / Prior (π_0):** Vytvoří se identická kopie modelu, jejíž parametry jsou **trvale zmrazeny** (režim `eval()`, vypnuté gradienty).

RL Inicializace : $\pi_\theta \leftarrow \text{FineTunedCheckpoint}$, $\pi_0 \leftarrow \text{FineTunedCheckpoint (Frozen)}$

Síť π_0 bude v Module 2 sloužit jako stabilizační kotva (exploration anchor), která zabrání rozpadu generátoru při vícekritériální optimalizaci.

6. Analýza chemického prostoru: t-SNE / UMAP a Scaffold distribuce

Slide 6/7

Pro rigorózní vyhodnocení transfer learningu v diplomové práci slouží dimensionality reduction techniky (t-SNE, UMAP, PCA) aplikované na ECFP4 fingerprinty:

Chemický prostor vykazuje charakteristickou dynamiku v jednotlivých fázích:

- **1. Papyrus v05.5 Pre-training prostor (Šedý oblak):** Pokrývá globální chemický vesmír od malých fragmentů po makrocykly.
- **2. Cílové ligandy CCR2 (Červené body):** Tvoří specifický shluk s charakteristickým hydrofobním a bázi-obsahujícím motivem.
- **3. Fine-tuned generované molekuly (Modrý oblak):** Dokonale obklopují cílové ligandy a expandují jejich bezprostřední chemické okolí, aniž by degenerovaly do jediného bodu.

Bemis-Murcko Scaffold Analýza

Kvantitativní analýza chemických jader (Murcko scaffolds) potvrzuje, že fine-tuning zachovává variabilitu jader a generuje průměrně 60–80 unikátních scaffoldů na každých 1 000 vygenerovaných molekul.

DOPORUČENÍ PRO VIZUALIZACI V BAKALÁŘSKÉ PRÁCI

Ve výsledkové části bakalářské práce vždy uvádějte 2D UMAP projekci chemického prostoru porovnávající Papyrus baseline, známé experimentální ligandy a nově vygenerované kandidáty z DrugEx!

7. Kompletní protokol trénování a fine-tuningu v DrugEx

Slide 7/7

Následující ucelený Python skript demonstruje kompletní workflow od načtení surových dat až po přípravu modelů pro MORL:

python

```
import os
from drugex.data.corpus.vocabulary import VocSmiles
from drugex.data.datasets import SequenceDataSet
from drugex.training.generators import SequenceRNN
from drugex.training.monitors import FileMonitor

# 1. Cesty k datům
VOC_PATH = "data/Papyrus05.5_smiles_voc.txt"
GENERAL_MODEL = "models/Papyrus05.5_general_rnn.pkg"
FINETUNED_MODEL = "models/ccr2_finetuned_rnn.pkg"
ACTIVES_DATA = "data/benchmarks/actives_ccr2_N75.csv"

# 2. Načtení slovníku
voc = VocSmiles.fromFile(VOC_PATH, encode_fragments=False)

# 3. Načtení předtrénovaného generátoru
agent = SequenceRNN(voc, embed_size=128, hidden_size=512, is_lstm=True, lr=1e-4)
if os.path.exists(GENERAL_MODEL):
    agent.loadStatesFromFile(GENERAL_MODEL)
    print("✓ Načten obecný předtrénovaný model Papyrus.")

# 4. Příprava datové sady pro cílový fine-tuning
dataset = SequenceDataSet(ACTIVES_DATA, voc=voc)
train_loader = dataset.asDataLoader(batch_size=32, shuffle=True)

# 5. Spuštění fine-tuningu s monitorem postupu
monitor = FileMonitor("logs/finetune_ccr2")
agent.fit(
    train_loader=train_loader,
    valid_loader=None,
    epochs=50,
    monitor=monitor
)

# 6. Uložení finálního modelu pro Fázi 2 (MORL)
agent.saveStatesToFile(FINETUNED_MODEL)
print(f"✓ Model úspěšně uložen do {FINETUNED_MODEL}. Připraveno pro MORL!")
```

Modul 2: Vícekriteriální Zpětnovazební Učení (MORL) & Paretova Optimalita

2.1 Formulace MORL: Agent vs Mutate (Prior) & Policy Gradient

Formulace generování molekul jako Markovova rozhodovacího procesu (MDP), matematické odvození algoritmu REINFORCE s baseline, prevence lipofilního kolapsu (Reward Hacking) a dual-network architektura s epsilon-greedy směřováním.

1. Formulace generování molekul jako Markovova rozhodovacího procesu (MDP)

Slide
1/8

Generování chemické struktury atom po atomu (resp. token po tokenu v SMILES reprezentaci) lze exaktně modelovat jako diskrétní **Markovův rozhodovací proces (Markov Decision Process - MDP)** definovaný pěticí $(\mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R}, \gamma)$:

- **Stavový prostor $\mathcal{S}$:** Stav $s_t = (x_1, x_2, \dots, x_t) \in \mathcal{S}$ představuje částečně vygenerovaný prefix chemického řetězce v čase t . Počáteční stav je definován iniciačním tokenem $s_0 = \langle \text{GO} \rangle$.
- **Prostor akcí $\mathcal{A}$:** Akce $a_t \in \mathcal{A} = \mathcal{V}$ odpovídá výběru následujícího tokenu z chemického slovníku $\mathcal{V}$ (atomy, náboje, stereochemie, závorky větvení, čísla cyklů nebo ukončovací token $\langle \text{EOS} \rangle$).
- **Přechodová funkce $\mathcal{P}$:** Deterministický přechod do nového stavu $s_{t+1} = [s_t, a_t]$, kdy je vybraný token a_t připojen na konec dosavadního řetězce.
- **Funkce odměny $\mathcal{R}$ (Delayed Sparse Reward):** Během generování mezilehlých atomů je okamžitá odměna nulová ($r_t = 0$ pro $t < T$). Terminální odměna $R(X) \in [0, 1]$ je udělena teprve po vygenerování ukončovacího tokenu $\langle \text{EOS} \rangle$, kdy je kompletní molekula X předána prostředí **DrugExEnvironment** k chemoinformatickému a biologickému vyhodnocení.
- **Diskontní faktor $\gamma = 1.0$:** Vzhledem ke konečnému horizontu generování molekuly ($T \leq 100$) a nulovým mezilehlým odměnám se diskontování neuplatňuje.

VÝZNAM PRO BAKALÁŘSKOU PRÁCI

Zpožděná odměna (sparse reward) představuje hlavní výzvu: neuronová síť musí učinit desítky správných rozhodnutí (otevřít cyklus, správně umístit heteroatomy, uzavřít kruh), aniž by předem věděla, zda celá molekula získá vysoké 3D tvarové ROCS skóre!

2. Ztrátová funkce Policy Gradient & Matematické odvození REINFORCE

Slide 2/8

Cílem trénování je nalézt optimální parametry θ^* neuronového generátoru (politiky π_θ), které maximalizují očekávanou kumulativní odměnu generovaných molekul:

$$J(\theta) = \mathbb{E}_{X \sim \pi_\theta} [R(X)] = \sum_{X \in \mathcal{X}} P(X; \theta) R(X)$$

kde $P(X; \theta) = \prod_{t=1}^T \pi_\theta(a_t | s_t)$ je pravděpodobnost vygenerování celé sekvence X .

Protože prostor všech možných molekul $\mathcal{X}$ je obrovský a odměna $R(X)$ je nespojitá (nediferencovatelná přes chemické editory), nelze gradient $\nabla_\theta J(\theta)$ počítat analyticky. Aplikujeme **Likelihood Ratio Trick (Log-Derivative Trick)**:

$$\nabla_\theta P(X; \theta) = P(X; \theta) \frac{\nabla_\theta P(X; \theta)}{P(X; \theta)} = P(X; \theta) \nabla_\theta \log P(X; \theta)$$

Dosazením do gradientu účelové funkce získáváme základní rovnici algoritmu **REINFORCE** (Williams, 1992):

$$\nabla_\theta J(\theta) = \sum_X P(X; \theta) \nabla_\theta \log P(X; \theta) R(X) = \mathbb{E}_{X \sim \pi_\theta} [\nabla_\theta \log P(X; \theta) \cdot R(X)]$$

Zavedení baseline β pro redukci rozptylu

Stochastický gradientní odhad trpí vysokým rozptylem (variance). V DrugEx zavádíme skalární **baseline** β (standardně $\beta = 0.0$ nebo klouzavý průměr odměn):

$$\nabla_\theta J(\theta) = \mathbb{E}_{X \sim \pi_\theta} \left[\sum_{t=1}^T \nabla_\theta \log \pi_\theta(a_t | s_t) \cdot (R(X) - \beta) \right]$$

Ztrátová funkce v PyTorch je pak implementována jako vážená záporná logaritmická věrohodnost: $\mathcal{L}_{PG}(\theta) = -\text{likelihood}(X) \cdot (R(X) - \beta)$.

python

```
import torch

# Implementace kroku Policy Gradient (REINFORCE) v SequenceExplorer
def compute_policy_gradient_loss(agent, seqs, rewards, beta=0.0):
    """
    Výpočet ztráty REINFORCE s odečtením baseline beta.
    seqs: LongTensor [batch_size, max_len]
    rewards: FloatTensor [batch_size, 1]
    """
    # 1. Výpočet log-likelihood sekvencí pod aktuální politikou agenta
    log_probs = agent.likelihood(seqs) # [batch_size, max_len]

    # 2. Vynásobení odměnou posunutou o baseline
    advantage = rewards - beta # [batch_size, 1]
    loss = - (log_probs * advantage).mean()

    return loss
```

Pokud bychom generátor optimalizovali pouze na jedno jediné biologické kritérium (např. maximalizaci predikované afinity z QSAR modelu nebo čistý 3D objemový překryv), generátor rychle nalezne patologické zkratky v reprezentaci (tzv. **Reward Hacking**):

Typické patologie jednokriteriálního učení v chemoinformatice:

- **1. Lipofilní kolaps (Lipophilic Drift):** QSAR modely afinity často korelují s hydrofobicitou. Model začne generovat nekonečné alifatické řetězce a polycyklické aromatické uhlovodíky ($\text{LogP} > 8.0$). Takové molekuly mají vysoké teoretické skóre, ale jsou zcela nerozpustné ve vodě a toxické.
- **2. Tvorba chemických monster (Molecular Weight Runaway):** Model navyšuje molekulovou hmotnost ($\text{MW} > 900 \text{ Da}$), protože obrovské molekuly nabízejí více kontaktních ploch pro nespécifické Van der Waalsovy interakce.
- **3. Syntetická neproveditelnost (Synthetic Infeasibility):** Vznik extrémně pnutých můstkových polycyklů, spiro-systémů a nestabilních peroxido-diazo vazeb, které žádný organický syntetik nedokáže připravit ($\text{SAScore} > 8.0$).

Proto DrugEx striktně odmítá jednokriteriální optimalizaci a zavádí **Multi-Objective Reinforcement Learning (MORL)**, který balancuje 3D tvarovou shodu, selektivitu, fyzikální vlastnosti i syntetickou dostupnost.

Jednokriteriální RL (Pathological)

- Extrémní hodnoty $\text{LogP} (> 8.0)$ a $\text{MW} (> 800 \text{ Da})$.
- Nulová syntetická proveditelnost ($\text{SAScore} > 7.0$).
- Kolaps diverzity do jediné nefunkční struktury.
- Vysoké riziko falešně pozitivních virtuálních 'hitů'.

Vícekriteriální MORL v DrugEx

- Harmonický kompromis (Pareto Frontier).
- Přísná kontrola $\text{MW} (300\text{--}500 \text{ Da})$, $\text{LogP} (1\text{--}4)$ a TPSA .
- Vysoká syntetická dostupnost ($\text{SAScore} < 3.5$).
- Vynikající 3D tvarový a farmakoforový překryv (ROCS).

4. Dual-Network Architektura: Agent (π_{θ}) vs Mutate / Prior (π_0)

Druhým fundamentálním úskalím posilovaného učení v diskrétním jazykovém prostoru je **kolaps politiky (Mode Collapse / Policy Drift)**. Jakmile agent náhodně objeví jednu sekvenci s vysokou odměnou, gradientní aktualizace prudce zvýší pravděpodobnost těchto tokenů a síť přestane prozkoumávat zbytek chemického prostoru.

DrugEx řeší tento problém unikátní **duální architekturou dvou souběžných neuronových sítí**:

1. **Agent Network (Učící se generátor π_{θ}):** Aktivní neuronová síť, jejíž váhy θ jsou po každé epoše aktualizovány algoritmem Policy Gradient na základě Paretovských odměn. Zodpovídá za *exploataci* (hledání struktur s maximálním skóre).
2. **Mutate / Prior Network (Fixní kotva π_0):** Zmrazený model (jemně dotrénovaný checkpoint z Fáze 1.3). Je trvale přepnut do režimu `eval()` a jeho váhy nepodléhají žádným gradientovým úpravám. Zodpovídá za *exploraci* a udržování chemické gramatiky.

Duální architektura : π_θ (Učící se Agent) $\longleftrightarrow$ π_0 (Fixní Prior / Mutate kotva)

5. Epsilon-Greedy Policy Mixing a řízená chemická explorace

Slide 5/8

Během generování každého tokenu a_t v autoregresní smyčce (metoda `evolve` v

`drugex/training/generators/sequence_rnn.py`) DrugEx stochasticky kombinuje predikce obou sítí pomocí parametru $\epsilon \in [0, 1]$ (standardně $\epsilon = 0.2$):

V každém časovém kroku t generátor vyhodnotí logity agenta $\mathbf{z}_t^A$ i mutační síť $\mathbf{z}_t^M$ a převede je na pravděpodobnostní vektory:

$$\mathbf{p}_t^A = \text{softmax}(\mathbf{z}_t^A), \quad \mathbf{p}_t^M = \text{softmax}(\mathbf{z}_t^M)$$

Následně je s pravděpodobností ϵ vybrán krok mutační sítě:

$$P(a_t | s_t) = (1 - \epsilon)\pi_\theta(a_t | s_t) + \epsilon\pi_0(a_t | s_t)$$

Proč je hodnota $\epsilon = 0.2$ optimální?

- V 80% kroků model generuje podle učícího se agenta π_θ , což žene populaci k vyššímu 3D tvarovému skóre a bioaktivitě.
- Ve 20% kroků model provede 'chemickou mutaci' řízenou obecným modelem π_0 . Tím dochází k zavádění nových substituentů, neobvyklých heterocyklů a bioisosterů, které brání uváznutí v lokálním optimu.

python

```
import torch

# Ukázka interního fungování metody evolve() v SequenceRNN
def evolve_step(agent, mutate, x, hA, hM, epsilon=0.2):
    """
    Jeden krok stochastického míchání politik Agent vs Mutate.
    """
    # 1. Dopředný průchod agentem
    logitA, hA = agent(x, hA)
    proba = logitA.softmax(dim=-1)

    # 2. Dopředný průchod mutační sítí (bez výpočtu gradientů)
    if mutate is not None:
        with torch.no_grad():
            logitM, hM = mutate(x, hM)
            probaM = logitM.softmax(dim=-1)

    # 3. Epsilon-greedy maskování: náhodný výběr vzorků k mutaci
    batch_size = x.size(0)
    is_mutate = (torch.rand(batch_size, device=x.device) < epsilon)
    proba[is_mutate, :] = probaM[is_mutate, :]

    # 4. Vzorkování dalšího tokenu ze smíchané distribuce
    next_token = torch.multinomial(proba, num_samples=1).view(-1)
    return next_token, hA, hM
```

6. Podpora Crover Network pro genetické křížení sekvencí v DrugEx

Slide 6/8

Kromě mutační sítě umožňuje DrugEx zapojit také třetí neuronovou síť zvanou **Crover Network (Křížicí generátor π_C)**.

Crover síť reprezentuje hybridní evoluční přístup inspirovaný genetickými algoritmy:

- Během tréninku je udržována elitní paměť molekul s nejvyšší Paretovskou odměnou z předchozích epoch.
- Crover síť je průběžně doučována na této elitní populaci.
- Při vzorkování se pravděpodobnostní rozdělení agenta a křížicí sítě kombinuje s náhodným poměrem $r \sim \mathcal{U}(0, 1)$:

$$\mathbf{p}_t = r \cdot \mathbf{p}_t^A + (1 - r) \cdot \mathbf{p}_t^C$$

Tento mechanismus simuluje genetické křížení (crossover) v prostoru latentních stavů neuronové sítě a umožňuje skokovou rekombinaci úspěšných farmakoforových fragmentů.

DOPORUČENÁ KONFIGURACE PRO BAKALÁŘSKOU PRÁCI

Pro stabilní trénink na cílech s 3D ROCS shape matchingem doporučujeme základní dvouramennou konfiguraci: Agent + Mutate (Prior) s epsilon = 0.2. Crover síť je volitelná a hodí se pro rozsáhlé vícedenní výpočetní experimenty.

Trénování posilovaného učení s neuronovými generátory je náchylné k numerickým nestabilitám. V DrugEx jsou implementována následující ochranná opatření:

1. **Ořezání normy gradientů (Gradient Clipping)**: Maximální norma gradientů je omezena na $\|\mathbf{g}\|_2 \leq 1.0$. Tím se eliminuje riziko explodujících gradientů při výskytu vzácné sekvence s extrémní chybou.
2. **Velikost vzorkovacího batche** ($N_{\text{samples}} = 1000$): V každé epoše model vygeneruje 1000 molekul. Dostatečně velká populace je nezbytná pro spolehlivý výpočet Paretovy fronty a Crowding Distance (malá populace < 100 vede k degenerovaným frontám).
3. **Nízký learning rate** ($lr = 10^{-4}$): Optimalizátor Adam s konzervativním krokem zaručuje plynulý posun vah bez destrukce chemické gramatiky.
4. **Patience a Early Stopping**: Pokud se podíl žádoucích molekul (Desired Ratio) nezlepší po dobu 50 epoch, trénink je automaticky ukončen.

8. Praktická implementace: SequenceExplorer & Trénovací smyčka

Následující ucelený Python skript demonstruje kompletní inicializaci a spuštění RL tréninku v DrugEx pomocí třídy

`SequenceExplorer`:

python

```
import torch
from drugex.data.corpus.vocabulary import VocSmiles
from drugex.training.generators import SequenceRNN
from drugex.training.explorers import SequenceExplorer
from drugex.training.monitors import FileMonitor

# 1. Načtení slovníku
voc = VocSmiles.fromFile("data/Papyrus05.5_smiles_voc.txt", encode_frags=False)

# 2. Inicializace Agenta (učící se model)
agent = SequenceRNN(voc, is_lstm=True, lr=1e-4)
agent.loadStatesFromFile("models/ccr2_finetuned_rnn.pkg")

# 3. Inicializace Prior / Mutate sítě (fixní model)
mutate = SequenceRNN(voc, is_lstm=True)
mutate.loadStatesFromFile("models/ccr2_finetuned_rnn.pkg")
mutate.eval() # Zmrazení parametrů!

# 4. Sestavení SequenceExploreru
explorer = SequenceExplorer(
    agent=agent,
    mutate=mutate,
    crover=None,
    env=env,          # DrugExEnvironment (definováno v Lekci 2.3)
    epsilon=0.2,      # 20% explorace z mutační sítě
    beta=0.0,         # Baseline pro policy gradient
    n_samples=1000,   # 1000 generovaných molekul na epochu
    batch_size=128
)

# 5. Spuštění MORL tréninku na 100 epoch
monitor = FileMonitor("logs/morl_ccr2_training")
print("Zahájení MORL optimalizace...")
explorer.fit(
    epochs=100,
    patience=30,
    monitor=monitor
)
print("✓ MORL trénink úspěšně dokončen!")
```

2.2 Paretova optimalita & Pareto Crowding Distance

Nedominované třídění řešení v multidimenzionálním prostoru cílů, matematická derivace algoritmu NSGA-II Crowding Distance pro zachování diverzity a přiřazení normalizovaných odměn.

1. Koncept vícekriteriální optimalizace v objevování léčiv

Slide 1/8

Vývoj léčiva představuje ze své podstaty **vysoce dimenzionální kompromisní optimalizaci**. Ideální lékový kandidát musí současně splňovat celou řadu protichůdných požadavků:

- Vysoká 3D tvarová a elektrostatická komplementarita k vazebnému místu cíle ($T_{\text{combo}} > 1.2$).

- Vysoká syntetická dostupnost pro organickou přípravu v laboratoři (SAScore < 3.5).
- Příznivé fyzikálně-chemické vlastnosti podle Lipinského pravidel (MW ∈ [300, 500], LogP ∈ [1.5, 4.0], TPSA ∈ [40, 120]).
- Nízká toxicita a selektivita vůči vedlejším cílům (např. iontovému kanálu hERG).

Selhání jednoduchého váženého součtu (Weighted Sum Approach)

Klasický přístup sčítající cíle do jedné skalární funkce $R = \sum w_i f_i$ v praxi selhává:

1. Není schopen nalézt optimální řešení v nekonvexních (propadlých) oblastech prostoru vlastností.
2. Vyžaduje subjektivní manuální ladění vah w_i , kde malá změna váhy může vést k úplnému potlačení jednoho z kritérií.

DrugEx proto implementuje rigorózní **Paretovskou optimalizaci bez nutnosti zadávání pevných vah**.

2. Matematická definice Paretovy dominance v multidimenzionálním prostoru Slide 2/8

Uvažujme M objektivních skórovacích funkcí $\mathbf{f}(X) = (f_1(X), f_2(X), \dots, f_M(X))^T$, kde každou funkci $f_m : \mathcal{X} \rightarrow [0, 1]$ chceme maximalizovat.

Pro libovolné dvě molekuly $A, B \in \mathcal{X}$ definujeme vztah **Paretovy dominance** následovně:

$$A \succ B \quad (A \text{ dominuje } B) \iff \forall m \in \{1, \dots, M\} : f_m(A) \geq f_m(B) \quad \wedge \quad \exists m \in \{1, \dots, M\} : f_m(A) > f_m(B)$$

To znamená: Molekula A je ve všech sledovaných vlastnostech alespoň tak dobrá jako molekula B a v alespoň jedné vlastnosti je striktně lepší.

Pokud $A \not\succ B$ a současně $B \not\succ A$, říkáme, že řešení jsou **vzájemně nedominovaná** ($A \sim B$). Žádné z nich nelze označit za jednoznačně lepší bez dodatečné subjektivní preference.

Množina všech nedominovaných řešení v celé populaci tvoří **Paretovu frontu (Pareto Frontier)**:

$$\mathcal{P}^* = \{X \in \mathcal{X} \mid \nexists X' \in \mathcal{X} : X' \succ X\}$$

3. Algoritmus nedominovaného třídění (Non-Dominated Sorting Layers) Slide 3/8

V každé trénovací epoše vygeneruje DrugEx populaci $N = 1000$ kandidátních molekul a vypočte matici skóre $\mathbf{S} \in \mathbb{R}^{N \times M}$.

Pomocí algoritmu **Fast Non-Dominated Sorting (NSGA-II)** je celá populace rozřazena do hierarchických vrstev (front) $\mathcal{F}_1, \mathcal{F}_2, \dots, \mathcal{F}_K$:

1. **Vrstva 1 (Rank 1 Front $\mathcal{F}_1$)**: Množina všech molekul v populaci, které nejsou dominovány žádnou jinou molekulou. Tvoří aktuální nejlepší Paretovu frontu.

2. **Vrstva 2 (Rank 2 Front $\mathcal{F}_2$):** Dočasně odstraníme všechny molekuly z $\mathcal{F}_1$. Znovu identifikujeme všechna nedominovaná řešení ze zbývajících populace. Tato řešení tvoří druhou frontu $\mathcal{F}_2$.
3. **Iterativní rozklad:** Proces se opakuje pro vrstvy $\mathcal{F}_3, \mathcal{F}_4, \dots$, dokud není každé molekule i v populaci přiřazena diskrétní hodnota $r_i = k$, kde $i \in \mathcal{F}_k$.

Molekuly ve vrstvě $\mathcal{F}_1$ mají nejvyšší možnou kvalitu, zatímco molekuly ve vyšších vrstvách jsou postupně horší.

VÝPOČETNÍ SLOŽITOST TŘÍDĚNÍ

Standardní nedominované třídění má časovou složitost $O(M \cdot N^2)$. Pro populaci $N = 1000$ molekul a $M = 4$ kritéria trvá výpočet v NumPy pouhých několik milisekund na CPU!

4. Problém shlukování (Crowding) a potřeba diverzity v cílovém prostoru

Slide 4/8

Samotné rozřazení do Paretovských vrstev má zásadní slabinu:

Všechny molekuly uvnitř stejné vrstvy (např. 150 molekul v Rank 1 $\mathcal{F}_1$) mají stejnou dominantní hodnotu. Pokud bychom všem těmto molekulám přiřadili stejnou odměnu:

- Generativní model by rychle zkolaboval do jediného úzkého shluku na Pareto frontě (např. tam, kde je nejjednodušší dosáhnout vysokého skóre na úkor ostatních).
- Chemická rozmanitost generovaných kandidátů by prudce klesla.

Aby model prozkoumával **celou šíři Paretoovy fronty** a nabízel různorodé chemické kompromisy, zavádí DrugEx metriku **Pareto Crowding Distance (Hustotní vzdálenost)** podle slavného algoritmu NSGA-II (Deb et al., 2002).

Molekuly, které leží v řídce osídlených (izolovaných) oblastech Paretoovy fronty, získávají vyšší odměnu než molekuly namačkané v hustém shluku.

5. Matematická derivace Pareto Crowding Distance (NSGA-II)

Slide 5/8

Výpočet Crowding Distance probíhá **samostatně pro každou Paretovskou vrstvu $\mathcal{F}_k$** :

Nechť $n_k = |\mathcal{F}_k|$ je počet molekul ve vrstvě $\mathcal{F}_k$.

1. Pro každou molekulu $i \in \mathcal{F}_k$ inicializujeme vzdálenost: $d_i = 0$.
2. Pro každé optimalizační kritérium $m \in \{1, 2, \dots, M\}$:
 - Seřadíme molekuly ve vrstvě $\mathcal{F}_k$ vzestupně podle hodnoty kritéria f_m :

$$I^{(m)} = \text{argsort}(\{f_m(i) \mid i \in \mathcal{F}_k\})$$

- **Hraničním řešením (Boundary Solutions)** s minimální a maximální hodnotou kritéria přiřadíme nekonečnou vzdálenost, aby byla vždy zachována:

$$d(I_1^{(m)}) = \infty, \quad d(I_{n_k}^{(m)}) = \infty$$

- Pro všechna vnitřní řešení $j \in \{2, 3, \dots, n_k - 1\}$ přičteme normalizovanou vzdálenost mezi sousedy:

$$d(I_j^{(m)}) += \frac{f_m(I_{j+1}^{(m)}) - f_m(I_{j-1}^{(m)})}{f_m^{\max} - f_m^{\min}}$$

kde $f_m^{\max}$ a $f_m^{\min}$ jsou maximální a minimální hodnota daného kritéria v celé vrstvě $\mathcal{F}_k$.

- Celková Crowding Distance pro molekulu i je součet přes všech M dimenzí: $d_i = \sum_{m=1}^M d_i^{(m)}$.

GEOMETRICKÝ VÝZNAM

Crowding distance d_i představuje obvod největšího hyper-kvádrů v prostoru cílů, který obklopuje molekulu i a neobsahuje žádné jiné řešení z dané Paretoovy vrstvy.

6. Převod Paretových hodnotí a Crowding Distance na skalární odměnu $R(X)$ Slide 6/8

Abychom mohli aplikovat Policy Gradient (REINFORCE), musíme Paretoovské vrstvy a Crowding Distance převést na jediné spojitě skalární číslo odměny $R(X) \in [0, 1]$ pro každou molekulu:

V třídě `ParetoCrowdingDistance` (v souboru `drugex/training/rewards.py`) probíhá finální seřazení populace následujícím deterministickým postupem:

- Uspořádání vrstev:** Molekuly jsou primárně seřazeny podle indexu své Paretoovské vrstvy (vrstva $\mathcal{F}_1$ má přednost před $\mathcal{F}_2$, ta před $\mathcal{F}_3$, atd.).
- Vnitřní uspořádání vrstvy podle diverzity:** Uvnitř každé vrstvy $\mathcal{F}_k$ jsou molekuly seřazeny **sestupně podle Crowding Distance** d_i (molekuly s $d_i = \infty$ a nejvyšší diverzitou jsou na prvních místech).
- Reverse pořadí:** Zřetěžený seznam indexů je invertován (`rank = rank[::-1]`), takže na indexu 0 leží nejhorší molekula v populaci a na indexu $N - 1$ leží nejlepší diverzifikovaná molekula z Rank 1.
- Normalizace odměny:**

$$R(X_i) = \frac{\text{pořadí}(X_i)}{N} \in [0, 1)$$

Tímto způsobem získává každá molekula unikátní, spojitou a rovnoměrně rozdělenou odměnu, která perfektně řídí gradientní optimalizaci!

python

```
import numpy as np

# Ukázka výpočtu finální odměny v ParetoCrowdingDistance
def compute_pareto_rewards(fronts, scores):
    """
    fronts: list of arrays (indexy molekul v jednotlivých vrstvách F1, F2...)
    scores: ndarray [N, M] (matice skóre molekul)
    """
    ranked_fronts = []
    for front in fronts:
        front_scores = scores[front]
        front_size = len(front)
        crowding_distance = np.zeros(front_size)

        # Výpočet Crowding Distance pro každé kritérium
        for m in range(front_scores.shape[1]):
            sorted_idx = np.argsort(front_scores[:, m])
            crowding_distance[sorted_idx[0]] = np.inf
            crowding_distance[sorted_idx[-1]] = np.inf

            score_range = front_scores[:, m].max() - front_scores[:, m].min()
            if score_range > 0:
                for j in range(1, front_size - 1):
                    crowding_distance[sorted_idx[j]] += (
                        front_scores[sorted_idx[j+1], m] - front_scores[sorted_idx[j-1], m]
                    ) / score_range

        # Seřazení uvnitř vrstvy sestupně podle crowding distance
        sorted_by_cd = np.argsort(-crowding_distance)
        ranked_fronts.append(front[sorted_by_cd])

    # Zřetězení a otočení: od nejhoršího (0) k nejlepšímu (N-1)
    full_rank = np.concatenate(ranked_fronts)[::-1]

    # Přiřazení normalizované odměny [0, 1)
    N = len(scores)
    rewards = np.zeros((N, 1))
    rewards[full_rank, 0] = np.arange(N) / N
    return rewards
```

7. Alternativní Paretovská schémata: ParetoTanimotoDistance & Hypervolume Slide 7/8

Vedle standardního `ParetoCrowdingDistance` podporuje DrugEx i další pokročilá schémata odměňování:

1. ParetoTanimotoDistance

Zatímco Crowding Distance měří vzdálenost v abstraktním prostoru vlastností (f_1, f_2), `ParetoTanimotoDistance` měří diverzitu přímo v **strukturním chemickém prostoru**:

$$d_{\text{chem}}(i) = 1 - \max_{j \in \mathcal{F}_k, j \neq i} T_{\text{Tanimoto}}(\mathbf{fp}(i), \mathbf{fp}(j))$$

Odměňuje molekuly, které mají odlišné chemické jádro (scaffold hopping) od ostatních molekul ve stejné Paretově vrstvě.

2. Hypervolume Indicator (HV)

Měří celkový M -dimenzionální objem prostoru vlastností ohraničený Paretovou frontou $\mathcal{P}^*$ a předem zvoleným referenčním bodem $\mathbf{r}_{\text{ref}} = (0, 0, \dots, 0)^T$:

$$\text{HV}(\mathcal{P}^*, \mathbf{r}_{\text{ref}}) = \Lambda \left(\bigcup_{X \in \mathcal{P}^*} [\mathbf{r}_{\text{ref}}, \mathbf{f}(X)] \right)$$

Hypervolume je jedinou monomateriální metrikou, která striktně zachovává Paretovu dominanci (vyšší HV vždy značí lepší Paretovu frontu).

ParetoCrowdingDistance (Doporučeno)

- Extrémně rychlý výpočet ($O(M \cdot N \log N)$).
- Výborné rovnoměrné pokrytí celého spektra vlastností.
- Nativní standard v evolučním počítání (NSGA-II).

ParetoTanimotoDistance

- Přímě nutí model objevovat nové chemické třídy (scaffolds).
- Vyžaduje výpočet matice Morganových otisků ($O(N^2)$).
- Skvělé pro projekty zaměřené na Scaffold Hopping u IDP.

8. Praktická implementace: Výpočet Paretových front a odměn v Pythonu

Slide 8/8

Následující plně funkční skript demonstruje výpočet Paretoovy fronty a Crowding Distance pro syntetickou populaci 5 molekul se 2 protichůdnými cíli (3D Shape vs SAScore):

python

```
import numpy as np
from drugex.training.rewards import ParetoCrowdingDistance
from drugex.utils import get_Pareto_fronts

# Simulace matice skóre pro 5 molekul a 2 cíle: [3D Shape TanimotoCombo, SAScore Desirability]
# Cíl 1: Tvarová shoda (vyšší = lepší)
# Cíl 2: Syntetická dostupnost (vyšší = lepší)
scores = np.array([
    [0.90, 0.30], # Mol A: Vynikající tvar, horší syntéza
    [0.50, 0.95], # Mol B: Horší tvar, triviální syntéza
    [0.85, 0.80], # Mol C: Vyvážený špičkový kompromis
    [0.40, 0.40], # Mol D: Dominována molekulou C
    [0.82, 0.78] # Mol E: Téměř na frontě, dominována C
])

# 1. Výpočet Paretových vrstev
fronts = get_Pareto_fronts(scores)
print("Rozdělení do Paretovských vrstev:")
for k, front in enumerate(fronts, 1):
    print(f" Front {k} (Rank {k}): indexy molekul {front}")

# 2. Výpočet finálních odměn přes ParetoCrowdingDistance
reward_scheme = ParetoCrowdingDistance()
rewards = reward_scheme(smiles=["A", "B", "C", "D", "E"], scores=scores, thresholds=[0.5, 0.5])

print("\nPřiřazené normalizované odměny R(X):")
for i, name in enumerate(["Mol A", "Mol B", "Mol C", "Mol D", "Mol E"]):
    print(f" {name} | Skóre: {scores[i]} | Odměna: {rewards[i, 0]:.3f}")
```

2.3 Skórovací funkce & Desirability Modifiers (SmoothClippedScore)

Architektura DrugExEnvironment, transformace fyzikálních parametrů na normalizované odměny [0, 1], syntetická dostupnost (SAScore, RAScore), QSAR prediktory a matematická odvození Desirability Modifiers.

1. Architektura DrugExEnvironment a role skórovačů

Slide 1/8

Třída `DrugExEnvironment` (v souboru `drugex/training/environment.py`) představuje centrální hodnotící rozhraní (Environment) celého systému posilovaného učení.

Pipeline vyhodnocení generované batche molekul probíhá v následujících krocích:

- 1. Syntaktická kontrola (`SmilesChecker`)**: Vyhodnocení chemické validity generovaných SMILES řetězců pomocí RDKit. Nevalidním molekulám a prázdným řetězcům je přiřazen příznak `Valid = 0`.
- 2. Výpočet surových skóre (Raw Objective Scoring)**: Paralelní vyhodnocení všech M registrovaných skórovačů (3D ROCS shape matching, SAScore, QSAR modely, MW, LogP).
- 3. Aplikace modifikátorů žádoucnosti (Desirability Modifiers)**: Každé surové fyzikální číslo (např. MW = 450 Da nebo SAScore = 2.8) je transformováno spojitou funkcí na normalizovanou odměnu $S_m \in [0, 1]$.

4. **4. Nulování nevalidních struktur:** Všem molekulám s `Valid == 0` jsou všechny hodnoty S_m striktně přepsány na 0.0.
5. **5. Klasifikace žádoucnosti** (`Desired`): Molekula je označena jako žádoucí (`Desired = 1`) právě tehdy, když splňuje minimální prahové hodnoty všech dílčích cílů současně:

$$\text{Desired}(X) = \prod_{m=1}^M \mathbb{I}(S_m(X) \geq \tau_m)$$

METRIKA DESIRED RATIO

Podíl žádoucích molekul (Desired Ratio = počet Desired / N_samples) je v DrugEx hlavní metrikou pro Early Stopping a sledování konvergence modelu.

2. Přehled fyzikálně-chemických deskriptorů v DrugEx

Slide 2/8

Třída `Property` (v `drugex/training/scorers/properties.py`) poskytuje přímé napojení na chemoinformatické deskriptory knihovny RDKit:

Klíč	Fyzikální veličina	RDKit Implementace	Optimální lékový interval
<code>MW</code>	Molekulová hmotnost [Da]	<code>Descriptors.MolWt</code>	300 – 500 Da
<code>logP</code>	Oktanol-voda rozdělovací koeficient	<code>Crippen.MolLogP</code>	1.5 – 4.0
<code>HBA</code>	Akceptory vodíkových vazeb (O, N)	<code>AllChem.CalcNumLipinskiHBA</code>	≤ 10
<code>HBD</code>	Donory vodíkových vazeb (OH, NH)	<code>AllChem.CalcNumLipinskiHBD</code>	≤ 5
<code>TPSA</code>	Topologický polární povrch [$\text{\AA}^2$]	<code>AllChem.CalcTPSA</code>	40 – 130 $\text{\AA}^2$
<code>Rotable</code>	Počet volně otočných vazeb	<code>AllChem.CalcNumRotatableBonds</code>	≤ 8
<code>QED</code>	Drug-likeness skóre (Bickerton)	<code>Chem.QED.qed</code>	> 0.6 (max 1.0)
<code>SA</code>	Syntetická obtížnost (Ertl)	<code>sascorer.calculateScore</code>	< 3.5 (1 = snadné)

3. SAScore: Výpočet syntetické dostupnosti molekul

Slide 3/8

Jedním z nejčastějších selhání de novo generátorů je návrh molekul, které sice mají fantastické virtuální skóre, ale jejichž syntéza by vyžadovala 40 kroků a byla by v praxi nemožná.

Metoda **SAScore (Synthetic Accessibility Score)** vyvinutá Peterem Ertlem a Ansgarem Schuffenhauerem (2009) modeluje syntetickou obtížnost molekuly kombinací dvou složek:

$$\text{SAScore} = \text{FragmentScore} - \text{ComplexityPenalty}$$

1. **Fragmentové skóre (Fragment Contribution):** Molekula je rozložena na cirkulární ECFP4 fragmenty (poloměr 2). Pro každý fragment je v databázi PubChem (obsahující ~13 milionů látek) zjištěna jeho statistická četnost. Často se vyskytující fragmenty (např. benzenový kruh, amidová vazba) získávají vysoké skóre snadnosti, zatímco vzácné fragmenty skóre snižují.
2. **Penalizace topologické komplexity (Complexity Penalty):** Nelineární penalizace zohledňující strukturní rysy, které komplikují syntézu:
 - o Počet stereocenter a asymetrických chirálních uhlíků.
 - o Přítomnost spiro atomů (dva cykly spojené jediným atomem).
 - o Můstkové atomy v bicyklických a polycyklických systémech (Bridgehead atoms).
 - o Makrocyclické kruhy s více než 8 atomy.
 - o Počet neobvyklých atomových kroužků a kondenzovaných systémů.

Výsledný SAScore leží na škále **1 (triviálně syntetizovatelné)** až **10 (extrémně náročná syntéza)**.

TRANSFORMACE SASCORE V DRUGEX

Protože v MORL maximalizujeme odměnu, ale u SAScore chceme nízkou hodnotu (snadnou syntézu), aplikujeme klesající modifikátor `SmoothClippedScore(lower_x=4.5, upper_x=2.5)`!

4. RAScore: Retrosyntetická proveditelnost pomocí strojového učení

Slide 4/8

Zatímco SAScore hodnotí pouze lokální strukturní složitost, moderní alternativa **RAScore (Retrosynthetic Accessibility Score)** vyvinutá Schwallerem a Genhedenem (2021) hodnotí přímou **retrosyntetickou proveditelnost**:

Princip RAScore:

- Model byl natrénován na více než **200 000 kompletních retrosyntetických rozkladech** provedených stromovým prohledávacím algoritmem MCTS v nástroji *AiZynthFinder*.
- Jako výchozí suroviny byly definovány komerčně dostupné chemikálie z katalogu ZINC / Enamine Building Blocks.
- Výstupem je pravděpodobnost $\text{RAScore} \in [0, 1]$, že molekulu lze úspěšně dekomponovat na komerčně dostupné bloky v **maximálně 10 syntetických krocích**.

Molekula s $\text{RAScore} > 0.8$ má vysokou pravděpodobnost, že ji organický chemik dokáže reálně nasyntetizovat z dostupných surovin během několika dní.

python

```
from drugex.training.scorers.properties import Property
from drugex.training.scorers.modifiers import SmoothClippedScore

# Nastavení skórovače syntetické dostupnosti pro DrugExEnvironment
sa_scorer = Property(
    prop='SA',
    modifier=SmoothClippedScore(
        lower_x=4.5, # Při SAScore >= 4.5 je odměna minimální (~0.0)
        upper_x=2.5, # Při SAScore <= 2.5 je odměna maximální (~1.0)
        high_score=1.0,
        low_score=0.0
    )
)
```

5. QSPRPred integrace: Prediktivní QSAR modely bioaktivity a selektivity

Slide 5/8

DrugEx integruje knihovnu **QSPRPred** (Quantitative Structure-Property Relationship Prediction) pro rychlé zapojení modelů strojového učení predikujících biologickou aktivitu (pIC_{50} , pK_i nebo $-\log_{10} EC_{50}$):

Podporované modelové architektury v QSPRPred:

- **Random Forest (RF)** a **Gradient Boosted Trees (LightGBM, XGBoost)** na Morganových ECFP6 otiscích.
- **Support Vector Machines (SVM / SVR)** s RBF jádrem.
- **Chemprop (Message Passing Neural Networks - MPNN)** pro přímé hluboké učení na molekulárních grafech.

Aplikabilní doména (Applicability Domain) & Konformní predikce

Strojově učené modely mohou generovat nespolehlivé předpovědi, pokud generovaná molekula leží mimo trénovací chemický prostor. QSPRPred integruje *Conformal Prediction*, která ke každému odhadu afinity přiřazuje interval spolehlivosti. Pokud je nejistota predikce příliš vysoká, skóre je penalizováno.

KOMBINACE S 3D SHAPE MATCHINGEM V BAKALÁŘSKÉ PRÁCI

V této bakalářské práci je hlavní důraz kladen na 3D ROCS shape matching jako bezstrukturní geometrický cíl, který lze v DrugExEnvironment elegantně kombinovat s QSAR prediktorem selektivity proti vedlejším cílům!

6. Matematická odvození Desirability Modifiers v DrugEx

Slide 6/8

Surové hodnoty z fyzikálních výpočtů a skórovačů mají různé jednotky a rozsahy (např. $T_{\text{combo}} \in [0, 2]$, $MW \in [100, 900]$, $SAScore \in [1, 10]$).

Modul `drugex/training/scorers/modifiers.py` implementuje rigorózní matematické transformace na interval odměn $[0, 1]$:

1. SmoothClippedScore (Hladká logistická transformace)

Klasické ořznutí (ClippedScore) má nespojitou derivaci a nulový gradient mimo hranice, což způsobuje 'zamrznutí' posilovaného učení. **SmoothClippedScore** řeší tento problém pomocí logistické sigmoidální funkce se spojitou první derivací:

$$S(x) = S_{\text{low}} + \frac{L}{1 + \exp(-k \cdot (x - x_{\text{mid}}))}$$

kde:

$$k = \frac{4}{x_{\text{upper}} - x_{\text{lower}}}, \quad x_{\text{mid}} = \frac{x_{\text{upper}} + x_{\text{lower}}}{2}, \quad L = S_{\text{high}} - S_{\text{low}}$$

Faktor $k = 4/\Delta x$ zaručuje, že strmost logistické křivky v inflexním bodě x_{mid} přesně odpovídá směrnici lineárního ořezání.

2. MinMaxGaussian & Gaussian (Gaussovský zvon)

Používá se pro veličiny, které mají optimální hodnotu uvnitř intervalu (např. MW = 420 ± 60 Da):

$$S(x) = \exp\left(-\frac{1}{2} \left(\frac{x - \mu}{\sigma}\right)^2\right)$$

Pro jednostrannou minimalizaci (**MinGaussian**) platí: $S(x) = 1.0$ pro $x \leq \mu$ a klesá jako poloviční Gauss pro $x > \mu$.

python

```
import numpy as np

# Matematická implementace SmoothClippedScore
class SmoothClippedScore:
    def __init__(self, upper_x: float, lower_x: float = 0.0, high_score: float = 1.0, low_score: float = 0.0):
        self.upper_x = upper_x
        self.lower_x = lower_x
        self.high_score = high_score
        self.low_score = low_score

        self.k = 4.0 / (upper_x - lower_x)
        self.middle_x = (upper_x + lower_x) / 2.0
        self.L = high_score - low_score

    def __call__(self, x):
        return self.low_score + self.L / (1.0 + np.exp(-self.k * (x - self.middle_x)))
```

7. Kalibrace profilu odměn pro flexibilní cíle & IDP ligandy

Slide 7/8

Správná volba prahů a modifikátorů definuje tzv. **profil ideálního kandidáta (Target Candidate Profile)**.

Doporučené nastavení parametrů v `DrugExEnvironment` pro bakalářskou práci na téma kombinace de novo designu a 3D shape matchingu:

- **3D ROCS Shape Matching (RDKitROCSScorer TanimotoCombo):** `SmoothClippedScore(lower_x=0.6, upper_x=1.2, low_score=0.0, high_score=1.0)`. Prahová hodnota: $\tau = 0.5$ (odpovídá $T_{\text{combo}} \approx 0.9$).
- **Syntetická dostupnost (SAScore):** `SmoothClippedScore(lower_x=4.5, upper_x=2.5, low_score=0.0, high_score=1.0)`. Prahová hodnota: $\tau = 0.5$ (odpovídá $\text{SAScore} \leq 3.5$).
- **Molekulová hmotnost (MW):** `Gaussian(mu=420.0, sigma=60.0)`. Prahová hodnota: $\tau = 0.5$ (rozsah MW 360–480 Da).
- **Lipofilita (LogP):** `MinGaussian(mu=2.8, sigma=1.2)`. Prahová hodnota: $\tau = 0.5$ (penalizuje $\text{LogP} > 4.0$).

KONZISTENCE PRAHOVÝCH HODNOT

Díky normalizaci přes modifikátory jsou všechny dílčí odměny škálovány do [0, 1]. Ve třídě `DrugExEnvironment` proto stačí nastavit jednotný práh `thresholds = [0.5, 0.5, 0.5, 0.5]`!

8. Kompletní kód: Sestavení `DrugExEnvironment` v Pythonu

Slide 8/8

Následující plně funkční skript demonstruje kompletní sestavení prostředí `DrugExEnvironment` s více cíli, modifikátory a schématem `ParetoCrowdingDistance`:

python

```
from drugex.training.environment import DrugExEnvironment
from drugex.training.rewards import ParetoCrowdingDistance
from drugex.training.scorers.properties import Property
from drugex.training.scorers.modifiers import SmoothClippedScore, Gaussian, MinMaxGaussian

# 1. Definice skórovačů s modifikátory
scorers = [
    # Cíl 1: SAScore (Syntetická dostupnost - minimalizace)
    Property(
        prop='SA',
        modifier=SmoothClippedScore(lower_x=4.5, upper_x=2.5)
    ),
    # Cíl 2: Molekulová hmotnost (MW - cílový Gaussovský zvon)
    Property(
        prop='MW',
        modifier=Gaussian(mu=420.0, sigma=60.0)
    ),
    # Cíl 3: Lipofilita (LogP - penalizace mastných kyselin)
    Property(
        prop='logP',
        modifier=MinMaxGaussian(mu=3.0, sigma=1.2, minimize=True)
    ),
    # Cíl 4: Drug-likeness (QED - maximalizace)
    Property(
        prop='QED',
        modifier=SmoothClippedScore(lower_x=0.4, upper_x=0.8)
    )
]

# 2. Prahové hodnoty pro klasifikaci 'Desired' (vše normalizováno na 0.5)
thresholds = [0.5, 0.5, 0.5, 0.5]

# 3. Paretovské schéma odměňování s Crowding Distance
reward_scheme = ParetoCrowdingDistance()

# 4. Inicializace finálního DrugExEnvironment
env = DrugExEnvironment(
    scorers=scorers,
    thresholds=thresholds,
    reward_scheme=reward_scheme
)

print(f"✓ DrugExEnvironment úspěšně inicializován s {len(scorers)} cíli.")
print(f"  Registrované skórovače: {[s.getKey() for s in scorers]}")
```

Modul 3: 3D Tvarové Porovnávání (ROCS), IDP & Konformační Enginy

3.1 Fyzikální podstata ROCS: Gaussovské objemy, Shape Tanimoto & Color TanimotoCombo

Grant-Pickupova Gaussovská reprezentace atomové hustoty, analytické uzavřené řešení objemových integrálů $V(A,B)$, farmakoforové barevné shody (ImplicitMillsDean) a kompozitní skóre TanimotoCombo.

1. Selhání 2D topologických deskriptorů při 'Scaffold Hoppingu'

Slide 1/6

Klasická chemoinformatika se po desetiletí opírala o 2D topologické otisky (např. Morgan / ECFP4 fingerprinty, Daylight cesty, MACCS klíče). Tyto metody kódují molekulu jako binární vektor přítomnosti podstruktur v topologickém okolí atomů do poloměru $r \leq 2$ vazeb.

Tento přístup má fundamentální teoretický limit: **dvě molekuly se zcela odlišnými chemickými jádry (scaffoldy) mají 2D Tanimoto podobnost blízkou nule ($T_{2D} < 0.20$)**, i když v trojrozměrném prostoru zaujímají **identický objem a stejné prostorové uspořádání klíčových funkčních skupin**.

Biologický cíl (receptor, enzym či proteinové rozhraní) nečte 2D graf ani SMILES řetězec. Vazebné rozhraní proteinu interaguje výhradně s:

- **Trojrozměrnou van der Waalsovou prostorovou obálkou** (sterické vyloučení a tvarové vyplnění kavity).
- **Prostorovým rozložením elektrostatického potenciálu** a směrovými vektory donorů a akceptorů vodíkových vazeb.
- **Hydrofobními a aromatickými π - π kontakty** orientovanými v přesných 3D úhlech a vzdálenostech.

Fenomén **Scaffold Hopping** (nalezení nových patentovatelných chemických tříd léčiv se zachováním požadované 3D vazebné afinity a selektivity) je proto na úrovni 2D otisků prakticky neřešitelný. Metoda **ROCS (Rapid Overlay of Chemical Structures)**, kterou v roce 1996 představili J. A. Grant, B. T. Pickup a A. Nicholls, překonává toto omezení přechodem od 2D grafů k přímému porovnávání 3D spojitých hustot.

2D Topologické Fingerprnty (ECFP4 / Morgan)

- Kódují pouze konektivitu 2D grafu a sousedství atomů do $r = 2$ vazeb.
- Citlivé na jakoukoliv změnu centrálního heterocyklu (nízké T_{2D} při záměně jádra).
- Nezohledňují konformační flexibilitu ani skutečný 3D prostorový tvar molekuly.
- Nerozeznávají bioisosterismus mezi topologicky nepodobnými strukturami.

3D Tvarové Zarovnání ROCS (Grant & Pickup)

- Modeluje molekulu jako spojitou 3D Gaussovskou elektronovou/objemovou hustotu.
- Umožňuje okamžitý *Scaffold Hopping* přes různé chemické rodiny.
- Integruje prostorový tvar (T_{shape}) s farmakoforovými vlastnostmi (T_{color}).
- Poskytuje hladkou a diferencovatelnou skórovací funkci pro Reinforcement Learning.

2. Grant-Pickupova Gaussovská reprezentace atomové a molekulární hustoty Slide 2/6

Historické přístupy k 3D tvarovému porovnávání modelovaly atomy jako pevné neprostupné koule (*hard spheres*) s van der Waalsovými poloměry R_i . Výpočet objemového překryvu dvou těles $V(A \cap B)$ však vyžadoval numerickou integraci na diskrétní 3D prostorové mřížce (voxel grid). Mřížkové metody trpěly obrovskou výpočetní náročností ($O(N^3)$ paměť i čas), chybami diskretizace a nespojitostí při rotaci.

Zásadní průlom Granta a Pickupa spočíval v nahrazení pevných koulí **spojitými trojrozměrnými Gaussovskými funkcemi hustoty**. Pro každý atom i s polohovým vektorem jádra $\mathbf{r}_i \in \mathbb{R}^3$ je atomová hustota v bodě $\mathbf{r}$ definována jako:

$$\rho_i(\mathbf{r}) = p_i \exp(-\alpha_i |\mathbf{r} - \mathbf{r}_i|^2)$$

kde:

- $\mathbf{r}_i = (x_i, y_i, z_i)^T$ jsou kartézské souřadnice jádra atomu i .
- p_i je centrální hustota atomu (standardně normalizovaná na $p_i = 1.0$ pro sférický tvar).
- α_i je koeficient rozptylu Gaussovské funkce, který přímo determinuje efektivní velikost atomu.

Parametr α_i je kalibrován tak, aby integrální objem Gaussovské funkce přes celý prostor $\mathbb{R}^3$ přesně odpovídal van der Waalsovu objemu atomu $V_i = \frac{4}{3}\pi R_i^3$:

$$V_i = \int_{\mathbb{R}^3} \rho_i(\mathbf{r}) d\mathbf{r} = p_i \left(\frac{\pi}{\alpha_i} \right)^{3/2} = \frac{4}{3}\pi R_i^3 \implies \alpha_i = \frac{\pi}{\left(\frac{4}{3}\pi \right)^{2/3} R_i^2} \approx \frac{1.1444\pi}{R_i^2}$$

V praktické implementaci ROCS (OpenEye, CDPKit, RDKit) se často volí zjednodušená normalizace $\alpha_i = \frac{\pi}{R_i^2}$, kde R_i je tabulkový van der Waalsův poloměr daného prvku (např. $R_C = 1.70 \text{ \AA}$, $R_N = 1.55 \text{ \AA}$, $R_O = 1.52 \text{ \AA}$, $R_S = 1.80 \text{ \AA}$, $R_F = 1.47 \text{ \AA}$).

Celková prostorová hustota molekuly A složené z N_A atomů je dána lineární superpozicí jednotlivých atomových Gaussovských hustot:

$$\rho_A(\mathbf{r}) = \sum_{i \in A} \rho_i(\mathbf{r}) = \sum_{i=1}^{N_A} p_i \exp(-\alpha_i |\mathbf{r} - \mathbf{r}_i|^2)$$

3. Uzavřené analytické řešení objemových překryvových integrálů $V(A, B)$

Slide 3/6

Míra prostorového tvarového překryvu mezi molekulou A a molekulou B je definována jako konvoluční integrál součinu jejich hustot přes celý prostor $\mathbb{R}^3$:

$$V(A, B) = \int_{\mathbb{R}^3} \rho_A(\mathbf{r}) \rho_B(\mathbf{r}) d\mathbf{r} = \int_{\mathbb{R}^3} \left(\sum_{i \in A} \rho_i(\mathbf{r}) \right) \left(\sum_{j \in B} \rho_j(\mathbf{r}) \right) d\mathbf{r} = \sum_{i \in A} \sum_{j \in B} \int_{\mathbb{R}^3} \rho_i(\mathbf{r}) \rho_j(\mathbf{r}) d\mathbf{r}$$

Zásadní matematickou vlastností součinu dvou trojrozměrných Gaussovských funkcí se středy v $\mathbf{r}_i$ a $\mathbf{r}_j$ je, že jejich integrál má **přesné analytické řešení v uzavřeném tvaru**:

$$I_{ij} = \int_{\mathbb{R}^3} \exp(-\alpha_i |\mathbf{r} - \mathbf{r}_i|^2) \exp(-\alpha_j |\mathbf{r} - \mathbf{r}_j|^2) d\mathbf{r} = \left(\frac{\pi}{\alpha_i + \alpha_j} \right)^{3/2} \exp\left(-\frac{\alpha_i \alpha_j}{\alpha_i + \alpha_j} |\mathbf{r}_i - \mathbf{r}_j|^2\right)$$

Celkový objemový překryv $V(A, B)$ je pak dán jednoduchou dvojitou sumou přes všechny dvojice atomů:

$$V(A, B) = \sum_{i \in A} \sum_{j \in B} p_i p_j \left(\frac{\pi}{\alpha_i + \alpha_j} \right)^{3/2} \exp\left(-\frac{\alpha_i \alpha_j}{\alpha_i + \alpha_j} |\mathbf{r}_i - \mathbf{r}_j|^2\right)$$

Stejným způsobem se spočítají i tzv. **vlastní objemy (self-volumes)** molekul A a B :

$$V(A, A) = \sum_{i \in A} \sum_{i' \in A} p_i p_{i'} \left(\frac{\pi}{\alpha_i + \alpha_{i'}} \right)^{3/2} \exp\left(-\frac{\alpha_i \alpha_{i'}}{\alpha_i + \alpha_{i'}} |\mathbf{r}_i - \mathbf{r}_{i'}|^2\right)$$

Proč je analytické řešení revoluční?

1. **Nulová diskretizační chyba:** Žádné artefakty způsobené volbou velikosti mřížky voxelů.
2. **Extrémní výpočetní rychlost:** Vyhodnocení jedné dvojice molekul trvá méně než $1 \mu s$ na moderním CPU.
3. **Diferencovatelnost:** Gradient $\nabla_{\mathbf{r}_j} V(A, B)$ má rovněž analytické vyjádření, což umožňuje bleskovou optimalizaci prostorové orientace pomocí kvazi-Newtonových metod (BFGS).

4. Metrika Shape Tanimoto a optimalizace prostorového zarovnání

Slide 4/6

Znalost integrálů $V(A, B)$, $V(A, A)$ a $V(B, B)$ umožňuje definovat normalizovanou míru prostorové podobnosti — **Shape Tanimoto koeficient** (T_{shape}):

$$T_{\text{shape}}(A, B) = \frac{V(A, B)}{V(A, A) + V(B, B) - V(A, B)}$$

Tato metrika splňuje všechny požadované matematické vlastnosti:

- **Ohraničenost:** $T_{\text{shape}}(A, B) \in [0, 1]$.
- **Identita:** $T_{\text{shape}}(A, A) = 1.0$ (pro identické molekuly v identické konformaci).
- **Symetrie:** $T_{\text{shape}}(A, B) = T_{\text{shape}}(B, A)$.
- **Míra disjunkce:** $T_{\text{shape}} = 0$ pro molekuly umístěné v nekonečné vzdálenosti ($|\mathbf{r}_i - \mathbf{r}_j| \rightarrow \infty$).

Optimalizace prostorového zarovnání v prostoru tuhých těles $SE(3)$

Hodnota T_{shape} závisí na vzájemné poloze a orientaci molekul. Cílem ROCS je nalézt rigidní transformaci $\mathbf{T} = (\mathbf{R}, \mathbf{t}) \in SE(3)$ (rotaci $\mathbf{R} \in SO(3)$ a translaci $\mathbf{t} \in \mathbb{R}^3$), která maximalizuje objemový překryv:

$$\mathbf{T}^* = \arg \max_{\mathbf{T}} V(A, \mathbf{T}(B))$$

Aby optimalizační algoritmus neuvízl v lokálních minimech, provádí se výpočet ve dvou krocích:

1. **Startovní generátor hlavních os setrvačnosti (Principal Axes of Inertia - PAI):** Pro obě molekuly se spočte tenzor momentu setrvačnosti $\mathbf{I}$. Vlastní vektory tenzoru definují 3 ortogonální hlavní osy. Sladěním hlavních os vzniknou 4 neekvivalentní výchozí orientace.
2. **Lokální gradientní optimalizace:** Z každé ze 4 startovních pozic se spustí kvazi-Newtonova optimalizace překryvu s analytickými gradienty. Nejlepší nalezené maximum definuje finální T_{shape} .

5. Farmakoforový Color Tanimoto & Silové pole ImplicitMillsDean

Slide 5/6

Samotný tvar (T_{shape}) pro molekulární návrh nestačí: hydrofobní naftalenový skelet má téměř identický 3D tvar jako polární chinazolin nebo isoquinolin ($T_{\text{shape}} > 0.85$), avšak jejich vazebné vlastnosti a elektrostatické profily jsou zcela protikladné.

Proto ROCS zavádí koncept tzv. **Color Features (farmakoforových center)**. Každé funkční skupině je přiřazena specifická chemická barva (typ interakce). V průmyslovém standardu silového pole **ImplicitMillsDean** rozlišujeme 6 základních typů vlastností:

1. **Donory vodíkových vazeb (Donors):** skupiny $-\text{OH}$, $-\text{NH}_2$, $-\text{NH}-$.
2. **Akceptory vodíkových vazeb (Acceptors):** karbonylové kyslíky $=\text{O}$, pyridinové dusíky $=\text{N}-$, ethery $-\text{O}-$.
3. **Kationická centra (Positive / Cations):** protonované aminy, guanidiniové skupiny, kvarterní dusíky.
4. **Anionická centra (Negative / Anions):** karboxylátové $-\text{COO}^-$, sulfonátové $-\text{SO}_3^-$, fosfátové skupiny.
5. **Hydrofobní centra (Hydrophobes):** alifatické a cyklické uhlíkové clustery (např. terc-butyl, isobutyl, cyklohexyl).
6. **Aromatické kruhy (Rings):** planární aromatické π -systémy (benzen, thiofen, indol).

Farmakoforová centra jsou modelována jako barevné Gaussovske funkce $\rho_{i,c}(\mathbf{r})$ umístěné v geometrických středech příslušných skupin. **K barevnému překryvu dochází VÝHRADNĚ mezi centry STEJNÉHO typu:**

$$C(A, B) = \sum_{c \in \text{Types}} \sum_{i \in A_c} \sum_{j \in B_c} w_c \left(\frac{\pi}{\alpha_{c,i} + \alpha_{c,j}} \right)^{3/2} \exp \left(- \frac{\alpha_{c,i} \alpha_{c,j}}{\alpha_{c,i} + \alpha_{c,j}} |\mathbf{r}_i - \mathbf{r}_j|^2 \right)$$

kde w_c je váha dané vlastnosti. Normalizovaný **Color Tanimoto koeficient** je pak definován jako:

$$T_{\text{color}}(A, B) = \frac{C(A, B)}{C(A, A) + C(B, B) - C(A, B)} \in [0, 1]$$

6. Kompozitní metrika TanimotoCombo & Interpretace ve výzkumu

Slide 6/6

Pro celkové hodnocení 3D tvarové a elektrostatické shody v generativním návrhu léčiv se používá kompozitní skóre **TanimotoCombo** (T_{combo}):

$$T_{\text{combo}}(A, B) = T_{\text{shape}}(A, B) + T_{\text{color}}(A, B) \in [0, 2]$$

V DrugEx MORL slouží T_{combo} jako primární spojitá skórovací funkce odměny. V literatuře a medicíně-chemické praxi se hodnoty interpretují následovně:

Klasifikace hodnot TanimotoCombo

- $T_{\text{combo}} < 0.80$: Nízká prostorová nebo barevná shoda. Molekula nepasuje do vazebné kavity nebo má špatně orientované polární skupiny.
- $0.80 \leq T_{\text{combo}} < 1.20$: Střední shoda. Dobrý tvarový překryv, ale chybí některé klíčové vodíkové vazby nebo nábojové interakce. Typické pro hrubé výchozí skelety.
- $1.20 \leq T_{\text{combo}} < 1.50$: **Vysoká bioisosterní shoda**. Molekula dokonale vyplňuje prostor a prezentuje klíčové farmakoforové body ve správné geometrii. Silný kandidát na *Scaffold Hop*.
- $T_{\text{combo}} \geq 1.50$: Téměř identický tvar i farmakofor (často analog původního ligandu s drobnou substitucí).

Proč TanimotoCombo v DrugEx MORL?

- **Hladká spojitá krajina odměn**: Na rozdíl od binárních deskriptorů poskytuje T_{combo} nenulový gradient i pro částečně překryté molekuly.
- **Robustnost vůči konformačnímu šumu**: Zohledňuje nejlepší konformer z vygenerovaného ansámblu.
- **Přímá korelace s IC_{50}** : U řady flexibilních cílů a receptorů (např. CCR2) dosahuje T_{combo} špičkové diskriminační schopnosti (ROC-AUC > 0.90).

python

```
from drugex.training.scorers.rocs_rdkit import RDKitROCSScorer
from drugex.training.scorers.conformer_generators import RDKitConformerGenerator

# Příklad výpočtu TanimotoCombo pro sadu molekul
conf_gen = RDKitConformerGenerator(max_conformers=30, max_isomers=2, num_threads=1)
rocs_scorer = RDKitROCSScorer(
    conformer_generator=conf_gen,
    references="CCR2_reference_ligands.sdf",
    score_type="TanimotoCombo", # Shape (0..1) + Color (0..1) = Combo (0..2)
    use_colors=True,
    show_progress=False
)

# getScores vrací numpy matici tvaru (num_molecules, num_reference_groups)
# scores = rocs_scorer.getScores(generated_mols)
```

3.2 Výzva flexibilních cílů & Intrinsically Disordered Proteins (IDP)

Proč rigidní krystalografické dokování selhává u IDP a dynamických kavit, Ligand-Based 3D paradigma, ansámblы vazebných konformací, konsenzuální supermolekuly a Multi-Reference Grouping.

1. Selhání rigidního strukturního dokování u flexibilních cílů a IDP

Slide 1/6

Tradiční strukturní de novo design léčiv (Structure-Based Drug Design - SBDD) vychází z předpokladu statického receptoru a teorie *zámku a klíče* (Lock-and-Key). Algoritmy molekulárního dokování (např. AutoDock Vina, Schrödinger Glide, Gold) vkládají ligand do tuhé krystalografické mřížky proteinu s vysokým rozlišením (< 2.0 Å).

V moderní medicíně a onkologii však klíčové terapeutické cíle tomuto paradigmatu zásadně vzdorují:

- **Intrinsically Disordered Proteins (IDP) a IDR domény:** Proteiny (např. onkoproteiny c-Myc, p53 transkripční doména, α -synuklein, tau protein), které postrádají stabilní sekundární a terciární strukturu. V roztoku existují jako dynamický konformační ansámbl na ploché energetické krajině s mělkými minimy ($\Delta G^\ddagger \approx k_B T$).
- **Flexibilní membránové receptory (GPCR, iontové kanály):** Kde vazba ligandu indukuje rozsáhlé alosterické posuny transmembránových helixů a přeskupení vazebné kapsy (mechanismus *Induced Fit* a *Conformational Selection*).
- **Proteiny s kryptickými (skrytými) kavitami:** Vazebné kapsy, které v nestimulovaném stavu vůbec neexistují a otevírají se teprve přítomností ligandu.
- **Modely s nízkým rozlišením (Cryo-EM > 3.5 Å, AlphaFold predikce):** Kde nepřesné rotamery postranních řetězců vedou při rigidním dokování k falešným sterickým srážkám (clashes) a vyřazení vysoce aktivních molekul.

Aplikace rigidního SBDD dokování na IDP vede k naprostému selhání (masivní výskyt falešně negativních i falešně pozitivních předpovědí).

SBDD Dokování do Rigidního Receptoru

- Vyžaduje rigidní krystalovou strukturu z PDB s vysokým rozlišením.
- Ignoruje konformační entropii a plasticitu vazebného rozhraní.
- Malá nepřesnost polohy aminokyseliny (0.5 Å) způsobí sterickou srážku a nulové skóre.
- U IDP a dynamických cílů zcela selhává.

Ligand-Based 3D ROCS Shape Matching (LBDD)

- Využívá experimentální konformace ověřených aktivních ligandů.
- Aktivní ligandy představují **negativní prostorový a elektrostatický otisk** vazebného místa.
- Zachovává toleranci k flexibilitě proteinu díky Gaussovskému překryvu.
- Umožňuje de novo generování i pro zcela nestrukturované cíle.

2. Ligand-Based 3D Drug Design (LBDD) jako rigorózní alternativa

Slide 2/6

Pokud máme k dispozici sadu experimentálně potvrzených aktivních ligandů (získaných např. z NMR titrací, povrchové plasmonové rezonance SPR, hmotnostní spektrometrie nebo biochemických esejí), jejich 3D konformace vázaná na protein představuje **dokonalý negativní prostorový a farmakoforový odlietek** funkčního rozhraní proteinu.

Termodynamické zdůvodnění: Vysoce afinitní ligand ($K_d < 100$ nM) stabilizuje specifický funkční konformační stav IDP nebo receptoru. Pokud generativní model navrhne novou molekulu, která:

1. Trojrozměrným tvarem přesně vyplní van der Waalsovský objem aktivních referencí ($T_{\text{shape}} \rightarrow 1.0$),
2. Prezентuje donory, akceptory a náboje ve shodných prostorových koordinátách ($T_{\text{color}} \rightarrow 1.0$),
3. Zachovává nízkou vnitřní pnutí a vysokou syntetickou dostupnost ($\text{SAScore} \leq 3.0$),

tato nová molekula má vysokou pravděpodobnost vázat se do stejného funkčního konformačního stavu proteinu se srovnatelnou či vyšší afinitou, bez ohledu na to, zda máme k dispozici krystalovou strukturu receptoru.

Tento koncept tvoří ústřední pilíř této bakalářské práce: **využití 3D ROCS shape matchingu jako objektivní odměňovací funkce v prostředí DrugEx MORL pro de novo design léčiv na flexibilní cíle.**

3. Ansámby bioaktivních konformací & Experimentální data (NMR / SPR)

Slide 3/6

U flexibilních proteinů ligand zřídka váže cíl v jediné rigidní geometrii. V roztoku se často uplatňuje konformační heterogenita:

- **NMR spektroskopie v roztoku:** Metody jako trNOE (transferred NOE) a měření chemických posunů (CSP) určují 3D konformaci ligandu přímo ve vázaném stavu v roztoku bez krystalizačních artefaktů.
- **Vícečetné vazebné módy (Binding Modes):** Ligand může obsazovat dvě překrývající se podkavity nebo vázat cíl v různých orientacích (např. monomer vs dimer rozhraní).
- **Cryo-EM konformační třídění:** Rekonstrukce několika koexistujících stavů makromolekulárního komplexu.

V DrugEx proto nelze spoléhat na porovnávání vůči jedinému statickému ligandu. Do skórovacího modulu se vkládají **ansámby bioaktivních referencí**, které pokrývají celou šíři experimentálně ověřeného vazebného prostoru.

Jednou z klíčových technik pro reprezentaci komplexního vazebného rozhraní je vytvoření **konsensuální supermolekuly (Supermolecule Template)**:

Postup tvorby supermolekuly:

1. Sjednotí se souřadné systémy několika známých krystalografických nebo NMR struktur ligandů ve vázaném stavu (např. ligandy 1, 2 a 3).
2. Strukturně se sloučí do jednoho SDF souboru (např. `CCR2_supermo1_123.sdf`).
3. Supermolekula definuje **sjednacení (union) prostorových objemů** všech referencí:

$$V_{\text{super}} = \bigcup_k V(R_k)$$

4. Farmakoforové body jsou konsolidovány: překrývající se identické interakce jsou zesíleny, zatímco unikátní skupiny rozšiřují povolený prostor pro chemickou substituci.

Výhody supermolekuly v DrugEx:

- Jediný výpočet 3D zarovnání na kandidáta ($1 \times$ zarovnání namísto $N \times$), což dramaticky zkracuje čas trénovací epochy.
- Generátor je motivován navrhovat molekuly, které propojují sub-kapsy obsazené různými referenčními ligandy (tvorba multivalentních či fragment-linked molekul).

5. Multi-Reference Group Scoring (max TanimotoCombo)

Pokud referenční ligandy vážou protein v navzájem se vylučujících konformacích (např. orthosterické vs alosterické vazebné místo), sloučení do supermolekuly by vytvořilo nerealisticky obří tvar.

Pro tento případ implementuje DrugEx pokročilý mechanismus **Multi-Reference Groupingu**:

Reference jsou uspořádány do slovníku pojmenovaných skupin:

$$\text{References} = \{ \text{'orthosteric'} : [R_1, R_2], \text{'allosteric'} : [R_3, R_4] \}$$

Skórovací funkce vyhodnotí shodu kandidátní molekuly X se všemi referencemi v dané skupině a vrátí **maximální dosažené skóre**:

$$\text{Score}_{\text{group}}(X) = \max_{R \in \text{Group}} \left(\max_{k \in \text{Conformers}(X)} T_{\text{combo}}(C_k(X), R) \right)$$

Tento přístup umožňuje multi-cílovou optimalizaci v DrugEx MORL: generátor může být odměňován za schopnost vázat buď libovolné ze známých vazebných míst, nebo současně optimalizovat selektivitu vůči více konformačním stavům.

Tato bakalářská práce spojuje nejmodernější koncepty generativní chemie a 3D modelování do uceleného výpočetního řetězce:

Generativní AI & MORL (DrugEx)

- Autoregresní jazykové modely (SMILES RNN / GPT) pro generování chemicky validních molekul.
- Duální síťová architektura (Agent vs Mutate Prior) bránící *mode collapse*.
- Paretovo nedominované třídění s Crowding Distance pro vícekritériální vyvažování.

3D Tvarové Řízení (ROCS Engine)

- Analytické Gaussovské objemové integrály pro ultra-rychlé 3D hodnocení.
- Optimalizace shody vůči experimentálním referencím flexibilního receptoru CCR2.
- Penalizace syntetické nedostupnosti (SAScore) a filtrace nežádoucích reaktivních skupin.

Výsledkem je plně automatizovaný systém schopný z nepopsaného listu navrhnout originální chemické entity se špičkovým 3D tvarem, perfektní farmakoforovou komplementaritou a vysokou syntetickou dostupností pro syntézu na ÚOCHB AV ČR.

python

```
# Příklad konfigurace Multi-Reference Groupingu v DrugEx
from drugex.training.scorers.rocs_rdkit import RDKitROCSScorer
from drugex.training.scorers.conformer_generators import RDKitConformerGenerator

conf_gen = RDKitConformerGenerator(max_conformers=50, max_isomers=4, num_threads=1)

# Skórovač s definicí funkčních skupin referencí
scorer = RDKitROCSScorer(
    conformer_generator=conf_gen,
    references={
        "CCR2_pocket_A": ["references/ref_ligand_1.sdf", "references/ref_ligand_2.sdf"],
        "CCR2_pocket_B": ["references/ref_ligand_3.sdf"]
    },
    score_type="TanimotoCombo",
    use_colors=True,
    n_jobs=-1
)
```

3.3 Hlubková analýza conformer_generators.py (RDKit, OMEGA, CDPKit, Schrödinger)

1. Architektura a kontrakt třídy ConformerGenerator (conformer_generators.py)

Slide
1/6

Generování nízkokonformačních 3D geometrií z 1D SMILES je výpočetně nejnáročnějším článkem celého 3D shape-matching řetězce. Během jedné trénovací epochy v DrugEx vygeneruje neuronový model 1 000 nových molekul. Pro každou z nich je nutné vygenerovat desítky 3D konformací, což znamená vygenerovat a optimalizovat 30 000 až 50 000 3D souřadnicových struktur během několika sekund.

V souboru `drugex/training/scorers/conformer_generators.py` je definována abstraktní základní třída `ConformerGenerator` (dědící z `drugex.training.scorers.interfaces.ConformerGenerator`).

Základní kontrakt rozhraní předepisuje dvě klíčové metody:

1. `genConformers(smiles_list: List[str], out_dir: str) -> str`:
 - Přijímá seznam SMILES řetězců a cestu k dočasnému výstupnímu adresáři.
 - Provádí filtraci struktur (heavy atoms, rotovatelné vazby), enumeraci stereoizomerů a generování konformačních ansámbků.
 - Ukládá vygenerované konformace do standardizovaného multi-molekulárního souboru (SDF nebo OEB.GZ) s pojmenováním ve formátu `mol_{i}+{j}` (kde *i* je index vstupní molekuly a *j* je index stereoizomeru).
 - Vrací absolutní cestu k výslednému souboru.
2. `write_conformers(mols: List, out_file: str) -> None`:
 - Pomocná metoda pro přímý zápis konformací z RDKit molekulárních objektů do cílového SDF souboru.

2. RDKit backend: Algoritmus ETKDv3 (Riniker & Landrum)

Slide 2/6

Třída `RDKitConformerGenerator` představuje výchozí, plně otevřený a multiplatformní generátor. Využívá metodu **ETKDv3 (Experimental-Torsion Knowledge Distance Geometry version 3)** vyvinutou S. Riniker a G. Landrumem (2015, 2020).

Algoritmický princip ETKDv3:

1. **Matice distančních mezí (Distance Bounds Matrix)**: Z 2D topologie a délek vazeb se sestaví matice minimálních a maximálních povolených vzdáleností mezi všemi dvojicemi atomů.
2. **Znalostní torzní potenciály z databáze CSD**: Na rotovatelné vazby jsou aplikovány statistické torzní úhlové preference odvozené z deseti tisíců experimentálních krystalografických struktur malých molekul v Cambridge Structural Database (CSD).
3. **Vnoření ze 4D do 3D prostoru (Embedding)**: Metodou Distance Geometry s náhodným inicializačním seedem (`params.randomSeed = 0xc0ffee`) se naleznou 3D souřadnice.
4. **Silová optimalizace**: Geometrie je dočištěna silovým polem MMFF94 nebo UFF pro odstranění sterických srážek.
5. **RMSD prořezávání (Pruning)**: Konformace s geometrickou odchylkou RMSD < 0.5 Å jsou zahozeny (`params.pruneRmsThresh = 0.5`), což brání redundanci.

python

```
class RDKitConformerGenerator(ConformerGenerator):
    def __init__(
        self,
        max_conformers: int = 10,
        max_isomers: int = 4,
        max_heavy_atoms: int = 35,
        max_rotatable_bonds: int = 15,
        num_threads: int = 0,
        show_progress: bool = False,
    ):
        self.max_conformers = min(max_conformers, 200)
        self.max_isomers = max_isomers
        self.max_heavy_atoms = max_heavy_atoms
        self.max_rotatable_bonds = max_rotatable_bonds
        self.num_threads = num_threads
        self.show_progress = show_progress

    def _create_fresh_etkdg(self):
        params = AllChem.ETKDGv3()
        params.randomSeed = 0xc0ffee
        params.numThreads = self.num_threads
        params.pruneRmsThresh = 0.5
        return params
```

3. OpenEye backend: OMEGA pravidlové torzní vzorkování a GPU mód

Slide 3/6

Třída `OmegaConformerGenerator` využívá komerční nástroj **OpenEye OMEGA** (Hawkins et al., OpenEye Scientific Software), který je v průmyslové farmacii považován za zlatý standard rychlosti a přesnosti.

Klíčové vlastnosti implementace v DrugEx:

- **Fragmentový rozklad:** Molekula je rozdělena na rigidní fragmenty spojené rotovatelnými vazbami. Konformace rigidních jader jsou načteny z předpočítané databáze.
- **Systematické torzní řízení (Torsion Driving):** OMEGA prohledává rotamery podle diskrétních energetických pravidel namísto stochastického vnořování.
- **Enumerace stereoizomerů přes OEFlipper:** Pro neoznačená chirální centra generuje stereoizomery třída `oeomega.OEFlipper` s limitem `max_centers`.
- **GPU Akcelarace:** Při volbě `use_gpu=True` a přítomnosti CUDA hardware se aktivuje GPU torzní engine přes `opts.GetTorDriveOptions().SetUseGPU(True)`, což umožňuje vzorkovat přes 5 000 konformací za sekundu na jedné GPU.

python

```
class OmegaConformerGenerator(ConformerGenerator):
    def _create_fresh_omega(self):
        opts = oeomega.OEOMegaOptions()
        opts.SetMaxConfs(self.max_conformers)
        opts.SetStrictStereo(False)
        opts.SetFromCT(True)
        opts.SetFixRMS(True)
        opts.SetRMSThreshold(0.5)
        opts.SetEnumRing(True)
        opts.SetRotorOffset(False)

        if self.use_gpu and oeomega.OEOMegaIsGPUReady():
            opts.GetTorDriveOptions().SetUseGPU(True)
            opts.SetSampleHydrogens(False)
        else:
            opts.GetTorDriveOptions().SetUseGPU(False)
            opts.SetSampleHydrogens(True)

        return oeomega.OEOMega(opts)
```

4. CDPKit backend: CDPL.ConfGen C++ pipeline

Slide 4/6

Třída `CDPKitConformerGenerator` integruje C++ knihovnu **CDPL (Chemical Data Processing Library)**. Poskytuje plně otevřenou alternativu k OMEGA s energetickým oknem a RMSD shlukováním.

Architektura CDPKit pipeline:

- `CDPLChem.calcBasicProperties(mol)`: Inicializuje základní chemické deskriptory (hybridizaci, aromatické kruhy, počet H-atomů).
- `CDPLChem.StereoisomerGenerator`: Provádí explicitní enumeraci konfigurací na atomech (`enumerateAtomConfig(True)`) i dvojných vazbách (`enumerateBondConfig(True)`) až do limitu `max_isomers`.
- `CDPLConfGen.ConformerGenerator`:
 - `timeout = self.timeout * 1000`: Časový limit v milisekundách.
 - `minRMSD = 0.5`: Minimální geometrická vzdálenost mezi konformacemi.
 - `energyWindow = 20.0 kcal/mol`: Energetické okno pro zachování nízkoenergetických stavů.
 - `maxNumOutputConformers = self.max_conformers`: Maximální počet výstupních konformací.
- Ošetření návratových kódů**: Korektní obsluha stavů `SUCCESS`, `TOO_MUCH_SYMMETRY` (vysoce symetrické molekuly), `TIMEOUT` a `FORCEFIELD_SETUP_FAILED`.

5. Schrödinger backend: ConfGenX & Oprava planárních souřadnic (+0.01 Å fix)

Slide 5/6

Třída `SchrodingerConformerGenerator` spouští proprietární nástroj `confgenx` z balíku Schrödinger Suite pomocí CLI subprocessu. Výstupní soubor Maestro `.maegz` je konvertován do SDF utilitou `sdconvert`.

Kritický inženýrský objev: Oprava singularity u planárních molekul (+0.01 Å fix)

Během rozsáhlých výpočtů v DrugEx došlo k závažnému problému: u dokonale planárních aromatických molekul (např. ligand 8SKP) vygeneroval `confgenx` konformaci, kde všechny atomy měly přesně nulovou z-souřadnici ($z_i = 0.0000 \text{ Å}$).

Při následném předání do ROCS došlo k **pádu výpočtu (singularity crash)**:

- Výpočet tenzoru momentu setrvačnosti a Gaussovske prostorové kovariance v z -ose vedl k nulovému rozptylu ($\sigma_z^2 = 0$).
- Algoritmus invertoval singulární matici, což způsobilo dělení nulou a pád celého procesu.

V `conformer_generators.py` byl tento problém vyřešen elegantní automatickou post-processing korekcí: k z-souřadnici každého atomu je přičten nepatrný offset $+0.01 \text{ Å}$, což zachová geometrii, ale odstraní numerickou singularitu:

python

```
# Oprava souřadnic v SchrodingerConformerGenerator
suppl = Chem.SDMolSupplier(tmp_outfile, removeHs=False)
corrected_mols = []
for mol in suppl:
    if mol is not None:
        for atom in mol.GetAtoms():
            pos = mol.GetConformer().GetAtomPosition(atom.GetIdx())
            # Přičtení +0.01 k ose Z zabraňuje kolapsu ROCS u planárních struktur
            new_pos = (pos.x, pos.y, pos.z + 0.01)
            mol.GetConformer().SetAtomPosition(atom.GetIdx(), new_pos)
        corrected_mols.append(mol)
```

6. Filtrace molekul & Pravidla vláknové bezpečnosti (Multi-threading Safety)

Slide 6/6

Generování konformací pro nekontrolované chemické struktury může snadno způsobit zamrznutí nebo pád celého RL tréninku. Proto jsou ve všech 4 generátorech implementovány striktní bezpečnostní filtry a pravidla pro paralelní běh:

1. Bezpečnostní chemické filtry

- `max_heavy_atoms = 35 - 45`: Molekuly s > 45 těžkými atomy (C, N, O, S...) jsou okamžitě přeskočeny a získávají nulové skóre. Zabraňuje paměťovému kolapsu při náhodném vygenerování obřích oligomerů.
- `max_rotatable_bonds = 15`: Molekuly s > 15 rotovatelnými vazbami mají konformační prostor o velikosti $3^{15} \approx 1.4 \times 10^7$ stavů, který nelze 50 konformacemi smysluplně pokrýt. Jsou proto penalizovány.
- `max_isomers = 4`: Pokud molekula obsahuje k neoznačených chirálních center (2^k izomerů), enumerace je omezena na maximálně 4 stereoizomery pro zachování rozumného výpočetního času.

2. Zlaté pravidlo vláknové bezpečnosti při paralelním běhu (num_threads)

Při trénování DrugEx na víceprocesorovém superpočítači se paralelismus realizuje na úrovni procesů přes

```
multiprocessing.Pool(n_jobs) .
```

POZOR: CPU OVERSUBSCRIPTION & DEADLOCK

Pokud je v

```
RDKitConformerGenerator
```

nastaveno

```
num_threads = 0
```

(použít všechna dostupná jádra) a skórovač současně běží s

```
n_jobs = 32
```

procesy, každý proces se pokusí alokovat 32 OpenMP vláken. Dojde k vytvoření

$32 \times 32 = 1024$

vláken, což způsobí masivní kontextové přepínání (CPU Thrashing), propad výkonu o 95 % a zamrznutí systému.

Pravidlo:

Při použití paralelního skórovače (

```
n_jobs > 1
```

) MUSÍ být v generátoru konformací striktně nastaveno

```
num_threads = 1
```

!

Modul 4: Hlubková Architektura ROCS Scorerů (RDKit, CDKit, OpenEye)

4.1 RDKit ROCS Scorer: rdShapeAlign, Worker Init & Pose Invariance

Implementace rocs_rdkit.py: třída RDKitROCSScorer, algoritmus _score_single_reference, sdílení stavu _rdkit_worker_init, SMILES deduplikace a skupinové multi-reference skórování.

1. Vnitřní architektura RDKitROCSScorer (rocs_rdkit.py)

Slide 1/5

Soubor `drugex/training/scorers/rocs_rdkit.py` představuje hlavní referenční implementaci pro 3D tvarové hodnocení v DrugEx. Využívá nativní C++ modul `rdkit.Chem.rdShapeAlign` pro optimalizaci prostorového zarovnání a výpočet Gaussovských objemových integrálů.

Třída `RDKitROCSScorer` dědí ze základního rozhraní `Scorer` a poskytuje mimořádně flexibilní inicializaci referenčních struktur:

- **Jednotlivý SDF soubor** (např. `references="CCR2_ligand.sdf"`)
- **Seznam SDF souborů** (např. `references=["ligand1.sdf", "ligand2.sdf"]`)
- **Slovník pojmenovaných skupin** pro multi-kavitní nebo multi-konformační skórování:

```
references = {  
    'pocket_A': ['ref1.sdf', 'ref2.sdf'],  
    'pocket_B': ['ref3.sdf']  
}
```

- **RDKit molekulární objekty** (`Chem.Mol`) s předpočítanými 3D konformacemi.

Automatické vnoření 2D referencí (Auto-Embedding)

Pokud uživatel předá referenční molekulu, která postrádá 3D souřadnice, metoda `_ensure_reference_conformers(mol)` automaticky vygeneruje nízkoenergetickou 3D konformaci pomocí algoritmu ETKDGv3 s fixním náhodným seedem (`params.randomSeed = 0xC0FFEE`) a přidáním explicitních vodíků.

```

class RDKitROCSScorer(Scorer):
    def __init__(
        self,
        conformer_generator: ConformerGenerator,
        references: Union[str, List[str], Dict[str, List[str]], Chem.Mol, List[Chem.Mol], Dict[str,
List[Chem.Mol]]],
        score_type: str = "TanimotoCombo",
        use_colors: bool = True,
        show_progress: bool = True,
        n_jobs: int = -1,
    ):
        super().__init__()
        self.conformer_generator = conformer_generator
        self.score_type = score_type
        self.use_colors = use_colors
        self.show_progress = show_progress
        self.n_jobs = n_jobs if n_jobs != -1 else cpu_count()

        # Příprava a normalizace referenčních skupin
        self.group_definitions = self._prepare_reference_groups(references)
        self.group_names = [name for name, _ in self.group_definitions]
        self.reference_mols, self.group_to_indices = self._flatten_groups(self.group_definitions)
        self.reference_mols = [self._ensure_reference_conformers(m) for m in self.reference_mols]
        self._validate_references()
        self._single_reference = len(self.reference_mols) == 1

```

2. Jádru výpočtu: `_score_single_reference` & `rdShapeAlign.AlignMol`

Slide 2/5

Základní výpočetní jednotkou pro zarovnání jedné testované molekuly vůči jedné referenci je funkce

`_score_single_reference`:

Algoritmický postup:

1. Funkce iteruje přes kartézský součin všech konformací generované molekuly (`query_conf`) a všech konformací referenční molekuly (`ref_conf`).
2. Pro každou dvojici vytvoří izolovanou kopii molekuly: `probe_copy = Chem.Mol(query_mol)`. Tím se zabrání nežádoucí mutaci souřadnic v původním ansámbli.
3. Zavolá optimalizační C++ rutinu `rdShapeAlign.AlignMol`:

```
result = rdShapeAlign.AlignMol(ref_mol, probe_copy, refConfId, probeConfId, useColors=True)
```

4. Funkce vrátí dvojici ($T_{\text{shape}}, T_{\text{color}}$).
5. V závislosti na parametru `score_type` se vyhodnotí skóre:
 - o `"TanimotoCombo"` $\implies T_{\text{shape}} + T_{\text{color}} \in [0, 2]$
 - o `"shape"` $\implies T_{\text{shape}} \in [0, 1]$
 - o `"color"` $\implies T_{\text{color}} \in [0, 1]$
6. Funkce udržuje globální maximum přes všechny vygenerované konformery a stereoizomery:

$$\text{Score}(M, R) = \max_{k \in \{1, \dots, K\}} \text{Score}(C_k, R)$$

python

```
def _score_single_reference(
    query_mol: Chem.Mol,
    ref_mol: Chem.Mol,
    score_type: str,
    use_colors: bool,
) -> float:
    """Výpočet nejlepšího skóre zarovnání mezi query molekulou a jednou referencí."""
    if query_mol is None or ref_mol is None:
        return 0.0
    if query_mol.GetNumConformers() == 0 or ref_mol.GetNumConformers() == 0:
        return 0.0

    best_score = 0.0
    for query_conf in query_mol.GetConformers():
        for ref_conf in ref_mol.GetConformers():
            try:
                probe_copy = Chem.Mol(query_mol)
                result = rdShapeAlign.AlignMol(
                    ref_mol,
                    probe_copy,
                    refConfId=ref_conf.GetId(),
                    probeConfId=query_conf.GetId(),
                    useColors=use_colors,
                )
            except (RuntimeError, ValueError):
                continue

            if not isinstance(result, (list, tuple)) or len(result) < 2:
                continue

            shape_score, color_score = result[0], result[1]
            if score_type == "shape":
                score = shape_score
            elif score_type == "color":
                score = color_score
            else:
                score = shape_score + color_score

            if score > best_score:
                best_score = score

    return best_score
```

3. Paralelizace a Worker Initializer (`_rdkit_worker_init`)

Slide 3/5

Při standardním použití `multiprocessing.Pool.map` v Pythonu dochází k závažnému výkonostnímu problému:

Pokud by se referenční molekuly a konfigurační parametry posílaly jako argument každé úlohy, Python by musel serializovat (*pickle*) velké 3D RDKit objekty pro každou z 1 000 molekul v každé epoše. To vede k zahlcení IPC sběrnice (Inter-Process Communication), masivnímu nárůstu paměti a propadu výkonu.

V `rocs_rdkit.py` je tento problém vyřešen architekturou **Worker Initializeru**:

1. Při startu procesu v `multiprocessing.Pool` je zavolána inicializační funkce `_rdkit_worker_init`:
`_rdkit_worker_init(reference_mols, group_to_indices, score_type, use_colors)`
2. Reference jsou uloženy do globálního slovníku procesu `_RDKIT_WORKER_SETTINGS` **pouze jednou za celou dobu existence poolu**.
3. Jednotlivé worker úlohy (`_score_molecule_rdkit_worker`) pak přijímají pouze minimální payload: `(mol_id, mol_conformers)`.
4. Worker přistupuje k přednačeným referencím přímo v paměti procesu bez jakékoliv režie serializace.

python

```
_RDKIT_WORKER_SETTINGS: Dict[str, object] = {}

def _rdkit_worker_init(
    reference_mols: List[Chem.Mol],
    group_to_indices: List[List[int]],
    score_type: str,
    use_colors: bool,
) -> None:
    """Initializer pro uložení neměnného stavu do paměti worker procesu."""
    global _RDKIT_WORKER_SETTINGS
    _RDKIT_WORKER_SETTINGS = {
        "reference_mols": reference_mols,
        "group_to_indices": group_to_indices,
        "score_type": score_type,
        "use_colors": use_colors,
    }

def _score_molecule_rdkit_worker(args: Tuple[int, List[Chem.Mol]]) -> Tuple[int, List[float]]:
    mol_id, mol_conformers = args
    settings = _RDKIT_WORKER_SETTINGS
    reference_mols = settings.get("reference_mols", [])
    group_to_indices = settings.get("group_to_indices", [])
    score_type = settings.get("score_type", "TanimotoCombo")
    use_colors = settings.get("use_colors", True)

    num_groups = len(group_to_indices)
    group_scores = [0.0] * num_groups

    for conf_mol in mol_conformers:
        if conf_mol is None or conf_mol.GetNumConformers() == 0:
            continue
        for group_idx, ref_indices in enumerate(group_to_indices):
            for ref_idx in ref_indices:
                ref_mol = reference_mols[ref_idx]
                score = _score_single_reference(conf_mol, ref_mol, score_type, use_colors)
                if score > group_scores[group_idx]:
                    group_scores[group_idx] = score

    return mol_id, group_scores
```

Během Reinforcement Learningu generativní model často navrhne stejné vysoce odměňované molekuly vícekrát v rámci jedné dávky (např. ze vzorku 1 000 SMILES je pouze 650 unikátních struktur).

Spouštění generování 50 konformací a 3D Gaussovské zarovnání pro duplicitní molekuly by znamenalo plýtvat desítkami procent výpočetního času GPU/CPU.

Metoda `_deduplicate_smiles` v `rocs_rdkit.py` implementuje deterministickou deduplikaci:

1. Projde vstupní seznam SMILES a vytvoří pole unikátních řetězců `unique_smiles`.
2. Současně sestaví mapovací slovník `unique_to_original: Dict[int, List[int]]`, který pro každý unikátní index uchovává seznam původních pozic v batchi.
3. Generátor konformací a 3D shape alignment jsou spuštěny **výhradně pro unikátní molekuly**.
4. Po dokončení výpočtu se výsledná skóre bleskově namapují zpět na původní indexy v matici `scores[original_idx] = scores_unique[unique_id]`.

Tato optimalizace přináší **30 % až 50 % zrychlení celého RL tréninkového cyklu** bez jakékoliv ztráty přesnosti.

python

```
@staticmethod
def _deduplicate_smiles(
    smiles_list: List[Union[str, None]]
) -> Tuple[List[str], Dict[int, List[int]]]:
    """Seskupení identických SMILES pro eliminaci redundantních výpočtů konformací."""
    unique_smiles: List[str] = []
    unique_lookup: Dict[str, int] = {}
    unique_to_original: Dict[int, List[int]] = defaultdict(list)

    for idx, smi in enumerate(smiles_list):
        if smi is None:
            continue
        unique_idx = unique_lookup.get(smi)
        if unique_idx is None:
            unique_idx = len(unique_smiles)
            unique_smiles.append(smi)
            unique_lookup[smi] = unique_idx
            unique_to_original[unique_idx].append(idx)

    return unique_smiles, unique_to_original
```

5. Kompletní produkční konfigurace a výpočetní příklad

Následující kód demonstruje kompletní produkční inicializaci a spuštění `RDKitROCSScorer` s generátorem konformací `RDKitConformerGenerator` v prostředí DrugEx:

python

```
import numpy as np
from drugex.training.scorers.conformer_generators import RDKitConformerGenerator
from drugex.training.scorers.rocs_rdkit import RDKitROCSScorer

# 1. Konfigurace ETKDgV3 generátoru konformací
# DŮLEŽITÉ: num_threads=1 zamezuje přetížení CPU při n_jobs=-1
conformer_engine = RDKitConformerGenerator(
    max_conformers=50,      # Počet konformací na izomer
    max_isomers=4,          # Až 4 stereoizomery na molekulu
    max_heavy_atoms=45,     # Ochrana před příliš velkými molekulami
    max_rotatable_bonds=15, # Filtrace hyperflexibilních řetězců
    num_threads=1,          # 1 vlákno na proces
    show_progress=False
)

# 2. Inicializace RDKit ROCS skórovače s multi-referenčními skupinami
rocs_scorer = RDKitROCSScorer(
    conformer_generator=conformer_engine,
    references={
        "CCR2_orthosteric": "rocs_r1_ccr/rdkit_cdpkit/CCR2_reference_ligands.sdf"
    },
    score_type="TanimotoCombo",
    use_colors=True,
    show_progress=True,
    n_jobs=-1 # Využije všechna dostupná CPU jádra
)

# 3. Vyhodnocení dávky molekul
test_smiles = [
    "Cc1ccc(NC(=O)c2cccc(C(=O)NC3CCN(Cc4ccccc4)CC3)c2)cc1",
    "O=C(Nc1ccc(F)cc1)c1ccc(CN2CCN(c3cccc(C1)c3)CC2)cc1",
    "COc1ccc2[nH]c(C(=O)N3CCC(c4cc5ccccc5[nH]4)CC3)cc2c1"
]

scores = rocs_scorer.getScores(test_smiles)
print("Výsledná TanimotoCombo skóre:")
for smi, score in zip(test_smiles, scores):
    print(f" SMILES: {smi[:45]}... -> Score: {score[0]:.3f}")
```

4.2 CDPKit ROCS Scorer: CDPL.Shape, WorkerContext & Open-Source Pipeline

Implementace rocs_cdpkit.py: 100% open-source C++ Gaussovský engine, CDPL.Shape.GaussianShapeGenerator, PrincipalAxesAlignmentStartGenerator, datová třída CDPKitWorkerContext a paměťově efektivní streamování.

1. Plně otevřený C++ Gaussovský engine CDPKit (rocs_cdpkit.py)

Slide 1/5

Zatímco průmyslový nástroj OpenEye ROCS vyžaduje nákladnou proprietární licenci a je vázán na licenční server,

CDPKitROCSScorer (implementovaný v `drugex/training/scorers/rocs_cdpkit.py`) poskytuje **100% open-source alternativu srovnatelné přesnosti**.

Využívá vysoce optimalizovanou C++ knihovnu **CDPL (Chemical Data Processing Library)** a její specializované moduly:

- `CDPL.Pharm.prepareForPharmacophoreGeneration(mol)` : Automaticky detekuje donory, akceptory, hydrofobní a aromatická centra.
- `CDPL.Shape.GaussianShapeGenerator` :
 - `generatePharmacophoreShape(True)` : Generuje barevné farmakoforové Gaussovske hustoty integrované přímo s prostorovým tvarem.
 - `multiConformerMode(True)` : Umožňuje multi-konformační reprezentaci query struktur.
- `CDPL.Shape.PrincipalAxesAlignmentStartGenerator` : Spočte matici momentů setrvačnosti a generuje 4 počáteční ortogonální orientace podél hlavních os setrvačnosti.
- `CDPL.Shape.GaussianShapeAlignment` : Gradientní optimalizace překryvu metodou kvazi-Newtonových kroků s parametry:

```
MAX_OPTIMIZATION_ITERATIONS = 20, OPTIMIZATION_STOP_GRADIENT = 1.0
```

což garantuje sub-milisekundový čas zarovnání na konformer.

- `CDPL.Shape.calcTanimotoComboScore` : Nativní C++ výpočet kompozitního TanimotoCombo skóre.

python

```
def _align_and_score_helper(query_shape, ref_shape):
    """Zarovnání dvou Gaussovských tvarů a vrácení nejvyššího TanimotoCombo skóre."""
    try:
        aligner = CDPLShape.GaussianShapeAlignment()
        start_generator = CDPLShape.PrincipalAxesAlignmentStartGenerator()
        aligner.setStartGenerator(start_generator)
        aligner.setMaxNumOptimizationIterations(MAX_OPTIMIZATION_ITERATIONS)
        aligner.setOptimizationStopGradient(OPTIMIZATION_STOP_GRADIENT)
        aligner.addReferenceShape(ref_shape)

        if not aligner.align(query_shape) or aligner.getNumResults() == 0:
            return 0.0

        best_score = 0.0
        for i in range(aligner.getNumResults()):
            alignment_result = aligner.getResult(i)
            score = CDPLShape.calcTanimotoComboScore(alignment_result)
            best_score = max(best_score, score)
        return best_score
    except (RuntimeError, ValueError):
        return 0.0
```

2. Izolace vláken a workeru: CDPKitWorkerContext & CDPKitScoringWorker

Slide 2/5

CDPKit je nativní C++ knihovna obalená do Pythonu (pomocí Boost.Python / Pybind11). Přímé sdílení instancí C++ tříd mezi Python procesy často vede k chybám typu *Segmentation Fault*, porušení paměti (Memory Corruption) nebo uváznutí v GIL (Global Interpreter Lock).

V `rocs_cdpkit.py` je tento problém vyřešen architekturou dvou dedikovaných tříd:

1. Datová třída CDPKitWorkerContext

Neměnný kontejner (`@dataclass`) obsahující veškerý stav potřebný pro výpočet:

- `reference_shapes: List`: Předpočítané Gaussovské tvary referenčních ligandů.
- `group_to_indices: List[List[int]]`: Mapování referenčních skupin.
- `conf_file: str`: Cesta k vygenerovanému dočasnému SDF souboru s konformacemi.

2. Volatelná třída CDPKitScoringWorker

Zapouzdřuje výkonnou logiku workeru bez použití globálních proměnných na úrovni modulu:

- Statická metoda `initialize(context)` uloží kontext na úrovni třídy (`CDPKitScoringWorker._context`) jednou při vytvoření poolu.
- Metoda `__call__(mol_id)` je volána pro každé ID molekuly přes `pool.map` a provede izolovaný výpočet.

python

```
@dataclass
class CDPKitWorkerContext:
    """Neměnný kontext pro CDPKit scoring workery."""
    reference_shapes: List
    group_to_indices: List[List[int]]
    conf_file: str

class CDPKitScoringWorker:
    _context: ClassVar[Optional[CDPKitWorkerContext]] = None

    @staticmethod
    def initialize(context: CDPKitWorkerContext) -> None:
        """Inicializace workeru sdíleným kontextem (voláno jednou per worker)."""
        CDPKitScoringWorker._context = context

    def __call__(self, mol_id: int) -> Tuple[int, List[float]]:
        """Oskórování jedné molekuly v izolovaném worker procesu."""
        ctx = CDPKitScoringWorker._context
        if ctx is None:
            return mol_id, []
        # ... provede čtení konformerů a výpočet zarovnání ...
        return mol_id, group_scores
```

3. Paměťově efektivní streamování konformerů ze souboru SDF

Slide 3/5

Při zpracování velkých batchů (např. 1 000 molekul po 50 konformacích = 50 000 3D struktur) by držení všech objektů v operační paměti RAM vyžadovalo gigabajty paměti na každý worker proces.

`CDPKitScoringWorker` implementuje paměťově úsporné **streamovací čtení ze souboru SDF**:

1. Worker otevře proudový čteč `CDPLChem.FileSDFMoleculeReader(ctx.conf_file)`.
2. Čte záznamy sekvenčně po jednom a provádí rychlý prefixový filtr na název molekuly:

```
if not name.startswith(f"mol_{mol_id}+"): continue
```

3. Pouze pro konformace patřící aktuálnímu `mol_id` vygeneruje Gaussovské tvary přes `_generate_shape_helper(m)`.
4. Spočte překryv vůči předpočítaným referenčním tvarům `ctx.reference_shapes`.
5. Po dokončení se molekulární objekty okamžitě uvolní z paměti.

Tento přístup udržuje paměťovou stopu worker procesu pod 50 MB i při zpracování desítek konformací.

python

```
# Úryvek streamovacího čtení v CDPKitScoringWorker
reader = CDPLChem.FileSDFMoleculeReader(ctx.conf_file)
target_prefix = f"mol_{mol_id}+"

while True:
    m = CDPLChem.BasicMolecule()
    if not reader.read(m):
        break
    try:
        name = CDPLChem.getName(m)
    except Exception:
        continue
    if not name or not name.startswith(target_prefix):
        continue

    query_shapes = _generate_shape_helper(m)
    if not query_shapes:
        continue

    for group_idx, ref_indices in enumerate(ctx.group_to_indices):
        best = group_scores[group_idx]
        for ref_idx in ref_indices:
            ref_shape = ctx.reference_shapes[ref_idx]
            for query_shape in query_shapes:
                score = _align_and_score_helper(query_shape, ref_shape)
                if score > best:
                    best = score
            group_scores[group_idx] = best
```

4. Porovnání přesnosti a rychlosti: CDPKit vs OpenEye vs RDKit

Slide 4/5

V rámci bakalářské práce bylo provedeno rozsáhlé srovnání všech tří implementací na benchmarkovém datasetu aktivních a decoy ligandů receptoru CCR2:

CDPKit ROCS Scorer (Open-Source)

- **Licence:** 100% zdarma, otevřená (GPL/LGPL/MIT).
- **Zarovnání:** PAI + kvazi-Newtonova optimalizace v C++.
- **Farmakofor:** Plně integrovaná barevná pole v `CDPL.Pharm`.
- **Korelace s OpenEye:** Pearsonovo $r > 0.93$ ($R^2 > 0.88$).
- **Výhoda:** Nulové licenční náklady, snadná instalace přes `pip install cdpkit`.

OpenEye ROCS Scorer (Proprietární)

- **Licence:** Komerční / akademická licence OpenEye.
- **Zarovnání:** Vysoce vyladěný engine ROCS s GPU podporou (fastROCS).
- **Farmakofor:** ImplicitMillsDean barevné pole + podpora .sq queries.
- **Rychlost:** Nejvyšší propustnost při využití fastROCS na GPU.
- **Omezení:** Nutnost správy licenčního serveru a binárních závislostí.

5. Produkční skript run_cdpkit_rocs.py v praxi

Slide 5/5

Následující kód ukazuje integraci `CDPKitROCSScorer` a `CDPKitConformerGenerator` do kompletního tréninkového skriptu DrugEx MORL (podle `tutorial/advanced/rocs/run_cdpkit_rocs.py`):

python

```
from pathlib import Path
from drugex.training.environment import DrugExEnvironment
from drugex.training.rewards import ParetoCrowdingDistance
from drugex.training.scorers.modifiers import SmoothClippedScore
from drugex.training.scorers.properties import Property
from drugex.training.scorers.conformer_generators import CDPKitConformerGenerator
from drugex.training.scorers.rocs_cdpkit import CDPKitROCSScorer

def create_cdpkit_environment(reference_sdf: Path, max_confs: int = 30):
    # 1. CDPKit generátor konformací s RMSD clusteringem
    cdp_gen = CDPKitConformerGenerator(
        max_conformers=max_confs,
        max_isomers=4,
        max_heavy_atoms=40,
        energy_window=20.0,
        min_rmsd=0.5,
        show_progress=False
    )

    # 2. CDPKit ROCS skórovač
    rocs_scorer = CDPKitROCSScorer(
        conformer_generator=cdp_gen,
        references=str(reference_sdf),
        show_progress=False,
        n_jobs=-1
    )

    # 3. Skórovač syntetické dostupnosti (SAScore)
    sa_scorer = Property('SA')
    sa_scorer.setModifier(SmoothClippedScore(lower_x=5.0, upper_x=3.0))

    # 4. Sestavení multi-objektivního prostředí s Paretovým odměňováním
    env = DrugExEnvironment(
        scorers=[rocs_scorer, sa_scorer],
        thresholds=[0.871, 0.1], # Youdenův optimální ROCS práh
        reward_scheme=ParetoCrowdingDistance()
    )
    return env
```

4.3 OpenEye ROCS Scorer: CLI Subprocess, .sq Queries & GPU Akcelrace

Implementace rocs_openeye.py: řízení binárky rocs přes CLI subprocess, podpora .sq Shape Queries z vROCS, parametry příkazové řádky, správa RAM disků _managed_tmpdir a fastROCS.

1. Komerční zlatý standard OpenEye ROCS (rocs_openeye.py)

Slide 1/6

OpenEyeROCSScorer (implementovaný v `drugex/training/scorers/rocs_openeye.py`) integruje proprietární průmyslový standard od OpenEye Scientific Software.

Místo přímého volání Python toolkitů (`openeye.oeshape`) je skórovač navržen jako **hybridní CLI Subprocess**

orchestrátor, který spouští zkompilevanou binárku `rocs`.

Důvody pro volbu CLI Subprocess architektury:

1. **Absolutní procesní a paměťová izolace:** Při dlouhotrvajícím RL tréninku (desítky epoch, miliony 3D struktur) chrání subprocess Python proces před případnými memory leaky v C++ knihovnách.
2. **Kompatibilita verzí knihoven:** Zabraňuje konfliktům sdílených dynamických knihoven (např. verze libstdc++, OpenMP, CUDA) mezi PyTorchem a OpenEye Toolkitem.
3. **Stabilita na superpočítačích (HPC):** Umožňuje bezproblémové spouštění na distribuovaných výpočetních uzlech bez kolizí v Python GILu.

python

```
class OpenEyeROCSScorer(Scorer):
    def __init__(
        self,
        conformer_generator: ConformerGenerator,
        references: dict[str, List[str] | str],
        score_type: str = "TanimotoCombo",
        shape_only: bool = False,
        optimize: bool = True,
        color_optimize: bool = True,
        color_force_field: str = "ImplicitMillsDean",
        rocs_binary: str = "rocs",
        binary_path: str | None = None,
        show_progress: bool = True,
    ):
        super().__init__()
        if not OE_AVAILABLE:
            raise ImportError("OpenEye toolkits required")
        self.conformer_generator = conformer_generator
        self.queries = references
        self._validate_query_files()
        # ...
```

2. Práce s vROCS Shape Queries (.sq) vs SDF soubory

Slide 2/6

`OpenEyeROCSScorer` podporuje dva typy referenčních vstupů:

1. Standardní 3D SDF soubory (.sdf)

Klasické souřadnicové soubory krystalografických ligandů. Skórovač z nich za běhu vygeneruje van der Waalsovský tvar a přiřadí výchozí farmakoforové vlastnosti podle zvoleného silového pole.

2. Shape Query soubory (.sq)

Vytvořené v grafickém editoru

vROCS GUI

. Umožňují detailní expertní vyladění vazebného farmakoforu pro konkrétní medicíně-chemický cíl.

Unikátní možnosti .sq dotazů z vROCS:

- **Váhové přizpůsobení farmakoforových bodů:** Možnost nastavit např. 2.0× vyšší váhu na klíčovou H-vazbu k aminokyselině v pantech (Hinge region) kinázy, nebo naopak vypnout nevýznamné hydrofobní body.
- **Tvarová tolerance a sterické vylučovací sféry (Exclusion Spheres):** Možnost definovat zakázané zóny v prostoru, kam molekula nesmí zasahovat (např. stěny proteinové kapsy), což penalizuje molekuly způsobující sterické srážky s receptorem.

python

```
def _validate_query_files(self):
    """Validate existence a validity referenčních SDF a .sq souborů."""
    for name, list_of_qf in self.queries.items():
        if isinstance(list_of_qf, str):
            list_of_qf = [list_of_qf]
        for qf in list_of_qf:
            if not os.path.exists(qf):
                raise FileNotFoundError(f"Reference file not found: {qf}")
            ext = oechem.OEGetFileExtension(qf)
            if ext == ".sq":
                # Validate Shape Query souboru přes OpenEye OEShape
                query = oeshape.OEShapeQuery()
                if not oeshape.OEReadShapeQuery(qf, query):
                    raise ValueError(f"Invalid reference .sq file: {qf}")
            else:
                # Validate SDF molekuly
                qfs = oechem.oemolistream()
                qfs.open(qf)
                query = oechem.OEGraphMol()
                if not oechem.OEReadMolecule(qfs, query):
                    raise ValueError(f"Unable to read SDF query: {qf}")
```

3. Stavba příkazové řádky binárky rocs (_build_rocs_command)

Slide 3/6

Metoda `_build_rocs_command` sestavuje precizní sadu přepínačů pro CLI binárku `rocs`, které maximalizují propustnost a zabraňují zbytečnému zápisu na disk:

Klíčové přepínače příkazové řádky:

- `-query <file>`: Cesta k referenčnímu SDF nebo .sq souboru.
- `-dbase <file>`: Cesta k vygenerované konformační databázi (komprimovaný formát `conformers.oeb.gz`).
- `-report one`: Vygenerování jediného souhrnného textového TSV reportu.
- `-reportfile <file>`: Přímé přesměrování výstupního TSV souboru do dočasného adresáře.
- `-stats best`: Reportuje **pouze nejlepší překryv pro každou molekulu** napříč všemi jejími konformery a stereoizomery.
- `-nostructs`: **Kritická optimalizace** — vypíná zápis 3D souřadnicových souborů překrytých molekul na disk. Zrychluje I/O operace o stovky procent.
- `-scdbase`: Zabraňuje slučování spojitých konformerů do jednoho záznamu.
- `-rankby <score_type>`: Nastavuje primární metriku řazení (např. `TanimotoCombo`, `ShapeTanimoto`).
- `-chemff ImplicitMillsDean`: Definuje použité farmakoforové silové pole.
- `-opt true`: Aktivuje analytickou kvazi-Newtonovu optimalizaci prostorového překryvu.

python

```
def _build_rocs_command(
    self, query_file: str, input_file: str, output_file: str
) -> List[str]:
    """Sestavení optimalizovaného CLI příkazu pro binárku rocs."""
    output_dir = os.path.dirname(output_file) or "."
    cmd = [
        self.binary_path,
        "-query", query_file,
        "-dbase", input_file,
        "-report", "one",
        "-reportfile", output_file,
        "-prefix", "rocs",
        "-outputdir", output_dir,
        "-stats", "best",          # Pouze nejlepší překryv na molekulu
        "-nostructs",             # Neukládat 3D výstupní soubory (obří úspora I/O)
        "-scdbase",               # Neslučovat konformery
    ]
    if self.shape_only:
        cmd.extend(["-shapeonly", "true"])
    else:
        cmd.extend(["-rankby", self.score_type])
        cmd.extend(["-chemff", self.color_force_field])

    cmd.extend(["-opt", str(self.optimize).lower()])
    return cmd
```

4. Správa dočasných RAM disků (_managed_tmpdir) & OpenMP řízení

Slide 4/6

Během 50 RL epoch s 1 000 molekulami v každé epoše proběhne 50 000 volání generátoru konformací a skórovače. Zápis dočasných souborů na klasický SSD disk by vedl k degradaci disku (opotřebení NVMe buněk) a závažným I/O prodlevám.

V `rocs_openeye.py` jsou implementována dvě zásadní inženýrská opatření:

1. Správa dočasných RAM adresářů přes _managed_tmpdir()

Kontextový manažer vytváří izolované složky v paměťovém RAM disku (`/dev/shm` nebo `/tmp`) a v bloku `finally` garantuje 100% smazání všech dočasných dat i při neočekávané výjimce:

2. OpenMP Thread Throttling (OMP_NUM_THREADS="1")

Binárka `rocs` je kompilována s podporou OpenMP a standardně by se pokusila obsadit všechna dostupná CPU jádra. Při paralelním volání více instancí by došlo k totálnímu přetížení procesoru.

Při spuštění `subprocess.run` je proto prostředí striktně omezeno nastavením `env=dict(os.environ, OMP_NUM_THREADS="1")`, což zajišťuje deterministické a vyrovnané vytížení všech jader.

python

```
@contextmanager
def _managed_tmpdir():
    """Kontextový manažer dočasného adresáře s garantovaným úklidem."""
    path = tempfile.mkdtemp(prefix="cli_rocs_")
    try:
        yield path
    finally:
        try:
            shutil.rmtree(path, ignore_errors=True)
        except Exception as e:
            print(f"Chyba při úklidu dočasného adresáře {path}: {e}")

# Spuštění subprocessu s OpenMP thread throttlingem
result = subprocess.run(
    cmd,
    capture_output=True,
    text=True,
    timeout=300,
    env=dict(os.environ, OMP_NUM_THREADS="1")
)
```

5. Parsování TSV reportu & GPU Akcelerace (fastROCS)

Slide 5/6

Po dokončení běhu binárky `rocs` metoda `_parse_results(output_file)` bleskově zpracuje výstupní TSV soubor pomocí knihovny `pandas`:

1. Načte tabulku s kolonkami `Name` a požadovanou metrikou (např. `TanimotoCombo`).
2. Z názvu záznamu `mol_{id}+{conf}` extrahuje ID molekuly pomocí regulárního výrazu / splitu.
3. Uloží maximální dosažené skóre pro danou molekulu:

```
scores[mol_id] = max(scores.get(mol_id, 0.0), conf_score)
```

GPU Akcelerace přes fastROCS

Pro ultra-rozsáhlé screeniny a RL trénink nabízí OpenEye technologii **fastROCS**. Ta přenáší analytické Gaussovske integrály přímo do shader jader grafických karet NVIDIA (CUDA):

- Propustnost přesahuje **2 000 000 konformací za sekundu** na jediné GPU NVIDIA RTX 4090 / A100.
- Umožňuje zkrátit dobu vyhodnocení jedné RL epochy z desítek sekund na zlomek sekundy.

6. Kompletní produkční skript run_openeye_rocs.py

Slide 6/6

Kompletní ukázka inicializace a spuštění OpenEye ROCS tréninku v DrugEx (podle `tutorial/advanced/rocs/run_openeye_rocs.py`):

python

```
import os
import shutil
from pathlib import Path
from drugex.training.environment import DrugExEnvironment
from drugex.training.rewards import ParetoCrowdingDistance
from drugex.training.scorers.modifiers import SmoothClippedScore
from drugex.training.scorers.properties import Property
from drugex.training.scorers.conformer_generators import OmegaConformerGenerator
from drugex.training.scorers.rocs_openeye import OpenEyeROCSScorer

# 1. Kontrola licence OpenEye a přítomnosti binárky rocs v PATH
assert "OE_LICENSE" in os.environ, "Nastavte proměnnou prostředí OE_LICENSE!"
rocs_bin = shutil.which("rocs")
assert rocs_bin is not None, "Binárka 'rocs' nebyla nalezena v systémové PATH!"

def create_openeye_environment(reference_sdf: Path, use_gpu: bool = False):
    # 2. OpenEye OMEGA generátor konformací s volitelnou GPU akcelerací
    omega_gen = OmegaConformerGenerator(
        max_conformers=30,
        max_centers=2,
        max_heavy_atoms=40,
        use_gpu=use_gpu,
        show_progress=False
    )

    # 3. OpenEye ROCS CLI skórovač
    oe_scorer = OpenEyeROCSScorer(
        conformer_generator=omega_gen,
        references={'CCR2_pocket': str(reference_sdf)},
        score_type='TanimotoCombo',
        shape_only=False,
        optimize=True,
        color_optimize=True,
        color_force_field="ImplicitMillsDean",
        rocs_binary=rocs_bin,
        show_progress=False
    )

    # 4. Syntetická dostupnost (SAScore)
    sa_scorer = Property('SA')
    sa_scorer.setModifier(SmoothClippedScore(lower_x=5.0, upper_x=3.0))

    # 5. Sestavení prostředí
    env = DrugExEnvironment(
        scorers=[oe_scorer, sa_scorer],
        thresholds=[0.871, 0.1],
        reward_scheme=ParetoCrowdingDistance()
    )
    return env
```

Modul 5: Experimentální Pipeline & Validace na CCR2 Benchmarku

5.1 Stanovení ROCS prahů, ROC analýza & Youdenův index (threshold_analysis.py)

Vědecké zdůvodnění kalibrace 3D prahů, experimentální design 75 aktivních vs 500 DUD-E decoyů, matematická optimalizace Youdenova indexu J a analýza překryvu.

1. Vědecké zdůvodnění kalibrace prahů v 3D ligandovém designu

Slide 1/6

Ve zpětnovazebním učení (Reinforcement Learning - RL) pro de novo návrh léčiv hraje definice cílových prahů v prostředí `DrugExEnvironment` kritickou roli. Prah určuje, které vygenerované molekuly jsou klasifikovány jako **žádoucí** (**Desired**, $D = 1$) a získávají pozitivní odměnu, a které jsou klasifikovány jako **nežádoucí** (**Undesired**, $D = 0$) a jsou penalizovány.

Zatímco u standardních fyzikálně-chemických vlastností (jako je molekulová hmotnost $MW < 500$ Da nebo $\log P < 5$) vycházíme z obecných Lipinského pravidel, pro **3D tvarovou a farmakoforovou shodu (ROCS TanimotoCombo $\in [0, 2]$)** žádné univerzální pravidlo neexistuje.

Volba nevhodného prahu vede ke dvěma fatálním selháním tréninku:

Příliš nízký prah (např. $\tau < 0.70$)

Důsledky pro generativní model:

- Reward Hacking:** Model se naučí generovat jednoduché sférické shluky atomů bez specifického farmakoforu, které mají dostatečný objemový překryv ($T_{shape} \approx 0.65$), ale nulovou biologickou aktivitu.
- Odměňování Decoyů:** Falešně pozitivní molekuly (decoys) splňují podmínku a generátor je zaplaven neaktivními strukturami.
- Ztráta specificity:** Ztrácí se schopnost rozlišit jemné elektrostatické a vodíkové interakce v kavitě.

Příliš vysoký prah (např. $\tau > 1.40$)

Důsledky pro generativní model:

- Nulový gradient odměny (Zero Gradient):** V prvních epochách generátor náhodně navrhuje molekuly se skóre 0.5 – 1.1. Žádná molekula nepřekročí prah 1.40.
- Ztráta signálu učení:** Prostředí vrací nulovou odměnu ($R = 0$) pro celou populaci a gradient $\nabla_{\theta} \mathcal{J}(\theta)$ kolabuje k nule.
- Uvážnutí v náhodném šumu:** Model se nemůže posunout směrem k aktivnímu chemickému prostoru.

VĚDECKÁ HYPOTÉZA KALIBRACE

Optimální dělicí práh τ^* musí maximalizovat schopnost skórovací funkce diskriminovat mezi skutečnými aktivními ligandy a fyzikálně shodnými neaktivními sloučeninami (decoys). Tento práh musí být předem experimentálně stanoven pomocí ROC analýzy na referenčním benchmarku.

2. Experimentální design: 75 CCR2 aktivních ligandů vs 500 DUD-E decoyů

Slide 2/6

Pro kalibraci dělicího prahu receptoru CCR2 (chemokinový receptor 2, klíčový cíl pro léčbu chronických zánětů a kardiovaskulárních chorob) byl vytvořen robustní testovací dataset:

- **Aktivní ligandy** ($N_{active} = 75$): Experimentálně potvrzení antagonisté lidského receptoru CCR2 s vysokou afinitou ($K_i < 100$ nM, $pIC_{50} \geq 7.0$) extrahovaní z databáze ChEMBL a standardizovaní v souboru `actives_ccr2_N75.csv`.
- **Decoy molekuly** ($N_{decoy} = 500$): Struktury z databáze *Directory of Useful Decoys - Enhanced (DUD-E)* uložené v `decoys_ccr2_N500.csv`. Tyto molekuly jsou pečlivě vybrány tak, aby měly **shodné globální fyzikálně-chemické vlastnosti** jako aktivní ligandy:
 - Molekulová hmotnost: $\Delta MW \leq 20$ Da
 - Lipofilita: $\Delta \log P \leq 0.5$
 - Počet donorů vodíkových vazeb (HBD): ± 0
 - Počet akceptorů vodíkových vazeb (HBA): ± 1
 - Počet rotovatelných vazeb: ± 1
 - Celkový formální náboj: identickýMají však **zásadně odlišnou 2D topologii a 3D prostorový tvar**, takže se nevážou do kavit CCR2.
- **Referenční krystalové templáty** ($N_{ref} = 5$): Pět vysoce afinitních ligandů v bioaktivní konformaci z rentgenostrukturních krystalů PDB (např. PDB ID: 5T1A, 6GPS) uložených v `CCR2_reference_ligands.sdf`.

Všechny molekuly procházejí identickým generátorem konformací `RDKitConformerGenerator(max_conformers=50, max_isomers=4, max_heavy_atoms=45, max_rotatable_bonds=15)` jako při následném RL tréninku.

3. Matematický aparát ROC a Precision-Recall analýzy

Slide 3/6

Pro každý testovaný dělicí práh $\tau \in [0, 2]$ rozdělíme predikce do konfuzní matice (Confusion Matrix):

$$\begin{aligned}
\text{TP}(\tau) &= \sum_{i=1}^{N_{\text{active}}} \mathbb{I}(\text{Score}(A_i) \geq \tau) && \text{(True Positives: správně zachycené aktivní)} \\
\text{FP}(\tau) &= \sum_{j=1}^{N_{\text{decoy}}} \mathbb{I}(\text{Score}(D_j) \geq \tau) && \text{(False Positives: falešně označení decoyi)} \\
\text{TN}(\tau) &= \sum_{j=1}^{N_{\text{decoy}}} \mathbb{I}(\text{Score}(D_j) < \tau) && \text{(True Negatives: správně odmítnutí decoyi)} \\
\text{FN}(\tau) &= \sum_{i=1}^{N_{\text{active}}} \mathbb{I}(\text{Score}(A_i) < \tau) && \text{(False Negatives: přehlédnuté aktivní)}
\end{aligned}$$

Z těchto hodnot počítáme základní validační křivky:

1. **Senzitivita (True Positive Rate - TPR / Recall):**

$$\text{TPR}(\tau) = \frac{\text{TP}(\tau)}{\text{TP}(\tau) + \text{FN}(\tau)} = \frac{\text{TP}(\tau)}{N_{\text{active}}}$$

2. **Míra falešné positivity (False Positive Rate - FPR / 1 - Specificita):**

$$\text{FPR}(\tau) = \frac{\text{FP}(\tau)}{\text{FP}(\tau) + \text{TN}(\tau)} = \frac{\text{FP}(\tau)}{N_{\text{decoy}}}$$

3. **Preciznost (Precision / Positive Predictive Value - PPV):**

$$\text{Precision}(\tau) = \frac{\text{TP}(\tau)}{\text{TP}(\tau) + \text{FP}(\tau)}$$

4. **Plocha pod ROC křivkou (ROC-AUC):**

$$\text{AUC}_{\text{ROC}} = \int_0^1 \text{TPR}(\text{FPR}) d\text{FPR}$$

4. Optimalizace Youdenova indexu J a odvození optimálního prahu

Slide 4/6

Pro nalezení optimálního prahu τ^* využíváme **Youdenův index (J)** (Youden, 1950), který představuje objektivní kritérium pro maximalizaci rozdílu mezi senzitivitou a mírou falešné positivity:

$$J(\tau) = \text{Sensitivity}(\tau) + \text{Specificity}(\tau) - 1 = \text{TPR}(\tau) - \text{FPR}(\tau) = \frac{\text{TP}(\tau)}{\text{TP}(\tau) + \text{FN}(\tau)} - \frac{\text{FP}(\tau)}{\text{FP}(\tau) + \text{TN}(\tau)}$$

Hledáme globální maximum funkce $J(\tau)$:

$$\tau^* = \arg \max_{\tau \in [0, 2]} J(\tau)$$

Geometrická interpretace:

Bod na ROC křivce odpovídající maximu Youdenova indexu J je bodem s **maximální vertikální vzdáleností** od diagonály náhodného hádání (Random Chance Line $y = x$).

Empirické výsledky pro CCR2 benchmark (threshold_analysis.py):

- **Plocha pod ROC křivkou (ROC-AUC): 0.941** (vynikající diskriminační schopnost).
- **Plocha pod PR křivkou (PR-AUC): 0.892**.
- **Optimální Youdenův dělicí práh: $\tau^* = 0.871$** ($J = 0.823$).
- **Senzitivita při τ^* : TPR = 90.7%** (správně klasifikováno 68 ze 75 aktivních ligandů).
- **Falešná pozitivita při τ^* : FPR = 8.4%** (pouze 42 z 500 decoyů proniklo přes práh).
- **Specifita při τ^* : TNR = 91.6%**.
- **Preciznost při τ^* : Precision = 61.8%** (při poměru aktivní:decoy 1 : 6.67).

5. Analýza překryvu distribucí a ověření vlastní podobnosti (Self-Similarity)

Slide 5/6

Kromě ROC křivky provádí `threshold_analysis.py` dva hloubkové diagnostické testy:

1. Analýza oblasti překryvu distribucí (Distribution Overlap)

Analýza histogramů rozdělení skóre aktivních ligandů a decoyů odhaluje:

- **Decoy distribuce:** Střední hodnota $\mu_{decoy} \approx 0.582$, směrodatná odchylka $\sigma_{decoy} \approx 0.141$. Více než 95% decoyů má TanimotoCombo skóre pod 0.820.
- **Actives distribuce:** Střední hodnota $\mu_{active} \approx 1.184$, směrodatná odchylka $\sigma_{active} \approx 0.226$. Většina aktivních sloučenin leží v pásmu 0.900 – 1.650.
- **Oblast překryvu (Overlap Region):** Interval [0.720, 1.050]. V této oblasti leží 9.3% aktivních a 8.4% decoyů. Práh $\tau^* = 0.871$ protíná tuto zónu v bodě optimální rovnováhy.

2. Vlastní podobnost referenčních ligandů (Self-Similarity Verification)

Při skórování 5 krystalových referencí proti referenčnímu souboru samotnému:

- Reference 1 (PDB 5T1A): $T_{combo} = 1.982$ (téměř dokonalá shoda s vlastním farmakoforem)
- Reference 2 (PDB 6GPS): $T_{combo} = 1.924$
- Reference 3: $T_{combo} = 1.891$
- Reference 4: $T_{combo} = 1.956$
- Reference 5: $T_{combo} = 1.912$
- **Průměrné skóre referencí: $\mu_{ref} = 1.933$** (garantuje strukturální a geometrickou integritu šablony).

PŘENOS DO KONFIGURACE

Vypočtená hodnota `ROCS_THRESHOLD = 0.871` je přímo exportována do souboru `tutorial/advanced/rocs/config.py` a slouží jako dělící linie v `DrugEnvironment` pro celý následný experiment.

6. Kompletní skript `threshold_analysis.py` a vizualizace

Slide 6/6

Následující kód demonstruje kompletní modulární spuštění analýzy prahů v Pythonu:

```
python

#!/usr/bin/env python3
"""
Threshold Analysis Workflow for CCR2 Shape Matching
Computes ROC-AUC, PR-AUC, Youden's Index and Overlap Distributions.
"""

from pathlib import Path
import numpy as np
import pandas as pd
from threshold_analysis import run_threshold_analysis
from config import ROCS_THRESHOLD

# Spuštění kompletní threshold analýzy
results = run_threshold_analysis(
    actives_csv="rocs_rl_ccr/rdkit_cdpkit/actives_decoys/actives_ccr2_N75.csv",
    decoys_csv="rocs_rl_ccr/rdkit_cdpkit/actives_decoys/decoys_ccr2_N500.csv",
    references_sdf="rocs_rl_ccr/rdkit_cdpkit/CCR2_reference_ligands.sdf",
    current_threshold=ROCS_THRESHOLD,
    output_dir="threshold_analysis_results",
    max_conformers=50,
    max_isomers=4,
    max_heavy_atoms=45,
    max_rotatable_bonds=15,
    num_threads=1,
    n_jobs=-1,
    show_plots=True,
    verbose=True
)

print(f"\n=== VÝSLEDKY KALIBRACE PRAHU PRO CCR2 ===")
print(f"Plocha pod ROC křivkou (ROC-AUC) : {results['roc_auc']:.4f}")
print(f"Optimální Youdenův dělící práh : {results['optimal_threshold']:.3f}")
print(f"Aktuální práh v config.py : {ROCS_THRESHOLD:.3f}")
print(f"Uložené vizualizace : threshold_analysis_results/combined_figure.png")
```

5.2 End-to-End RL experimentální tréninkový cyklus (`config.py`, `rocs_rl_tutorial.ipynb`)

1. Krok 1: Dvoustupňový transfer znalostí (prepare_models.py)

Slide 1/6

Trénování generativní sítě začíná dvoustupňovým transferem znalostí (Transfer Learning), který řeší problém omezeného počtu experimentálních dat pro specifický cíl:

- 1. Pre-training (PT) na databázi Papyrus v05.5:** Model `SequenceRNN` (3-vrstvé LSTM s 512 skrytými jednotkami na vrstvu) byl předtrénován na ~1,5 milionu bioaktivních struktur z databáze Papyrus. Model se naučil obecnou gramatiku chemických SMILES a pravidla valence. Uložen jako `Papyrus05.5_smiles_rnn_PT.pkg`.
- 2. Fine-Tuning (FT) na známých ligandech CCR2 (prepare_models.py):** Sada 1 324 známých ligandů CCR2 z `CCR_HUMAN_AL.tsv` je standardizována pomocí `Standardization(n_proc=20)` a zakódována s využitím fixního slovníku `VocSmiles` (98 unikátních tokenů).

Dataset je rozdělen v poměru 95:5 na trénovací a testovací množinu:

$$\mathcal{L}_{FT}(\theta) = -\frac{1}{|D_{train}|} \sum_{X \in D_{train}} \sum_{t=1}^T \log P(x_t | x_{<t}; \theta)$$

Model je dotrénován po dobu 100 epoch s learning rate $\eta = 10^{-4}$ a early stoppingem s trpělivostí (patience) 30 epoch.

python

```
# Spuštění přípravy modelů v terminálu
python prepare_models.py --epochs 100 --batch-size 64 --n-processes 16 --patience 30

# Výstupem jsou soubory:
# demo_out/models/CCR2_finetuned.pkg      (váhy modelu)
# demo_out/models/CCR2_finetuned.vocab   (chemický slovník)
```

2. Krok 2: Inicializace vícekriteriálního prostředí (config.py)

Slide 2/6

Optimalizační prostředí `DrugExEnvironment` definuje cílové vlastnosti, které chceme v molekulách současně maximalizovat:

1. 3D Tvarové a farmakoforové skóre (`RDKitROCScorer`)

Využívá `RDKitConformerGenerator` s parametry sladěnými s OpenEye OMEGA standardem:

- `max_conformers = 50`: Vzorkování až 50 nízkoenergetických konformací na izomer.
- `max_isomers = 4`: Automatická enumerace až 4 stereoizomerů pro molekuly s nejasnou chiralitou.
- `max_heavy_atoms = 45` a `max_rotatable_bonds = 15`: Filtrace obřích nebo hyperflexibilních struktur.

- `score_type = 'TanimotoCombo'`: Kombinace tvarového a farmakoforového překryvu ($T_{combo} = T_{shape} + T_{color}$).
- `threshold = 0.871`: Dělicí práh stanovený v threshold analýze.

2. Syntetická dostupnost (`Property('SA')` s `SmoothClippedScore`)

SAScore hodnotí složitost syntézy na škále 1.0 (snadná) až 10.0 (extrémní). Modifikátor provádí hladkou transformaci:

$$S_{SA}(x) = \begin{cases} 1.0 & x \leq 3.0 \\ 0.5 \left(1 + \cos \left(\pi \frac{x-3.0}{5.0-3.0} \right) \right) & 3.0 < x < 5.0 \\ 0.0 & x \geq 5.0 \end{cases}$$

Molekuly s SAScore ≤ 3.0 mají maximální odměnu 1.0, molekuly s SAScore ≥ 5.0 mají odměnu 0.0.

3. Vícekriteriální vyvažování (`ParetoCrowdingDistance`)

Místo fixních vah provádí nedominované třídění do Paretových front s penalizací shlukování (Crowding Distance).

python

```
from drugex.training.environment import DrugExEnvironment
from drugex.training.rewards import ParetoCrowdingDistance
from drugex.training.scorers.modifiers import SmoothClippedScore
from drugex.training.scorers.properties import Property
from drugex.training.scorers.conformer_generators import RDKitConformerGenerator
from drugex.training.scorers.rocs_rdkit import RDKitROCSScorer

# 1. 3D ROCS Scorer
rocs_scorer = RDKitROCSScorer(
    conformer_generator=RDKitConformerGenerator(
        max_conformers=50, max_isomers=4,
        max_heavy_atoms=45, max_rotatable_bonds=15,
        num_threads=0, show_progress=False
    ),
    references="rocs_r1_ccr/rdkit_cdpkit/CCR2_reference_ligands.sdf",
    score_type="TanimotoCombo",
    use_colors=True,
    n_jobs=-1
)

# 2. SA Scorer
sa_scorer = Property('SA')
sa_scorer.setModifier(SmoothClippedScore(lower_x=5.0, upper_x=3.0))

# 3. Environment
env = DrugExEnvironment(
    scorers=[rocs_scorer, sa_scorer],
    thresholds=[0.871, 0.100],
    reward_scheme=ParetoCrowdingDistance()
)
```

Reinforcement Learning v DrugEx využívá architekturu **Policy Gradient s duální politikou (Dual Policy Exploration)**, která chrání model před katastrofickým zapomínáním (Catastrophic Forgetting) a kolapsem do jediného modu (Mode Collapse):

Agent Network π_θ (Aktivně trénovaná síť)

Parametrizovaná váhami

θ

. Začíná z vah předtrénovaného nebo jemně dotrénovaného modelu. V každé epoše jsou její váhy aktualizovány pomocí policy gradientu tak, aby generovala molekuly s vyšší odměnou

$R(X)$

.

Mutate Network π_0 (Fixní Prior Kotva)

Váhy modelu jsou

trvale zmrazeny

na hodnotách

`CCR2_finetuned.pkg`

. Slouží jako stabilizační reference a zdroj chemické diversity.

V každém kroku generování tokenů se s pravděpodobností $\epsilon = 0.20$ (20%) použije distribuce pravděpodobností ze sítě π_0 a s pravděpodobností $1 - \epsilon = 0.80$ (80%) ze sítě π_θ :

$$P(x_t \mid x_{<t}) = (1 - \epsilon) \cdot \pi_\theta(x_t \mid x_{<t}) + \epsilon \cdot \pi_0(x_t \mid x_{<t})$$

python

```
from drugex.training.explorers import SequenceExplorer

# Inicializace SequenceExploreru
explorer = SequenceExplorer(
    agent=agent,          # Aktualizovaná síť
    mutate=mutate,        # Zmrazená prior síť (CCR2_finetuned)
    crover=None,
    env=env,              # Prostředí s ROCS a SA skórovači
    epsilon=0.2,          # 20% explorace z mutační sítě
    n_samples=1000,       # 1000 molekul na epochu
    batch_size=64
)
```

4. Krok 4: Matematika gradientu REINFORCE v MORL smyčce

Cílem tréninku je maximalizovat očekávanou Paretoovu odměnu $\mathcal{J}(\theta) = \mathbb{E}_{X \sim \pi_\theta}[R(X)]$.

Gradient účelové funkce podle parametrů sítě θ je odvozen pomocí věty o policy gradientu (Williams, 1992):

$$\nabla_{\theta} \mathcal{J}(\theta) = \mathbb{E}_{X \sim \pi_{\theta}} \left[\sum_{t=1}^T \nabla_{\theta} \log \pi_{\theta}(x_t | x_{<t}) \cdot (R(X) - \beta) \right]$$

kde:

- x_t je token vygenerovaný v čase t a $x_{<t}$ je dosavadní prefix SMILES sekvence.
- $R(X) \in [0, 2]$ je celková Paretova odměna molekuly spočtená z Paretova ranku a Crowding Distance:

$$R(X_i) = \frac{1}{\text{Rank}(X_i)} + \frac{d_i}{1 + d_i}$$

- β je **baseline odměna** (klouzavý průměr odměn v populaci), která snižuje rozptyl (variance) gradientního odhadu bez zavedení systematické chyby.

Váhy neuronové sítě θ jsou aktualizovány Adam optimalizátorem s learning rate $\eta = 10^{-4}$:

$$\theta_{k+1} = \theta_k + \eta \cdot \widehat{\nabla_{\theta} \mathcal{J}(\theta)}$$

5. Monitorování konvergence: Analýza metrik z fit.tsv

Slide 5/6

Během 50 epoch RL tréninku zapisuje `FileMonitor` metriky po každé epoše do souboru `CCR2_rdkit_reinforced_fit.tsv`.

Typický průběh konvergence úspěšného experimentu:

Epocha	valid_ratio	desired_ratio	mean_score	rocs_mean	sa_mean	Poznámka k fázi učení
1	0.962	0.042 (4.2%)	0.215	0.621	2.45	Výchozí stav: většina molekul neprochází prahem ROCS 0.871
10	0.971	0.185 (18.5%)	0.384	0.785	2.61	Fáze 1: Objevování základních tvarových motivů kavit
25	0.968	0.382 (38.2%)	0.542	0.964	2.78	Fáze 2: Rychlá expanze populace na Paretově frontě
40	0.975	0.524 (52.4%)	0.681	1.112	2.92	Fáze 3: Optimalizace farmakoforových bodů a linkerů
50	0.978	0.586 (58.6%)	0.742	1.185	3.05	Konvergovaný stav: stabilní generování vysoce afinitních tvarů

Klíčový ukazatel úspěchu: Poměr žádoucích molekul (`desired_ratio`) vzroste z počátečních 4.2% na téměř 60%, aniž by došlo k degradaci syntaktické validity (`valid_ratio > 97%`).

6. Spuštění tréninku v rocs_rl_tutorial.ipynb

Slide 6/6

Následující kód představuje finální exekuční blok tréninku:

python

```
import time
from pathlib import Path
import pandas as pd
import matplotlib.pyplot as plt
from drugex.training.monitors import FileMonitor
from config import setup_rl_rdkit, RL_EPOCHS, RL_EPSILON, RL_N_SAMPLES

# 1. Inicializace všech komponent z config.py
agent, mutate, env, output_dir = setup_rl_rdkit()

# 2. Vytvoření SequenceExplorer
explorer = SequenceExplorer(
    agent=agent,
    mutate=mutate,
    env=env,
    epsilon=RL_EPSILON,
    n_samples=RL_N_SAMPLES
)

# 3. Příprava monitoru a spuštění tréninku
output_base = output_dir / "CCR2_rdkit_reinforced"
monitor = FileMonitor(str(output_base), save_smiles=True, reset_directory=True)

print(f"Spouštím RL trénink: {RL_EPOCHS} epoch, {RL_N_SAMPLES} vzorků/epocha, epsilon={RL_EPSILON}")
start_time = time.time()

explorer.fit(monitor=monitor, epochs=RL_EPOCHS)
monitor.close()

elapsed = time.time() - start_time
print(f"\nTrénink úspěšně dokončen za {elapsed/60:.1f} minut!")
print(f"Model uložen v: {output_base}.pkg")

# 4. Vykreslení křivek konvergence
df_fit = pd.read_csv(f"{output_base}_fit.tsv", sep="\t")
fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(14, 5))

df_fit.plot(x="Epoch", y="desired_ratio", ax=ax1, color="#3b82f6", linewidth=2, grid=True)
ax1.set_title("Poměr žádoucích molekul (desired_ratio)")
ax1.set_ylabel("Desired Ratio")

df_fit.plot(x="Epoch", y="mean_score", ax=ax2, color="#10b981", linewidth=2, grid=True)
ax2.set_title("Průměrná Paretova odměna (mean_score)")
ax2.set_ylabel("Mean Score")

plt.tight_layout()
plt.savefig("rl_convergence_plot.png", dpi=300)
plt.show()
```

5.3 Generování kandidátů, filtrace novosti & chemické ověření (generate_molecules.py)

1. Masivní vzorkování z finálního modelu CCR2_rdkit_reinforced.pkg

Slide 1/6

Po úspěšném dokončení 50 epoch RL tréninku je nejlepší checkpoint modelu (CCR2_rdkit_reinforced.pkg) využit pro generování rozsáhlé virtuální knihovny kandidátních sloučenin (typicky $N = 10\,000$ až $50\,000$ molekul).

Generování probíhá pomocí skriptu `tutorial/advanced/rocs/generate_molecules.py`, který:

1. Načte natrénovanou síť `SequenceRNN` a chemický slovník `VocSmiles`.
2. Proveďte autoregresivní vzorkování token po tokenu pomocí **teplotního vzorkování (Temperature Sampling)** s parametrem $T = 1.0$:

$$P(x_t = k \mid x_{<t}) = \frac{\exp(z_k/T)}{\sum_j \exp(z_j/T)}$$

3. Okamžitě ohodnotí všechny vygenerované molekuly v prostředí `DrugEnvironment` (3D ROCS + SAScore).
4. Uloží kompletní tabulku výsledků včetně detailních skóre jednotlivých cílů do `CCR2_rdkit_reinforced_generated.tsv`.

python

```
#!/usr/bin/env python3
# Příkaz pro vygenerování 10 000 molekul v terminálu
python generate_molecules.py \
  --model demo_out/rl_runs_demo/rdkit_rl/CCR2_rdkit_reinforced.pkg \
  --num-samples 10000 \
  --output ccr2_generated_10k.tsv
```

2. Čtyřstupňový chemoinformatický validační audit

Slide 2/6

Před jakýmkoliv výběrem konkrétních molekul musí vygenerovaná knihovna projít rigorózním statistickým auditem kvality (podle standardů benchmarku GuacaMol a MOSES):

1. **Validita (Chemical Validity):** Podíl syntakticky správných SMILES, které lze v RDKit převést na molekulární graf a sanitovat bez valenčních chyb:

$$\text{Validity} = \frac{N_{\text{valid}}}{N_{\text{total}}} \times 100\% \quad (\text{požadavek} > 98.0\%, \text{ náš model dosahuje } \mathbf{98.4\%})$$

2. **Unikátnost (Uniqueness):** Podíl strukturně unikátních kanonických SMILES v rámci validní sady:

$$\text{Uniqueness} = \frac{N_{\text{unique}}}{N_{\text{valid}}} \times 100\% \quad (\text{požadavek} > 90.0\%, \text{ náš model dosahuje } \mathbf{92.1\%})$$

3. **Novost (Novelty):** Podíl unikátních molekul, které se **vůbec nevyskytují** v obecné trénovací databázi Papyrus ani v sadě známých aktivních ligandů CCR2:

$$\text{Novelty} = \frac{|S_{\text{gen,unique}} \setminus (S_{\text{Papyrus}} \cup S_{\text{train}})|}{|S_{\text{gen,unique}}|} \times 100\% \quad (\text{požadavek} > 85.0\%, \text{ náš model: } \mathbf{88.7\%})$$

4. **4. Interní diverzita (Internal Diversity - IntDiv):** Míra strukturní pestrosti uvnitř vygenerované knihovny, měřená průměrnou Morgan Tanimoto vzdáleností:

$$\text{IntDiv}_1(S) = 1 - \frac{2}{|S|(|S| - 1)} \sum_{i < j} T_{\text{Morgan}}(s_i, s_j) \quad (\text{požadavek} > 0.80, \text{ náš model: } \mathbf{0.842})$$

$$\text{IntDiv}_2(S) = 1 - \sqrt{\frac{2}{|S|(|S| - 1)} \sum_{i < j} T_{\text{Morgan}}^2(s_i, s_j)} \quad (\text{náš model: } \mathbf{0.816})$$

3. Distribuce fyzikálně-chemických vlastností (Property Landscapes)

Slide 3/6

Kromě strukturních metrik porovnáváme distribuci klíčových medicínálně-chemických parametrů generované sady vůči známým CCR2 ligandům:

Generovaná sada (DrugEx RL)

- **Molekulová hmotnost (MW):** Střední hodnota 428.5 Da (rozsah 340 – 510 Da).
- **Lipofilita (cLogP):** Střední hodnota 3.24 (rozsah 2.1 – 4.4). Ideální pro orální biologickou dostupnost.
- **Polární povrch (TPSA):** Střední hodnota 78.2 Å² (rozsah 55 – 105 Å²).
- **Syntetická dostupnost (SAScore):** Střední hodnota 2.74 (více než 89% molekul má SAScore < 3.5).
- **Odhad lékovosti (QED):** Střední hodnota 0.76 (vynikající lékový profil).

Znamé CCR2 aktivní ligandy (ChEMBL)

- **Molekulová hmotnost (MW):** Střední hodnota 452.1 Da.
- **Lipofilita (cLogP):** Střední hodnota 3.68. Mírně vyšší hydrofobicita.
- **Polární povrch (TPSA):** Střední hodnota 82.4 Å².
- **Syntetická dostupnost (SAScore):** Střední hodnota 2.89.
- **Odhad lékovosti (QED):** Střední hodnota 0.69.

Generovaný model vykazuje **optimalizovaný profil**: zachovává farmakoforové rozložení známých ligandů, ale mírně snižuje molekulovou hmotnost a lipofilitu, což vede k vyššímu průměrnému QED skóre.

4. 3D Farmakoforové zarovnání s krystalovými templáty

Slide 4/6

Při detailním zkoumání 3D konformací nejlépe hodnocených molekul ($T_{\text{combo}} > 1.30$) zjišťujeme, že model úspěšně reprodukoval klíčové interakční motivy receptoru CCR2:

1. **Základní dusíkaté centrum (Protonovaný amin / Piperidin):** Všechny top molekuly obsahují bazický terciární amin nebo piperidinový/pyrrolidinový kruh, který tvoří kritický solný můstek (Salt Bridge) s karboxylátovou

skupinou **Glu291 (pozice 7.39)** v transmembránové šroubovici TM7 receptoru CCR2.

2. **Aromatické hydrofobní jádro:** Benzenový nebo heteroaromatický kruh perfektně vyplňuje hlubokou hydrofobní subkavitu tvořenou zbytky **Trp98, Phe112 a Tyr120**, což generuje vysokou hodnotu $T_{shape} > 0.75$.
3. **Polární akceptorová skupina (Sulfonamid / Karboxamid):** Orientována do horní vestibulární části vazebného místa, kde tvoří síť vodíkových vazeb s **His121 a Tyr49**.

STRUKTURNÍ VALIDACE BEZ DOKOVÁNÍ

Model DrugEx vedený čistě 3D ROCS shape matchingem dokázal zrekonstruovat přesné prostorové uspořádání farmakoforových prvků vyžadovaných proteinovou kavitou CCR2, aniž by měl během tréninku jakýkoliv přímý přístup ke krystalové struktuře receptoru!

5. Výběr finálních Top-5 olověných struktur (Lead Candidates)

Slide 5/6

Z 10 000 vygenerovaných molekul bylo vyfiltrováno 5 nejlepších olověných kandidátů pro experimentální syntézu a biologické testování na ÚOCHB AV ČR:

ID	Kanonický SMILES	T_{combo} (ROCS)	T_{shape}	T_{color}	SAScore	QED	MW (Da)
CCR2-GEN-01	<chem>O=C(Nc1ccccc1)C1CCN(Cc2ccc(C1)cc2)CC1</chem>	1.482	0.812	0.670	2.15	0.82	370.9
CCR2-GEN-02	<chem>Cc1ccc(S(=O)(=O)N2CCN(Cc3ccccc3)CC2)cc1</chem>	1.425	0.785	0.640	2.32	0.79	330.4
CCR2-GEN-03	<chem>Fc1ccc(CN2CCC(NC(=O)c3ccncc3)CC2)cc1</chem>	1.398	0.764	0.634	2.41	0.84	313.4
CCR2-GEN-04	<chem>O=C(c1ccc(F)cc1)N1CCC(Nc2ncccn2)CC1</chem>	1.362	0.751	0.611	2.58	0.81	300.3
CCR2-GEN-05	<chem>C1c1ccc(C(=O)N2CCC(c3nc4ccccc4[nH]3)CC2)cc1</chem>	1.341	0.742	0.599	2.74	0.75	339.8

Všech 5 struktur vykazuje vynikající syntetickou dostupnost (SAScore < 2.8), optimální molekulovou hmotnost (300 – 375 Da) a vysokou shodu s 3D tvarem aktivního konformačního stavu CCR2.

6. Kompletní Python validační a vizualizační skript

Slide 6/6

Následující kód provádí kompletní analýzu generované sady, filtraci a vykreslení 2D mřížky top molekul:

python

```
import pandas as pd
from rdkit import Chem
from rdkit.Chem import Draw
from rdkit.Chem import Descriptors

# 1. Načtení vygenerovaných molekul
df_gen = pd.read_csv("ccr2_generated_10k.tsv", sep="\t")
print(f"Celkem načteno molekul: {len(df_gen)}")

# 2. Filtrace validních a žádoucích struktur
tanimoto_col = "RDKit_Aggregate_5refs_TanimotoCombo"
df_desired = df_gen[df_gen["Desired"].eq(1)].copy()
print(f"Počet žádoucích struktur (ROCS >= 0.871 & SA >= 0.1): {len(df_desired)}")

# 3. Výběr Top-5 struktur podle ROCS TanimotoCombo
top5 = df_desired.sort_values(tanimoto_col, ascending=False).head(5)

# 4. Generování 2D obrázku s Legendou
mols = [Chem.MolFromSmiles(s) for s in top5["SMILES"]]
legends = [
    f"ROCS={score:.3f}\nSA={sa:.2f}\nMW={Descriptors.MolWt(m):.1f}"
    for score, sa, m in zip(top5[tanimoto_col], top5["SA"], mols)
]

img = Draw.MolsToGridImage(
    mols,
    molsPerRow=5,
    subImgSize=(250, 250),
    legends=legends,
    useSVG=False
)
img.save("top5_ccr2_candidates.png")
print("Top-5 kandidáti uloženi do top5_ccr2_candidates.png")
```

Modul 6: Fragmentový Design (BRICS), CLI & Škálování na HPC Superpočítačích

6.1 Fragmentový de novo design & chemické scaffolds (BRICS, Murcko, Transformers)

Překonání limitů atom-po-atomu generování, 16 retrosyntetických pravidel BRICS L1-L16, FragSequenceExplorer vs FragGraphExplorer a scaffold-based RL.

1. Proč fragmentový design? Překonání limitů atom-po-atomu generování

Slide 1/5

Standardní generativní modely navrhující molekuly atom po atomu (např. čisté SMILES RNN) trpí zásadním limitem: prohledávají teoretický chemický prostor všech možných uspořádání atomů ($> 10^{60}$ struktur).

V tomto obrovském prostoru model často generuje:

- **Synteticky nepřístupné motivy:** Labilní acetaly, peroxidové vazby, nestabilní 4-členné nebo 8-členné cykly s vysokým pnutím.
- **Nestabilní tautomery a reaktivní funkční skupiny** (např. acyl chloridy, Michaelovy akceptory), které způsobují nespecifickou toxicitu (PAINS).
- **Dlouhé syntetické cesty:** Molekuly vyžadující 15 a více reakčních kroků s minimálním celkovým výtěžkem.

Fragment-Based Drug Design (FBDD) tento problém elegantně řeší: molekuly nejsou skládány z jednotlivých atomů, nýbrž z **předpřipravených synteticky validních stavebních bloků (synthonů)** odvozených z komerčně dostupných chemikálií.

Druhým klíčovým konceptem je **Scaffold Hopping (přeskakování mezi scaffolds)**: schopnost zachovat klíčové farmakoforové skupiny na periferii molekuly a radikálně obměnit centrální nosné jádro (scaffold) pro zlepšení rozpustnosti, permeability nebo obejítí patentové ochrany konkurence.

2. 16 BRICS retrosyntetických štěpných pravidel (L1 - L16)

Slide 2/5

Pro dekompozici velkých knihoven molekul na synteticky relevantní synthony využívá DrugEx algoritmus **BRICS (Breaking of Retrosynthetically Interesting Chemical Substructures)** (Degen et al., ChemMedChem 2008).

BRICS definuje 16 typů syntetických vazeb L1 až L16 odpovídajících robustním a spolehlivým chemickým reakcím:

BRICS Pravidla L1 – L8 (Acylace, Sulfonamidy, C-C vazby)

- **L1:** Primární/sekundární aminový dusík (např. pro tvorbu amidů a močoviny).
- **L2:** Karbonylový uhlík (karboxylová kyselina, acyl chlorid, ester).
- **L3:** Sulfonylová skupina (sulfonyl chlorid, sulfonamid).
- **L4:** Sulfonamidový dusíkatý atom.
- **L5:** Aromatický uhlík (Suzuki-Miyaura, Stille, Buchwald-Hartwig coupling).
- **L6:** Heteroaromatický uhlík (kondenzované heterocykly).
- **L7:** Alifatický etherový kyslík (Williamsonova syntéza).
- **L8:** Alifatický thioetherový sírový atom.

BRICS Pravidla L9 – L16 (Aminace, Močoviny, Alifatické řetězce)

- **L9:** Sekundární/terciární alifatický amin (reduktivní aminace).
- **L10:** Alifatický halogen / odstupující skupina (nukleofilní substituce).
- **L11:** Močovinový dusíkatý atom.
- **L12:** Karbamátový / karbonátový kyslík.
- **L13:** Guanidinový uhlík.
- **L14:** Guanidinový dusík.
- **L15:** Alifatický sp^3 uhlík (alkylační reakce, Grignardova činidla).
- **L16:** Alifatický sp^2/sp uhlík (Heckova reakce, Sonogashira coupling).

Kromě BRICS podporuje DrugEx také algoritmus **RECAP** (11 pravidel) a dekompozici na **Bemis-Murcko Frameworks** (nosná jádra tvořená pouze kruhy a linkery bez postranních řetězců).

3. Architektury fragmentových modelů: FragSequence vs FragGraph

Slide 3/5

DrugEx integruje dvě pokročilé transformerové architektury pro generování řízené fragmenty:

1. FragSequenceExplorer (Sekvenční Transformer / GPT-2 styl)

Pracuje se sekvenční reprezentací ve formátu `Fragment.Molecule`:

- Vstupní fragment (např. `c1cnccn1` pro pyrazinové jádro) je zakódován pomocí `SequenceFragmentEncoder` jako fixní prompt (prefix).
- Autoregresivní dekodér s maskovanou samo-pozorností (Self-Attention) doplňuje zbytek řetězce atom po atomu.
- Garantuje zachování vloženého fragmentu v každé vygenerované struktuře.

2. FragGraphExplorer (Grafový Transformer / Node-Edge Attention)

Pracuje s tenzory molekulárních grafů o rozměru $(N, 80, 5)$:

- Každý uzel kóduje typ atomu, index v grafu, vazebného souseda, formální náboj a binární příznak růstu (growth mask).
- Uzly fixního fragmentu jsou zmrazeny a model predikuje připojování nových atomů a vazeb z definovaných vazebných míst (attachment points).

python

```
from drugex.data.fragments import FragmentCorpusEncoder, SequenceFragmentEncoder
from drugex.molecules.converters.fragmenters import Fragmenter
from drugex.data.corpus.vocabulary import VocSmiles

# 1. Nastavení fragmentéru BRICS
fragmenter = Fragmenter(
    n_frags=4,          # Maximálně 4 fragmenty na molekulu
    n_combs=2,          # Kombinace až 2 fragmentů
    method='brics',     # Použití BRICS štěpných pravidel
    max_bonds=75
)

# 2. Inicializace sekvenčního fragmentového kodéru
voc = VocSmiles.fromFile("models/Papyrus05.5.vocab", encode_frags=True)
encoder = FragmentCorpusEncoder(
    fragmenter=fragmenter,
    encoder=SequenceFragmentEncoder(voc, update_voc=False, throw=True),
    n_proc=16
)
```

4. Scaffold-based RL: Fixace jádra a růst variabilních substituentů

Slide 4/5

V řadě reálných projektů medicínální chemie má výzkumný tým definovaný slibný centrální skelet (např. pyrazinové, chinazolinové nebo benzimidazolové jádro) a cílem je optimalizovat postranní řetězce (R-groups) tak, aby molekula dosáhla maximální 3D tvarové a farmakoforové shody s vazebnou kavitou:

Tento přístup je implementován v `tutorial/advanced/scaffold_based.ipynb`:

1. Definice fixního fragmentu nebo kombinace fragmentů (např. `frags = ['c1cnccn1', 'c1cnccn1.c1ccsc1']`).
2. Využití konvertoru `dummyMolsFromFragments()`, který vytvoří fiktivní molekulární páry pro inicializaci dataloaderu.
3. Spuštění `FragSequenceExplorer` nebo `FragGraphExplorer` v prostředí `DrugExEnvironment` s 3D ROCS skórovačem.

Aplikace pro bifunkční modulátory (PROTACs & IDP Binders):

Tato metodika je ideální pro návrh bifunkčních molekul:

- Na vstupu zadáme dva oddělené fragmenty: vazač proteinu A a vazač proteinu B spojené tečkou (`fragA.fragB`).
- DrugEx automaticky vygeneruje chemický linker (Linker Design) s optimální prostorovou délkou a konformační flexibilitou pro překlenutí vzdálenosti mezi oběma vazebnými místy.

5. Kompletní kód Scaffold-Based RL v Pythonu

Slide 5/5

Následující kód demonstruje kompletní inicializaci fragmentového modelu pro fixní lešení:

python

```
import os
from drugex.data.datasets import GraphFragDataSet
from drugex.molecules.converters.dummy_molecules import dummyMolsFromFragments
from drugex.data.fragments import FragmentCorpusEncoder, GraphFragmentEncoder
from drugex.data.corpus.vocabulary import VocGraph
from drugex.training.generators import GraphTransformer
from drugex.training.explorers import FragGraphExplorer
from config import create_rdkit_environment

# 1. Definice požadovaných scaffoldů (např. pyrazin + thiofen)
scaffolds = ['c1cnccn1', 'c1cnccn1.c1ccsc1']

# 2. Příprava datové sady ze scaffoldů
encoder = FragmentCorpusEncoder(
    fragmenter=dummyMolsFromFragments(),
    encoder=GraphFragmentEncoder(VocGraph(n_frgs=4)),
    pairs_splitter=None,
    n_proc=1
)

dataset = GraphFragDataSet("datasets/scaffolds.tsv", rewrite=True)
encoder.apply(scaffolds, encodingCollectors=[dataset])

# 3. Načtení natrénovaného grafového transforméru
voc = VocGraph.fromFile("models/Graph_FT.vocab")
agent = GraphTransformer(voc_trg=voc, use_gpu=(0,))
agent.loadStatesFromFile("models/Graph_FT.pkg")
prior = GraphTransformer(voc_trg=voc, use_gpu=(0,))
prior.loadStatesFromFile("models/Graph_FT.pkg")

# 4. Inicializace prostředí a exploračního
env = create_rdkit_environment()
explorer = FragGraphExplorer(
    agent=agent,
    mutate=prior,
    env=env,
    epsilon=0.15,
    n_samples=500,
    use_gpu=(0,))

# 5. Spuštění fragmentového RL tréninku
explorer.fit(epochs=50)
```

6.2 Příkazová řádka DrugEx: drugex dataset, train & generate (CLI Mastery)

1. Architektura a filozofie CLI rozhraní DrugEx

Slide 1/5

Pro produkční nasazení v superpočítačových centrech (HPC) a integraci do automatizovaných bioinformatických pipeline je DrugEx vybaven robustním rozhraním příkazové řádky (CLI - Command Line Interface).

CLI řeší klíčové nevýhody interaktivních Jupyter notebooků:

- 100% Reprodukovatelnost:** Každé spuštění automaticky ukládá kompletní JSON konfiguraci parametrů (např. `dataset.json`, `train.json`) a podrobný logovací soubor.
- Nulová režie grafického serveru:** Běží v čistě bezhlavém (headless) režimu bez nutnosti GUI nebo webových serverů.
- Paralelizace a dávkové zpracování:** Umožňuje snadné spouštění desítek úloh paralelně přes plánovače úloh (Slurm, PBS Pro).

CLI se skládá ze 3 hlavních modulů:

- `python -m drugex.dataset`: Standardizace, filtrace, fragmentace a tokenizace molekul.
- `python -m drugex.train`: Předtrénování (PT), fine-tuning (FT) a reinforcement learning (RL).
- `python -m drugex.generate`: Vzorkování z finálních modelů a skórování.

2. Kompletní matice parametrů: python -m drugex.dataset

Slide 2/5

Následující tabulka obsahuje vyčerpávající přehled parametrů modulu pro přípravu dat:

Přepínač (krátký / dlouhý)	Typ	Výchozí hodnota	Popis a medicínální význam
<code>-b, --base_dir</code>	str	.	Kořenový adresář projektu obsahující složky <code>data/</code> a <code>generators/</code> .
<code>-i, --input_file</code>	str	povinný	Cesta ke vstupnímu souboru TSV/CSV/SDF s chemickými strukturami.
<code>-mc, --mol_col</code>	str	SMILES	Název sloupce obsahujícího SMILES řetězce ve vstupním souboru.
<code>-o, --out</code>	str	povinný	Prefix názvu výstupních souborů datasetu a slovníku.
<code>-mt, --mol_type</code>	str	smiles	Typ molekulární reprezentace: <code>smiles</code> (sekvence) nebo <code>graph</code> (grafy).
<code>-nof, --no_filter</code>	flag	False	Vypne fyzikální filtry (MW, rotovatelné vazby). Doporučeno zapnout pro cílové ligandy.
<code>-fm, --frag_method</code>	str	recap	Metoda fragmentace: <code>brics</code> (16 pravidel) nebo <code>recap</code> (11 pravidel).
<code>-nf, --n_frag</code>	int	4	Maximální počet fragmentů vygenerovaných na jednu molekulu.
<code>-sfl, --selected_fragment</code>	str	None	SMILES fixního jádra/scaffoldu pro cílenou fragmentaci.
<code>-np, --n_proc</code>	int	1	Počet paralelních procesů pro standardizaci a kódování datasetu.

Následující tabulka shrnuje klíčové parametry trénovacího modulu `drugex.train`:

Parametr	Hodnoty	Režim	Popis funkce
<code>-tm, --train_mode</code>	<code>PT</code> , <code>FT</code> , <code>RL</code>	Všechny	Režim tréninku: <code>PT</code> (Pre-training), <code>FT</code> (Fine-tuning), <code>RL</code> (Reinforcement Learning).
<code>-ag, --agent_model</code>	cesta k <code>.pkg</code>	FT, RL	Výchozí model agenta (např. předtrénovaný Papyrus model).
<code>-pr, --prior_model</code>	cesta k <code>.pkg</code>	RL	Mutační síť (Prior kotva) pro stabilizaci politiky.
<code>-e, --epochs</code>	int (50-200)	Všechny	Počet trénovacích epoch (pro FT typicky 100, pro RL 50).
<code>-bs, --batch_size</code>	int (32-256)	Všechny	Velikost trénovací dávky (batch size).
<code>-lr, --learning_rate</code>	float	PT, FT	Rychlost učení (pro PT 10^{-3} , pro FT 10^{-4}).
<code>-eps, --epsilon</code>	float (0.1-0.3)	RL	Míra explorační z mutační sítě (doporučeno 0.2).
<code>-s, --scheme</code>	<code>PRCD</code> , <code>PRTD</code> , <code>WS</code>	RL	Optimalizační schéma: <code>PRCD</code> (Pareto Crowding Distance), <code>WS</code> (Weighted Sum).
<code>--sa_score</code>	flag	RL	Aktivuje penalizaci za obtížnou syntetickou dostupnost (SAScore).
<code>-gpu, --use_gpus</code>	'0' nebo '0,1'	Všechny	Seznam ID grafických karet pro akceleraci výpočtu.

4. Kompletní matice parametrů: `python -m drugex.generate`

Parametry pro masivní generování a skórování molekul:

- `-g, --generator`: Název finálního modelu bez přípony `.pkg` (např. `CCR2_rdkit_reinforced`).
- `-n, --num`: Celkový počet molekul k vygenerování (např. `10000`).
- `-bs, --batch_size`: Velikost batche pro paralelní inferenci na GPU (např. `1024`).
- `--keep_invalid`: Ponechá ve výstupu i syntakticky nevalidní SMILES (standardně vypnuto).
- `--keep_duplicates`: Ponechá duplicitní molekuly v rámci vygenerované sady.
- `--keep_undesired`: Ponechá molekuly, které nesplnily prahy prostředí (užitečné pro statistickou analýzu distribucí).

```
python
```

```
# Příklad vygenerování 5000 validních a unikátních molekul
python -m drugex.generate \
  -b /home/kolar/learn_projects/drugex/workdir \
  -g CCR2_rdkit_reinforced \
  -n 5000 \
  -bs 1024 \
  -gpu 0
```

Následující skript demonstruje kompletní, robustní pipeline řetězec v Bash s ošetřením chyb:

python

```
#!/usr/bin/env bash
# =====
# DrugEx Production Pipeline: From Raw Data to Reinforced Leads
# =====
set -euo pipefail

WORKDIR="/home/kolar/learn_projects/drugex/workdir"
DATA_IN="./data/benchmarks/CCR_HUMAN_AL.tsv"
PRETRAINED="./models/Papyrus05.5_smiles_rnn_PT.pkg"
GPUS=""

mkdir -p "$WORKDIR/data" "$WORKDIR/generators" "$WORKDIR/new_molecules"

echo "======"
echo " [1/4] Preprocessing & Tokenizace datasetu CCR2"
echo "======"
python -m drugex.dataset \
    -b "$WORKDIR" \
    -i "$DATA_IN" \
    -mc SMILES \
    -o ccr2_corpus \
    -mt smiles \
    -nof \
    -np 16

echo "======"
echo " [2/4] Fine-Tuning modelu (100 epoch)"
echo "======"
python -m drugex.train \
    -tm FT \
    -b "$WORKDIR" \
    -i ccr2_corpus \
    -ag "$PRETRAINED" \
    -e 100 \
    -bs 64 \
    -lr 0.0001 \
    -p 30 \
    -gpu "$GPUS"

echo "======"
echo " [3/4] Generování 10 000 kandidátních molekul"
echo "======"
python -m drugex.generate \
    -b "$WORKDIR" \
    -g ccr2_corpus_FT \
    -n 10000 \
    -bs 1024 \
    -gpu "$GPUS"

echo "======"
echo " Pipeline úspěšně dokončena: $(date)"
echo "=====
```

6.3 Škálování na GPU klastru: Slurm skripty & správa paměti (MetaCentrum / IT4Innovations)

Produkční Slurm batch šablony, správa licencí OE_LICENSE, eliminace CPU thread oversubscription a prevence GPU VRAM memory leaků.

1. Architektura superpočítačové infrastruktury (MetaCentrum & IT4Innovations)

Slide
1/5

Výpočetní experimenty kombinující de novo generování molekul s rozsáhlým 3D konformačním vzorkováním (stovky tisíc konformerů za běh) přesahují možnosti běžných pracovních stanic a vyžadují národní superpočítačovou infrastrukturu:

- **MetaCentrum (CESNET / e-INFRA CZ):** Národní gridová a klastrová infrastruktura. Poskytuje dedikované GPU uzly s kartami NVIDIA A100 (40/80 GB) a H100. Klíčovou vlastností je **rychlý lokální NVMe scratch disk (proměnná `$SCRATCHDIR`)**, který eliminuje I/O zpoždění při práci s tisíci dočasnými soubory.
- **IT4Innovations (Superpočítačové centrum Ostrava):** Superpočítače *Karolína* a *Barbora* řízené plánovačem úloh **Slurm**. Využívají paralelní sdílený souborový systém Lustre.

Běh úloh na superpočítači probíhá v **dávkovém (batch) režimu**: úloha je definována shellovým skriptem s direktivami `#SBATCH` a odeslána do fronty příkazem `sbatch script.sh`.

2. Produkční Slurm dávkový skript (Kompletní šablona)

Slide 2/5

Následující skript představuje kompletní, v praxi prověřenou šablonu dávkové úlohy pro klastr Karolína / MetaCentrum:

python

```
#!/bin/bash
# =====
# Slurm Batch Job: DrugEx MORL + 3D ROCS Shape Matching Pipeline
# Bachelor Thesis: Flexible Targets & IDP Drug Design (VŠCHT / ÚOCHB)
# =====
#SBATCH --job-name=drugex_rocs_ccr2
#SBATCH --partition=gpu
#SBATCH --nodes=1
#SBATCH --ntasks=1
#SBATCH --cpus-per-task=16
#SBATCH --gres=gpu:nvidia_a100_80gb_pcie:1
#SBATCH --mem=64GB
#SBATCH --time=24:00:00
#SBATCH --output=logs/drugex_%j.out
#SBATCH --error=logs/drugex_%j.err
#SBATCH --mail-type=END,FAIL
#SBATCH --mail-user=student@vscht.cz

set -euo pipefail

echo "======"
echo " Výpočet spuštěn na uzlu : $(hostname)"
echo " Datum a čas : $(date)"
echo " Slurm Job ID : $SLURM_JOB_ID"
echo " Alokováno CPU jader : $SLURM_CPUS_PER_TASK"
echo " Alokována GPU : $CUDA_VISIBLE_DEVICES"
echo "======"

# 1. Načtení softwarových modulů
module purge
module load CUDA/12.1.1 Python/3.11.5 GCC/12.2.0 OpenEye/2023.2.0

# 2. Aktivace virtuálního prostředí
source /storage/praha1/home/kolar/.venvs/drugex/bin/activate

# 3. Nastavení kritických proměnných prostředí
export OE_LICENSE=/storage/praha1/home/kolar/licenses/oe_license.txt
export OMP_NUM_THREADS=1
export OPENBLAS_NUM_THREADS=1
export MKL_NUM_THREADS=1
export VECLIB_MAXIMUM_THREADS=1
export NUMEXPR_NUM_THREADS=1
export PYTORCH_CUDA_ALLOC_CONF=max_split_size_mb:128

# 4. Příprava lokálního scratch disku a ošetření bezpečného úklidu
SCRATCH_DIR="${SCRATCHDIR:-/tmp/drugex_${SLURM_JOB_ID}}"
mkdir -p "$SCRATCH_DIR"
cd "$SLURM_SUBMIT_DIR"

trap 'echo "Zachycen signál ukončení. Kopíruji data zpět..."; cp -r "$SCRATCH_DIR"/*
"$SLURM_SUBMIT_DIR/results/" || true; rm -rf "$SCRATCH_DIR"' EXIT TERM

# 5. Spuštění samotného výpočtu
python tutorial/advanced/rocs/prepare_models.py --epochs 100 --batch-size 64
python tutorial/advanced/rocs/generate_molecules.py --num-samples 10000

echo "======"
```

```
echo " Výpočet úspěšně dokončen: $(date)"
echo "=====
```

3. Kritická past 1: CPU Thread Oversubscription a jeho eliminace

Slide 3/5

Při nasazení na klastru se často vyskytuje zákeřná chyba vedoucí k **desetinásobnému až padesátinásobnému zpomalení výpočtu**, známá jako *CPU Thread Oversubscription*:

Jak k problému dochází?

1. Výpočetní uzly na superpočítačích mají typicky 64 až 128 fyzických CPU jader na socket.
2. Knihovny lineární algebry (OpenBLAS, Intel MKL, OpenMP, NumExpr) ve výchozím nastavení detekují celkový počet jader na serveru a pro každou matematickou operaci vytvoří 128 vláken.
3. Když Python skript spustí `multiprocessing.Pool(n_jobs=16)` nebo `RDKitROCSScorer(n_jobs=16)`, každý ze 16 procesů vytvoří 128 vláken.
4. Vznikne $16 \times 128 = 2048$ konkurenčních vláken, která bojují o 16 CPU jader přidělených vaší úloze!

Důsledky:

Procesor tráví 95% času přepínáním kontextu (Context Switching) a dochází k zahlcení L1/L2/L3 cache paměti.

Řešení (Povinné pro všechny dávkové skripty):

Před spuštěním Pythonu exportujte proměnné omezující počet podvláken na 1:

```
python

# Vypnutí vnitřního multitaskingu v C/Fortran knihovnách
export OMP_NUM_THREADS=1
export OPENBLAS_NUM_THREADS=1
export MKL_NUM_THREADS=1
export VECLIB_MAXIMUM_THREADS=1
export NUMEXPR_NUM_THREADS=1

# V Python kódu:
# conf_gen = RDKitConformerGenerator(num_threads=1)
```

4. Kritická past 2: GPU VRAM paměťové úniky v PyTorch a OOM prevence

Slide 4/5

Během dlouhotrvajícího RL tréninku (50+ epoch) dochází v PyTorch k postupnému zaplňování grafické paměti (GPU VRAM), které často končí chybou `RuntimeError: CUDA out of memory`:

Hlavní příčiny a jejich řešení:

1. Hromadění výpočetního grafu (Autograd)

Při vzorkování molekul z modelu nesmí PyTorch počítat gradienty. Vzorkovací smyčka musí být striktně uzavřena v kontextu:

```
with torch.no_grad():
```

Při ukládání ztráty do logu používejte

```
loss.item()
```

namísto pouhého

```
loss
```

(jinak se v paměti drží celý tenzorový graf).

2. Fragmentace PyTorch Caching Allocatoru

PyTorch neuvolňuje alokované bloky paměti zpět operačnímu systému, nýbrž je drží v mezipaměti. Při proměnných délkách SMILES sekvencí dochází k fragmentaci.

Řešení:

1.

```
export  
PYTORCH_CUDA_ALLOC_CONF=max_split_size_mb:128
```

2. Volání

```
torch.cuda.empty_cache()
```

na konci každé epochy.

SPRÁVA DOČASNÝCH SOUBORŮ V RAM DISKU

Při použití OpenEye ROCS skórovače se generují soubory `.oeb.gz`. Ujistěte se, že skórovač běží v paměťovém disku `/dev/shm` a okamžitě maže dočasné soubory po přečtení skóre, aby nedošlo k zaplnění diskového prostoru uzlu.

5. Škálování pomocí Slurm Array Jobs a statistické replikáty

Slide 5/5

Ve vědecké diplomové práci nesmí být výsledky založeny na jediném náhodném běhu. Pro publikovatelné výsledky je nutné provést **statistické vyhodnocení (např. 10 až 20 nezávislých RL replikátů)** s různými náhodnými semínky (seeds):

K tomuto účelu slouží **Slurm Array Jobs**:

python

```
#!/bin/bash
#SBATCH --job-name=drugex_array
#SBATCH --partition=gpu
#SBATCH --nodes=1
#SBATCH --ntasks=1
#SBATCH --cpus-per-task=8
#SBATCH --gres=gpu:1
#SBATCH --mem=32GB
#SBATCH --time=12:00:00
#SBATCH --array=1-10%5      # 10 replikátů, maximálně 5 běží současně
#SBATCH --output=logs/array_%A_%a.out

# Číslo úlohy v poli ($SLURM_ARRAY_TASK_ID) použijeme jako random seed
SEED=$SLURM_ARRAY_TASK_ID
OUTPUT_DIR="experiments/run_seed_${SEED}"
mkdir -p "$OUTPUT_DIR"

echo "Spouštím replikát č. $SEED s random seedem $SEED..."

python run_experiment.py \
  --seed "$SEED" \
  --output-dir "$OUTPUT_DIR" \
  --epochs 50 \
  --epsilon 0.2
```

Modul 7: Uživatelská Kuchařka, Skládání Skórovačů & Hyperparametry

Matice Hyperparametrů & Doporučené Rozsahy pro Výzkumníka

Hyperparametr	Výchozí	Rozsah	Dopad na Trénink	Riziko
learning_rate (lr)	1e-4	5e-5 až 3e-4	Při lr >= 1e-3 dojde během 5 epoch ke kolapsu chemické gramatiky (validita < 50%). Při lr <= 1e-5 se model učí příliš pomalu a nestihne konvergovat za 50 epoch. Hodnota 1e-4 je zlatý standard.	Explodující gradienty vs zamrznutí učení
epsilon (eps)	0.20	0.10 až 0.35	V 80 % kroků generuje Agent (exploatace vysokého skóre), ve 20 % mutační síť (přísun nových funkčních skupin). Pokud v tréninku nastane Mode Collapse (duplicita > 30%), zvýšte epsilon na 0.25–0.30.	Mode collapse vs ztráta zacílení na cíl
n_samples (batch)	1000	500 až 2000	Pro spolehlivé rozřazení do Paretovských vrstev a výpočet Crowding Distance je potřeba alespoň 500–1000 molekul. Na výkonných GPU klastrech doporučujeme 1000–2000 pro maximální stabilitu Paretovy fronty.	Degenerované Paretovy fronty při malém N
epochs	50	30 až 100	Pro SequenceRNN stačí 50 epoch (cca 50 000 vyhodnocených molekul). Pokud se 'desired_ratio' nezlepší po dobu 20 epoch (patience=20), trénink se automaticky zastaví.	Přetrénování (overfitting) a ztráta diverzity
temperature (T)	1.0	0.75 až 1.25	T=0.85 pro konzervativní generování blízkých analogů s vysokou validitou (>98%). T=1.0 pro vyvážený běh. T=1.15 pro explorativní Scaffold Hopping u neznámých IDP kavit.	Fádní repetice vs nevalidní syntaktické chyby
max_conformers	30–50	20 až 100	30 konformací pro RDKit/CDPKit poskytuje 90 % maximálního možného překryvu při polovičním výpočetním čase oproti 100 konformacím. Vhodné pro rychlé iterace.	Časová náročnost RL epochy
num_threads	1	Striktně 1 při n_jobs > 1	KRITICKÉ: Při n_jobs=16 paralelních procesech MUSÍ mít každý worker nastaveno num_threads=1. Nastavení 0 (všechna jádra) způsobí 16x16=256 vláken a pád systému (CPU Thrashing)!	Systémový deadlock a zamrznutí

Recept 1: Kompletní Multi-Objektivní Stack (ROCS + QSAR + SA + Fyzikální Vlastnosti)

Základní Recept pro
Bakalářskou Práci

Jak v DrugExEnvironment elegantně zkombinovat 3D tvarové porovnávání (ROCS), strojově učený QSAR model afinity, syntetickou dostupnost (SAScore) a Lipinského fyzikálně-chemické filtry (MW, LogP, TPSA, QED).

```
#!/usr/bin/env python3
```

```
"""
```

```
Recept 1: Plný Multi-Objektivní Stack v DrugExEnvironment  
Kombinace 3D ROCS + QSAR + SAScore + MW + LogP + TPSA + QED
```

```
"""
```

```
import os
from pathlib import Path
from drugex.training.environment import DrugExEnvironment
from drugex.training.rewards import ParetoCrowdingDistance
from drugex.training.scorers.modifiers import SmoothClippedScore, MinMaxGaussian, Gaussian
from drugex.training.scorers.properties import Property
from drugex.training.scorers.conformer_generators import RDKitConformerGenerator
from drugex.training.scorers.rocs_rdkit import RDKitROCSScorer
from drugex.training.scorers.qsprpred import QSPRPredScorer # nebo vlastní Scorer
```

```
def build_full_practitioner_environment():
    # 1. 3D ROCS Tvarový a Farmakoforový Skórovač (TanimotoCombo)
    conformer_engine = RDKitConformerGenerator(
        max_conformers=40,
        max_isomers=4,
        max_heavy_atoms=45,
        max_rotatable_bonds=15,
        num_threads=1,          # Vlákenná bezpečnost v multiprocessing poolu
        show_progress=False
    )
    rocs_scorer = RDKitROCSScorer(
        conformer_generator=conformer_engine,
        references="data/CCR2_reference_ligands.sdf",
        score_type="TanimotoCombo",
        use_colors=True,
        n_jobs=-1               # Využije všechna dostupná CPU jádra
    )

    # 2. QSAR Prediktor Bioaktivity (pIC50 k cíli CCR2)
    # Požadujeme pIC50 >= 7.0 (odpovídá Ki < 100 nM)
    qsar_activity = QSPRPredScorer(model_path="models/qsar_ccr2_random_forest.pkl")
    qsar_activity.setModifier(SmoothClippedScore(
        lower_x=6.0,            # pIC50 <= 6.0 získává odměnu ~0.0
        upper_x=8.0,            # pIC50 >= 8.0 získává maximální odměnu ~1.0
        high_score=1.0,
        low_score=0.0
    ))

    # 3. Syntetická Dostupnost (SAScore)
    # Chceme nízký SAScore (1.0 = snadná syntéza, 10.0 = neproveditelné)
    sa_scorer = Property('SA')
    sa_scorer.setModifier(SmoothClippedScore(
        lower_x=4.5,            # SAScore >= 4.5 je penalizován (odměna ~0.0)
        upper_x=2.5,            # SAScore <= 2.5 je ideální (odměna ~1.0)
        high_score=1.0,
        low_score=0.0
    ))

    # 4. Fyzikálně-chemické deskriptory (Lipinski & Veber pravidla)
    # Molekulová hmotnost (MW): optimální interval 360-480 Da
    mw_scorer = Property('MW', modifier=Gaussian(mu=420.0, sigma=60.0))

    # Lipofilita (LogP): penalizace mastných kyselin (LogP > 4.0)
```

```

logp_scorer = Property('logP', modifier=MinMaxGaussian(mu=3.0, sigma=1.2, minimize=True))

# Polární povrch (TPSA): optimální pro permeabilitu hematoencefalické bariéry / střeva
tpsa_scorer = Property('TPSA', modifier=SmoothClippedScore(lower_x=30.0, upper_x=90.0))

# 5. Sestavení celého prostředí v DrugExEnvironment
scorers = [rocs_scorer, qsar_activity, sa_scorer, mw_scorer, logp_scorer, tpsa_scorer]

# Jednotné prahy pro klasifikaci žádoucnosti (Desired)
# Díky modifikátorům jsou všechny složky škálovány do [0, 1]
thresholds = [
    0.871, # Youdenův optimalizovaný práh pro ROCS TanimotoCombo
    0.500, # QSAR aktivita práh (pIC50 > 7.0)
    0.500, # SAScore práh (SAScore < 3.5)
    0.500, # Mw práh
    0.500, # LogP práh
    0.500 # TPSA práh
]

# Nedominované třídění do Paretových front s hustotní diverzitou
reward_scheme = ParetoCrowdingDistance()

env = DrugExEnvironment(
    scorers=scorers,
    thresholds=thresholds,
    reward_scheme=reward_scheme
)

print(f"✓ Úspěšně vytvořeno prostředí s {len(scorers)} cíli.")
return env

if __name__ == "__main__":
    env = build_full_practitioner_environment()

```

Recept 2: 3D Scaffold Hopping & Odměňování Strukturní Novosti (ROCS Patentová Novost & IDP + SimSmiles Penále)

Jak donutit generátor najít zcela nové chemické jádro (jiný heterocyklus) při zachování 100% prostorového tvaru a farmakoforových bodů původního známého inhibitoru.

```
#!/usr/bin/env python3
```

```
"""
```

Recept 2: Scaffold Hopping s penále na podobnost k původnímu ligandu

Kombinace: 3D ROCS (vysoká tvarová shoda) + SimSmiles (penalizace strukturní podobnosti)

```
"""
```

```
from drugex.training.environment import DrugExEnvironment
from drugex.training.rewards import ParetoCrowdingDistance
from drugex.training.scorers.modifiers import SmoothClippedScore
from drugex.training.scorers.properties import Property
from drugex.training.scorers.conformer_generators import RDKitConformerGenerator
from drugex.training.scorers.rocs_rdkit import RDKitROCSScorer
from drugex.training.scorers.similarity import SimSmiles

def build_scaffold_hopping_environment(parent_smiles: str, reference_sdf: str):
    # 1. 3D ROCS Scorer: Chceme, aby nová molekula přesně kopírovala 3D tvar
    conf_gen = RDKitConformerGenerator(max_conformers=40, num_threads=1)
    rocs = RDKitROCSScorer(
        conformer_generator=conf_gen,
        references=reference_sdf,
        score_type="TanimotoCombo"
    )

    # 2. Similarity Penále (SimSmiles):
    # Spočte 2D Morgan Tanimoto podobnost vůči původnímu patentovanému ligandu
    # Použijeme klesající modifikátor: čím je podobnost NIŽŠÍ, tím je odměna VYŠŠÍ!
    sim_penalty = SimSmiles(smiles=[parent_smiles], sim_type="tanimoto")
    sim_penalty.setModifier(SmoothClippedScore(
        lower_x=0.60,          # Podobnost >= 0.60 (analog mateřské látky) -> odměna ~0.0
        upper_x=0.25,         # Podobnost <= 0.25 (zcela nový scaffold) -> odměna ~1.0
        high_score=1.0,
        low_score=0.0
    ))

    # 3. Syntetická dostupnost
    sa = Property('SA', modifier=SmoothClippedScore(lower_x=4.5, upper_x=2.5))

    # 4. Sestavení prostředí
    env = DrugExEnvironment(
        scorers=[rocs, sim_penalty, sa],
        thresholds=[0.871, 0.500, 0.500],
        reward_scheme=ParetoCrowdingDistance()
    )
    return env
```

Recept 3: Selektivní Dvou-Cílový Design (Aktivace Cíle A vs Potlačení Cíle B / hERG)

Farmakologická
Bezpečnost

Jak optimalizovat molekulu pro vysokou afinitu k terapeutickému cíli (CCR2) a současně penalizovat vazbu k homolognímu receptoru (CCR5) nebo kardiálnímu iontovému kanálu hERG.

```
#!/usr/bin/env python3
"""
Recept 3: Selektivní multi-cílový design (On-Target vs Off-Target)
"""

from drugex.training.environment import DrugExEnvironment
from drugex.training.rewards import ParetoCrowdingDistance
from drugex.training.scorers.modifiers import SmoothClippedScore
from drugex.training.scorers.properties import Property
from drugex.training.scorers.qsprpred import QSPRPredScorer
from drugex.training.scorers.rocs_rdkit import RDKitROCSScorer
from drugex.training.scorers.conformer_generators import RDKitConformerGenerator

def build_selectivity_environment():
    # 1. 3D ROCS tvarové skóre vůči cíli A (CCR2)
    rocs = RDKitROCSScorer(
        conformer_generator=RDKitConformerGenerator(max_conformers=30, num_threads=1),
        references="data/CCR2_reference_ligands.sdf",
        score_type="TanimotoCombo"
    )

    # 2. QSAR On-Target aktivita (Cíl A: CCR2) -> maximalizovat (rostoucí křivka)
    on_target = QSPRPredScorer(model_path="models/qsar_ccr2.pkg")
    on_target.setModifier(SmoothClippedScore(lower_x=6.0, upper_x=8.0))

    # 3. QSAR Off-Target toxicita (Kardiotoxický hERG kanál) -> minimalizovat (klesající křivka)
    herg_filter = QSPRPredScorer(model_path="models/qsar_herg_channel.pkg")
    herg_filter.setModifier(SmoothClippedScore(
        lower_x=6.5,          # pIC50 k hERG >= 6.5 (vysoká toxicita) -> odměna ~0.0
        upper_x=4.5,          # pIC50 k hERG <= 4.5 (bezpečné) -> odměna ~1.0
        high_score=1.0,
        low_score=0.0
    ))

    # 4. Syntetická dostupnost
    sa = Property('SA', modifier=SmoothClippedScore(lower_x=4.5, upper_x=2.5))

    env = DrugExEnvironment(
        scorers=[rocs, on_target, herg_filter, sa],
        thresholds=[0.871, 0.500, 0.500, 0.500],
        reward_scheme=ParetoCrowdingDistance()
    )
    return env
```

Recept 4: Automatická Optimalizace Hyperparametrů pomocí Optuna

Bayesovské Ladění pro
Studenta

Kompletní skript pro automatické nalezení optimální kombinace learning rate, epsilonu a velikosti vzorku pro maximalizaci podílu žádoucích kandidátů (Desired Ratio).

```
#!/usr/bin/env python3
```

```
"""
```

Recept 4: Automatické ladění hyperparametrů DrugEx MORL pomocí Optuna

```
"""
```

```
import optuna
import torch

from drugex.data.corpus.vocabulary import VocSmiles
from drugex.training.generators import SequenceRNN
from drugex.training.explorers import SequenceExplorer
from drugex.training.monitors import FileMonitor
from config import setup_rl_rdkit

def objective(trial):
    # 1. Definice vyhledávacího prostoru hyperparametrů
    lr = trial.suggest_float("lr", 5e-5, 3e-4, log=True)
    epsilon = trial.suggest_float("epsilon", 0.10, 0.30, step=0.05)
    n_samples = trial.suggest_categorical("n_samples", [500, 1000])
    batch_size = trial.suggest_categorical("batch_size", [64, 128])

    # 2. Inicializace sítě a prostředí
    agent, mutate, env, output_dir = setup_rl_rdkit()
    agent.optim = torch.optim.Adam(agent.parameters(), lr=lr)

    # 3. Nastavení rychlého zkušebního tréninku (15 epoch)
    trial_dir = output_dir / f"optuna_trial_{trial.number}"
    monitor = FileMonitor(str(trial_dir / "fit"), save_smiles=False)

    explorer = SequenceExplorer(
        agent=agent,
        mutate=mutate,
        crover=None,
        env=env,
        epsilon=epsilon,
        n_samples=n_samples,
        batch_size=batch_size
    )

    # 4. Trénink
    explorer.fit(monitor=monitor, epochs=15)
    monitor.close()

    # 5. Vyhodnocení cílové metriky (poslední desired_ratio z logu)
    # Cílem je maximalizovat poměr molekul, které splňují všechny cíle
    import pandas as pd
    df = pd.read_csv(f"{trial_dir}/fit_fit.tsv", sep="\t")
    final_desired_ratio = df["desired_ratio"].iloc[-1]
    final_mean_score = df["mean_score"].iloc[-1]

    # Kompozitní skóre pro Optuna
    return final_desired_ratio * 0.7 + final_mean_score * 0.3

if __name__ == "__main__":
    study = optuna.create_study(direction="maximize")
    print("🚀 Spouštím 10 pokusů Optuna pro nalezení nejlepších hyperparametrů...")
    study.optimize(objective, n_trials=10)

    print("
=====")
```

```
print(" ✨ NEJLEPŠÍ NALEZENÉ HYPERPARAMETRY:")
for k, v in study.best_params.items():
    print(f" - {k}: {v}")
print(f" Dosažená hodnota cíle: {study.best_value:.4f}")
print("=====")
```

Diagnostický Strom: Co dělat, když trénink nekonverguje?

⚠️ Problém: Desired Ratio zůstává na 0.0 % a neroste po 10 epochách

Příčina: Příliš přísný práh u některého skórovače (např. ROCS práh nastaven na 1.40 namísto 0.871), nebo nulový gradient u skórovače.

💡 Řešení:

1. Spustíte `threshold_analysis.py` a zkontrolujete Youdenův index.
2. Zkontrolujte, zda všechny skórovače používají `SmoothClippedScore` (hladký gradient) namísto skokového `ClippedScore`.
3. Zvyšte `epsilon` z 0.1 na 0.25 pro podporu explorace.

⚠️ Problém: Lipofilní kolaps (LogP roste nad 6.0, molekuly jsou 'mastné vosky')

Příčina: Optimalizujete pouze afinitu nebo 3D tvar bez záporné regulace velikosti a hydrofobicity.

💡 Řešení:

Přidejte do `DrugExEnvironment` skórovač `Property('logP', modifier=MinMaxGaussian(mu=3.0, sigma=1.2, minimize=True))` a `Property('MW', modifier=Gaussian(mu=420.0, sigma=60.0))`.

⚠️ Problém: Mode Collapse (Generátor dokola navrhuje 5 stejných molekul, duplicita > 50 %)

Příčina: Agent uvízl v lokálním optimu; chybí mutační tlak nebo je použita vážená suma (Weighted Sum).

💡 Řešení:

1. Přepněte `reward_scheme` na `ParetoCrowdingDistance()` (odměňuje izolované molekuly na frontě).
2. Zvyšte `epsilon` na 0.25–0.30.
3. Zkontrolujte, zda je síť `mutate` správně zmrazena (`mutate.eval()`).

⚠️ Problém: Generátor navrhuje synteticky nemožné molekuly (plné spiro-cyklů a můstků)

Příčina: Chybí penalizace syntetické dostupnosti.

💡 Řešení:

Přidejte `Property('SA', modifier=SmoothClippedScore(lower_x=4.5, upper_x=2.5))` s prahem 0.5 do prostředí, nebo přejděte na fragmentový `FragSequenceExplorer` s pravidly BRICS.

⚠️ Problém: Pád výpočtu při `n_jobs > 1` (CPU Thrashing / Freeze)

Příčina: V generátoru konformací je nastaveno `num_threads=0` nebo `num_threads > 1` uvnitř multiprocessing workerů.

💡 Řešení:

Nastavte striktně `RDKitConformerGenerator(num_threads=1)` a před spuštěním skriptu exportujte `export OMP_NUM_THREADS=1`.

Příloha: Metodologický Protokol & Šablona Textu Práce

Šablona Výpočetních Metod pro Text Bakalářské Práce

Výpočetní metody (Computational Methods)

De novo generování molekul bylo realizováno pomocí platformy DrugEx v3.4 s využitím vícekritériálního zpětnovazebního učení (MORL). Jako výchozí generátor byl použit SequenceRNN předtrénovaný na databázi Papyrus v05.5 (~1,5 mil. sloučenin) a jemně dotrénovaný (fine-tuning) na známých ligandech po dobu 100 epoch.

Optimalizační prostředí (DrugEnvironment) integrovalo:

- 3D Tvarové porovnávání (ROCS): RDKitROCSScorer s metrikou TanimotoCombo a konformačním generátorem ETKDGV3 (max. 50 konformerů, 4 stereoisomery). Dělicí práh byl stanoven na základě ROC analýzy a Youdenova indexu.
- Syntetická dostupnost: SAScore s modifikátorem SmoothClippedScore(lower_x=5.0, upper_x=3.0).

Vícekritériální rovnováha byla řízena pomocí Pareto Crowding Distance. Trénink probíhal 50 epoch s exploračním poměrem epsilon = 0.2.